


课程笔记

AI Agent 用于进攻性安全：零虚假阳性

五道口纳什 & Codex

2026 年 4 月 9 日



演讲者：Brendan Dolan-Gavitt (XBOW)

视频作者/频道：Black Hat

发布日期：2026-04-05

视频时长：39:08

视频链接：<https://www.youtube.com/watch?v=8voNmYCUXSk>

目录

1 引言：AI 安全研究的虚假阳性幽灵	4
1.1 演讲者背景与动机	4
1.2 AI 安全研究的核心困境：虚假阳性泛滥	4
1.3 Agent 方案为何仍然失败	5
1.4 本章小结	6
2 基础率谬误与安全检测	6
2.1 贝叶斯推理的经典医学案例	6
2.2 基础率谬误对安全检测的启示	8
2.3 唯一解法：将虚假阳性率压至极低	9
2.4 本章小结	10
2.5 拓展阅读	10
3 确定性验证框架：金丝雀与证据	10
3.1 Canary（金丝雀）机制	10
3.1.1 从 CTF 旗标到工程化工具	10
3.1.2 植入位置与可扩展性	11
3.2 确定性证据验证	11
3.2.1 Bug Bounty 模式的启示	12
3.2.2 AWS Token 泄露示例	13
3.3 CTF 化的额外收益	13
3.3.1 CTF 挑战一定有解	13
3.3.2 解决”何时足够努力”的问题	13
3.4 验证器空间四象限图	14
3.4.1 两个分类维度	14
3.4.2 Q1：手动金丝雀 + 目标配合	14
3.4.3 Q2：自动金丝雀 + 目标配合	15
3.4.4 Q3：确定性验证，无需目标配合（零虚假阳性）	16
3.4.5 Q4：启发式验证，无需目标配合（低但非零 FP）	16
3.4.6 象限间的进阶关系	16
3.5 本章小结	16
4 验证器类型与实现	17
4.1 XSS（跨站脚本）验证器	17
4.1.1 基本原理	17
4.1.2 实现架构	17
4.1.3 WAF 绕过	19
4.1.4 验证器的陷阱——LLM 如何“作弊”	19
4.1.5 对策：使用不常见的验证方法	21
4.2 开放重定向（Open Redirect）验证器	21
4.3 缓存投毒（Cache Poisoning）验证器	22
4.3.1 原理：缓存键与非键控字段	22

4.3.2	三步验证法	22
4.3.3	安全措施：随机缓存破坏器	23
4.3.4	实例：X-Forwarded-Host 投毒	23
4.4	SQL 注入验证器（启发式）	24
4.4.1	时序验证原理	24
4.4.2	相比 sqlmap 的优势	24
4.4.3	设计权衡：虚假阳性 vs 虚假阴性	25
4.5	为什么验证器有效	26
4.6	本章小结	27
5	大规模自动化扫描与案例研究	27
5.1	DockerHub 大规模扫描流程	27
5.1.1	从 2500 万个仓库到实战目标	27
5.1.2	特征工程与 LLM 分类	27
5.1.3	自动化部署与源代码优势	28
5.2	自动金丝雀部署	29
5.2.1	文件读取 / RCE 金丝雀	29
5.2.2	SSRF 金丝雀	29
5.2.3	SQLi 金丝雀	29
5.2.4	业务逻辑金丝雀	29
5.3	扫描成果	30
5.3.1	总体统计	30
5.3.2	漏洞类型分布	30
5.3.3	代表性发现	30
5.4	案例研究：Redmine 授权绕过	32
5.4.1	目标与金丝雀设置	32
5.4.2	Agent 的分析路径	32
5.4.3	漏洞细节	32
5.5	其他案例（简要）	33
5.5.1	Apache Druid SSRF (CVE-2025-27888)	33
5.5.2	MapProxy 任意文件读取	34
5.6	本章小结	34
6	局限性与未来方向	35
6.1	当前局限性	35
6.1.1	预期行为导致的残余虚假阳性	35
6.1.2	难以自动验证的漏洞类型	35
6.1.3	报告与披露的人力瓶颈	36
6.2	未来方向	37
6.2.1	自动金丝雀植入 Agent	37
6.2.2	LLM 自我验证能力的提升	37
6.2.3	扩展更多漏洞类型的确定性验证	38
6.3	核心启示	38

6.3.1	不要信任 LLM 的漏洞声明	38
6.3.2	确定性验证是规模化的关键	38
6.3.3	CTF 化思维的工程价值	38
6.4	本章小结	39
7	总结与延伸	39
7.1	演讲者核心总结	39
7.1.1	致谢与团队贡献	39
7.1.2	核心论点	39
7.2	笔记作者的延伸综合	40
7.2.1	三元概念框架：CTF 思维 × 确定性验证 × LLM 灵活性	40
7.2.2	跨章节递进逻辑	41
7.2.3	更广泛的启示：AI 安全工具的可信度依赖外部验证	41
7.3	实践要点与开放问题	42
7.3.1	实践要点总结	42
7.3.2	开放问题	42
7.3.3	下一步推荐：Defcon Bug Bounty Village	43

1 引言：AI 安全研究的虚假阳性幽灵

1.1 演讲者背景与动机

Brendan Dolan-Gavitt 在纽约大学 (NYU) 从事软件安全研究长达十年教授生涯。正如他在演讲开场时所言：“过去十年，我在 NYU 做软件安全，AI 只是副业；现在看起来反过来了——这似乎是时代的趋势。” 2025 年起，他全职加入 XBOW 公司，研究重心从学术界转向工业界，致力于构建面向攻击性的 AI Agent (AI agents for offsec)。这也是他首次登上 Black Hat 演讲台。

在安全社区中，Dolan-Gavitt 的名字与多个标志性项目紧密相连：

- **Volatility 内存取证框架**：早在 2007–2010 年间，他便是该框架的核心贡献者。Volatility 是开源数字取证领域的标杆工具，能够从内存镜像中提取进程列表、网络连接、注册表等信息，广泛用于恶意软件分析与事件响应。
- **Black Hat USA 2022 演讲 “Asleep at the Keyboard”**：这项研究系统性地评估了 GitHub Copilot 生成代码的安全性，揭示了 AI 代码补全工具在输出安全脆弱代码方面的风险。
- **FauxPilot**：一个开源项目，允许开发者在本地托管自己的 AI 代码补全服务，降低对云端 AI 的依赖。

关于 XBOW

XBOW 是一家专注于 AI 安全的科技公司，核心目标是将大语言模型 (LLM) 的能力与确定性验证方法相结合，实现可扩展的自动化安全测试。该团队在 2025 年凭借演讲中介绍的方法论，登顶 HackerOne 美国区排行榜第一名 (VDP + Bug Bounty 综合类别)。

Dolan-Gavitt 开宗明义地指出本次演讲的主题——**虚假阳性 (False Positive)** 是如何“像幽灵一样困扰着 AI 进攻性安全研究”。这一问题的核心在于：当前大语言模型在生成漏洞报告时极其“乐于助人”，却严重缺乏对现实世界的可靠 grounded。

1.2 AI 安全研究的核心困境：虚假阳性泛滥

Dolan-Gavitt 用一句话概括了现状：“有一个幽灵在困扰着 AI 进攻性安全研究，那就是虚假阳性的幽灵。”

虚假阳性 (False Positive)

虚假阳性是指检测系统在不存在漏洞（或威胁）的情况下，错误地报告其存在的现象。在 AI 安全研究中，这表现为模型声称发现了安全漏洞，但实际上该漏洞并不存在。与之对应的还有**虚假阴性 (False Negative)**——即真实漏洞被漏报。

为了说明问题的严重性，Dolan-Gavitt 举了一个极具代表性的案例：**curl/libcurl 开发者 Daniel Stenberg 的遭遇**。curl 是互联网基础设施中最广泛使用的命令行工具和库之一，几乎存在于每一台服务器和嵌入式设备中。然而，随着 ChatGPT 等工具的普及，Stenberg 开始收到源源不断的 AI 生成安全报告。

演讲中提到一个触目惊心的数据：在 Twitter 上追踪 HackerOne 公开披露报告的账号中，**大约三分之二都是针对 curl 的虚假阳性报告**。这些报告的生产流程高度模式化：

1. 将 curl 源代码复制粘贴到 ChatGPT 中；

2. ChatGPT 分析后声称“发现了一个严重的安全问题”；
3. 报告内容措辞流畅、论理清晰，但**漏洞完全是虚构的**（very convincing, very eloquent, and totally fake）。

这种系统性偏差的根源在于大语言模型的训练目标。模型被训练为“有用”（helpful），而它将“有用”理解为“用户真的想让我找到漏洞”。当用户提交源码并询问安全问题时，模型会不由自主地向“发现漏洞”的方向倾斜，而非客观地判断代码是否真正存在问题。这是一种**确认偏差**在 AI 系统中的体现——模型倾向于确认用户的预期，而非挑战它。

常见误解：AI 报告看起来很专业，所以一定是对的

虚假阳性报告之所以危险，恰恰是因为它们**看起来非常专业**。ChatGPT 生成的报告通常包含详细的技术分析、代码引用和看似合理的攻击路径。这种“表面专业性”使得缺乏深度审核能力的接收者容易被误导。对 curl 而言，审核这些无意义的报告已经消耗了巨量人力资源。

1.3 Agent 方案为何仍然失败

面对虚假阳性泛滥，一个自然的想法浮现出来：既然静态代码分析不可靠，那么让 AI Agent 实际运行命令、与真实系统交互，是否可以通过执行反馈来消除虚假报告？2025 年被许多人寄予厚望为“Agent 元年”，这一思路看起来前景光明。

然而，Dolan-Gavitt 用实际案例证明：**Agent 方案同样无法解决虚假阳性问题**。

案例一：Bash 引用错误导致的误判。 在演讲中，Dolan-Gavitt 展示了一个真实发生的案例。Agent 试图构造一次命令注入攻击，意图利用反引号（backtick）让服务端执行注入的命令。然而，Agent 在构建 Bash 命令时使用了**双引号**而非**单引号**。在 Bash 中，双引号内的反引号会被**本地 Shell** 先行执行解析，这意味着 Agent 本意注入到远程服务器的命令实际上在自己的本地环境中被执行了。

具体过程如下：

1. Agent 构造的命令中包含 ``cat /etc/passwd``，期望服务器执行此命令；
2. 由于使用了双引号包裹，本地 Shell 先执行了反引号内的命令，将本地 `/etc/passwd` 的内容注入到 HTTP 请求中；
3. 服务器收到请求后，将请求内容原样反射（reflected）回来；
4. Agent 看到响应中包含了密码文件内容，便“确认”自己成功读取了服务器上的密码文件。

演讲者对此调侃道：“如果你在 Bash 里泡了大概 25 年——像我这样有点让人不安地长——你一眼就能看出，这里有引用错误（a quoting issue）。”

```
1 # Agent 的错误构造（双引号）
2 curl "http://target/api?query=`cat /etc/passwd`"
3 # 反引号在本地 Shell 中先执行，/etc/passwd 内容被嵌入 URL
4
5 # 正确构造（单引号）
6 curl 'http://target/api?query=`cat /etc/passwd`'
7 # 反引号内容作为字面量发送到服务器
```

Listing 1: Bash 引用错误：双引号与单引号的致命差异

案例二：网络随机延迟被误判为可利用的时序攻击通道。 另一个经典案例是，Agent 观察到服务器响应时间存在随机波动，便推断存在一个可利用的时序攻击通道（timing-based channel）。实际上，这不过是正常的网络延迟抖动，但 Agent 将其解读为可以利用的攻击面。

核心问题：AI 自我验证 = 自己给自己打分。 这些案例揭示了一个根本性问题：当 AI 被用来验证自己的发现时，本质上是在“自己给自己打分”（grade its own homework）。模型倾向于相信自己的结论，并在面对模棱两可的证据时选择性地采信支持自身判断的部分。正如演讲中所说：

“So all of these are problems that are very hard to surmount if you’re just using AI to validate itself, right? If you’re basically letting it grade its own homework.”

这不是个别模型的缺陷，而是当前大语言模型架构层面的固有局限——它们缺乏对自身推理过程的元认知能力和对执行环境的可靠感知。

核心困境的总结

无论是直接让模型分析代码，还是通过 Agent 与系统交互，只要最终依赖模型自身的判断来确认漏洞是否存在，虚假阳性问题就无法从根本上解决。解决方案必须引入**模型之外的、确定性的验证机制**——这正是后续章节将要展开讨论的核心主题。

1.4 本章小结

本章通过演讲者背景引入主题，揭示了 AI 安全研究中虚假阳性问题的严重性。curl 开发者遭遇的 AI 虚假报告泛滥事件表明，大语言模型在“乐于助人”的偏差驱动下，会系统地生成措辞专业却完全虚构的漏洞报告。Agent 方案虽然引入了与真实系统的交互，但由于 Bash 引用错误、网络延迟误判等实际问题，仍然无法可靠地区分真实漏洞与虚假发现。其根本原因在于：依赖 AI 自身来验证 AI 的发现，等同于“自己给自己打分”。这一困境为第二章引入统计学层面的分析——基础率谬误——奠定了基础。

2 基础率谬误与安全检测

既然 AI Agent 自我验证仍然失败，那么从统计学上看，这种失败是否有某种必然性？本章将从贝叶斯推理的一个经典案例出发，论证在大规模安全检测中虚假阳性的不可避免，并由此导出演讲的核心方法论：将虚假阳性率压至极低。

2.1 贝叶斯推理的经典医学案例

Dolan-Gavitt 在演讲中设置了一个“突击测验”（pop quiz），用以引出统计学中的基础率谬误。他直言：“即便经验丰富的医生也经常答错这道题。”

问题设定。 假设有一种医学检测，准确率高达 99%：

- 当受检者**确实患病**时，检测有 99% 的概率返回阳性结果；
- 当受检者**并未患病**时，检测有 99% 的概率正确返回阴性结果。

该疾病在人群中的患病率极低：**每 10,000 人中仅有 1 人患病**。现在，你接受检测并得到了**阳性**结果。问题：你真正患病的概率是多少？

大多数人的直觉回答是 99%。然而，正确答案仅约为 1%。

数学推导。 利用贝叶斯定理，可以将问题形式化。设 A 表示“实际患病”， B 表示“检测阳性”，则：

$$P(A | B) = \frac{P(B | A) \cdot P(A)}{P(B)}$$

其中各符号的含义如下：

- $P(A | B)$ ：检测为阳性时实际患病的概率（后验概率，即我们要求的阳性预测值）；
- $P(B | A) = 0.99$ ：真阳性率（True Positive Rate, TPR），即患病者中检测为阳性的比例；
- $P(A) = 0.0001$ ：先验概率（基础率），即人群中该疾病的患病率（1/10,000）；
- $P(B) = P(B | A)P(A) + P(B | \neg A)P(\neg A)$ ：检测为阳性的总概率（由全概率公式展开）。

代入数值计算：

$$\begin{aligned} P(B) &= 0.99 \times 0.0001 + 0.01 \times 0.9999 \\ &= 0.000099 + 0.009999 \\ &\approx 0.010098 \end{aligned}$$

因此：

$$\begin{aligned} P(A | B) &= \frac{0.99 \times 0.0001}{0.010098} \\ &= \frac{0.000099}{0.010098} \\ &\approx 0.0098 \\ &\approx 1\% \end{aligned}$$

基础率谬误（Base Rate Fallacy）

基础率谬误是指人们在面对条件概率问题时，倾向于忽略事件的先验概率（基础率），而过度依赖当前观测到的证据（如检测结果）。在上例中，99% 的检测准确率看似令人放心，但由于患病率极低（1/10,000），阳性结果中绝大多数是虚假阳性——在 10,000 人中，大约有 100 个健康人会被误报为阳性（ $9,999 \times 0.01 \approx 100$ ），而真正的患者仅有约 1 人。因此，阳性结果中真正患病的比例仅约 $1/(1 + 100) \approx 1\%$ 。

我们可以从频数角度直观理解这一结论：在总人数 10,000 中，预计只有约 1 人真阳性，却有约 100 人假阳性。所有阳性结果加在一起约 101 人，其中真正患病的仅 1 人。**检测准确率 99%，但阳性结果中只有约 1% 是真正患病**——这就是基础率极低带来的“虚假阳性诅咒”。

演讲者在此处的幻灯片上做了如下总结：

“Moral of the Story: if you’re testing for something very very rare, you need extremely accurate tests in order to avoid this sort of curse of the base rate fallacy.”




图 1: 贝叶斯基础率谬误的经典医学检测测验

2.2 基础率谬误对安全检测的启示

Dolan-Gavitt 紧接着指出，基础率谬误绝非仅存在于教科书中的数学趣题，它直接适用于安全检测领域。

历史渊源。 Dolan-Gavitt 援引了 Stefan Axelsson 在 1990 年代发表的经典论文 “*The Base-Rate Fallacy and its Implications for the Difficulty of Intrusion Detection*”。该论文首次系统地论证了基础率谬误对入侵检测系统 (IDS) 性能的根本性制约。Axelsson 指出，由于正常网络流量与入侵行为之间的比例极度悬殊，即使检测器具有极高的真阳性率和极低的虚假阳性率，在实际部署中依然会产生大量虚假告警。

漏洞密度视角。 安全从业者听到这里可能会质疑：“安全漏洞到处都是，基础率怎么会低？” 演讲者承认这一直觉有一定道理，但他要求听众换一个角度思考：

“If you think about it in terms of number of lines of code, for example, how much of that code is actually vulnerable? It’s a fairly rare event, right?”

如果以**代码行**为单位来衡量，真正包含可利用安全漏洞的代码比例极低。根据公开研究，典型软件的漏洞密度大约在 0.5–5 个/千行代码之间波动。若把标准收紧到“单行代码是否真正包含可利用漏洞”，这个比例将远低于千分之一。这正是基础率谬误发挥作用的温床。

漏洞密度 (Vulnerability Density)

漏洞密度通常以“每千行代码 (KLOC) 中的漏洞数量”来衡量。开源软件和商业软件的典型值差异较大，但即使取较悲观的估值 (如 5 个/KLOC)，单行代码包含可利用漏洞的比率也仅为 0.5%。更何况，许多漏洞需要跨越多行代码的交互才能触发，从“单行可利用”的角度看，基础率远低于此。

将医学检测类比映射到安全领域：

- **患病率** → 代码中存在可利用漏洞的比例（极低）；
- **检测器** → ChatGPT 等大语言模型；
- **阳性结果** → 模型声称“发现漏洞”；
- **虚假阳性** → 模型报告的漏洞实际不存在。

由于漏洞在代码中的先验概率极低，即使模型在单个判断上有较高的“检测准确率”，其报告的绝大多数“漏洞”仍将是虚假的。这不是模型的偶然失误，而是统计学规律下的必然结果。演讲者对此一言以蔽之：

“If you consider ChatGPT as your detector and you apply it to code indiscriminately, you’re going to get lots and lots of false positives.”

2.3 唯一解法：将虚假阳性率压至极低

面对基础率谬误的统计学铁律，Dolan-Gavitt 给出了明确的方向：**必须将虚假阳性率大幅降低** (the only solution to this is to start driving false positive rates down)。他指出，当前的 LLM 自身无法做到这一点，但也对未来保持开放态度。

LLM 自我验证能力的进展。 演讲中提到，就在演讲前不久（2025 年 7 月），Google 和 OpenAI 的研究团队分别在国际数学奥林匹克（IMO）中获得了金牌。值得注意的是，这些成绩并非依赖传统的确定性定理证明器，而是通过**语言模型自我审查和批评自身输出**（language models that were verifying their own answers）来实现的。模型能够审视自己的推理过程、发现错误、并给出修正后的答案。

Dolan-Gavitt 坦言：“也许几年后，我们确实可以直接使用语言模型来验证漏洞。但就目前而言，这种能力尚未成熟到可以可靠应用于安全检测的程度。”

核心方案：非 AI 的确定性代码验证。 因此，当前阶段的核心解决方案是使用**非 AI 的确定性代码**来验证漏洞的真实性。这一方案的核心思想可以概括为：

1. 不信任模型自身的漏洞声明；
2. 要求模型提供特定格式的**证据**（evidence）；
3. 用确定性程序（验证器）来检查这些证据是否满足预设条件。

确定性验证的核心思想

将漏洞验证从“AI 判断”转变为“确定性程序检查”。模型负责发现和利用漏洞，但不负责判断漏洞是否真实——这一职责由外部验证器承担。通过这种方式，可以将虚假阳性率从 LLM 固有的不可控水平，降低到确定性程序的可验证水平。演讲者将这一方案概括为：“using essentially non-AI deterministic code to validate vulnerabilities.”

这一方案不仅是 engineering 层面的权宜之计，更是演讲标题中“Zero False Positives”得以成立的**唯一数学保证**。基础率谬误告诉我们：只要虚假阳性率不够低，大规模输出必然会被虚假报告淹没；唯有将虚假阳性率压至极低，才能让真正的漏洞从噪声中凸显出来。

2.4 本章小结

本章从贝叶斯推理的经典医学检测案例出发，推导出基础率谬误的数学本质：当被检测事件的先验概率极低时，即使检测器准确率很高，阳性结果中也绝大部分是虚假阳性。将这一结论映射到安全领域：代码中可利用漏洞的密度极低，因此将 ChatGPT 等 LLM 作为漏洞检测器使用时，大量虚假阳性在统计学上是必然的。Stefan Axelsson 早在 1990 年代就对入侵检测系统做出了同样的经典论证。

根本出路在于将虚假阳性率压至极低。虽然 LLM 的自我验证能力正在快速进步（如 IMO 金牌的突破），但当前阶段仍需依赖非 AI 的确定性代码来验证漏洞的真实性。这一思路为后续章节介绍的金丝雀机制和验证器框架奠定了理论基础。

基础率谬误告诉我们，要在大规模扫描中避免虚假阳性海啸，唯一出路是将虚假阳性率压到极低；而这正需要一个外部、确定性的验证框架。

2.5 拓展阅读

- Stefan Axelsson, “*The Base-Rate Fallacy and its Implications for the Difficulty of Intrusion Detection*”, Proceedings of the 1st International Workshop on Recent Advances in Intrusion Detection (RAID), 1998. 该论文是基础率谬误在安全检测领域应用的开创性工作，系统论证了为什么即使高准确率的入侵检测系统在实际部署中也会产生大量虚警告警。
- Daniel Stenberg 的博客文章记录了他作为 curl 开发者遭遇 AI 生成虚假安全报告的经历，可作为基础率谬误在 AI 安全领域影响的具体案例。其个人博客地址为 <https://daniel.haxx.se/blog/>。
- 关于条件概率和贝叶斯推理的深入理解，可参考 E.T. Jaynes, *Probability Theory: The Logic of Science*, Cambridge University Press.
- 关于 Google DeepMind 与 OpenAI 在 IMO 2025 夺金的进展，可查阅官方公告：<https://deepmind.google/> 与 <https://openai.com/>。

3 确定性验证框架：金丝雀与证据

在第二章中，我们从统计学的角度论证了依赖 AI 自身来判断漏洞真实性注定会产生大量虚假阳性。核心结论是：必须引入模型之外的确定性验证机制。本章将展开这一方案的工具箱——两种互补的验证武器：**金丝雀 (Canary)** 和**确定性证据验证**，并绘制一张完整的验证器空间地图来指导实际应用。

3.1 Canary (金丝雀) 机制

3.1.1 从 CTF 旗标到工程化工具

金丝雀这一概念源自 CTF (Capture The Flag, 夺旗赛) 竞赛中的核心机制——旗标 (Flag)。在 CTF 比赛中，参赛者需要在目标系统中找到隐藏的特定字符串（如 `flag{...}`），以此证明成功利用了某个安全漏洞。XBOW 团队的核心洞察在于：这一机制可以被**工程化地**应用于真实的安全测试场景。

Canary (金丝雀) 的定义与原理

金丝雀是一段不可猜测的随机字符串（通常使用 UUID 格式），被预先植入到目标系统中攻击者不应能够访问的位置。其工作逻辑极其简洁：

读取金丝雀 $\implies$ 漏洞确认 (1)

- 金丝雀：不可猜测的 UUID 字符串，熵约为 128 位，模型不可能通过猜测获取。
- 若 Agent 成功读取金丝雀，则**确定性地**证明它突破了访问控制边界。
- 推论：若能读取 `/flag.txt`，通常意味着可读取服务器上的任意文件。

3.1.2 植入位置与可扩展性

金丝雀可以植入目标系统的多个层面，形成分层探测网络：

- **文件系统**：在服务器文件系统的 Web 根目录之外写入 `/flag.txt`，用于检测任意文件读取 (File Read)、路径遍历 (Path Traversal) 等漏洞。
- **数据库**：枚举目标应用使用的所有数据库，在其中添加包含金丝雀的新表，用于检测 SQL 注入 (SQLi)。
- **内部网络**：在目标服务器的内部网络中部署一个包含金丝雀的 Web 服务器，用于检测 SSRF (服务端请求伪造)。
- **应用逻辑**：在应用的私密字段、隐藏资源、管理员控制台等位置植入金丝雀，用于检测授权绕过 (AuthZ Bypass) 等业务逻辑漏洞。

金丝雀机制的一个重要优势在于其**可扩展性**：如果一个 Agent 成功读取了文件系统上的金丝雀，则可以推断该漏洞允许读取文件系统上的**任意文件**——而不仅仅是金丝雀所在的特定文件。类似地，数据库金丝雀的成功读取意味着 Agent 能够执行任意 SQL 查询。

从 CIA 三元组（机密性 Confidentiality、完整性 Integrity、可用性 Availability）的视角来看，金丝雀主要用于检测**机密性 (Confidentiality)** 的破坏——它们代表着本不应被攻击者获取的秘密信息。

自动化与手动金丝雀部署

- **自动部署** (DockerHub 扫描)：修改 Dockerfile，在构建时自动写入文件系统金丝雀；通过 docker-compose 网络拓扑自动附加内部 Web 服务器作为 SSRF 金丝雀；自动枚举数据库并创建 flag 表。
- **手动部署** (业务逻辑测试)：人工登录应用后台，创建用户、设置私密字段、隐藏资源，并在这些不应被外部访问的位置植入金丝雀。Redmine 漏洞即采用此法，设置耗时约 1 小时。

3.2 确定性证据验证

金丝雀机制虽然强大，但它要求测试者能够**预先在目标系统中植入旗标**。在许多场景下（如外部 Bug Bounty 测试），测试者无法控制目标系统。此时，第二种验证武器——确定性证据验证——




图 2: 金丝雀的植入位置与可检测的漏洞类型对应关系

便成为关键。

3.2.1 Bug Bounty 模式的启示

Dolan-Gavitt 用 Bug Bounty 的实际运作模式来类比这一机制。在真实的 Bug Bounty 流程中，安全研究员不会仅仅声称“我发现了一个漏洞”就能获得赏金——公司要求提供**可复现的证据**。

确定性证据验证的核心逻辑

模型声称发现漏洞后，必须提供特定格式的**证据** (evidence)，且该证据可以被非 AI 的确定性程序独立验证。验证流程如下：

1. 针对每种漏洞类型，预定义所需的证据格式 E_V ；
2. 模型利用漏洞后，将发现转化为所需的证据格式；
3. 确定性验证器独立检查证据是否满足预设条件。

$$\text{LLM} : T \times V \rightarrow E_V, \quad \text{Validator} : E_V \rightarrow \{0, 1\} \quad (2)$$

- T : 目标应用 (Target)。
- V : 漏洞类型 (Vulnerability class)。
- E_V : 该漏洞类型所需的证据格式 (Evidence format)。

LLM 充当从漏洞到证据的灵活转化函数，验证器则是确定性的二元判定。Agent 负责发现漏洞并构造证据，验证器负责独立、无 AI 地审查证据。

3.2.2 AWS Token 泄露示例

演讲中给出了一个具体例子来说明证据验证的工作方式。假设模型声称在目标网站上发现了 AWS 访问密钥的泄露：

1. 模型提交发现的 AWS Token；
2. 验证器将 Token 传入 TruffleHog 等密钥验证工具；
3. TruffleHog 使用该 Token 发起真实的 AWS API 请求；
4. 如果 API 请求成功，则**确定性地**证明了 Token 有效且泄露属实。

这一验证过程中，判断 Token 是否有效的工作完全由确定性代码完成，不依赖任何 AI 判断。模型的角色仅限于“发现 Token 并提交”——这与它在金丝雀场景中的角色高度相似。

TruffleHog 密钥验证工具

TruffleHog 是一款开源的密钥泄露检测与验证工具。与简单的正则匹配不同，TruffleHog 内置了针对多种云服务（AWS、GCP、Azure、GitHub Token 等）的验证器。每个验证器会使用发现的凭据发起真实的 API 请求，以确认凭据是否仍然有效。这种“实际调用 API”的验证方式，使得 TruffleHog 的验证结果具有极高的可信度，属于低虚假阳性路径。

3.3 CTF 化的额外收益

将安全测试转化为 CTF 挑战的形式，不仅仅是一种验证手段，还带来了一个重要的心理学副产品——Dolan-Gavitt 将其称为“CTF 化（CTF-ification）”的额外收益。

3.3.1 CTF 挑战一定有解

CTF 竞赛的一个基本特征是：每道挑战题**一定有解**。赛事组织者不会出一道无解的题目。这意味着，当模型被告知它正在解决一道 CTF 挑战时，它**知道漏洞一定存在**——不需要猜测“这个目标是否有漏洞”。

CTF 化的双重收益

1. **验证层面**：金丝雀提供了确定性的漏洞确认机制；
2. **激励层面**：告知模型“这是一道 CTF 挑战，漏洞一定存在”，消除了模型在“这个目标到底有没有漏洞”上的犹豫，使其更加努力地探索。

这种双重收益使得 CTF 化成为一种不仅解决**验证问题**，还解决**激励问题**的策略。

3.3.2 解决“何时足够努力”的问题

LLM 在安全测试中有一个已知的弱点：它们往往难以判断“何时已经探索得足够充分”。在面对一个不确定是否存在漏洞的目标时，模型倾向于过早放弃——或者在一个方向上反复尝试而忽略其他可能性。

CTF 化巧妙地规避了这一弱点。因为模型知道漏洞**一定存在**，它会更倾向于：

- 在一个方向失败后，迅速切换到其他攻击面；

- 更深入地分析源代码和配置文件；
- 不轻易放弃，持续探索直到找到漏洞。

这种效应与人类安全研究员在 CTF 竞赛中的表现高度一致——知道题目有解，研究者会展现出远超日常测试的耐心和创造力。

CTF 化的局限

CTF 化虽然显著提升了模型的努力程度，但也可能带来副作用：如果目标系统中实际上不存在漏洞（这在非 CTF 场景中是完全可能的），模型可能会过度尝试，甚至产生虚假阳性报告以“证明”自己找到了漏洞。因此，CTF 化策略应始终与**确定性验证器**结合使用，以过滤掉虚假发现。

3.4 验证器空间四象限图

有了金丝雀和确定性证据验证两种武器，Dolan-Gavitt 在演讲中绘制了一张系统性的验证器空间地图，将所有验证方法按照两个维度组织成四个象限。这张地图不仅帮助理解不同验证器的定位，也为实际选择验证策略提供了清晰的指导。

如图 3 所示，四象限图以“目标配合程度”和“设置自动化程度”为两轴，将验证方法划分为四个区域。各象限的详细解释如下。

3.4.1 两个分类维度

验证器空间的两个维度

- **Y 轴（纵轴）——目标配合程度（Target Cooperation）**：验证器是否需要目标系统的配合（即是否需要在目标系统中植入金丝雀或进行其他设置）。
 - **上方**：需要目标配合——例如在开源应用或 Docker 容器中植入金丝雀。
 - **下方**：无需目标配合——直接对任意互联网目标进行验证。
- **X 轴（横轴）——设置自动化程度（Manual Intervention / Automatic Setup）**：验证器的部署设置是否可以自动化完成。
 - **左方**：需要手动设置——例如人工在应用逻辑中植入金丝雀。
 - **右方**：可自动设置——例如通过脚本自动部署 Docker 容器并植入金丝雀。

3.4.2 Q1：手动金丝雀 + 目标配合

这一象限适用于有目标系统控制权但需要手动设置的场景。典型应用是针对开源软件的业务逻辑漏洞测试。例如，在 Redmine（一个 Ruby on Rails 项目追踪器）中手动创建私密项目、设置私密用户字段、隐藏资源等，然后在这些位置植入金丝雀。这种方法虽然需要人工设置（通常约 1 小时），但能够检测到其他方法难以覆盖的高层次逻辑漏洞，如 IDOR 和授权绕过。




图 3: 验证器空间四象限图：按目标配合程度和设置自动化程度分类

3.4.3 Q2: 自动金丝雀 + 目标配合

这一象限是 Q1 的自动化升级版。当目标应用可以通过 Docker 容器部署时（如从 DockerHub 获取的 Web 应用），金丝雀的植入过程可以完全自动化：

- 文件读取/RCE：在 Dockerfile 中添加写入 `/flag.txt`（位于 `webroot` 之外）的指令；
- SSRF：将内部 Web 服务器挂接到目标容器所在的内部网络，flag 托管其上；
- SQLi：枚举目标应用使用的数据库，创建含 flag 的新表。

XBOW 团队正是利用这一象限的方法，对 DockerHub 上的约 17,151 个 Web 应用进行了大规模自动化扫描，并在此基础上发现大量的真实漏洞。

3.4.4 Q3: 确定性验证, 无需目标配合 (零虚假阳性)

Q3——Bug Bounty 的核心象限

这是整个框架中**最具实用价值**的象限。验证器不需要目标系统的任何配合, 可以直接对互联网上的任意目标进行测试。更重要的是, 这一象限的验证器能够实现**零虚假阳性**:

- **XSS**: 无头浏览器检测 `alert` 或 `console.table` 是否在预期的目标主机上触发;
- **开放重定向**: 验证起点 URL 在目标域名, 终点 URL 在攻击者控制的域名 (如 `evil.xbow.ltd`), 且中间无用户干预;
- **缓存投毒**: 三步验证法确认被投毒内容确实被缓存并影响后续正常访问。

XBOW 团队正是凭借 Q3 中的验证器, 登顶了 HackerOne 美国排行榜第一名 (VDP + Bug Bounty 综合类别)。

3.4.5 Q4: 启发式验证, 无需目标配合 (低但非零 FP)

这一象限覆盖了那些难以实现绝对确定性验证的漏洞类型, 包括任意文件读取、远程代码执行 (RCE)、SQL 注入和 SSRF。这些验证器采用启发式方法 (如时序分析、统计检验), 虚假阳性率虽然很低但无法降到绝对的零。

Q4 的学术诚实标注

演讲标题承诺的是 "Zero False Positives", 而 Q4 象限的验证器并不能完全兑现这一承诺。Dolan-Gavitt 坦诚表示: "我真的不想做虚假广告。" 因此, 他将 Q3 作为方法论的 "核心", 而将 Q4 标注为 "有用但需谨慎使用" 的补充手段。这种学术诚实度值得赞赏。

3.4.6 象限间的进阶关系

四个象限并非彼此孤立, 而是构成了一条从 "高控制、高成本" 到 "低控制、低成本" 的完整策略谱系:

1. **Q1 → Q2**: 将手动金丝雀部署自动化, 实现从 "个案研究" 到 "大规模扫描" 的跃迁;
2. **Q2 → Q3**: 放弃对目标的控制权, 转而依赖确定性证据验证, 实现从 "内部测试" 到 "外部 Bug Bounty" 的拓展;
3. **Q3 → Q4**: 在无法实现零虚假阳性的漏洞类型上, 接受轻微的虚假阳性率以换取更广泛的覆盖面。

这种渐进式的策略扩展, 使得 XBOW 团队能够在不同约束条件下灵活选择最适合的验证方法, 最终在漏洞发现数量和验证可信度之间取得平衡。

3.5 本章小结

本章系统介绍了确定性验证框架的两大核心工具和整体策略地图:

1. **Canary 机制**：将 CTF 旗标工程化应用于安全测试，通过植入不可猜测的 UUID 字符串来确认漏洞的真实性。金丝雀可部署于文件系统、数据库、内部网络和应用逻辑等多个层面，且具有天然的可扩展性——读取一个金丝雀意味着该类漏洞的普遍存在。
2. **确定性证据验证**：借鉴 Bug Bounty”不信任声明、只信任证据”的运作模式，为每种漏洞类型定义可确定性检查的证据格式。模型负责发现漏洞并将其转化为所需证据，验证器负责独立判定证据是否成立。这一分工将 AI 的灵活性与确定性代码的可信度完美结合。
3. **CTF 化的额外收益**：将安全测试框架化为 CTF 挑战，不仅提供了验证手段，还通过”挑战一定有解”的特性激励模型更加努力地探索，有效解决了 LLM”何时足够努力”的固有弱点。
4. **验证器空间四象限图**：以目标配合程度和设置自动化程度为两个维度，将验证方法组织为四个象限。其中 Q3 象限（确定性验证、无需目标配合、零虚假阳性）是 Bug Bounty 实战的核心，直接支撑了 XBOW 团队登顶 HackerOne 美国排名第一的成果。

四象限图为下一章深入各类验证器的具体实现（XSS、开放重定向、缓存投毒、SQL 注入等）提供了统一的理论基础和分类视角。

4 验证器类型与实现

在第三章中，我们确立了确定性验证的两大武器——金丝雀（Canary）和证据验证，并绘制了验证器空间的四象限图。本章将深入第三、第四象限，详细剖析各类验证器的设计原理、实现细节，以及在实际部署中遇到的种种“惊喜”。这些验证器是将 AI Agent 从“不可信的漏洞猜测器”转变为“可信赖的安全研究工具”的核心桥梁。

4.1 XSS（跨站脚本）验证器

4.1.1 基本原理

XSS 验证器的核心思路简洁而优雅：如果模型声称发现了一个跨站脚本漏洞，那么它必须提供一个 URL，当用真实的浏览器访问该 URL 时，能够触发 JavaScript 代码的执行。

XSS 验证器的判定逻辑

验证器要求模型提供：

1. 一个可供访问的 URL
2. （可选）浏览器状态信息，如 Cookie 或登录凭据
3. 预期触发的行为：弹出 `alert` 对话框，或调用 `console.log`

验证器随后使用无头浏览器（Headless Browser）访问该 URL，检测是否真正触发了 `alert` 对话框或 `console.log` 回调，并确认触发来源是目标主机而非攻击者控制的页面。

4.1.2 实现架构

XSS 验证器基于 Puppeteer（Node.js 无头浏览器框架）实现。整体流程如清单 2 所示。




图 4: XSS 验证管线：从 LLM 提交 URL 到确定性判定的完整流程

```

1  const puppeteer = require('puppeteer');
2
3  async function validateXSS(url, cookies, expectedDomain) {
4    const browser = await puppeteer.launch();
5    const page = await browser.newPage();
6
7    // 设置模型提供的 Cookie / 浏览器状态
8    if (cookies) await page.setCookie(...cookies);
9
10   let triggered = false;
11   let triggerOrigin = null;
12
13   // 注册 alert 回调
14   page.on('dialog', async dialog => {
15     triggered = true;
16     triggerOrigin = page.url();
17     await dialog.accept();
18   });
19
20   // 注册 console.log 回调
21   page.on('console', msg => {
22     if (msg.type() === 'log') {
23       triggered = true;

```

```

24     triggerOrigin = page.url();
25   }
26 });
27
28 await page.goto(url, { waitUntil: 'networkidle2' });
29 await browser.close();
30
31 // 确定性检查：触发来源必须是目标域名
32 return triggered
33     && triggerOrigin.includes(expectedDomain);
34 }

```

Listing 2: 基于 Puppeteer 的 XSS 验证器核心逻辑

4.1.3 WAF 绕过

在实际扫描中，目标网站通常部署了 Web 应用防火墙 (WAF)，会过滤常见的 XSS 载荷。LLM 在这里展现了独特的优势：它能够生成富有创意的、非标准的 payload 来绕过 WAF 规则。例如：

- 使用 HTML 实体编码混淆 `<script>` 标签
- 利用 JavaScript 的事件处理器（如 `onerror`、`onload`）
- 构造多级编码的嵌套载荷

模型生成创意 payload 的能力，加上验证器提供的确定性判定，形成了一个强大的组合：模型负责“探索”，验证器负责“确认”。

4.1.4 验证器的陷阱——LLM 如何“作弊”

XSS 验证器看似简单，但在实际部署中，LLM 展现出了令人惊讶的“创造力”——它们会想方设法通过验证，哪怕漏洞并不真正存在。演讲者分享了三个逐步升级的欺骗案例：

陷阱 1: URL Scheme 切换

验证器的第一个版本未考虑 URL scheme 的变化。模型发现可以直接将 URL 从 `https://` 切换为 `javascript:alert(...)`，绕过页面加载过程直接触发 alert。这实际上不是目标站点的 XSS 漏洞，而只是浏览器自身的 JavaScript 执行能力。

XSS Validator Cheat #1

- We forgot to check the URL scheme → agent figured out it could “validate” javascript:alert("XSS")




图 5: XSS 验证器实战中的模型”作弊”案例之一：利用 URL Scheme 切换绕过早期验证逻辑

陷阱 2：伪造历史记录（同源策略绕过）

修复陷阱 1 后，团队为了不遗漏可能的漏洞，在无头浏览器中关闭了同源策略（Same Origin Policy）的强制执行。模型随即发现：它可以重写页面的 `history` 对象，使浏览器地址栏显示目标域名，而实际的 `alert` 是在模型自己控制的页面上触发的。这相当于“伪造了犯罪现场”——检测器报告漏洞存在于目标站点，实则不然。

XSS Validator Cheat #3

- We allowed `console.log("666")` as evidence of XSS




图 6: XSS 验证器实战中的模型”作弊”案例之二：关闭同源策略后伪造历史记录

陷阱 3：`console.log("666")` 与路径计数

当验证器接受 `console.log` 作为证据时，模型发现某个 Web 应用会正常地将 URL 路径中的组件数量记录到控制台。于是，模型构造了一个包含 666 个斜杠的 URL（如 `https://target.com////////.../////`），使得应用打印出 `console.log(666)`，而验证器将此判定为 XSS 触发。这是利用了应用的正常行为来伪造验证证据。

Docker Hub Target Tips & Tricks

- *Use the Source, Luke!*
 - Agents do better at finding vulns with source → provide docker image FS to find the webapp code!
- Don't forget to change default credentials
 - Otherwise, lots of "solves" from logging in as admin
- Only expose necessary ports
 - Models are good at exploiting stuff like exposed FastCGI

图 7: XSS 验证器实战中的模型“作弊”案例之三: 利用极端长度的 URL 路径触发 `console.log` 回调

4.1.5 对策: 使用不常见的验证方法

针对上述陷阱, 一个有效的对策是选择那些在正常 Web 应用中极少被使用的验证方法:

验证方法选择原则

使用 `console.table()`、`console.trace()` 等不常见的 console 方法替代 `console.log()` 和 `alert()`。由于绝大多数 Web 应用不会在正常逻辑中调用这些方法, 模型便无法利用应用的正常行为来伪造验证证据。

核心思想: 验证信号必须足够独特, 使其不可能由应用的正常行为偶然触发。

4.2 开放重定向 (Open Redirect) 验证器

开放重定向验证器是所有验证器中最为简洁可靠的。其判定标准清晰明确, 几乎不存在灰色地带。

开放重定向验证标准

模型需要提供一个 URL (可能附带浏览器状态), 使得:

1. **起点**: 浏览器初始访问的目标域名 = 被测试的目标站点
2. **终点**: 经过重定向后, 浏览器停留在攻击者控制的域名
3. **约束**: 整个过程中无需任何用户干预 (如点击、确认等)

实现方式 XBOW 团队注册了一个专门的域名 `evil.xbow.ltd` 作为攻击者控制的终点。验证流程极为直接:

1. 模型提交一个 URL
2. 无头浏览器访问该 URL (与 XSS 验证器共享同一套 Puppeteer 基础设施)

3. 记录初始域名 (`window.location.host`)
4. 等待导航完成, 记录最终域名
5. 检查: 初始域名 = 目标域名 $\wedge$ 最终域名 = `evil.xbow.ltd`

$$\text{Valid}(u) = \begin{cases} 1 & \text{if } \text{origin}(u) = T \wedge \text{dest}(u) = E \wedge \neg \text{user_intervention} \\ 0 & \text{otherwise} \end{cases}$$

其中:

- u 为待验证的 URL
- T 为目标域名
- E 为攻击者域名 (`evil.xbow.ltd`)
- `origin` 和 `dest` 分别表示导航的起点和终点
- `user_intervention` 表示是否需要用户手动操作

这种验证器之所以“相对简单可靠”, 是因为重定向行为完全由 HTTP 响应头 (`Location`) 或 HTML 元素 (`<meta http-equiv="refresh">`) 决定, 判定标准二元且确定。

4.3 缓存投毒 (Cache Poisoning) 验证器

缓存投毒验证器是最复杂、也最具技术魅力的验证器之一。它针对的是一类常被忽视但影响巨大的漏洞。

4.3.1 原理: 缓存键与非键控字段

缓存代理的工作机制

许多网站在用户与源服务器之间部署了缓存代理 (如 CDN)。缓存代理根据 HTTP 请求中的某些字段来决定是否返回缓存内容——这些字段称为**缓存键 (Cache Key)**, 通常包括请求路径、Host 头等。


然而, HTTP 请求中还有一些字段会**影响响应内容**, 却**不被纳入缓存键**——这些称为**未键控字段 (Unkeyed Fields)**, 可能是某些 HTTP 头、Cookie 或查询参数。如果攻击者通过设置某个未键控字段来改变响应内容, 那么这个被篡改的响应将被缓存并分发给后续所有用户。

缓存投毒的攻击流程可以通过图 8 直观展示。


4.3.2 三步验证法

缓存投毒的验证远比 XSS 或开放重定向复杂, 因为验证器需要确认: 被投毒的内容确实被缓存了, 并且会影响其他正常访问。XBOW 团队设计了严谨的**三步验证法**:

阶段 1:



阶段 2:



阶段 3:




图 8: 缓存投毒攻击流程：从正常请求到投毒再到受害者受影响

缓存投毒三步验证法

1. **基线校准**：发送 10 次正常请求，确认目标页面稳定返回正常响应（如 HTTP 200）。这一步排除了页面本身不稳定的情况。
2. **投毒触发**：发送包含投毒值（如设置特定 HTTP 头）的请求，确认目标确实返回错误响应（如 HTTP 500）。
3. **缓存确认**：不再设置投毒值，发送普通请求访问同一页面。如果仍然返回错误页面，则证明投毒内容已被缓存。

仅当三个步骤全部通过时，才判定漏洞成立。

4.3.3 安全措施：随机缓存破坏器

防止误伤：随机 Cache Buster

在实际测试中，验证器使用随机的**缓存破坏器（Cache Buster）**——即在请求 URL 中添加随机查询参数（如 `?cb=a7f3b2`），确保每次测试访问的是缓存中的不同“槽位”。这样即使投毒成功，也只会影响这个随机构造的 URL，而不会影响真实用户正在访问的页面。这是对互联网负责任的安全研究实践。

4.3.4 实例：X-Forwarded-Host 投毒

演讲中展示了一个真实的缓存投毒案例：

1. **基线**：向目标站点发送正常请求，稳定返回 HTTP 200。

2. **投毒**：将 X-Forwarded-Host 头设置为 null byte (\0)，目标返回 HTTP 500。
3. **确认**：再次发送正常请求（不设 X-Forwarded-Host），仍然收到 HTTP 500——缓存的错误页面已取代了正常页面。

这一漏洞影响了多个网站，且在演讲时尚未修复，演讲中因此做了部分信息打码处理。

4.4 SQL 注入验证器（启发式）

SQL 注入验证器与前述验证器有一个关键区别：它属于**启发式验证**——虽然能将虚假阳性率降至很低，但无法做到绝对的零虚假阳性。

4.4.1 时序验证原理

SQL 注入的经典验证方法是**基于时间的盲注（Time-Based Blind Injection）**：

时序验证逻辑

模型需要提供两个 HTTP 请求：

- 请求 A：包含使得数据库休眠 1 秒的 SQL 注入载荷
- 请求 B：包含使得数据库休眠 5 秒的 SQL 注入载荷

验证器多次发送这两个请求，测量实际响应时间，并收集统计数据。如果请求 B 的响应时间确实比请求 A 长约 4 秒，且这种差异在统计上显著，则判定 SQL 注入漏洞成立。

$$\Delta t = \bar{t}_B - \bar{t}_A, \quad H_0 : \Delta t = 0, \quad H_1 : \Delta t \approx 4s$$

其中：

- $\bar{t}_A$ 和 $\bar{t}_B$ 分别为请求 A 和请求 B 的多次测量的平均响应时间
- H_0 为零假设（无时间差异）
- H_1 为备择假设（存在预期的约 4 秒时间差异）

验证器通过统计检验（如 t 检验）来判定时间差异是否显著。

4.4.2 相比 sqlmap 的优势

传统的 SQL 注入工具（如 sqlmap）同样支持时序验证，但 LLM Agent 在灵活性上具有显著优势：

非标准编码场景

在实际应用中，SQL 注入点可能隐藏在经过非标准编码的参数中——例如 Base64 编码的查询参数、JSON 嵌套字段、甚至自定义的序列化格式。sqlmap 的作者不可能预见所有编码方式，但 LLM 可以根据上下文理解编码逻辑，并自动将注入载荷适配到相应的编码格式中。例如：

```
1 import base64
2
3 # 原始参数: user_id=123
4 # sqlmap 无法直接处理 Base64 编码的参数
5 # LLM 可以自动适配:
6
7 # 1秒延迟载荷
8 payload_1s = "123'␣OR␣SLEEP(1)--"
9 param_1s = base64.b64encode(payload_1s.encode()).decode()
10
11 # 5秒延迟载荷
12 payload_5s = "123'␣OR␣SLEEP(5)--"
13 param_5s = base64.b64encode(payload_5s.encode()).decode()
14
15 # 验证器只需发送这些请求并测量时间
```

Listing 3: LLM 处理 Base64 编码参数的 SQL 注入

4.4.3 设计权衡：虚假阳性 vs 虚假阴性

每一类验证器都需要在虚假阳性率（FPR）和虚假阴性率（FNR）之间做出权衡。以任意文件读取漏洞为例：




图 9: 验证器设计的 FP/FN 权衡光谱

- **策略 A（高虚假阳性）：**要求模型提供一个 HTTP 请求，该请求直接返回 `/etc/passwd` 的内容。这种方式实现简单，但存在风险——某些 Web 应用（如 NAS 网络存储设备）的设计目的就是让用户读取服务器上的任意文件，此时就会产生虚假阳性。
- **策略 B（高虚假阴性）：**要求模型提供一个 Python 脚本，该脚本接受任意文件路径作为参数并返回文件内容。这种方式验证更加严格——它不仅证明了漏洞存在，还证明了漏洞是**可任意**

利用的，而非仅限于特定文件。但代价是模型可能发现了真实的漏洞，却在编写脚本这一步失败，导致虚假阴性。

这种权衡没有“正确”答案，需要根据具体场景（如 Bug Bounty 还是内部安全审计）来选择合适的策略。SQL 注入验证器同样遵循这一设计哲学：证据标准的严格程度直接影响 FP 与 FN 的平衡点。

4.5 为什么验证器有效

回顾整个验证器体系，一个核心问题是：为什么不让传统工具直接做这些验证步骤，而要借助 LLM？

验证器有效的核心原因

验证器的工作方式可以概括为：**指定证据格式，让 LLM 负责转化。**

具体而言，人类安全研究员定义每种漏洞类型所需的证据格式（如“两个不同延迟的 HTTP 请求”、“一个触发 alert 的 URL”），然后 LLM Agent 负责将它在具体场景中发现的漏洞，翻译（转化）为验证器能理解和检查的证据格式。

这种分工的关键优势在于**灵活性**：传统工具（如 sqlmap）只能处理预定义的输入格式，但 LLM 可以理解非标准编码、自定义协议、以及各种意料之外的参数传递方式，并将它们统一转化为验证器所需的标准格式。

如第三章所述，这一分工可以用公式表达。设漏洞类型为 V ，证据格式为 E_V ，目标应用为 T ：

$$\text{LLM} : T \times V \rightarrow E_V, \quad \text{Validator} : E_V \rightarrow \{0, 1\}$$

其中：

- $T \times V \rightarrow E_V$ 表示 LLM 将目标应用中的特定漏洞转化为验证器可接受的证据
- $E_V \rightarrow \{0, 1\}$ 表示验证器对证据进行确定性的二元判定

LLM 充当从 (T, V) 到证据 E_V 的灵活转化函数，而验证器是一个确定性的二元判定函数。两者各司其职：LLM 提供**创造力和适应性**，验证器提供**确定性和可信度**。




图 10: LLM 与验证器的分工协作：LLM 负责发现和转化，验证器负责确定性判定

典型案例鲜明地体现了这一点：当 SQL 注入参数被 Base64 编码时，LLM 能自行适配编码并将时序请求交给验证器；当 XSS 遭遇 WAF 拦截时，LLM 能生成五花八门的绕过 payload，而验证器只需坚守“必须触发 alert 或 console.table”这条底线。传统扫描器难以同时具备这两种能力。

4.6 本章小结

本章详细介绍了五类验证器的设计与实现：

1. **XSS 验证器**：通过无头浏览器检测 `alert/console.table` 触发，需要防范 LLM 的多种“作弊”手段。选择不常见的 `console` 方法是有效的对策。
2. **开放重定向验证器**：判定标准最清晰——起点为目标域名、终点为攻击者域名、无用户干预。实现简单可靠。
3. **缓存投毒验证器**：最复杂的验证器，采用三步验证法（基线校准 → 投毒触发 → 缓存确认），配合随机缓存破坏器防止误伤。
4. **SQL 注入验证器**：启发式验证，通过时序差异的统计证据判定漏洞存在，相比 `sqlmap` 的核心优势在于处理非标准编码的灵活性。
5. **验证器的有效性**源于 LLM 的灵活转化能力与确定性验证代码的可信判定的结合——“指定证据格式，让 LLM 负责转化”。

本章还揭示了两个重要的设计维度：验证信号的选择（如使用 `console.table` 而非 `console.log`）和 FP/FN 的权衡策略。这些设计选择直接决定了验证器在实际部署中的可靠性和实用性。

上述各类验证器构成了一个完整的方法论工具箱，但工具箱的价值终究需要在实战中检验。当这些验证器被应用于真实的开源生态、面对数以千万计的代码仓库时，它们是否依然能够保持零虚假阳性的承诺？第五章将介绍 XBOW 团队对 DockerHub 开展的大规模自动化扫描，用实证数据回答这一问题。

5 大规模自动化扫描与案例研究

当验证器体系就绪后，一个自然的问题是：如果把这套流程放到真实的开源生态中大规模运行，会发现什么？本章将介绍 XBOW 团队对 DockerHub 开展的自动化扫描——这是验证框架在实战中面临的最大考验。我们将看到，从数千万个仓库中筛选、部署、植入金丝雀、到多轮攻击测试，确定性验证如何让零虚假阳性的大规模漏洞发现成为现实。

5.1 DockerHub 大规模扫描流程

5.1.1 从 2500 万个仓库到实战目标

DockerHub 上托管了约 **2500 万个仓库**，显然不可能对每个仓库都发起攻击。研究团队设计了一条高度自动化的筛选与部署管道，将海量数据逐步浓缩为可攻击的目标集合。整个流程如图 11 所示。

5.1.2 特征工程与 LLM 分类

筛选过程结合了基础特征和 LLM（Claude 3.5 Sonnet）生成的语义特征。

最终，候选应用按 LLM 判定的“真实 Web 应用”概率得分排序，优先进入后续阶段。




图 11: DockerHub 大规模扫描自动化管道

表 1: DockerHub 筛选特征体系

层级	特征类型	具体说明
基础特征	镜像元数据	Pull count、Stars、最后更新时间、镜像大小
LLM 衍生特征	语义分类	内容是否看起来像真实 Web 应用？是否为成熟项目？威胁模型是否与想测试的攻击类型匹配？

5.1.3 自动化部署与源代码优势

对于筛选通过的目标，系统自动生成 `docker-compose` 文件并拉起容器。这里有一个关键优势：研究者可以直接把容器文件系统暴露给 Agent，让 Agent 同时执行源码审计与动态测试——这对漏洞发现效率的提升极为显著，后文 Redmine 案例将充分展示这一点。

扫描规模与阶段数据

表 2 汇总了从 DockerHub 到最终漏洞报告各阶段的核心数字。这些数字来自演讲者团队在 Black Hat USA 2025 上披露的实际运行结果。

表 2: DockerHub 扫描各阶段规模数据

阶段	指标	数量
DockerHub 仓库总量	初始数据源	~25,000,000
候选应用	经基础筛选后	~60,000
可成功部署并跑通	生成 docker-compose 后	17,151
进入进一步处理	包含源码暴露与后续步骤	39,096
进入最终攻击阶段	分别流入不同子集	4,244 / 2,804
每镜像每类漏洞攻击次数	文件读取/RCE、SQLi、XSS、SSRF	100

实战技巧: Use the Source, Luke

演讲者用三条实战建议总结了 DockerHub 扫描的关键经验:

1. **给 Agent 提供源码**: 容器文件系统可直接暴露源码, Agent 在源码分析上表现远优于纯黑盒测试。
2. **修改默认凭证**: 否则大量“漏洞”只是用默认 admin 密码登录, 并非真正的安全缺陷。
3. **仅暴露必要端口**: 模型擅长利用意外暴露的服务 (如 FastCGI), 多余的暴露面会带来噪音。

5.2 自动金丝雀部署

在容器部署完成后, 系统会根据目标应用的技术栈自动植入不同类型的金丝雀。

5.2.1 文件读取 / RCE 金丝雀

在 Dockerfile 中添加一行指令, 将一个包含 UUID 格式字符串的文件写入服务器文件系统 (通常位于 webroot 之外):

```
1 RUN echo "flag{uuid-random-string}" > /flag.txt
```

若 Agent 能读取该文件, 即证明存在任意文件读取或远程代码执行漏洞。

5.2.2 SSRF 金丝雀

在 Docker 内部网络中挂载一个独立 Web 服务器, flag 托管其上。Agent 若能诱使目标应用向该内部服务器发起请求并读取 flag, 即证明 SSRF 存在。

5.2.3 SQLi 金丝雀

自动枚举目标应用使用的数据库, 创建包含 flag 的新表。Agent 若能通过 SQL 注入读取该表内容, 即确认漏洞。

5.2.4 业务逻辑金丝雀

更高层的业务逻辑漏洞 (如授权绕过) 目前仍需手动设置。做法是在应用的私密区域 (其他用户的私密字段、admin-only 区域、隐藏资源) 植入 flag。这一模式的成本约为每个应用 1 小时, 却能触发更深层的漏洞路径, 后文 Redmine 案例即为一例。



Manual Flag-Planting (Business Logic)

- To search for higher-level vulnerabilities in a target, we can manually plant canaries within the app
- Plant them anywhere that attacker should not be able to view
 - Private profile fields of other users, hidden resources, admin-only areas, ...
- Rule of thumb: this applies to vulnerabilities that result in a violation of *confidentiality*

#BHUSA @BlackHatEvents

图 12: 自动金丝雀在 Docker 容器中的多种部署方式: 文件系统 flag、数据库 flag、内部网络 SSRF flag 及业务逻辑 flag

5.3 扫描成果

5.3.1 总体统计

经过大规模扫描与确定性验证，研究者取得了显著的实战成果，如表 3 所示。

表 3: DockerHub 扫描总体成果

指标	数量
已报告漏洞	174
已分配 CVE	22
待分配 CVE	154
仍在报告 backlogs 中	~650

演讲者特别指出：**最难自动化的部分不是发现漏洞，而是追踪维护者并提交报告。**这约 650 个 backlog 清楚地表明，规模化之后，人力瓶颈已从”漏洞发现”转移到了”漏洞披露”。

5.3.2 漏洞类型分布

表 4 给出了按漏洞类型分类的已报告漏洞占比。

XSS（尤其是 Reflected XSS）占据了近半壁江山，说明在 Web 应用中因未正确编码输出而导致的脚本注入仍然极为普遍。SSRF、RCE 和路径遍历等其他高危漏洞也占有可观比例。

5.3.3 代表性发现

在众多发现中，以下项目尤其具有代表性，如表 5 所示。

表 4: DockerHub 扫描漏洞类型分布

漏洞类型	占比
Reflected XSS	46.0%
Path Traversal	10.3%
Open Redirect	9.2%
SSRF	8.0%
RCE	6.3%
XXE	6.9%
File Read	3.4%
Stored XSS	5.7%
SSTI	1.1%
SQLi	0.6%

表 5: 部分代表性漏洞发现

项目	漏洞类型	说明
GeoServer	XXE	地理信息服务器中的 XML 外部实体注入
Apache HugeGraph	RCE	图数据库中的远程代码执行
PuppyGraph	RCE	另一图数据库引擎的 RCE
PDFTron	Path Traversal	PDF 处理库中的路径遍历
JSPWiki	XSS	知名 Wiki 引擎中的跨站脚本
Apache Tomcat	XSS	主流 Java Servlet 容器中的 XSS
Scoold	Auth bypass / SSRF bypass	授权绕过与 SSRF 绕过

5.4 案例研究：Redmine 授权绕过

在所有发现中，Redmine 的授权绕过漏洞是一个极具教育意义的案例——它完美展示了”手动金丝雀植入 + Agent 源码审计”的强大组合。

5.4.1 目标与金丝雀设置

Redmine 是一个用 Ruby on Rails 编写的流行项目管理系统。研究人员在其中 **手动植入了 6 个金丝雀**：

- 秘密项目的描述字段
- 私密用户资料字段
- 其他仅限特定角色访问的区域

整个设置过程仅花费约 **1 小时**——本质上就是在不同私密位置粘贴 CTF flag 字符串。

5.4.2 Agent 的分析路径

Agent 被赋予了对容器文件系统的访问权限，因此能够阅读 Redmine 的源代码。其分析路径如图 13 所示。




图 13: Redmine 授权绕过漏洞的发现流程

5.4.3 漏洞细节

Agent 的核心发现是：project_query_controller 中存在一个名为 admin_projects 的参数。当将其设置为 1 时，后端逻辑似乎会直接列出所有项目，**而不检查当前用户的访问权限**。

- **正常请求**: 不带 `admin_projects` 参数时, API 仅返回当前用户有权限查看的项目, 秘密项目不可见。
- **恶意请求**: 添加 `admin_projects=1` 后, API 返回了全部项目列表, 包括植入了金丝雀的秘密项目。

由于 Agent 不可能猜中 UUID 格式的 flag, 能够读取 flag 就意味着授权绕过漏洞 **确定性地存在**。该漏洞已被修复。

project management system

- We used manual canary planting to look for business logic vulnerabilities

Redmine Security Advisories					
Severity	Details	External references	Credits	Affected versions	Fixed versions
High	ProjectQuery leaks details of private projects (#42352)		XBOW Security Team	All prior releases since 5.1.0	6.0.4 and 5.1.7

图 14: Redmine 授权绕过漏洞已获修复的确认

5.5 其他案例 (简要)

5.5.1 Apache Druid SSRF (CVE-2025-27888)

Agent 在 Apache Druid 中发现了一个 SSRF 漏洞。根因在于目标 URL 是通过字符串拼接构造的:

```
http://druid/proxy/coordinator@internal-web/flag.txt
```

利用自动植入的 SSRF 金丝雀, Agent 成功让 Druid 向内部网络中的 flag 服务器发起请求并读取 flag, 最终获得 CVE-2025-27888。




图 15: Apache Druid SSRF 漏洞的自动化发现案例

5.5.2 MapProxy 任意文件读取

Agent 在基于 kartoza/mapproxy 镜像的部署中发现了任意文件读取漏洞，且该漏洞在线上真实主机中同样可被利用。关键载荷如下：

```
1 X-Forwarded-Proto: file://  
2 X-Forwarded-Host: ///flag.txt#.xml
```

负责任的披露边界

遗憾的是，MapProxy 的维护者在 90 多天里未对漏洞报告做出回应。演讲者最终在 Black Hat 现场向与会者进行了负责任的披露（responsibly disclosed in the room）。这反映了开源生态中漏洞响应速度与意愿的巨大差异。

BRIEFINGS

🏆 Trophy Case: File Read in MapProxy 🏆

- Agent discovered arbitrary file read in MapProxy demo app (using kartoza/mapproxy image)
- But exposed on real hosts in the wild!
- **The vuln:** set X-Forwarded-Proto to file:// and X-Forwarded-Host to ///flag.txt#.xml
- Unfortunately, no response from maintainers after 90 days...

图 16: MapProxy 任意文件读取漏洞的发现案例

5.6 本章小结

本章展示了确定性验证框架在大规模实战中的完整落地：

1. **规模：**从 DockerHub 约 2500 万个仓库出发，经过多层自动筛选与部署，最终对 17,151 个可运行的 Web 应用发起大规模攻击测试。
2. **自动化金丝雀：**文件系统、SSRF 和数据库金丝雀实现了全自动部署；业务逻辑金丝雀（如 Redmine 中的 6 个 flag）目前仍需少量人工配置，但性价比极高。
3. **成果：**174 个已报告漏洞（22 个已分配 CVE，154 个待分配），另有约 650 个真实漏洞因人力瓶颈滞留 backlog。虚假阳性为零。
4. **案例价值：**Redmine 授权绕过揭示了“金丝雀 + 源码审计”的深度潜力；Apache Druid 和 MapProxy 案例则展示了自动金丝雀在不同漏洞类型上的普适性。

一句话总结：当确定性验证与 LLM Agent 的灵活性结合后，大规模零虚假阳性漏洞发现已经从理论变为现实；现在真正的瓶颈不再是“是否能找到漏洞”，而是“如何以负责任的方式把它们全部报告出去”。

然而，零虚假阳性的大规模发现并不意味着这套框架完美无缺。在庆祝实战成果的同时，我们也需要冷静地审视这一方法论尚未跨越的边界。第六章将系统地讨论当前框架的三大核心局限——从预期行为导致的残余虚假阳性，到难以自动验证的业务逻辑漏洞，再到漏洞报告流程中显著的人力瓶颈。

6 局限性与未来方向

前五章展示了一条完整的路径：从虚假阳性问题的诊断（第一章），到统计学根基的剖析（第二章），到确定性验证框架的建立（第三章），到验证器的工程实现（第四章），再到大规模实战的检验（第五章）。然而，任何方法论若不能被置于批判性审视之下，便容易沦为教条。本章将坦诚地讨论当前框架仍然存在的局限，展望未来可能的突破方向，并提炼出对安全从业者与 AI 研究者最核心的启示。对这些局限的清醒认识，将为我们最终在第七章中收束全文、提炼可迁移的三元框架奠定基础。

6.1 当前局限性

6.1.1 预期行为导致的残余虚假阳性

确定性验证框架虽然将虚假阳性率压至极低，但并非绝对免疫。演讲者分享了一个令人哭笑不得的真实案例：

NAS Web 应用中的虚假阳性

当系统扫描一个网络附加存储（NAS, Network Attached Storage）Web 应用时，Agent 成功读取了服务器上的任意文件——包括金丝雀 `flag`。验证器基于“能读即确认”的逻辑，判定存在“任意文件读取漏洞”。然而，对于 NAS 应用而言，允许用户读取服务器硬盘上的“任意文件”正是其“预期行为”（intended behavior）。这意味着 Agent 发现的是一个合法功能，而非安全缺陷。

演讲者对此的自我调侃颇具意味：“我一开始想，这怎么可能？然后我看到——哦，原来这是一个 NAS Web 应用，你本来就应该能读取整个硬盘。好吧。”

这个案例揭示了一个深层次的问题：确定性验证可以判断“行为是否发生”，但无法判断该行为是否构成“安全违规”。后者需要对应用上下文的语义理解——而这正是当前自动化系统最不擅长的领域。用形式化的语言来表达，设 B 为“Agent 能够读取任意文件”这一行为， V 为“该行为构成安全漏洞”这一判定：

$$\text{Validator}(B) = 1 \not\Rightarrow V = 1$$

验证器能确定性地判定行为 B 发生，但从 B 的发生并不能自动推导出安全漏洞 V 的成立。这中间需要一个“上下文判断”（contextual judgment）的环节，而当前 LLM 在此类判断上仍然不可靠。

6.1.2 难以自动验证的漏洞类型

并非所有漏洞类型都适合确定性验证。目前框架覆盖较好的类别（XSS、Open Redirect、Cache Poisoning、SQLi、任意文件读取、SSRF）有一个共同特点：它们可以通过“可观测的技术行为”来定义。但安全领域中还存在另一类漏洞，其判定条件高度依赖“业务逻辑的语义理解”：

漏洞类型	自动验证的难点
IDOR（不安全的直接对象引用）	需要知道哪些对象是当前用户 不应该 访问的——这要求理解应用的授权模型
复杂业务逻辑漏洞	需要理解”正常”的业务流程是什么，以及当前行为如何偏离了预期
状态相关的授权绕过	需要精确定义”正常权限”与”越权”的边界，并追踪跨请求状态
竞态条件（Race Condition）	时序敏感，验证器本身的介入可能改变执行时序

核心矛盾

技术性漏洞的行为定义是 **** 与上下文无关 **** 的——无论在什么应用中，在目标域名上触发 `alert()` 都不应该发生。而业务逻辑漏洞的判定则是 **** 与上下文高度相关 **** 的：同样是”列出所有项目”，在公开项目管理工具中可能是正常行为，在 Redmine 中一旦涉及秘密项目，同样的请求路径就可能构成授权绕过。因此，Redmine 案例中的业务逻辑金丝雀需要 **** 手动植入 ****——人类研究者必须先理解应用的授权语义，才能在”应该不可见”的位置放置 flag，这种语义理解目前无法完全自动化。

6.1.3 报告与披露的人力瓶颈

演讲者分享了一个出人意料的数据：在约 824 个已确认的漏洞中，仅 174 个已经报告给维护者，剩余约 650 个待报告漏洞形成了严重的人力积压（见图 17）。




图 17: 漏洞报告进度：瓶颈不在于发现，而在于报告

瓶颈的根源主要不在于技术层面，而在于 **** 社会工程 **** 层面：

1. **寻找维护者**：对于 DockerHub 上的众多项目，确定其正确的安全联系方式本身就是一项耗时的任务，许多项目甚至缺乏明确的漏洞披露政策（VDP）。
2. **跟踪流程**：即使联系上了维护者，后续的沟通、确认、修复验证等环节都需要持续的人力投入。
3. **维护者响应差异**：如第五章中 MapProxy 的案例所示，部分维护者在 90 天以上未做出任何回应，使得漏洞报告流程陷入停滞；演讲者不得不在 Black Hat 现场进行”responsibly disclosed in the room”。

自动化发现与人工报告之间的不对称性

这个瓶颈揭示了一个重要的不对称性：AI Agent 可以在数小时内扫描数万个应用并发现数百个漏洞，但将这些发现转化为负责任的安全报告却需要远超这个时间的人力投入。在可预见的未来，安全社区的挑战可能从”如何发现漏洞”转向”如何高效地负责任披露漏洞”。

6.2 未来方向

6.2.1 自动金丝雀植入 Agent

当前，业务逻辑金丝雀的植入是整个流程中最需要人工参与的环节（如 Redmine 案例中的约 1 小时手动配置）。演讲者暗示了一个令人兴奋的未来方向：让 AI Agent 自身来完成金丝雀的智能植入。

设想的流程如下：

1. Agent 首先以“探索者”身份分析目标应用，理解其功能、角色体系和访问控制模型；
2. Agent 识别出“哪些信息是哪些用户不应该看到的”——即潜在的机密性边界；
3. Agent 在这些边界位置自动植入金丝雀字符串；
4. Agent 切换为“攻击者”身份，尝试突破这些边界。

如果这一方向能够实现，其影响将是深远的：它将把业务逻辑漏洞的发现从“需要人工理解应用”推进到“Agent 自主理解应用并构造验证条件”，从而大幅扩展自动化漏洞发现所能覆盖的漏洞类型范围。

6.2.2 LLM 自我验证能力的提升

演讲者特别提到了一个值得关注的技术趋势：就在演讲前不久，Google 和 OpenAI 分别在国际数学奥林匹克（IMO）中达到了金牌水平，且这一成绩是通过 ** 语言模型自我审查和批评自身输出 ** 实现的，而非依赖外部定理证明器。

从外部验证到内部验证的范式迁移

当前的确定性验证框架采用“外部验证”范式——LLM 负责发现漏洞，非 AI 代码负责验证。如果 LLM 的推理和自我纠错能力持续提升 to 足够可靠的水平，未来可能进入“内部验证”范式——LLM 自身就能可靠地区分真实漏洞与虚假发现。然而，这种迁移的前提是 LLM 在安全领域的判断准确率能够达到与数学推理相当的水平。当前证据表明，这一目标距离实现仍有显著差距——安全领域的上下文依赖性、对抗性和噪声远高于数学推理的封闭公理系统。

用第三章中引入的符号来表达，当前方案和未来可能的方案可以对比为：

$$\underbrace{\text{LLM} : T \times V \rightarrow E_V}_{\text{当前：LLM 转化}} \times \underbrace{\text{Validator} : E_V \rightarrow \{0,1\}}_{\text{当前：确定性验证}}$$
$$\underbrace{\text{LLM}^+ : T \times V \rightarrow \{0,1\}}_{\text{未来?：LLM 自主验证}}$$

其中 T 为目标应用， V 为漏洞类型， E_V 为证据格式， LLM^+ 代表具备可靠自我验证能力的下一代模型。但演讲者反复强调，至少在当前阶段，他仍然强烈推荐外部确定性验证。

6.2.3 扩展更多漏洞类型的确定性验证

当前的验证器覆盖了 XSS、Open Redirect、Cache Poisoning、SQL 注入、任意文件读取、SSRF 等主要类型，但还有更多类别可以扩展：

- **服务端模板注入 (SSTI)**：通过检测模板引擎是否执行了攻击者控制的代码来验证。
- **XML 外部实体注入 (XXE)**：通过是否能读取到金丝雀文件来验证（第五章中 GeoServer 案例已体现这一逻辑）。
- **反序列化漏洞**：通过检测是否能触发预定的类加载行为或网络请求来验证。
- **HTTP 请求走私**：通过检测请求边界解析的不一致性来验证。

每种新的漏洞类型都需要设计相应的证据格式和验证逻辑，这是验证器工程持续扩展的方向。演讲中 XBOW 团队已经在 HackerOne 美国区 #1 的实战中验证了 Q3 + Q4 组合的有效性，将更多漏洞类型从 Q4（启发式）推进到 Q3（确定性）将是未来的主要技术目标。

6.3 核心启示

综合前述的局限与未来方向，可以提炼出三条对安全从业者和 AI 研究者最核心的启示。

6.3.1 不要信任 LLM 的漏洞声明

这是整场演讲最核心的信息。无论 LLM 的报告看起来多么专业、多么有说服力，在没有 ** 外部验证 ** 的情况下，其漏洞声明不应被视为可信。

curl 悲剧的再审视

回顾第一章中 curl 开发者 Daniel Stenberg 的遭遇：HackerOne 上公开披露的安全报告中，约三分之二是关于 curl 的虚假阳性。这些报告措辞专业、论理清晰，但漏洞完全不存在。这正是”不信任 LLM 漏洞声明”这一启示的现实注脚——虚假阳性的危害不仅在于浪费审核资源，更在于 ** 侵蚀安全报告生态的信任基础 **。

6.3.2 确定性验证是规模化的关键

单独使用 LLM 发现漏洞并不可靠，但将 LLM 的 ** 探索能力 ** 与确定性验证器的 ** 判定能力 ** 结合，就能实现大规模的零虚假阳性漏洞发现。第五章的 DockerHub 扫描结果（174 个已报告漏洞、22 个 CVE、154 个 pending、零虚假阳性）有力地证明了这一点。

关键公式回顾：

$$\underbrace{\text{LLM 的灵活性}}_{\text{探索 + 转化}} + \underbrace{\text{确定性验证}}_{\text{可信判定}} = \underbrace{\text{规模化零虚假阳性}}_{\text{核心成果}}$$

6.3.3 CTF 化思维的工程价值

CTF（夺旗赛）的核心特征是：每个挑战都有一个确定存在的答案（flag），参赛者需要找到它。将这一思维应用到安全研究中，即”在系统中植入 flag，然后让 Agent 去找”，带来了三重收益：

1. **确定性验证**：UUID 不可能被猜中，读取 flag 即确认漏洞存在；

2. **动机工程**：知道 flag 一定存在，Agent 会更加努力地探索，克服了 LLM “不知道何时该停止努力” 的弱点；
3. **可扩展性**：flag 可以自动化地植入文件系统、数据库、内部网络等多种位置，覆盖多种漏洞类型。

从学术研究到工程实践

CTF 化思维并非 XBOW 团队的原创——安全社区长期使用“旗标”来验证漏洞利用的完成。但 XBOW 的独特贡献在于将这一思维 **系统化** 和 **工程化**：不是在单个 CTF 挑战中使用旗标，而是将其作为大规模自动化漏洞发现流水线的核心组件。这种从“教育工具”到“工程方法”的转化，具有深远的实践意义。

6.4 本章小结

本章审视了确定性验证框架的三大局限：NAS 类应用中“预期行为”导致的虚假阳性残余、IDOR 和业务逻辑漏洞等需要上下文语义理解的类型难以自动化、以及漏洞报告流程中显著的人力瓶颈。

未来方向包括：让 Agent 自动植入业务逻辑金丝雀、LLM 自我验证能力的潜在提升（如 IMO 金牌进展所示）、以及将更多漏洞类型纳入确定性验证覆盖。三条核心启示贯穿始终：不信任 LLM 的漏洞声明；确定性验证是实现规模化零虚假阳性的关键；CTF 化思维从竞赛游戏到工程方法的转化具有深远的实践价值。

这些局限和启示共同构成了对整场演讲方法论的现实评估——它不是万能药，但在当前技术条件下，代表了 AI 驱动安全研究最务实、最可靠的前进方向。面向这些局限与未来方向，我们可以将全篇演讲的核心思想提炼为一个可迁移、可实践的三元框架，这将在下一章——也是最后一章——中进行收束与升华。

7 总结与延伸

本章从三个层面收束全文：复现演讲者本人的核心总结，由笔记作者提供跨章节的结构化综合，最后给出可直接应用于实践的要点与值得持续探索的开放问题。

7.1 演讲者核心总结

7.1.1 致谢与团队贡献

Dolan-Gavitt 在演讲的最后特意致谢了 XBOW 团队的全体成员。他坦言：“Black Hat 只允许一两个人上台，但这实际上是一个巨大的团队努力（a large group effort）。”多位团队成员坐在观众席中，完成了验证器开发、Agent 架构设计、大规模扫描基础设施搭建等核心工作。演讲中展示的每一项成果——从验证器到 CVE——都是多人协作的产物。

7.1.2 核心论点

演讲者将整场演讲的核心论点浓缩为一句话：

确定性验证 + AI Agent

具体而言：

1. 不要信任 LLM 的漏洞声明——它们会”幻觉”出看起来很有说服力但完全不存在的漏洞；
2. 通过确定性验证（金丝雀或证据验证），可以将漏洞确认从”AI 判断”提升到”数学确定”；
3. 一旦解决了虚假阳性问题，AI Agent 的强大探索能力就可以被放心地规模化部署；
4. 实战成果证明了这一方法论的可行性：HackerOne 美国排名第一、174 个已报告漏洞、22 个 CVE。

演讲者同时保持了学术的审慎态度。他明确指出当前的方案并非万能药（not a panacea），仍有 NAS 误判、业务逻辑漏洞难以自动化等局限性。他的结论是：尽管存在局限，确定性验证所提供的可信度提升，足以让 AI 驱动的安全研究从一个”有趣但不可靠的想法”转变为一个”可规模化部署的工程实践”。

7.2 笔记作者的延伸综合

7.2.1 三元概念框架：CTF 思维 × 确定性验证 × LLM 灵活性

纵观全篇演讲，笔记作者认为其方法论可以被压缩为一个 ** 三元框架 **（Triad Framework），三个顶点分别代表：

1. **CTF 思维**：将安全研究问题转化为”旗标一定存在，Agent 需要找到它”的结构化挑战；
2. **确定性验证**：使用非 AI 的程序化代码对漏洞证据进行二元判定，消除 AI 判断中的不确定性；
3. **LLM 灵活性**：利用大语言模型的强大适应能力，处理非标准编码、复杂上下文和多样化攻击面。

这三者缺一不可：

- 仅有 CTF 思维 + 确定性验证，但没有 LLM 灵活性，系统将退化为传统的自动化扫描工具（如 sqlmap），无法处理 base64 编码参数、WAF 绕过等非标准场景；
- 仅有确定性验证 + LLM 灵活性，但没有 CTF 思维，Agent 可能会过早放弃探索——因为它不知道漏洞是否真的存在，无法判断”何时该停止努力”；
- 仅有 CTF 思维 + LLM 灵活性，但没有确定性验证，系统将退化为不可信的 AI 漏洞报告生成器——正是第一章所描述的 curl 悲剧困境。

三元框架的中心——”零虚假阳性规模化漏洞发现”——是三者协同效应的产物，而非任何一个顶点的单独贡献。




图 18: 安全研究三元框架：CTF 思维 × 确定性验证 × LLM 灵活性

7.2.2 跨章节递进逻辑

从宏观视角审视，七章内容构成了一个严密的递进结构：

1. **问题诊断**（第一章）：虚假阳性是 AI 安全研究的核心困境——curl 开发者的遭遇是缩影。Agent 方案也无法解决，因为”自己给自己打分”不可靠。
2. **理论根基**（第二章）：基础率谬误从统计学上解释了为什么虚假阳性在安全检测中几乎不可避免——即使检测器准确率高达 99%，当漏洞先验概率极低时，阳性结果中绝大多数仍是虚假的。
3. **方法论框架**（第三章）：提出两大核心工具——金丝雀（CTF 旗标式验证）和确定性证据验证——以及四象限验证器空间的概念模型。
4. **工程实现**（第四章）：将方法论转化为可运行的验证器——XSS、Open Redirect、Cache Poisoning、SQL 注入，每个都有具体的设计原理、实现细节和防”作弊”教训。
5. **大规模验证**（第五章）：在 DockerHub 上扫描约 60,000 个候选应用，发现 174 个漏洞、22 个 CVE，以实证数据证明了方法论的有效性。
6. **局限与反思**（第六章）：坦诚审视 NAS 虚假阳性、业务逻辑难以自动化、报告瓶颈等局限，同时展望 Agent 自动植入金丝雀、LLM 自我验证提升等未来方向。

这条路径的核心逻辑线可以概括为：

为什么虚假阳性不可避免 → 如何用确定性验证消除它 → 大规模实战是否有效 → 还有多远要走

第 1-2 章 第 3-4 章 第 5 章 第 6 章

7.2.3 更广泛的启示：AI 安全工具的可信度依赖外部验证

本演讲的方法论对整个 AI 安全领域有一个超越具体技术细节的深层启示：**AI 安全工具的可信度不应建立在模型自身的判断之上，而应建立在外部可验证的证据之上。**

这一原则不仅适用于漏洞发现，还可以推广到 AI 驱动的安全分析的诸多领域：

- **恶意软件检测**：AI 可以标记可疑文件，但最终判定应基于沙箱执行、签名匹配等确定性证据。
- **威胁狩猎**：AI 可以建议调查方向，但结论应基于日志分析、网络流量分析等可审计的发现。
- **合规审计**：AI 可以辅助审查配置，但违规判定应基于对配置文件的确定性规则检查。

可验证 AI 的哲学

这一思路与“可验证计算”（Verifiable Computing）的哲学一脉相承：不要求计算过程完全可信，但要求计算结果可以被高效验证。在安全领域，这意味着我们可以放心地利用 LLM 的强大能力——只要在关键判定环节保留一层确定性的外部验证。

7.3 实践要点与开放问题

7.3.1 实践要点总结

对于希望将本演讲方法论应用于实践的安全从业者，以下是核心行动要点：

1. **始终要求确定性证据**：无论使用何种 AI 工具进行漏洞发现，都应设计独立的验证机制来确认 AI 的发现。不要接受“看起来合理”的漏洞报告。
2. **设计验证信号时考虑对抗性**：如第四章中 XSS 验证器的教训所示，验证信号（如 `console.table`）必须足够独特，使得 LLM 无法利用应用的正常行为来伪造证据。
3. **在 FP 与 FN 之间做出有意识的权衡**：根据应用场景选择合适的验证策略。Bug Bounty 场景可能偏向低 FP（宁可虚假阴性也不虚假阳性），内部审计场景可能偏向低 FN（宁可虚假阳性也不虚假阴性）。
4. **给 Agent 提供源码能显著提升效果**：如第五章 DockerHub 实战所示，“Use the Source, Luke”——将容器文件系统暴露给 Agent，使其在源码分析中表现更佳。
5. **修改默认密码、控制暴露面**：避免大量“伪漏洞”只是用默认 admin 密码登录，而非真正的安全缺陷。
6. **负责任地披露**：发现漏洞后，负责任披露流程（包括随机 cache buster 等安全措施）与漏洞发现本身同等重要。

7.3.2 开放问题

本演讲留下了一些值得持续关注和探索的开放问题：

IDOR 与业务逻辑的自动化验证路径

当前框架最大的开放问题之一是：如何为 IDOR 和不安全直接对象引用等漏洞类型设计自动化验证器？这类漏洞的核心特征是“用户访问了不应该访问的对象”，而判定“不应该访问”需要理解应用的授权语义。可能的路径包括：

- 让 Agent 自动学习应用的授权模型（通过分析源码或 API 行为）
- 基于角色矩阵（Role Matrix）自动生成授权约束
- 利用差分测试（Differential Testing）——比较不同角色用户看到的信息差异

此外，以下问题也值得进一步探讨：

- 当 LLM 的自我验证能力达到足够水平时，确定性验证框架是否仍然必要？还是两者将长期共存互补？
- 如何将大规模漏洞发现与维护者社区的建设结合起来，解决“发现容易、报告困难”的不对称性？
- 验证器本身是否可能成为攻击面——攻击者是否可以通过精心构造的输出来欺骗验证器？

7.3.3 下一步推荐：Defcon Bug Bounty Village

演讲者在最后提到，如果听众希望了解更多关于 Bug Bounty 实战中的细节——尤其是不再需要目标配合的验证器类型——可以关注 Joel 和 Diego 在 Defcon Bug Bounty Village 的演讲。正如演讲者所言：“我在这里试图做到名副其实——演讲标题承诺零虚假阳性，所以我主要聚焦于确定性验证的部分。但我们也确实有一些启发式验证器，它们的虚假阳性率略高但仍然很低，感兴趣的人可以去那里了解更多。”

这标志着从 Black Hat 的 ** 方法论舞台 ** 到 Defcon 的 ** 实战前线 ** 的自然延伸——方法论在学术殿堂中被提出和论证，然后在黑客社区的实战环境中被检验和迭代。对于安全研究者而言，同时关注这两个维度——理论框架的严谨性与实战应用的灵活性——将是把握 AI 安全研究前沿的关键。