

课程笔记

Anthropic | Chris Olah 使用机制可解释性研究 神经网络的内部结构

至高机器学习 & Codex

2026 年 5 月 31 日



视频作者 / 频道：至高机器学习

发布日期：未在本次元数据中提供

视频时长：00:38:25

视频链接：<https://www.bilibili.com/video/BV1p8oTBNEgB/>

字幕来源：Bilibili AI 中文字幕（平台未提供可下载英文字幕轨）

目录

1 引子：怀疑、目标与叠加挑战2

2 从参数到“源代码”：机制可解释性的任务3

3 视觉模型里的三件事：特征、权重与电路6

4 叠加：多语义神经元背后的压缩几何10

5 Transformer 的特殊机制：残差流、注意力特征与归纳头14

6 安全主张需要什么：覆盖特征、排除电路、扩大规模18

7 梯度下降生成的精妙结构21

8 问答一：隐含模块化与视觉模型分支24

9 问答二：特征定义、代码含义与人工神经科学优势27

10 问答三：语言模型为何更难，以及仍未知的问题29

11 总结与延伸：从显微镜到安全证据32

阅读约定与术语速查

这份笔记把视频内容整理成三条线索：先看研究目标和可信度标准，再看视觉网络与 Transformer 中已经找到的结构，最后回到叠加和安全覆盖。正文中的“特征”先按候选计算单元来读：它可能是单个神经元，也可能是激活空间中的方向或线性组合；在可靠案例中，它会被输入样本、权重连接、干预结果和上下游电路共同约束。Olah 在问答中明确保留了定义问题，因此这里的速查只给阅读入口，不给最终判准。“电路”指多个特征、权重和注意力头组成的可复用计算路径。

术语	阅读时的含义
机制可解释性	把神经网络当作可拆解的计算系统，追问内部哪一组结构在产生特定行为。
特征与方向	特征常被表示为激活空间中的方向；若输入沿该方向激活更强，模型在相关行为上通常会更敏感。
叠加	多个稀疏特征共享同一组神经元或维度，形成压缩表示，也增加读出难度。
电路	特征之间通过权重、非线性层、残差流或注意力头连接起来后的计算链条。
安全覆盖	安全解释需要覆盖隐藏特征、参与电路和触发条件，单个显眼案例只能作为证据入口。

1 引子：怀疑、目标与叠加挑战

1.1 这场演讲从怀疑开始

Chris Olah 的开场并没有急着展示漂亮的电路图。他先交代了一个更尴尬、也更重要的背景：几年前，一位合作多年的同事曾经非常直接地告诉他，这类研究“全是垃圾”。这句话在演讲中被保留下来，因为它点出了机制可解释性（mechanistic interpretability）面对的真实处境：很多人并非只是不熟悉这项工作，他们对它的科学性、可扩展性和安全价值有根本怀疑。

Olah 没有试图在一场讲座里把所有怀疑者一次性说服。他的态度更接近研究者之间的开放审查：如果听众对这类工作持怀疑态度，他愿意在办公时间里专门讨论疑虑，看看双方能否更接近事实。这一点很关键。机制可解释性不是靠口号获得信用，它需要用具体电路、可重复实验、因果干预和数学结构逐步赢得可信度。

不要把怀疑当成无知

本讲开头的怀疑并不是铺垫情绪，它是整场演讲的压力测试。一个可解释性研究方案如果只能解释少量漂亮案例，却无法面对“这些解释是否真实”“能否扩展到大模型”“能否服务安全判断”等问题，就还没有到达 Olah 关心的标准。

1.2 三件事：入门、可信度、核心挑战

Olah 给听众安排了三条主线。

第一条主线是快速介绍机制可解释性。现场听众来自不同方向，并非每个人都熟悉这个领域，因此他会先建立一个直观入口：研究者希望理解神经网络内部到底在执行什么计算，而不只是在外部观察输入输出行为。

第二条主线是讨论这项工作的程度和可信度。所谓“程度”，可以理解为两个问题：现在到底理解到了什么层级？这些理解是幻觉式命名，还是经得起干预和验证的结构？这条线会在后面的视觉模型例子中展开：如果一个神经元被称为“曲线检测器”，研究者需要说明它为什么真能被这样理解，而不是只展示一张看起来像曲线的图片。

第三条主线是叠加（superposition）这个挑战。Olah 明确说，叠加关系到机制可解释性对 AI 安全影响的上限与下限。他认为这是核心问题，并且值得投入时间：一方面它重要，另一方面它并不必然需要极大的计算资源，还拥有丰富的数学结构。

开场的真正议程

这场演讲不是“可解释性很好，所以大家应该相信”。更准确地说，它提出一个研究任务：先展示神经网络内部确实存在可理解结构，再承认这些结构会被叠加等现象隐藏，最后讨论这种理解能否支撑安全相关的强声明。

1.3 为什么叠加会被放在开场

如果只从外部行为看模型，研究者通常能问的问题是“模型在这个测试集上表现如何”。机制可解释性想问的问题更尖锐：模型内部是否存在某个会导致危险行为的结构？这种结构在什么条件下被激活？它与其他结构如何连接？

叠加之所以在开场就被点名，是因为它会妨碍这类内部审查。Olah 在这里只做预告，没有展开数学细节：如果模型把多个计算对象混在同一组神经元或方向里，那么研究者看到的单个神经元就可能是混合物。混合物会让“我没有看到危险特征”这种说法变得非常脆弱，因为危险方向

可能藏在低频、低激活、未被命名的空间里。

这里可以先用一个类比抓住直觉：如果一份软件只有二进制文件，没有源代码，逆向工程已经很难；如果这个二进制还把多个模块的逻辑压缩、交织、复用到同一段机器指令里，难度会再上一个台阶。叠加就是神经网络语境里的这种压缩与交织问题。具体机制留到后续章节展开，本节只强调它为什么配得上开场位置。

读者可能忽略的一点：安全问题需要“全称”证据

很多机器学习评估给出的是样本级证据：某些输入上模型表现良好。安全问题常常需要更强的全称说法，例如“在所有相关情境中，模型不会故意执行某类行为”。机制可解释性之所以被寄予希望，是因为它可能从内部机制层面支持这种说法；叠加之所以危险，是因为它会让内部机制覆盖变得不完整。

1.4 本章小结

本节的重点是把演讲的姿态摆正。Olah 的起点不是一个已经被证明成熟的技术栈；他的起点是怀疑、可验证性和安全压力。他承诺介绍机制可解释性的基本图景，也会展示这项工作已经取得的具体进展；同时，他把叠加列为核心挑战，因为它直接影响研究者能否真正看清模型内部结构。

接下来，第二节会正式进入机制可解释性的核心类比：常规软件有规划、源代码和二进制，而神经网络训练常常从目标函数直接抵达参数。机制可解释性的任务，就是试图找回中间那层“类源代码”的结构。

2 从参数到“源代码”：机制可解释性的任务

2.1 软件工程类比：缺失的中间层

Olah 对机制可解释性（mechanistic interpretability）的三十秒介绍，核心是一张软件工程类比图。

在常规软件工程中，人类通常先有规划文档、目标说明或设计文档，然后编写源代码（source code），再把源代码编译成二进制文件（binary）。二进制可以运行，但它不是人类最适合阅读和修改的表达形式；源代码才是工程师理解系统结构、定位问题、做出修改的主要媒介。

神经网络的训练流程缺少这一层。研究者设定优化目标，训练过程把目标转化为一组参数，最后得到训练好的网络。中间没有一个天然出现、可以被人类阅读的“源代码文件”。因此，机制可解释性的目标可以说成：把训练后的神经网络参数，逆向工程成类似源代码的计算结构。

机制可解释性的任务边界

机制可解释性要恢复的是“类源代码解释”（source-code-like explanation）：变量是什么，状态如何流动，哪些权重在执行类似指令的作用，局部计算如何组合成更大的例程。它不是保证当前已经理解每个参数，也不是把模型翻译成一份真正的 Python 程序。

2.2 变量、状态、架构、参数的对应关系

这个类比之所以深刻，是因为它不只是“神经网络像程序”这样一句空泛说法。Olah 逐项给出对应关系。




图 1: Olah 用软件工程管线对应神经网络训练管线：变量、状态、架构和参数都有对应物，但神经网络缺少天然可读的源代码层。（视频画面时间区间：00:02:20–00:03:25。）

计算机程序有变量。神经网络里，变量的候选对象可能是神经元，也可能是由多个神经元线性组合出来的特征方向。这里先只保留这个入口：模型内部确实有一些可被追踪的量，它们在不同输入下取不同值，并参与后续计算。

计算机程序有运行时状态。神经网络的对应物是激活值（activation）：给定一个输入后，某一层、某个神经元或某组内部表示产生的数值。状态不是写在参数文件里的静态东西，它是在模型运行时被具体输入激发出来的中间结果。

计算机程序运行在处理器或虚拟机上。神经网络的对应物是架构（architecture）：卷积层、残差连接、注意力头、MLP 等结构规定了信息能怎样流动。架构像一套“可执行格式”的规则，决定参数和激活值如何发生相互作用。

最后，编译产物的二进制文件对应训练后的参数（parameter / weight）。参数是学习得到的数字，它们承载了模型从数据中学到的结构，但单独看一串数字通常无法直接读出语义。

一个最小的形式化写法可以帮助定位这些对象：

$$f_{\theta}(x) \rightarrow h^{(\ell)}(x), \quad a_i^{(\ell)}(x)$$

其中， x 表示输入； f_{θ} 表示参数为 θ 的训练后网络； θ 是所有学习到的参数； $h^{(\ell)}(x)$ 表示第 ℓ 层的整体隐藏激活向量； $a_i^{(\ell)}(x)$ 表示第 ℓ 层第 i 个单元在输入 x 下的激活值。这个公式不负责解释模型，它只是给后文的“参数、激活、变量候选”提供坐标系。

二进制类比为什么有用

二进制文件并非毫无结构，它当然由真实指令组成；问题在于人类很难直接从二进制读出设计意图。神经网络参数也类似：它们不是随机噪声，训练已经把大量结构写进去了；困难在于这些结构没有自动以人类友好的源代码形式出现。

2.3 中间地带：困难，但不自动等于不可能

Olah 随后反对一种常见二分：可解释性要么应该简单，要么完全不可能。他认为这两个极端都不对。更合理的位置是“极其困难，但可能存在可推进的中间地带”。

他用逆向工程 Linux 内核作类比：如果研究者面对一个庞大复杂的程序，而且事先不了解它的源代码，逆向工程会非常艰巨。这个艰巨性没有推出“绝无可能”。同样，生物学理解细胞也极难，但没有人会因为细胞复杂就放弃研究细胞。复杂系统研究常常处在一个不舒服的位置：不能指望一步到位，也不能把困难直接当成失败证明。

这就引出机制可解释性的局部到整体策略。完全理解整个神经网络是非常高的目标；更实际的方式是先理解小部分，再把这些小部分严谨地扩展成较大的模块。这里的“严谨”很重要：不能只给神经元起名字，还要验证这些名字是否对应可复现、可干预、能解释上下游权重的内部对象。

常见误解：会命名不等于会解释

把一个神经元叫作“汽车检测器”只是起点。机制解释还要说明：这个检测器从哪些前置特征得到证据，哪些权重支持或抑制它，它在后续计算中触发什么，以及这些关系能否被干预实验或重写实验检验。

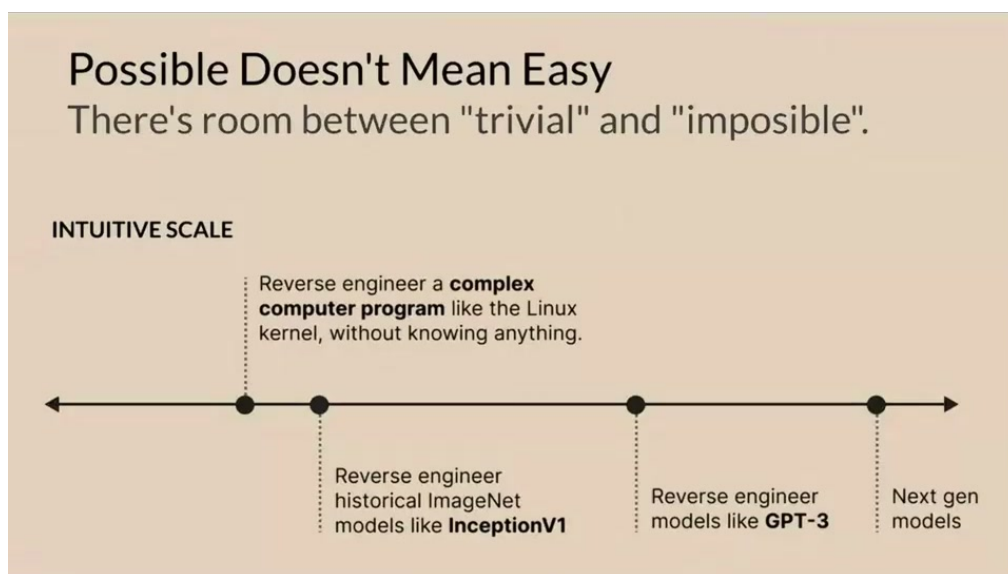


图 2：“可能”并不等于“容易”：Olah 把逆向工程 Inception-v1、GPT-3 和下一代模型放在同一条难度尺度上，强调研究要在轻率乐观与直接放弃之间推进。（视频画面时间区间：00:03:31–00:05:27。）

2.4 从局部结构走向全局理解

第二节的核心结论可以压缩为一句话：机制可解释性是一种逆向工程训练后网络的研究计划。它承认参数层面真实存在计算结构，也承认这些结构不会自动以清晰源码形式呈现。

这条路线有两个实践含义。

第一，研究者要先找到可稳定讨论的内部对象。后文会在视觉模型中看到三类对象：特征、权重和电路。它们分别对应“变量名”“连接关系”和“组合起来的程序片段”。这个说法在本节只是承接软件类比，具体定义和例子由第三节承担。

第二，研究者要接受逐层推进。先理解曲线检测器、边缘检测器、车窗和车轮如何共同支持汽车检测，再追问这些对象在更大网络和更复杂任务中如何组合。这个路线听起来慢，但它比直接宣布“整个模型已经解释完毕”更诚实。

2.5 本章小结

本节正式界定了机制可解释性的目标：从训练后参数中恢复类源代码的计算结构。Olah 的软件类比给出四个对应点：变量对应神经元或特征方向，状态对应激活值，处理器或虚拟机对应网络架构，二进制对应训练后的参数。

更重要的是，他把这项工作放在“困难但可推进”的中间地带。研究者不应期待轻松读懂整个模型，也不必因为复杂性直接放弃。下一节会进入这条路线的具体样本：视觉模型中的特征、权重和电路。

3 视觉模型里的三件事：特征、权重与电路

3.1 为什么从视觉模型开始

在建立“找回类源代码”的目标之后，Olah 选择从视觉模型讲起。原因很实际：视觉模型中的许多内部对象更容易被人类观察、命名和验证。图像里有边缘、曲线、颜色对比、车窗、车轮、动物头部等结构，研究者可以把神经元激活、权重连接和输入图像联系起来，逐步追踪模型内部的计算。

他把视觉模型中的机制对象分为三类：特征（feature）、权重（weight）和电路（circuit）。在这些视觉案例里，可以先把特征当作模型表示的某种有计算意义的属性，例如汽车检测器、曲线检测器、边缘检测器、垂耳检测器；严格边界会在叠加与问答部分再收紧。权重连接这些特征，让一个对象的出现支持或抑制另一个对象。电路则是特征与权重组合起来执行的可识别计算。

视觉模型的三件事

特征像变量，权重像带有上下文的指令，电路像由多条指令组成的小程序。只有三者放在一起，研究者才开始看到“源代码感”：某些输入属性被表示出来，连接关系把这些属性组合起来，最终形成更高层的判断。




图 3：视觉模型案例把机制可解释性的对象压缩成三类：特征提供可命名的内部变量，权重连接这些变量，电路把连接关系组合成可识别计算。（视频画面时间区间：00:06:01–00:06:27。）

3.2 特征：从曲线检测器到可验证对象

Olah 首先举 Inception-v1 的曲线检测器例子。研究团队在 Inception-v1 中发现大量曲线检测器，并且他说，这类检测器出现在他们研究过的每个视觉模型里。它们大致寻找曲线，但这里的重点不是“看起来像曲线”。

他强调这些曲线检测器经过严格验证，团队甚至写了两篇只讨论曲线检测器的论文。他们做了各种测试，证明这些单元确实承担曲线检测功能；更进一步，他们能够基于理解重写整个电路，再把它植回去。这种“能重写、能植回”的说法很重，因为它把解释从图像命名推进到因果控制：如果研究者真的理解了一个部件，就应该能预测它被改动后的影响。

特征可视化不是终点

许多特征图像来自输入优化（input optimization）：从随机噪声开始调整像素，让目标神经元激活最大化。这样的图像很适合给神经元起变量名，但变量名本身不是最终证明。可靠解释还需要数据集示例、消融、干预、重写等多种证据配合。




图 4：曲线检测器的可信度来自多种验证信号：特征可视化、数据集样例、合成样例、联合调谐、实现方式、用途和手写电路共同约束同一个解释。（视频画面时间区间：00:06:27–00:07:00。）

3.3 权重：单独看数字没有意义，放回语境才像指令

接着，Olah 转向权重。卷积层中的权重带有空间结构：它们不是普通列表；它们像网格一样对应相对位置。一个输入特征在左上、右侧、下方，可能对输出特征有不同作用。这就是感受野（receptive field）和空间偏移重要的原因。

可以用一个简化记号表达卷积权重的空间含义：

$K_{\Delta x, \Delta y}$ ：输入特征在相对偏移 $(\Delta x, \Delta y)$ 处对输出特征的影响

其中， $K_{\Delta x, \Delta y}$ 表示卷积核在某个相对位置上的权重； Δx 和 Δy 分别表示水平和垂直方向的偏移；“输入特征”和“输出特征”指的是已经被研究者识别出来的内部对象。这个记号的教学价值在于提醒读者：卷积权重的意义依赖空间位置。

Olah 的狗头例子非常具体：一侧是“右脸狗头加长鼻”的检测器，另一侧连接到“狗头加颈

部”检测器。当研究者知道输入端和输出端分别是什么，权重就突然变得可读了：如果在狗的右侧、也就是头部应该出现的位置看到狗头，就激发狗头加颈部检测器。继续观察还会看到，不同朝向的狗头检测器会收敛到一致的鼻子位置，呈现出姿态不变性的结构。

汽车检测器也类似。它会在上方寻找车窗，在下方寻找车轮。这个解释朴素得像一句规则：“上面有窗、下面有轮，组合起来支持车身或汽车。” 但它的价值就在这里：当特征与权重都被放回空间语境中，神经网络内部的数字开始像一段可阅读的汇编指令。

权重需要上下文

单独看权重矩阵，研究者看到的是数字；知道两端特征和空间偏移后，权重才获得语义。狗头到颈部、车窗到车身、车轮到车身这些例子说明，权重的可解释性来自“连接了什么”和“以什么空间关系连接”。




图 5：狗头例子展示了权重如何借助空间语境获得意义：右脸狗头检测器通过卷积权重支持右脸狗头加颈部检测器。（视频画面时间区间：00:07:14–00:07:55。）

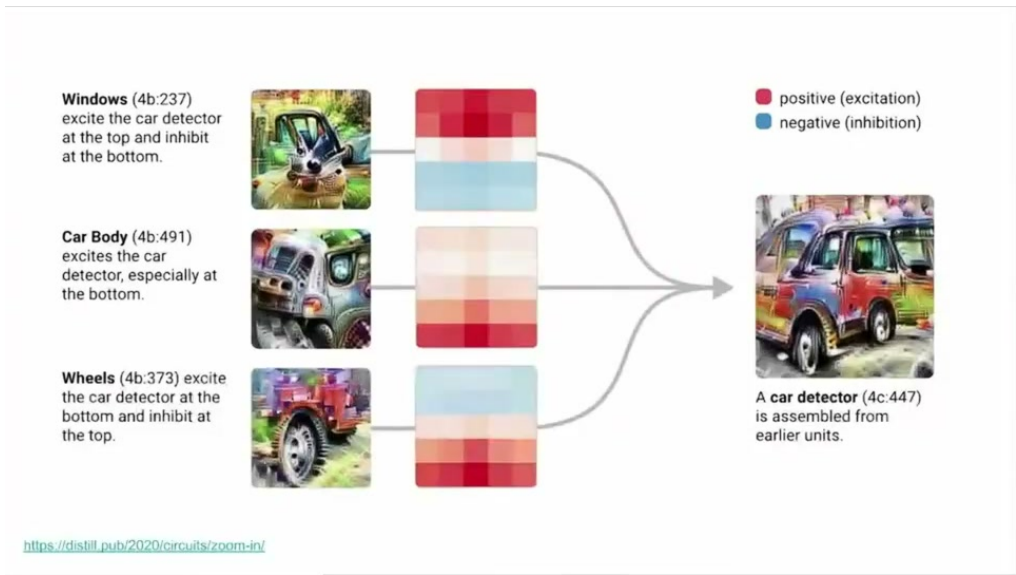


图 6：汽车检测器把车窗、车身和车轮等较早单元组合起来：上方车窗和下方车轮分别以不同空间位置支持最终汽车特征。（视频画面时间区间：00:08:24–00:09:13。）

3.4 特征可视化：变量名、证据和局限

现场有人问“这些图像是什么”。Olah 解释说，它们是通过输入优化生成的特征可视化。具体做法是从随机噪声开始，优化输入像素，让某个神经元的激活尽可能高。优化后的图像常常呈现某种可读形状，于是研究者可以把“4c447”这类内部编号替换成“曲线检测器”“车轮检测器”这样的变量名。

但他马上加了限制：这些图像并不构成决定性证据。它们更像实用变量名，能提示功能，也提供一定支持；如果要真正确信某个神经元的作用，就需要像曲线检测器研究那样进行详细调查。这个态度很重要，因为机制可解释性最容易被误解成“看图说话”。Olah 的版本更严格：图像帮助定位对象，解释需要追踪对象的上下游关系，并用多种方法验证。

常见误读：漂亮图片不等于机制解释

输入优化图像可能很有启发性，也可能误导。可靠的机制解释要能回答更硬的问题：这个单元在真实数据中何时激活？哪些前置特征驱动它？改变这些连接会怎样？它是否参与后续可识别电路？

3.5 电路：小部件如何组装成更复杂的检测器

第三类对象是电路。Olah 在这一段快速列出许多视觉电路案例，重点是让听众感受到权重中充满结构。

第一类是高低频检测器。某些单元在感受野一侧寻找高频模式，在另一侧寻找低频模式。研究者可以看到它们通过收集前一层中代表高频和低频的神经元来构建；当高低频检测器旋转时，对应权重也同步旋转。这说明权重并非杂乱连线，它跟随特征的几何变化一起组织。

第二类是颜色对比与中心环绕结构。许多颜色对比检测器被组装成中心环绕检测器；还有黑白与颜色检测电路，它们继续参与构建后续检测器。这类结构在视觉系统中很直观：局部区域与周围区域的差异，经常是边界、物体轮廓和材质变化的重要线索。

第三类是曲线、三角形和小圆。后续曲线检测器由更早的曲线检测器构建：方向匹配时激活，方向相反时抑制，并且权重随着特征旋转而旋转。三角形检测器可以由边缘检测器组装出来，小圆检测器可以由早期曲线检测器构建。大量颜色对比检测器还会被用来生成线条。

从局部线索到对象判断

视觉模型的计算很像搭积木：边缘支持曲线，曲线支持圆形或轮廓，颜色对比支持中心环绕，车窗和车轮共同支持汽车。单个部件的意义有限，组合关系才让模型形成可识别判断。

3.6 从例子读出的总体信号

Olah 希望听众从这些例子中带走一个具体判断：神经网络权重一旦被放进已理解特征的语境里，就充满结构。这里有狗头连接到下一部分，有不同姿态的狗头对齐到鼻子位置，有车窗和车轮支持汽车，有高低频线索、颜色对比线索、中心环绕线索、曲线线索一起构建复杂边界检测器。

这不是说视觉模型已经被完整解释。Olah 明确承认还有很多未理解内容。重点在于，已理解的局部区域呈现出足够清晰的结构，让“从参数恢复计算结构”这个目标不再只是哲学愿望。至少在这些案例里，研究者能把神经元和权重组织成类似程序片段的解释。

当现场有人继续追问这些可视化如何可信时，Olah 给出一个承上启下的回答：这些可视化是变量名；真正像代码或汇编指令的是权重。以汽车检测器为例，车窗检测器和车轮检测器参与定




图 7：边界检测器由多类线索共同支持：高低频变化、边缘、颜色对比和线端特征通过权重汇入更高层的边界判断。（视频画面时间区间：00:10:42-00:11:10。）

义车身或汽车检测器。为了信任这个解释，研究者需要继续往前追溯，理解更早的变量；如果需要，可以一直追溯到输入。这需要大量工作，但它正是机制可解释性的工作方式。

第三节的核心结论

视觉模型的案例证明了一件有限但重要的事：在某些区域，神经网络内部可以被拆成特征、权重和电路。特征给变量命名，权重在上下文中像指令，电路把局部指令组合成可识别计算。

3.7 本章小结

本节把第二节的“类源代码”目标落到视觉模型案例上。Olah 先定义了三类对象：特征、权重和电路；随后用 Inception-v1 曲线检测器、狗头到颈部的空间连接、车窗和车轮支持汽车检测器、高低频检测器、颜色对比、中心环绕、三角形和小圆检测器等例子说明，模型权重在合适语境中具有丰富结构。

同时，本节也保留了方法论谨慎：特征可视化主要提供变量名和线索，不能单独充当最终证明。真正的机制解释需要追踪上下游、验证因果关系，并在必要时一直回溯到输入。这个乐观图景马上会遇到下一章的困难：当特征无法干净对齐到单个神经元时，解释会被叠加结构显著复杂化。

4 叠加：多语义神经元背后的压缩几何

4.1 从清晰电路到多语义神经元

前一章的视觉模型例子给人一种乐观图景：某个神经元像“曲线检测器”，某条权重像“把狗头连接到狗脖子”，若继续向前追溯，网络似乎能逐层翻译成类源代码结构。Olah 随即给出转折：真实网络里大量存在多语义神经元（polysemantic neuron）。同一个神经元会对许多互不相关的输入属性响应，例如一个单元可能在某些图像中像纹理检测器，在另一些图像中像物体部件检测器。

多语义神经元只是表面症状

多语义性不等同于“这个神经元很杂乱，所以无法解释”。更准确地说，它提示研究者看错了坐标系：模型内部真正使用的特征可能沿着某些方向分布，而单个神经元只是观察坐标轴。若只盯着坐标轴，就像在倾斜的网格上读地图，很多道路会被切成碎片。

这里的关键难点是容量。若网络要表示的有用特征数量超过神经元数量，训练过程没有理由给每个特征都分配一个干净的单独神经元。于是，模型可能把多个稀疏特征压进同一个向量空间，让每个可观察神经元承载多个方向的投影。

这一点可以先用最朴素的计数直觉表达：如果模型想表示的特征数大于可用维度数，单特征单神经元的方案就装不下。

$$m > d$$

符号说明：

- m ：模型希望表示的特征数量。
- d ：可用的神经元数量或表示维度。
- $m > d$ ：特征数超过维度数，形成叠加压力。

叠加的核心定义

叠加（superposition）指模型用少于特征数量的神经元或维度来表示更多特征，常见方式是把稀疏特征编码为向量空间中的方向或线性组合。多语义神经元由此出现：一个坐标轴会同时截到多个特征方向。




图 8：玩具模型展示了稀疏性增加时，模型如何在有限维度中安排更多特征方向：重要特征获得更干净的方向，较稀疏的特征则通过叠加共享空间。（视频画面时间区间：00:12:44–00:15:38。）

4.2 更大的稀疏网络被折叠进较小网络

Olah 用一个更激进的比喻解释叠加：我们观察到的网络像是一个较小的投影，背后好像有一个更大的稀疏网络被折叠到这个空间里。所谓“更大的网络”并不表示实际另有一份隐藏参数；更

准确地说，模型执行的计算可以在概念上展开成更多特征节点、更高维的计算图，训练后的有限维激活把这些计算压缩到一起。

直觉上，一份激活向量 h 像一张被折叠的透明胶片。每个特征 k 在胶片上有一个方向 v_k ，输入 x 来时会让其中少数方向，亮度为 $z_k(x)$ 。多个方向叠在一起后，观察者看到的是一个总向量。

$$h(x) \approx \sum_{k=1}^m z_k(x) v_k$$

符号说明：

- $h(x)$ ：输入 x 触发的隐藏激活向量。
- v_k ：第 k 个特征在表示空间中的方向。
- $z_k(x)$ ：第 k 个特征在输入 x 上的激活强度；它表示概念上的系数，通常不能直接用普通坐标轴读出。
- $\sum_{k=1}^m z_k(x) v_k$ ：多个特征方向叠加成同一个可观察激活。

这个公式只是教学用的简化模型。它有助于理解“神经元不直接对应特征”这句话：神经元是坐标轴，特征更像空间中的斜向箭头。一个神经元读到的是许多斜向箭头在该坐标轴上的影子。

为什么“方向”比“神经元”更灵活

在二维平面里只有两个坐标轴，却可以画出很多方向。只要这些方向很少同时被点亮，它们就能共享同一张平面。神经网络中的叠加也利用了类似几何余地：特征以方向存在，坐标轴只是测量工具。

4.3 稀疏性、重要性与干扰

叠加能成立，核心条件是稀疏性（sparsity）。若两个特征几乎总是同时出现，把它们压进相近方向会产生严重干扰；若它们很少共同激活，它们可以共享维度，代价较低。Olah 在玩具模型里强调，随着特征越来越稀疏，固定维度空间能容纳的特征数量会增加，甚至可以在二维空间中安排五个特征。

干扰的直觉可以用共同激活概率表示。两个特征越少同时出现，它们越容易共用表示空间。

$\Pr[z_i(x) \neq 0, z_j(x) \neq 0]$ 越小，特征 i 与 j 的共享维度代价越低

符号说明：

- $z_i(x)$ 、 $z_j(x)$ ：输入 x 上第 i 、第 j 个特征的激活强度。
- $\Pr[\cdot]$ ：事件发生概率。
- $z_i(x) \neq 0, z_j(x) \neq 0$ ：两个特征同时激活。

还有第二个因素：重要性（importance）。若某些特征对损失下降贡献很大，模型更愿意给它们保留干净表示；若某些特征罕见但仍有价值，模型可能把它们塞入叠加空间。于是常见、高价值特征更容易显得像“单语义神经元”，罕见特征则更容易隐身在混合方向里。

叠加是一种压缩策略

稀疏特征共享维度，重要特征获得更低干扰的方向，这让网络在有限宽度里表达更多计算。这个策略提升了容量，也提高了解释难度：研究者看到的是压缩后的投影，需要反推压缩前的特征图。

4.4 玩具模型为什么重要

真实大模型里的特征无法直接标注，研究者很难证明某个混合神经元究竟由哪些底层特征组成。玩具模型（toy model）的价值在于研究者预先知道“真实特征”是什么，并能控制稀疏性、重要性和维度数量。这样一来，当模型把已知特征组织成线性组合，叠加就可以被清楚展示。

Olah 提到，在这些玩具模型中，特征会自行组织成正多面体或均匀多面体（regular / uniform polytope）之类的对称几何结构。这一点很重要：叠加带来的混乱外观，底层可能有高度规则的压缩数学。学习动态也会出现奇异跳跃，像系统突然从一种几何排列跃迁到另一种排列。

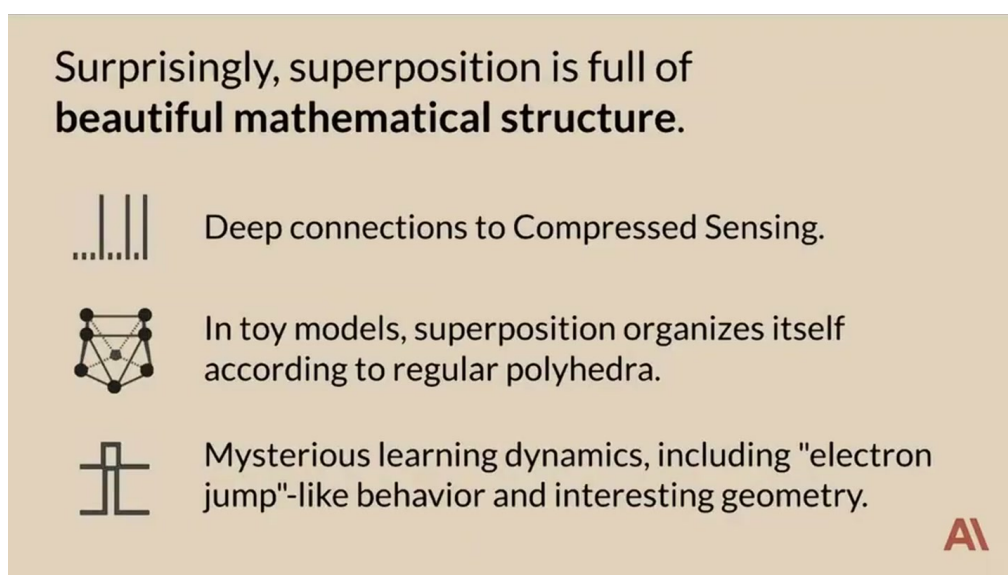


图 9：叠加在玩具模型中呈现出压缩感知、正多面体排列和跳跃式学习动态等结构性线索，说明混合表示背后可能有可分析的几何规律。（视频画面时间区间：00:16:16–00:17:00。）

正多面体的教学类比

若把每个特征看成一根从原点伸出的箭头，正多面体就是“尽量公平地摆放这些箭头”的方案。二维里可能像均匀散开的五个方向；高维里会出现更复杂的对称排列。对称性说明模型并非随意把特征乱塞进去，训练过程更像是在寻找低干扰的压缩几何。

玩具模型还有一个更深的启发：叠加并不只影响表示，也可以影响计算。Olah 指出，可以在叠加状态中执行计算：一个较高维的计算图被投影到较低维空间后，仍然保持有用计算。这对机制可解释性尤其棘手，因为解释者需要同时恢复“变量是什么”和“变量之间怎样计算”。

4.5 特征定义只在这里保留为边界条件

叠加让“特征”无法稳定等同于单个神经元。本节只保留这个限制：真实模型里的特征可能藏在线性组合或方向中；更完整的定义问题放到第九节问答展开。

换句话说，第四节的重点在表示几何：同一个可观察神经元可能只是多个特征方向的投影。第九节再处理更宽的问题，包括特征是否必须人类可理解、权重为何能被称为代码，以及人工神经网络相比神经科学有哪些测量优势。

不要把“特征”简化成中文标签

“汽车”“曲线”“狗头”这些标签只是人类给特征起的变量名。标签方便交流，却不能充当完整定义。真正要找的是模型内部可参与计算、可被上下游权重利用、能在行为上产生作用的表示单元。

这也解释了为什么叠加会成为安全相关难题。若许多稀疏特征藏在低激活方向里，研究者即使理解了若干显眼神经元，也仍可能漏掉某些罕见但关键的行为条件。Olah 的担忧集中在这里：只要无法恢复叠加结构，权重的真实作用就无法被完整理解。

这里还需要保留 Olah 的一个限制条件：叠加问题尚未解决时，机制可解释性仍能产出有价值的局部工作，例如命名特征、验证小电路、追踪局部权重关系。真正受损的是安全覆盖的上限：若叠加结构无法恢复，研究者就很难确认自己已经检查到全部关键特征，也很难完整说明权重在罕见情境中的实际作用。因此，叠加影响的是解释的可靠边界和安全论证强度，并不抹掉局部发现的研究价值。

4.6 本章小结

本章从多语义神经元进入叠加问题：单个神经元响应多个无关特征，背后原因可能是模型用有限维度压缩更多稀疏特征。叠加的几何图像是“特征方向”多于“神经元坐标轴”，稀疏性降低共同激活干扰，重要性影响哪些特征获得更清晰的表示。

玩具模型之所以关键，在于研究者知道真实特征，可以清楚展示特征如何被投影、折叠和组织成正多面体结构。与此同时，Olah 保留了必要的谨慎：真实模型中“特征”是什么仍无最终定义，尤其不能把特征限定为人类已经会命名的概念。叠加既是容量压缩机制，也是当前机制可解释性的核心阻塞点。

5 Transformer 的特殊机制：残差流、注意力特征与归纳头

5.1 为什么 Transformer 需要额外机械图景

视觉模型的电路分析给了研究者一套基本对象：特征、权重、电路。Transformer 仍然可以使用这些对象，但架构本身引入了新的单位和连接方式。Olah 在这一段强调两点：残差流（residual stream）与注意力头（attention head）。另外还有一个背景事实：Transformer 中的叠加通常比早期视觉模型更重，因此“看神经元找特征”的策略更快遇到瓶颈。

Transformer 分析的两个新增单位

残差流像一个跨层共享的工作台，许多模块从中读取信息，也把结果写回其中。注意力头则像一种独立的读写机构，它能按 token 之间的关系搬运信息，并形成可重复的注意力特征。

5.2 残差流：加法共享工作区

残差流的关键操作很简单：多个组件的输出被加到同一个表示里，后续组件再从这个表示中读出信息。它比普通残差网络更有解释学意义，因为 Transformer 的层、注意力头、MLP 都围绕同一条共享通道进行读写。结果是，两个组件即使不在相邻层，也可能通过残差流形成隐式连接。




图 10: Transformer 相比标准神经网络引入了两个关键机制对象：残差流提供跨层共享工作区，注意力头则形成按 token 关系搬运信息的读写单元。(视频画面时间区间：00:18:30–00:19:40。)

直觉上，可以把每个 token 位置的残差流看成一块不断被写入的白板。第 ℓ 层之前白板上已有内容，注意力或 MLP 读它、计算、再把新内容写回白板。

$$r_t^{(\ell+1)} = r_t^{(\ell)} + \Delta r_{t,\text{attn}}^{(\ell)} + \Delta r_{t,\text{mlp}}^{(\ell)}$$

符号说明：

- $r_t^{(\ell)}$ ：第 t 个 token 在第 ℓ 层的残差流向量。
- $\Delta r_{t,\text{attn}}^{(\ell)}$ ：第 ℓ 层注意力模块写入残差流的增量。
- $\Delta r_{t,\text{mlp}}^{(\ell)}$ ：第 ℓ 层 MLP 写入残差流的增量。
- 加号表示共享工作区的累积写入。

这种加法结构制造了大量潜在连接。一个早期注意力头写入的方向，可能被后面某个 MLP 使用；某层的神经元，也可能通过读残差流间接依赖其他层的注意力头。于是，Transformer 电路图不再只是层与层之间的局部边，而更像一张跨层共享内存上的读写依赖图。

残差流与“黑板”类比

课堂黑板上可以先写定义，再写例子，后面的人继续引用前面的符号。残差流也是这样：组件不需要彼此直接连线，只要约定读写同一块向量空间，就能形成远距离依赖。解释 Transformer 时，研究者需要问“谁在黑板上写了什么方向，谁又读走了它”。

5.3 注意力头与注意力特征

注意力头带来另一类机制对象。它先为 token 之间计算注意力模式，再把被关注位置的信息搬运到当前位置。Olah 提到，可以把一些稳定出现的注意力模式看作注意力特征 (attention feature)：它们像视觉模型里的曲线检测器一样，是机制分析中的可复用对象，只是对象从“输入图像属性”换成“token 之间的关系模式”。

注意力头的基本直觉是“当前位置向哪些过去位置取信息”。先由 query 和 key 产生匹配分数，再用 softmax 得到权重，最后按这些权重混合 value。

$$A_h = \text{softmax}\left(\frac{Q_h K_h^\top}{\sqrt{d_k}}\right)$$

符号说明：

- h ：某个注意力头的编号。
- Q_h 、 K_h ：该注意力头的 query 与 key 表示。
- d_k ：key/query 的维度，用于缩放点积大小。
- A_h ：注意力头 h 形成的 token 到 token 注意力模式。

这里的注意力特征（attention feature）指可重复出现、可被验证的注意力模式或搬运机制。它不同于整个注意力头，重点在于某个头在特定任务中稳定执行的关系模式。

讲座中特别引人注目的是注意力图上的“对角线外元素”：它们并非随机噪声，可能对应一种特定电路。Olah 将其引向归纳头（induction head），这是 Transformer Circuits 研究中的核心例子。

5.4 归纳头：从局部复制到上下文学习

归纳头的机制可以用一句话概括：在当前上下文里找到以前出现过的相同或相似片段，向后移动一步，复制那个位置后面的信息。它把“我现在又看到了 A ”转化成“上一次 A 后面跟着 B ，所以这次也提高 B 的概率”。

先看一个极简 token 序列。若历史中出现过 A, B ，当前位置再次出现 A ，归纳头会把注意力指向历史中的 A 附近，并搬运后继 B 的信息。

$$x_i = A, \quad x_{i+1} = B, \quad x_t = A \quad \Rightarrow \quad \hat{x}_{t+1} \approx B$$

符号说明：

- x_i ：序列第 i 个 token。
- A 、 B ：示例中的两个 token 或 token 模式。
- $x_t = A$ ：当前位置再次出现 A 。
- $\hat{x}_{t+1} \approx B$ ：模型提高下一个 token 为 B 的预测倾向。

这个机制把微观电路连接到了宏观能力。上下文学习（in-context learning）指模型在当前提示中利用模式，而不更新权重。归纳头提供了一种可见机制：它不需要把新规律写进参数，只需在当前上下文中检索、移动、复制。Olah 的表述保持谨慎：广义版本的归纳机制似乎是上下文学习的重要驱动因素，至少已有部分证据支持这一假说。

归纳头的三步机制

第一步，搜索过去出现过的相同或相关上下文；第二步，从匹配位置向前移动一个 token；第三步，把后继信息复制到当前位置，影响下一 token 预测。这个电路展示了机制可解释性想

要的连接：微观结构可以解释可观察能力。

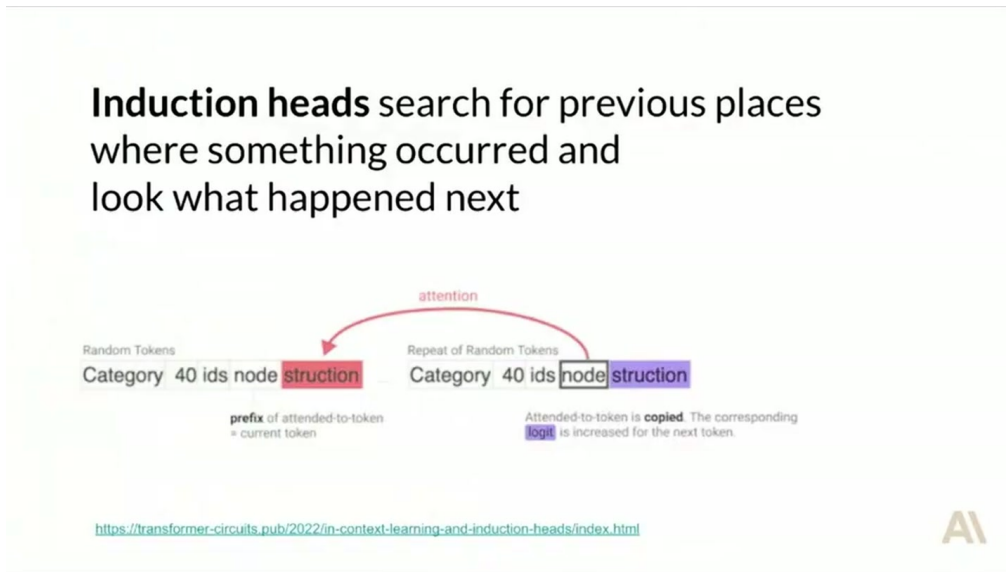


图 11：归纳头会寻找上下文中先前出现的位置，并读取其后继 token 的信息；图中的复制链路把微观注意力机制和上下文学习联系起来。（视频画面时间区间：00:20:00–00:21:18。）

5.5 损失曲线突增与同时形成

Olah 进一步指出，归纳头的重要性会出现在训练曲线里。训练超过两层的 Transformer 时，损失曲线常出现一个可见的突增或弯折（loss-curve bump）。在缩放定律图景中，也能看到某个点偏离原始趋势；这对应模型尚未形成归纳头，然后开始形成归纳头。

直觉上，损失 $L(t)$ 随训练步 t 下降。若某个电路突然形成，模型的预测能力会跨过一个阶段边界，曲线就可能出现非平滑的弯折。

$L(t)$ 在 $t = t_*$ 附近出现可见弯折， $t_* \approx$ 归纳头形成的训练阶段

符号说明：

- $L(t)$ ：训练步 t 时的训练损失。
- t_* ：归纳头相关电路快速形成的阶段。
- “可见弯折”：经验观察中的训练曲线相变信号，而非严格数学定理。

为什么大量归纳头会在短时间窗口内同时出现？Olah 的解释是反馈循环。归纳头电路需要多个组件一起存在；当足够多的原料就位，电路带来强训练收益，梯度会迅速强化相关组件。于是许多归纳头几乎一起形成，之后还可能继续演化。

问答里还补了一个例外情形：如果研究者搭建一种特别容易学会归纳头的架构，归纳头可能在训练一开始就形成。此时相关变化发生在损失函数极陡的初始阶段，曲线上未必留下后面那种清楚的突增。也就是说，损失曲线弯折是归纳头形成的常见外部信号，不能反过来当作必要条件；更稳妥的证据仍然是直接追踪归纳头随训练时间出现的过程。

损失突增不能充当安全证据

损失曲线弯折说明某类机制在训练中产生了宏观影响，但它不能直接说明模型行为安全。这里的价值是把“训练曲线上的相变”和“内部电路形成”联系起来，为后续安全讨论提供一种证据格式。

5.6 本章小结

Transformer 给机制可解释性增加了新的分析对象。残差流是跨层共享的加法工作区，注意力头通过 token 关系搬运信息，注意力特征则把稳定模式变成可研究的机制对象。归纳头是本章的核心案例：它搜索过去出现的上下文，移动一步，复制后继信息，从而支持上下文学习。

这一章最重要的连接在于尺度：归纳头既是可拆解的微观电路，也能在训练损失曲线和缩放趋势中留下宏观痕迹。下一章讨论安全时，正需要这种从内部机制到外部行为的桥梁；同时也必须记住，发现一个重要电路距离证明模型安全仍然很远。

6 安全主张需要什么：覆盖特征、排除电路、扩大规模

6.1 最想要的安全声明

Olah 在安全段落里没有列举许多宽泛应用，他抓住一个最雄心勃勃的目标：研究者希望能够对模型作出类似声明——对于模型可能遇到的所有情况，它绝不会故意执行某个行为 X 。这里的关键词有三个：“所有情况”“故意”“行为 X ”。它要求解释者穿过表面评测，进入模型是否拥有相关内部动机、特征和电路的问题。

先用普通语言理解：安全评测常问“在这些测试题上模型有没有做坏事”。Olah 想象的机制性声明更强：模型内部没有会主动参与行为 X 的表示和计算路径，因此即使换到未见场景，也没有相应电路可被触发。

$$\forall s \in \mathcal{S}, \text{ model}(s) \text{ does not intentionally do } X$$

符号说明：

- s ：模型可能遇到的某个情境或输入上下文。
- $\mathcal{S}$ ：希望覆盖的情境集合。
- X ：安全相关的禁止行为。
- $\forall s \in \mathcal{S}$ ：对所有相关情境提出声明。

这是一种远期目标，当前方法无法给出完整认证

Olah 明确表示，距离做出这种安全声明还很遥远。机制可解释性在这里提供的是一种理想证据形态：若能覆盖相关特征并排除参与电路，安全论证会更接近内部机制层面。它目前不能替代红队测试、行为评估、训练约束或运行时监控。

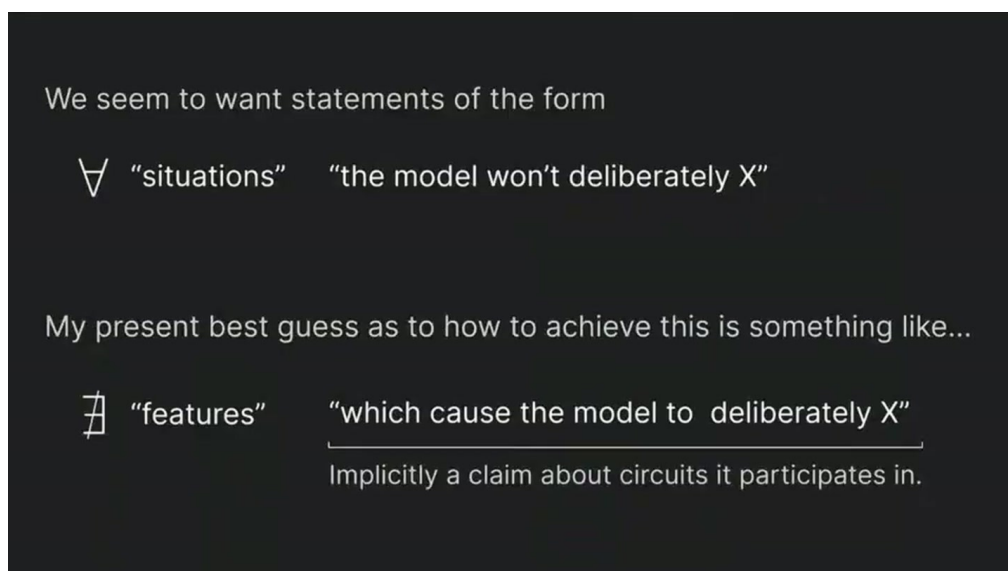


图 12：安全目标被表述为跨所有情境的全称声明，并进一步转化为对相关特征与参与电路的排除或控制；这只是远期证据形态，并不构成当前认证。（视频画面时间区间：00:22:26–00:24:15。）

6.2 从行为 X 到参与电路

要把上面的全称声明落到机制层面，需要把“模型做 X”拆成内部构件。Olah 提到的路线是：如果存在某些特征会让模型主动参与执行 X，那就需要对这些特征和它们组成的参与电路（participation circuit）提出声明。安全目标因此变成两类证据：

- 没有发现会代表“主动执行 X”的特征，或这些特征在关键条件下不可触发。
- 没有发现把这些特征连接到行动输出的参与电路，或这些电路被可靠抑制。

这个转化很重要。纯行为层面的“没测到 X”容易受测试集覆盖限制；机制层面的“没有相关特征/电路”如果能成立，才更有机会支持跨情境外推。但这里的“如果”很大，因为它要求研究者知道该找哪些特征、在哪里找、怎样验证缺失。

安全论证需要从输出转向内部因果路径

一个真正有力的机制性安全论证，不能只说“模型这次没有做 X”。它必须解释哪些内部特征会参与 X，哪些权重路径会把它们接到行动上，以及为什么这些路径缺失、失效或被控制。

6.3 迷信问题：隐藏方向与覆盖失败

Olah 将第一个挑战称作迷信问题，也可以称作覆盖问题（coverage problem）。它的直觉很尖锐：模型空间里可能存在一个几乎不激活的特征，只是高维空间中某个角落的方向；在常规测试中它从未出现，一旦被特定输入点亮，模型行为会完全不同。

这正是叠加带来的安全压力。若特征沿着混合方向存在，解释者无法只检查显眼神经元。罕见特征可能不占用单独坐标轴，也可能在普通数据集上几乎沉默。于是，“没有看到危险特征”很容易滑向自我安慰。

可以把安全覆盖（safety coverage）问题写成一个集合差异。研究者实际检查到的特征集合往往只是全部安全相关特征集合的一部分。

$$\mathcal{F}_{\text{checked}} \subseteq \mathcal{F}_{\text{relevant}}, \quad \mathcal{F}_{\text{missed}} = \mathcal{F}_{\text{relevant}} \setminus \mathcal{F}_{\text{checked}}$$

符号说明：

- $\mathcal{F}_{\text{checked}}$ ：研究者已经检查、命名或验证过的特征集合。
- $\mathcal{F}_{\text{relevant}}$ ：对行为 X 或安全性质相关的全部特征集合。
- $\mathcal{F}_{\text{missed}}$ ：尚未覆盖的相关特征。
- $\subseteq$ ：已检查集合可能只是相关集合的一部分。

“未观察到”不等于“机制不存在”

在高维叠加空间里，危险特征可能低频、低激活、被其他特征遮蔽，或只在非常特定的组合输入下显现。机制可解释性若要服务安全，必须正面处理这些未知未知，而不能把有限样本上的沉默当成不存在证明。

6.4 可扩展性：从微小电路到大型模型

第二个挑战是可扩展性（scalability）。目前机制可解释性的成功案例往往很小：曲线检测器、局部视觉电路、归纳头等都展示了强证据，但大型真实模型包含海量组件、层间依赖和叠加表示。问题很朴素：研究者如何把微小电路研究扩展到完整系统？

Olah 对可扩展性相对更乐观。他列出几条可能路线：用 AI 自动化解释流程；利用模块化或模型图结构；寻找像视觉模型中那样能大幅压缩解释复杂度的模式；发现对称性，使大量看似不同的部件可以归入同一类机制。

模型图结构为什么可能降低复杂度

若一个大模型真由许多重复模块、对称结构和可复用电路组成，解释者无需逐个理解每条边。就像软件工程里读懂一个函数模板后能理解许多调用点，机制可解释性也可能通过“模块类型”压缩理解成本。这个希望依赖一个前提：研究者能先把叠加拆开，看见真实模块。

6.5 为什么叠加仍是更令人担忧的阻塞点

Olah 的风险排序很清楚：他对可扩展性更乐观，对叠加更担忧。原因在于可扩展性主要像工程放大问题：若有模块、图结构、自动化和对称性，规模可能逐步推进。叠加则触及“我们是否能访问想理解的单元”。如果关键特征没有以可直接访问的神经元形式出现，解释者连对象边界都难以确定。

这也解释了安全段落与上一章的连接。归纳头展示了小电路能影响大行为，说明机制证据有潜力触及宏观能力；叠加提醒研究者，尚未发现的稀疏方向可能同样影响行为。安全论证需要两者同时成立：能找到重要电路，也能有理由相信没有漏掉危险电路。

安全路线的硬门槛

机制可解释性若要支持强安全声明，至少需要三件事：覆盖安全相关特征，理解这些特征如何参与电路，扩展到真实模型规模。三者中，覆盖问题最容易被低估，因为它要求证明“没有漏掉关键对象”。

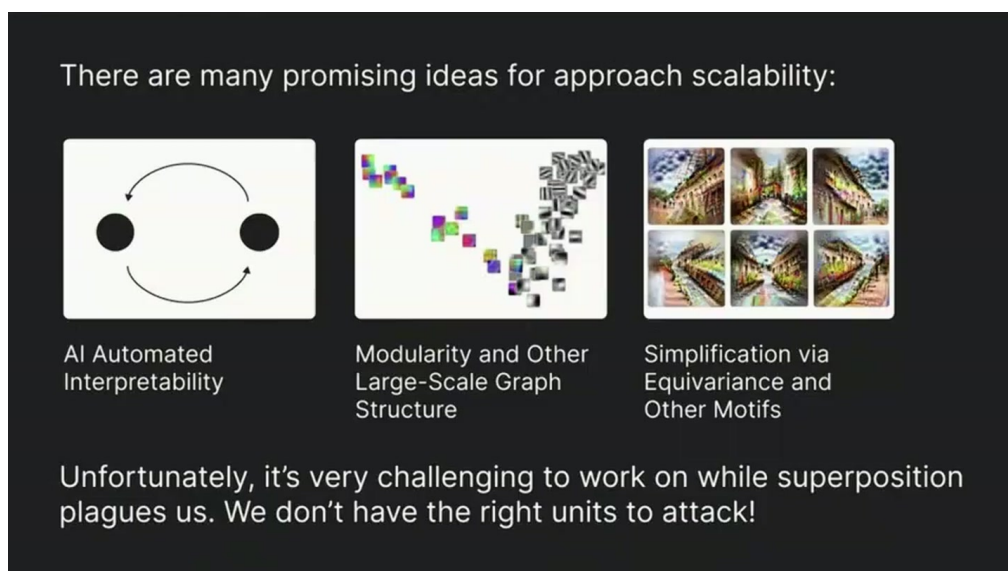


图 13: 可扩展性路线包括 AI 自动化解释、利用大规模图结构与模块化, 以及通过等变性和重复模式压缩理解成本; 叠加仍会阻碍研究者找到正确分析单元。(视频画面时间区间: 00:24:15–00:25:08。)

6.6 本章小结

本章把机制可解释性连接到安全目标: 理想声明是“对所有相关情境, 模型不会故意执行 X ”。要支撑这种声明, 研究者需要从输出行为进入内部因果路径, 检查是否存在相关特征和参与电路。

Olah 同时给出冷静限制。当前方法距离认证安全很远, 最大难点包括覆盖问题和可扩展性。覆盖问题来自隐藏方向、罕见特征和叠加; 可扩展性来自大型模型的体量与复杂连接。Olah 对自动化、模块化、模型图结构和对称性抱有希望, 但他更担心叠加, 因为它让研究者无法直接访问真正需要理解的计算单元。

7 梯度下降生成的精妙结构

前一章把机制可解释性放到安全目标中: 研究者希望有一天能对模型行为给出覆盖性的机制证据。Olah 在正式演讲的结尾把话题稍微移开, 从安全论证转向一种更底层的研究动机: 神经网络本身值得被当作自然对象认真研究。这里的重点避开了泛泛的“模型很神奇”, 落在一个具体判断上: 训练过程会把权重组织成有结构、有对称性、可被逆向工程的计算系统。

7.1 从安全动机到研究趣味

Olah 承认, 安全是这项工作的强烈动机。前文的目标是理解模型是否存在某些参与电路、是否存在隐藏的危险特征、是否能够排除“模型故意做 X ”一类行为。可是, 他说真正让他在情感层面持续投入的, 还有另一层原因: 当神经网络被当作研究对象时, 它们看起来充满精妙结构。

这种说法需要谨慎理解。它并不意味着每个权重都已经有了清晰解释, 也不意味着现有方法已经能覆盖大型模型。更准确地说, Olah 的经验是: 许多最初看起来杂乱的对象, 一旦找到合适的变量名、几何视角或电路分解, 就会显露出规律。视觉模型中的曲线检测器、高低频检测器、中心环绕电路, 以及玩具模型中的正多面体排列, 都是这种研究直觉的来源。

结尾的核心主张

Olah 的结尾主张是：梯度下降（gradient descent）像进化一样，是一种能够生成复杂结构的过程。机制可解释性的任务，就是把这些结构从权重和激活中重新读出来，而不是只停留在行为测试或整体性能指标上。

7.2 梯度下降与进化的类比

Olah 用生物学作类比：进化通过局部选择、变异和长期积累，生成了自然界中高度复杂的结构。机器学习中的梯度下降也有某种相似性。它从随机初始化出发，根据损失函数一点点调整参数，最后形成看起来像“设计过”的电路、对称性和几何组织。

用最简单的形式写，梯度下降可以表示为：

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} L(\theta_t)$$

其中：

- θ_t ：第 t 步训练时的全部参数，也就是模型当前的权重状态；
- $L(\theta_t)$ ：在当前参数下的训练损失；
- $\nabla_{\theta} L(\theta_t)$ ：损失对参数的梯度，指出哪些方向会让损失上升最快；
- η ：学习率，控制每一步更新的幅度。

这个公式本身很朴素：沿着降低损失的方向移动参数。真正令人惊讶的是，反复执行这种局部更新后，模型内部会出现可复用的特征、权重关系和电路结构。就像进化没有全局蓝图却能产生眼睛、翅膀和细胞机制，梯度下降也没有显式写入“曲线检测器”“归纳头”“正多面体特征排列”，却可能在优化压力下形成这些对象。

类比的边界

进化类比的值在于帮助读者理解“局部过程如何生成全局结构”。它不能替代机制证据。研究者仍然需要用激活、权重、干预实验、可视化和几何分析来证明某个结构确实存在。

7.3 混乱有时是未读懂的结构

Olah 特别强调了一个研究经验：模型里确实有很多看起来混乱的部分，但其中一些后来会变成“以前尚未理解的美丽结构”。这个判断来自前面几章的例子。

在视觉模型中，单独看权重矩阵时，很多数字没有可读意义；一旦知道输入端和输出端分别代表什么特征，权重就变成了上下文中的指令。狗头、鼻子、脖子之间的空间关系，车窗与车轮对汽车检测器的支持，高低频特征随着方向旋转而同步旋转，这些都说明结构经常隐藏在合适的坐标系之后。

在叠加研究中，混乱感更强。一个神经元可能同时响应多个看似无关的语义，直接读神经元坐标会失败。可是玩具模型显示，当特征数量超过维度数量、且特征足够稀疏时，模型会用几何方式把更多特征压入更少维度，甚至形成正多面体这类高度对称的排列。也就是说，“多语义”有时是压缩几何的表面症状。

不要把“结构感”当成已完成的解释

“模型充满结构”是一种研究假设和经验判断，不能直接推出大型模型已经可解释。尤其在叠加严重的区域，研究者可能连正确的特征坐标都没有找到。这个结尾的力量在于指明为什么值得继续挖掘，而不是宣告问题已经解决。

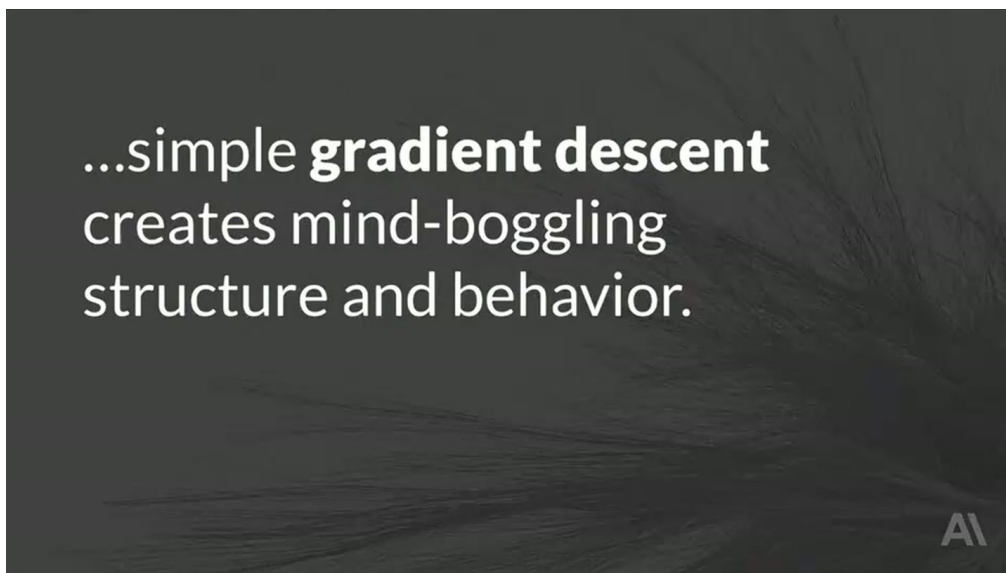


图 14: Olah 用这一页把结尾的研究趣味压缩成一句话：简单的梯度下降可以生成令人惊讶的结构与行为。这里的“结构”指前文反复出现的特征、权重关系、电路和几何组织，而不只是模型输出看起来聪明。（视频画面时间区间：00:26:00–00:26:44。）

7.4 协作与阅读路径

Olah 在结尾也提醒，这些结果是许多人长期协作的产物，涉及不同机构的研究者。机制可解释性很难由单个直觉完成，因为它需要同时处理工程实验、神经网络架构、线性代数、可视化、因果验证和安全问题。

他给出的阅读路径很具体：

- 原始的 Circuits 研究线索：重点是对视觉模型做严肃的逆向工程，适合从特征、权重、电路三件事进入；
- Transformer Circuits 研究线索：把类似方法推进到 Transformer，重点关注残差流、注意力头和归纳头等结构；
- Neel Nanda 的详细注释阅读材料：Olah 认为这可能是很好的切入点，因为它把许多论文和概念串成可学习路径。

怎样读这条研究线

如果读者从零开始，较稳妥的顺序是先读视觉电路，因为那里有更直观的特征可视化和权重关系；再读 Transformer Circuits，因为残差流和注意力会改变“变量”和“电路”的单位；最后回到叠加与安全问题，因为这两者决定了方法能否扩展到真正困难的模型。

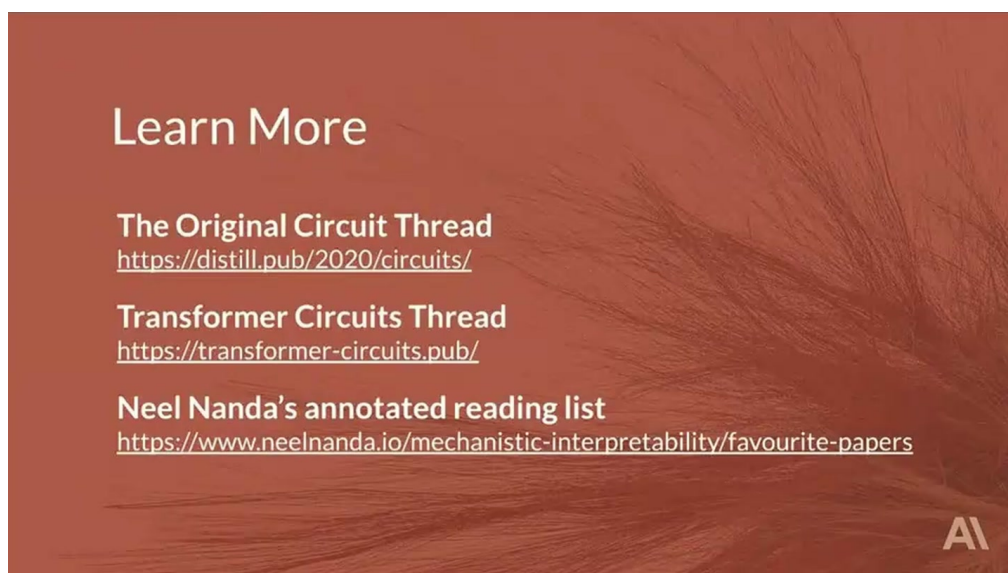


图 15: 结尾给出的三条阅读路径: 先从视觉模型的 Circuits 线程建立“特征-权重-电路”的对象感, 再进入 Transformer Circuits, 最后用 Neel Nanda 的注释材料把论文和概念串起来。(视频画面时间区间: 00:27:16–00:27:34。)

7.5 本章小结

本章保留了演讲结尾的实质内容: Olah 把梯度下降看作一种能生成复杂内部结构的过程, 并用进化作类比。这个类比的关键在于, 局部优化可以长期积累出全局结构; 机制可解释性的工作, 就是为这些结构找到正确的变量、坐标系和电路解释。

这一章也给出阅读路线: 从视觉模型的 Circuits 工作入手, 再进入 Transformer Circuits, 最后结合注释材料追踪叠加和安全问题。结尾真正要传达的重点是研究判断: 许多看似混乱的权重和激活, 可能只是尚未被放进正确语境的结构。

8 问答一: 隐含模块化与视觉模型分支

问答的第一段回到模块化(modularity)问题。前文已经提到, 可扩展性可能依赖模型内部是否存在可拆分、可复用的组织结构。听众的问题大意是: 既然神经网络可能有模块, 那么这些模块在哪里能被看见? Olah 的回答很具体: 视觉模型早期层中确实能看到清晰分支; 在更深层和语言模型中, 模块化可能仍然存在, 但被叠加遮住了。

8.1 AlexNet 式早期分支: 灰度与颜色对比

Olah 首先提到 Krizhevsky 2012 时代的现象, 也就是 AlexNet 一类早期视觉模型中的第一层分裂。由于当时模型分布在两块 GPU 上训练, 两侧只有有限通信。观察第一层滤波器时, 一侧更偏向黑白或灰度滤波器, 另一侧更偏向颜色对比检测器。继续看下一层, 还能看到类似组织。

这个例子有两个教学价值。第一, 它说明模块化有时会以非常朴素的形式出现: 一部分通道处理亮度、边缘、灰度纹理, 另一部分通道处理颜色差异。第二, 它提醒读者, 架构细节会影响可见结构。两块 GPU 的通信限制像一堵半透明隔板, 让模型更容易形成可观察的分支。

早期视觉层为什么容易看见模块

早期视觉任务有大量高频、局部、重复出现的特征，例如边缘、颜色对比、纹理方向。它们经常在同一张图像中出现，叠加压力相对较小，因此神经元和特征更容易接近一一对应，模块边界也更容易直接暴露。

8.2 Inception-v1 中的分支内容

Olah 接着把这种观察推广到更多视觉模型，尤其提到 Inception-v1。Inception 架构本身就有分支结构；在可解释性分析中，这些分支有具体功能，承载了不同类型的视觉计算。

他列出的分支内容包括：

- 黑白与彩色、颜色对比单元；
- 曲线检测器；
- 毛发和眼睛相关检测器；
- 边界检测器；
- 三维几何检测器。

Olah 还强调，这个分组有概率分布支持，来源超出研究者的视觉印象：相关概率分布显示，这些分支确实以这种方式组织信息。换句话说，灰度、颜色对比、曲线、边界和三维几何这些分组，既是方便记忆的标签，也反映了模型内部连接和激活的统计结构。

这些例子与第三章的视觉电路形成呼应。曲线检测器、边界检测器和几何检测器并非孤立神经元标签，它们可以在更高层组织成分支。模块化在这里像城市分区：同一个城市中有道路、住宅、工厂和学校；单独看一栋建筑只能知道局部用途，观察分区才会看到更大的功能组织。




图 16: Inception-v1 的分支图把模块化落到可见对象上：有的分支偏向黑白与颜色对比，有的分支集中曲线、毛发、眼睛和边界检测器，还有的分支承载三维几何与复杂形状。(视频画面时间区间：00:28:10–00:29:25。)

8.3 用 SVD 提取隐藏结构

更重要的是，Olah 说这种结构并不总是由显式分支给出。在其他模型中，研究者可以看同一层特征与另一层特征之间的连接权重，对这个连接矩阵做奇异值分解（singular value decomposition, SVD），然后发现类似结构隐含其中。

直观地说，SVD 是一种把矩阵拆成“主要方向”的方法。假设 W 表示两组已知特征之间的连接权重，可以写成：

$$W = U\Sigma V^T$$

其中：

- W ：从一组特征到另一组特征的连接权重矩阵；
- U ：输出侧的主要方向；
- Σ ：各个方向的重要强度，通常按奇异值大小排序；
- V^T ：输入侧的主要方向。

如果某些视觉功能确实成组连接，SVD 可能把这些组以主方向的形式分离出来。比如一组方向对应颜色对比，一组方向对应曲线和边界，另一组方向对应三维几何。这样一来，即使网络架构没有给出清晰分支，连接权重中的低秩结构也可能泄露出模块化。

SVD 在这里扮演什么角色

SVD 不是魔法解释器。它只是在线性连接矩阵里寻找强方向和成组模式。它有用的前提是：研究者已经有相对可靠的特征集合，并且这些特征之间的连接确实含有可分解的组织结构。

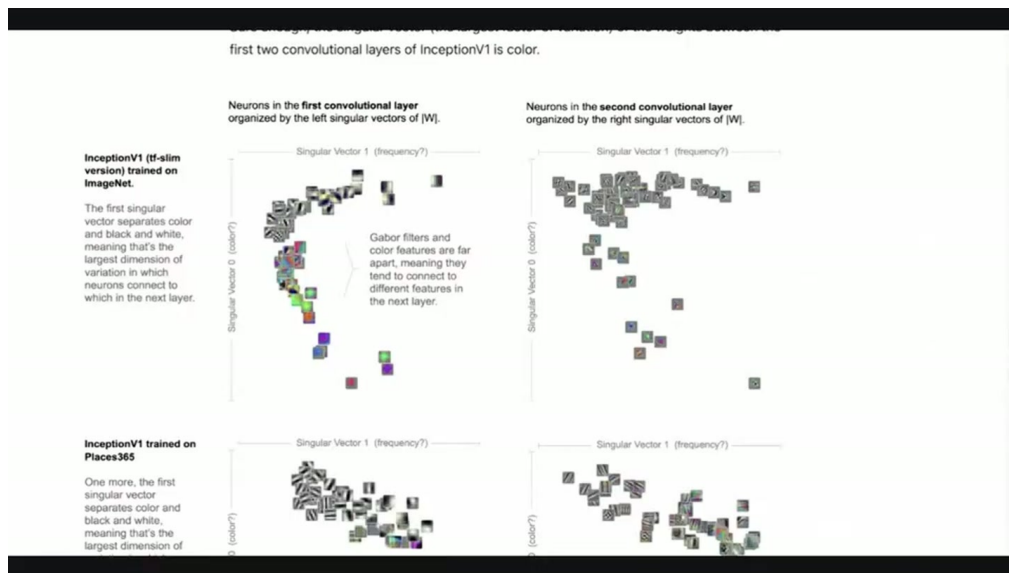


图 17: SVD 视角下的特征连接图：左、右奇异向量把相邻卷积层中的神经元重新排布，颜色与灰度滤波器被分到不同区域，说明模块化有时藏在连接矩阵的主要方向里。(视频画面时间区间：00:29:12–00:29:35。)

8.4 叠加如何隐藏模块

Olah 也明确说，在视觉模型的后期层和语言模型中，这种模块化更难直接看到。他的解释是叠加：两个完全无关的计算图可能被压到同一组神经元或同一片向量空间中。这样一来，原本可分开的模块像几张透明胶片叠在一起，肉眼看每个像素都会觉得混乱。

这正好连接第四章的核心问题。如果特征数量 m 超过可用维度 d ，模型会被迫把特征写成共享空间中的线性组合。模块仍可能存在于“正确的特征坐标”里，但在神经元坐标中看起来会相互穿插。Olah 最乐观的设想之一，就是一旦叠加问题得到解决，研究者会发现大量隐含模块化和组织结构。

不要把“看不见模块”误读为“没有模块”

后期视觉层和语言模型中难以直接看见分支，原因可能是特征被叠加到共享表示中。当前证据还不足以保证所有隐藏结构都能被恢复，但早期视觉层给出了一个重要提示：当叠加压力较小，模块化会变得非常明显。

8.5 本章小结

本章把问答中的模块化澄清整合成三个层次。第一，AlexNet 式早期视觉模型中，灰度滤波器和颜色对比检测器可以形成直观分裂。第二，Inception-v1 的分支承载了更丰富的视觉功能，包括曲线、毛发、眼睛、边界和三维几何。第三，显式分支之外，还可以用 SVD 分析特征连接矩阵，提取隐藏组织结构。

Olah 的关键判断是：模块化在早期视觉层最容易直接观察，因为那里叠加较少；在后期层和语言模型中，叠加会把模块压缩到混合坐标里。解决叠加问题，可能会把许多当前不可见的模块重新显影出来。

9 问答二：特征定义、代码含义与人工神经科学优势

第二段问答处理三个容易误解的问题：什么算特征，所谓“把权重读成代码”到底是什么意思，以及为什么人工神经网络比生物大脑更适合做这种细粒度研究。Olah 的回答很坦率：特征定义仍然没有完全解决；“代码”指的是被语境化后的权重和电路；人工网络的优势在于研究者能拿到几乎完整的测量与干预权限。

9.1 特征定义仍然悬而未决

Olah 直接承认，特征（feature）的严格定义很困难。他并不想把特征定义成“人类可理解的概念”，因为这会把模型可能拥有、但人类还没有语言描述的计算单元排除掉。一个模型可能表示某种对任务有用的内部属性，研究者暂时只能看到它的激活模式和因果作用，却还没有合适名称。

更稳妥的说法是：特征是模型计算中的基本单元候选。它有时对应单个神经元，有时对应一组神经元的线性组合，有时需要先解开叠加才能显形。在玩具模型里，研究者能预先定义真实特征，因此可以清楚观察它们如何被投影、折叠和叠加；在通用生成模型中，研究者通常没有这种先验答案。

特征标签只是研究工具

“汽车检测器”“曲线检测器”“高低频检测器”这些名字有教学价值，也有实验依据，但名字本身不是定义。真正要确认一个特征，需要看它在计算中扮演什么角色、如何被上游特征支持、如何影响下游行为，以及干预它会发生什么。

这段问答的语气比普通定义争论更坦率：Olah 承认，自己先指向一个稳定现象，漂亮定义还没有到位。他用数学学习中的例子说明，研究者有时会先被定义困住，随后在处理具体对象、反例和证明的过程中，逐步逼近更实用的定义。放到机制可解释性里，特征定义也处在这种阶段：现象已经足够稳定，正式边界还在形成。

9.2 “权重就是代码”的准确含义

当 Olah 说把网络转化为代码时，他特意澄清，他并不是说要把模型翻译成 Python 程序。权重本身就可以是代码，但前提是它们被放进正确上下文中。这里的“代码”更接近汇编指令或连接规则：某个上游特征在某个空间位置激活后，通过某个权重影响下游特征。

汽车检测器是最清楚的例子。若一个检测器在上方接收车窗特征，在下方接收车轮特征，并在这些部件同时出现时激活，那么这组权重连接已经给出了直接解释。没有必要再把它改写成伪代码；更有信息量的解释就是展示这些特征、空间位置和权重关系。

权重作为代码的条件

单独的权重数字通常不可读。输入特征、输出特征、空间偏移、激活行为和因果验证都被放到一起后，权重才像代码：它说明哪些变量怎样连接，哪些证据会支持某个下游计算。

这也解释了为什么语境化（contextualization）如此重要。研究者需要先识别或命名上游变量，再看权重如何组合它们；如果遇到叠加，还需要尽量把混合表示解开。没有这个步骤，权重矩阵只是数字表；有了这个步骤，它可能变成电路说明书。

9.3 未知概念如何变得可理解

Olah 还用高低频检测器举了一个反例，说明“暂时不理解”并不等于“永远没有人类解释”。视觉模型中有些单元起初很难命名；后来研究者发现，它们在感受野的一侧寻找高频纹理，另一侧寻找低频区域。这类模式经常出现在物体边界处，比如复杂背景和较平滑物体之间。

这个例子说明，特征未必一开始就像“狗耳朵”“车轮”这样直观。它可能更像一种统计线索、一种几何关系或一种边界条件。研究者要做的是把它放入电路中，观察它由哪些上游信号组成，又支持哪些下游判断。

概念、特征、变量的区别

概念通常指人类能说出口的语义对象，例如“汽车”。特征更偏向模型内部的计算单元，例如“上方车窗加下方车轮”或“一侧高频一侧低频”。变量是解释时给这些计算单元起的可操作名字。三者会重叠，但不能混为一谈。

9.4 人工网络相对神经科学的研究优势

Olah 认为，研究人工神经网络相比研究生物大脑有巨大优势。原因不在于人工网络简单，关键在于研究者拥有罕见的测量和控制权限。

这些优势包括：

- 可以无损读取每个神经元或表示维度的激活；
- 可以收集任意数量的刺激样本，并重复运行相同输入；
- 拥有完整连接组（connectome），知道哪些单元连接到哪些单元；
- 不只知道连接是否存在，还知道连接权重的大小和符号；
- 可以通过网络结构计算梯度，并用优化方法构造输入或干预；
- 可以反复研究同一个模型，把同一份权重分享给同事，让不同研究者讨论同一个神经元或同一条电路；
- 实验周期更短，失败后可以快速改变量、重新跑实验、检查中间状态。

在生物神经科学里，很多测量昂贵、带噪、局部且不可完全重复。人工网络像一个可以无限暂停、复制、探针化的“数字脑切片”。这种优势不会自动解决叠加和特征定义问题，但它让机制可解释性拥有比传统神经科学更强的实验反馈回路。

人工网络的关键优势

机制可解释性研究者同时拥有激活、权重、连接、梯度和可重复模型实例。这意味着他们不只是在观察系统输出，还能进入系统内部，反复测量同一对象，并对内部变量做精确干预。

9.5 本章小结

本章整理了问答中最容易被误读的三点。第一，特征定义仍然开放，不能简单等同于人类可理解概念；它更像模型计算中的基本单元候选。第二，“权重是代码”指的是权重在特征、电路和空间语境中承担指令作用，并非把模型翻译成 Python。第三，人工神经网络研究拥有完整激活、权重、连接组、梯度和可重复模型访问，这使它比生物神经科学更容易做精细逆向工程。

这些澄清把前文的乐观和谨慎同时保留下来：研究者确实拥有强大的实验条件，也已经读出一些具体电路；同时，特征定义和叠加解除仍是核心难题。

10 问答三：语言模型为何更难，以及仍未知的问题

最后一段问答聚焦语言模型。Olah 的回答有一个重要转向：语言模型难解释的核心原因，不主要是文本样本比图像样本更难浏览；更深层的问题是特征重要性曲线、稀疏性和概念空间都把模型推向更强的叠加。

10.1 特征重要性曲线：为什么平缓曲线会增加叠加压力

Olah 提出一个当前理论图景：可以想象把模型可能学习的所有特征按重要性排序。重要性可以粗略理解为某个特征能减少多少损失，或它对任务表现有多大贡献。把这些重要性从高到低画成曲线，就得到特征重要性曲线（feature-importance curve）。

一种简化写法是：

$$I_1 \geq I_2 \geq \dots \geq I_k \geq \dots$$

其中：

- I_k ：排名第 k 的特征重要性，可以理解为该特征带来的损失下降或预测收益；
- k ：特征按重要性排序后的序号；
- 曲线形状：指 I_k 随 k 增大而下降的速度。

如果曲线下降很陡，少数特征特别重要，后面大量特征价值很低，模型更倾向于为最重要的特征分配清晰维度。若曲线很平缓，许多特征都有中等价值，模型会有更强动力把大量特征塞进有限维度里，叠加压力随之增强。

语言模型的第一重困难

Olah 的判断是：语言模型需要表示的有用特征太多，且重要性长尾更平缓。这会让“给每个重要特征一个干净神经元”的方案变得昂贵，模型更可能使用叠加来压缩表示。

10.2 稀疏性差异：边缘很多，人名很少

第二个因素是稀疏性（sparsity）。在早期视觉模型中，许多基础特征并不稀有。Olah 用垂直边缘作例子：随便看一张图像，里面通常有很多垂直边缘、水平边缘、颜色边界和纹理变化。这些特征在样本中高频出现，模型可以反复使用它们，单个神经元或少量方向承担这些特征并不浪费。

语言模型的很多特征则稀有得多。比如一个具体人物、罕见短语、专业实体或长尾事实，可能每百万个 token 才出现一次，甚至更少。即使它们对某些上下文有价值，也不常一起出现。稀疏特征越多，模型越容易把它们混合进共享表示，因为单独为每个罕见特征保留独立维度代价太高。

从视觉到语言的直觉差别

早期视觉像在一张图上找大量重复笔画：边缘、角点、颜色对比处处可见。语言长尾更像一本巨大百科中的罕见条目：每个条目有意义，但出现频率低，种类又多。后者天然更容易产生压缩和叠加。

Olah 还指出，语言模型从词嵌入开始后，很快会转向更复杂、更密集的特征。语言模型中也能找到单语义神经元，但它们通常对应高频特征；大量低频或组合特征更可能藏在叠加表示中。

10.3 概念空间更大，曲线更长

第三个因素是概念空间。ImageNet 视觉模型需要区分有限类别和大量视觉线索；语言模型要处理实体、关系、语法、语义、事实、风格、推理模式、代码模式和上下文任务。可表达内容的空间大得多。

这会拉长特征重要性曲线。即使前几个特征非常重要，后面仍然有大量中等重要、低频但有用的特征。模型面对的是一个更长、更扁平的价值尾部：太多特征值得保留，维度又有限，叠加成为一种自然压缩策略。

文本可读性不是主要瓶颈

Olah 认为解释语言神经元可能会多花一点时间，因为图像样本可以更快扫视；但这不是主要问题。真正的瓶颈在表示几何：语言特征更多、更稀疏、重要性曲线更平缓，导致叠加压力更强。

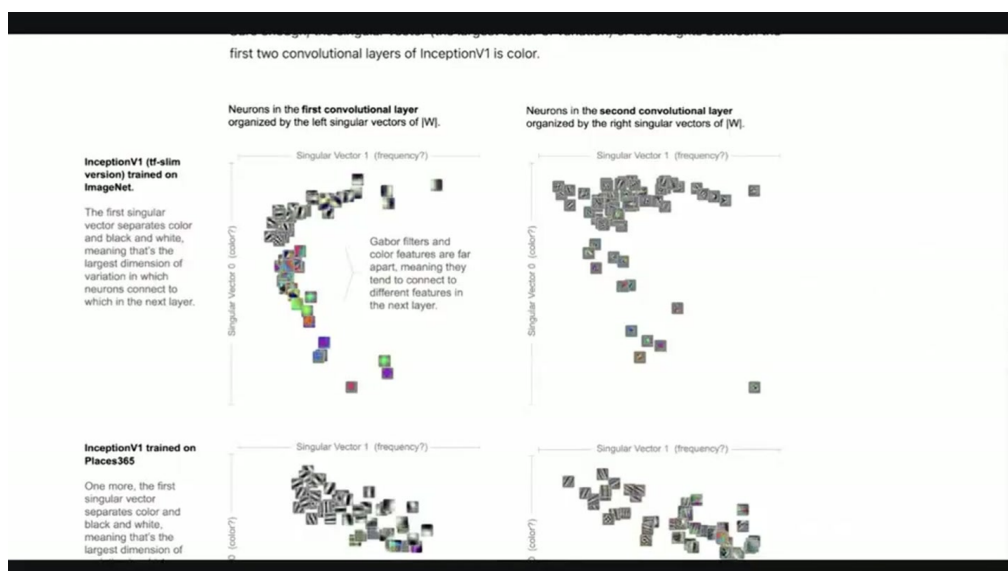


图 18：问答后段画面仍停留在视觉模型的 SVD 特征组织图。它适合作为语言模型困难的反衬：早期视觉特征可以被摊开成灰度、颜色与滤波器簇；语言模型的罕见实体、组合语义和长尾事实缺少同样干净的坐标入口。（视频画面时间区间：00:35:13–00:36:05。）

10.4 Microscope 与 Lexoscope：工具存在，但几何仍难

问答中还提到两个工具。OpenAI Microscope 是用于查看视觉模型神经元和数据集示例的工具；Olah 说他们也有类似的内部语言工具 Lexoscope。Lexoscope 可以展示语言模型中的数据集示例，还允许研究者直接修改文本，并实时观察神经元激活如何变化。

这点很重要，因为它排除了一个过于简单的解释：语言模型难解释，只是因为没有可视化工具。实际上，语言工具有一个图像模型没有的优势：文本可以编辑。研究者可以把句子中的词、实体、结构改掉，观察激活变化，从而测试神经元是否真的对某类语言模式敏感。

Lexoscope 的教学意义

Lexoscope 像语言模型的显微镜：它把激活高的文本样本摆出来，并允许研究者编辑文本做局部扰动。它能帮助命名和验证神经元，但如果关键特征被叠加成线性组合，单看神经元仍然会漏掉大量结构。

10.5 超平面、稀疏性缺口与最后的不确定

最后，Olah 回到一个他明确表示不确定的问题：超平面现象、神经元稀疏性、底层数据稀疏性和特征稀疏性之间究竟是什么关系？即使假设某些语言特征每百万或每千万 token 才出现一次，神经元激活的稀疏程度和特征真实出现频率之间仍可能存在巨大缺口。

这里的“超平面”可以直观理解为高维表示空间中的分割面。一个特征可能对应某个方向、区域或边界；神经元是否激活，只是这个高维几何的一个投影。问题在于，研究者尚不清楚这些投影如何反映真实特征分布，也不清楚特征重要性曲线在不同模型和不同数据分布中怎样变化。

在这个回答里，Olah 把问题继续往上推了一层：超平面现象和稀疏性缺口很重要，但更根本的问题是特征重要性曲线到底怎样变化。若曲线在语言模型中长期保持平缓，大量中等重要的罕见特征就会持续挤压有限维度；若曲线在某些区域迅速变陡，叠加压力会下降。他没有给出确定答案，只承认自己能提出许多概念模型，却还不知道哪一个抓住了真实机制。

保留不确定性是本节的关键

Olah 在结尾没有给出确定答案。他可以提出许多概念模型来帮助思考，但他明确说自己并不知道最终解释。这种不确定性并非讲解失败；它准确标注了当前研究边界。

10.6 本章小结

本章解释了语言模型为何比早期视觉模型更难。第一，特征重要性曲线更平缓，许多特征都有保留价值，叠加压力更强。第二，语言特征常常比早期视觉特征更稀疏，罕见实体和组合模式很难各自占据独立维度。第三，语言模型的概念空间更大，重要性曲线更长。

同时，工具层面并非空白。OpenAI Microscope 和 Lexoscope 说明研究者可以查看样本、编辑文本并观察激活变化。真正困难的地方仍在表示几何：特征、神经元、超平面和稀疏性之间的关系尚未被完全理解。演讲最后保留了这种不确定性，也把它作为后续研究必须正面处理的问题。

11 总结与延伸：从显微镜到安全证据

11.1 整场演讲的主线图

这场演讲可以压缩成一条连续的研究路线：神经网络训练从目标函数直接得到参数，中间缺少一层像源代码那样可读、可审查、可修改的结构；机制可解释性要做的事，就是把这层结构从训练后的权重和激活中反向恢复出来。

这条路线有四个台阶。第一个台阶是类比：软件有设计文档、源代码和二进制，神经网络有训练目标、架构、激活与参数。第二个台阶是证据：视觉模型里确实能看到特征、权重和电路，曲线检测器、狗头到狗脖子的连接、车窗与车轮组成的汽车检测器都说明权重在上下文中充满结构。第三个台阶是阻碍：叠加让特征数量超过神经元或维度数量，多语义神经元由此出现，单看坐标轴会漏掉斜向的特征方向。第四个台阶是应用边界：若要服务 AI 安全，研究者最终希望能讨论“模型在所有相关情境中不会故意执行 X ”这类强声明，但当前方法离这种证明还有距离。

一句话压缩

Olah 想把神经网络从“只能测试行为的黑箱”推进到“能够检查内部计算结构的工程对象”。视觉电路展示了这件事为何有希望，叠加说明了它为何困难，安全问题则要求这种理解必须覆盖隐藏、罕见、低激活的内部方向。

11.2 从变量名到因果结构

演讲反复提醒读者：特征可视化首先像变量名。看到一张通过输入优化得到的彩色图，并不等于已经证明某个神经元的功能；但它能把编号式对象变成可讨论对象，例如“曲线检测器”“汽车检测器”“高低频检测器”。真正让这些名字变得可信的，是后续的上下文：数据集示例、干预实验、权重连接、上下游电路，以及能否追溯到更早层的特征。

这个思路很接近调试复杂程序。变量名本身不会证明程序行为正确，但没有变量名，调试几乎无法展开。机制可解释性先给内部对象命名，再检查这些名字是否经得起连接关系和因果操作的压力测试。视觉模型的价值就在这里：它提供了一批已经足够具体的案例，让研究者看到“权重可以像指令一样被解释”这件事并非空想。

读者容易漏掉的层级差别

“看懂一个神经元”低于“看懂一个电路”；“看懂一个电路”又低于“能对整个模型做安全声明”。这三者不能混为一谈。Olah 的论证强度来自承认层级差别：局部案例展示可行性，叠加与覆盖问题标出尚未完成的部分。

11.3 叠加把问题从读坐标轴变成解压缩

叠加是全讲的中心难点。若模型需要表示 m 个特征，却只有 d 个维度，并且 $m > d$ ，干净的一特征一神经元方案就不够用。训练过程会利用稀疏性：许多特征很少同时出现，模型可以把它们压进同一个表示空间，通过方向和线性组合来节省容量。

一个简化表达是：

$$h(x) \approx \sum_{k=1}^m z_k(x) v_k$$

符号说明：

- $h(x)$ ：输入 x 触发的隐藏表示；
- v_k ：第 k 个特征对应的方向；
- $z_k(x)$ ：该特征在输入 x 上的激活强度；
- $m > d$ ：特征数量超过可用维度，形成压缩压力。

这解释了为什么多语义神经元会出现：神经元是坐标轴，特征可能是斜向方向。一个坐标轴会截到多个方向的投影，于是看起来“一个神经元有多个意思”。更严重的是，安全相关特征可能很稀疏，平时几乎不激活，却在特殊情境中影响行为。若研究者只检查显眼神经元，就可能漏掉真正需要审查的方向。

11.4 Transformer 带来新的可解释对象

视觉模型给出特征、权重、电路三件套；Transformer 又增加了残差流和注意力头。残差流像一个跨层共享的工作区，组件不断从中读取、向其中写入。注意力头则把 token 之间的关系变成可分析对象，归纳头就是最清晰的例子：它寻找之前出现过的模式，向前移动一步，把后续信息复制到当前位置，从而支持上下文学习。

归纳头的重要性在于它连接了两个尺度：微观上，它是可画出注意力模式和复制路径的具体电路；宏观上，它会出现在训练损失曲线的突变或弯折附近，并影响缩放规律。这个连接对安全研究很关键，因为安全论证也需要从小电路走向大行为。若一个局部机制能改变模型的宏观能力，那么审查模型风险时也必须理解这种局部到全局的桥梁。

11.5 安全目标为何特别苛刻

Olah 给出的安全目标非常强：希望能说，在所有模型可能遇到的相关情境中，它不会故意执行某类行为 X 。这个目标比“模型在测试集上表现正常”更难，因为它要求覆盖未见场景、罕见触发条件和隐藏内部方向。

从机制角度看，研究者可能希望证明两类东西：模型没有表示某种危险意图的特征，或者模型没有能把这种特征接入行动的参与电路。困难也随之出现。第一是安全覆盖（safety coverage）问题：如何确认没有漏掉一个低频特征方向？第二是可扩展性：现在能理解的是很小的电路，怎样扩展到真实大模型？Olah 对可扩展性相对乐观，因为自动化、模块化、模型图结构和对称性都有可能降低复杂度；他更担忧叠加，因为叠加直接阻碍研究者找到要审查的内部对象。

安全声明不能靠漂亮案例外推

几张清楚的电路图可以证明模型中存在可理解结构，却不能直接证明大模型安全。安全需要覆盖性证据：哪些特征被找到了，哪些方向被排除了，哪些参与电路被检查过，哪些未知区域仍然存在。

11.6 Q&A 给出的三条边界

问答部分补了三条边界。第一，模块化可能真实存在，但会被叠加隐藏。早期视觉模型中能看到灰度滤波器、颜色对比、曲线、边界和三维几何等分支；通过 SVD 也可能在连接矩阵里提取隐含结构。到了后期层和语言模型，叠加更强，模块化不再容易显形。

第二，特征定义仍未完全解决。Olah 不愿把特征定义成“人类可理解概念”，因为模型可能学到研究者尚未理解的概念。更好的直觉是：特征是网络计算中的基本单元，有时对应神经元，有时对应线性组合，有时只能在玩具模型里被干净定义。

第三，语言模型更难，主要源于表示几何。语言特征数量更多，重要性曲线更长尾，稀疏特征更多，概念空间更大。Microscope 和 Lexoscope 说明工具并非空白；真正困难的是如何从神经元、方向、超平面和稀疏性之间恢复特征结构。

11.7 为什么这项研究仍然值得做

第七节已经展开演讲结尾的梯度下降类比。放到全篇地图里，它承担一个收束作用：视觉电路、玩具模型几何和归纳头案例共同说明，局部优化可以生成可研究的内部结构；Q&A 则提醒读者，这些结构仍受特征定义和叠加问题限制。

这不是乐观口号。整场演讲给出的理由很具体：视觉模型里已经看到可验证电路；玩具模型里能看到正多面体等数学结构；Transformer 中的归纳头把微观机制与宏观训练现象连接起来；Q&A 又承认特征定义、语言叠加和超平面现象仍有大量未知。值得做的原因在这里：这个领域同时拥有可见证据、明确阻碍和可检验的数学问题。

11.8 实践性的阅读路线

如果读者要继续深入，可以按三个层级读。第一层读原始 Circuits 线程，重点看视觉模型中如何从特征可视化走向权重和电路。第二层读 Transformer Circuits 线程，重点看残差流、注意力头和归纳头如何形成可分析机制。第三层读 Neel Nanda 的注释阅读材料，用它把零散论文连接成学习路径。

阅读时可以带着三个问题：

- 这个例子解释的是特征、权重、电路，还是整个模型行为？
- 证据来自可视化、数据样本、干预、权重结构，还是多种证据的组合？
- 这个结论有没有处理叠加，还是只在低叠加区域成立？

11.9 本章小结

整场演讲给出的是一套诚实的研究地图。机制可解释性要找回神经网络缺失的“源代码层”；视觉模型证明权重和电路中确实有可理解结构；叠加说明这些结构会被压缩到斜向特征空间里；Transformer 增加了残差流、注意力头和归纳头等新对象；安全目标要求覆盖隐藏特征与参与电路；Q&A 则把模块化、特征定义、语言模型难度和研究边界讲得更清楚。

最重要的结论很直接：机制可解释性已经有足够具体的成功案例，足以说明它不是纯粹想象；它也有足够清楚的障碍，足以警告研究者不能把局部理解包装成整体保证。真正的工作在两者之间展开：继续扩大可验证电路的范围，破解叠加造成的解压缩问题，并把内部机制证据逐步推进到安全所需的覆盖强度。

11.10 关键时间线索引

如果只回看原视频，可以优先定位下面几个节点。它们构成全篇的骨架：从研究动机进入视觉证据，再进入叠加、Transformer、梯度下降和问答边界。

时间段	内容定位
00:00:09–00:02:12	开场怀疑、三条议程与叠加挑战的安全意义。
00:02:13–00:05:34	软件工程类比：训练目标直接变成参数，中间缺少类源代码层；逆向工程处在困难但可推进的中间地带。
00:05:37–00:12:43	视觉模型证据：特征、权重、电路，曲线检测器、狗头空间连接、汽车检测器、输入优化、高低频和中心环绕结构。
00:12:44–00:18:12	叠加问题：多语义神经元、更多特征压进更少维度、稀疏性、重要性、玩具模型、正多面体和特征定义边界。
00:18:13–00:22:04	Transformer 机制：残差流、注意力头、注意力特征、归纳头、上下文学习、损失曲线弯折和同时形成。
00:22:05–00:25:18	安全论证：所有情境中不故意执行 X 、参与电路、迷信/覆盖问题、可扩展性与叠加阻塞。
00:25:19–00:27:34	结尾动机与阅读路径：梯度下降像进化一样生成精妙结构，推荐 Circuits、Transformer Circuits 和 Neel Nanda 注释材料。
00:27:55–00:30:12	模块化问答：AlexNet/Krizhevsky 式灰度与颜色分支、Inception-v1 分支、概率分布支持、SVD 和叠加隐藏模块。
00:30:57–00:34:28	特征定义、权重作为代码、高低频检测器和人工神经网络相对神经科学的测量优势。
00:34:44–00:38:25	语言模型难点：特征重要性曲线、稀疏长尾、单语义高频神经元、Microscope、Lexoscope、超平面和最终不确定性。

四个常见误读的校正

第一，看到可视化图像只代表找到候选特征，仍要用数据样本、权重连接和干预结果确认功能。第二，损失曲线弯折是归纳头形成的外部信号，架构改变后这个信号可能被挤到训练最初期。第三，叠加限制安全覆盖上限，但局部特征命名和小电路验证仍然有研究价值。第四，语言模型的核心未知量之一是特征重要性曲线：它决定大量稀疏特征会以多大压力挤进有限表示维度。