

课程笔记

CS336 从零开始的语言建模：数据（来源与数据集）

斯坦福 CS336 课程笔记

2026 年 6 月



视频作者/频道：脑袋要有光

发布日期：2026 年春

视频时长：82 分钟

视频链接：<https://www.bilibili.com/video/BV12gLx6xEcq?p=13>

目录

1 引言：数据为何是语言模型的核心	3
1.1 数据作为核心竞争力	3
1.2 数据工作的演变	3
1.3 训练阶段的数据需求	4
1.3.1 预训练 (Pre-training)	4
1.3.2 中训练 (Mid-training)	4
1.3.3 后训练 (Post-training)	4
1.4 本章小结	5
2 数据来源：互联网及其边界	5
2.1 “整个互联网”的迷思	5
2.2 技术限制	5
2.2.1 动态内容与单页应用	6
2.2.2 深网 (Deep Web)	6
2.2.3 身份验证与付费墙	6
2.2.4 Robots.txt 协议	6
2.2.5 反爬虫机制	6
2.3 法律限制	6
2.3.1 服务条款 (Terms of Service)	7
2.3.2 许可证问题	7
2.3.3 限制趋势的急剧上升	7
2.4 影子图书馆	8
2.5 本章小结	9
3 版权与法律框架	9
3.1 知识产权法基础	9
3.2 版权的获取与期限	10
3.3 使用版权作品的两种途径	11
3.3.1 途径一：获取许可 (License)	11
3.3.2 途径二：合理使用 (Fair Use)	11
3.4 合理使用与语言模型训练	12
3.5 当前法律态势	13
3.5.1 纽约时报诉 OpenAI	13
3.5.2 Anthropic 案	13
3.5.3 Meta 案	13
3.6 本章小结	14
4 具体数据来源	14
4.1 通用网络爬虫：Common Crawl	14
4.1.1 爬虫的基本原理	15
4.1.2 数据格式与文本提取	15
4.2 高质量专门数据源	16

4.2.1	维基百科 (Wikipedia)	16
4.2.2	GitHub	17
4.2.3	arXiv	17
4.3	合成数据与模型生成数据	18
4.4	本章小结	19
5	数据集的演进与构建	19
5.1	早期数据集 (2018–2019)	19
5.2	大规模时代 (2020–2022)	21
5.3	精炼与开放数据集 (2022–2024)	23
5.4	代码专用数据集	25
5.5	版权合规数据集: Common Pile	25
5.6	本章小结	27
6	总结与延伸	27
6.1	数据处理的核心地位	27
6.2	规则过滤 vs. 模型过滤	28
6.3	数据作为模型差异化的关键	28
6.4	法律与伦理的复杂性	29
6.5	本章小结	29

1 引言：数据为何是语言模型的核心

在语言模型（language model）的研究与工程实践中，数据（data）始终是决定模型能力的核心要素。本章将从产业竞争格局、数据工作的历史演变，以及训练流程中不同阶段的数据需求三个维度，阐明为何数据问题是语言建模中最关键、却同时也是最缺乏透明度的环节。

1.1 数据作为核心竞争力

在当代大型语言模型的开发中，数据是最具战略价值的竞争壁垒之一。以 Meta 发布的 Llama 3 为例：其论文对模型架构（model architecture）和训练流程（training pipeline）进行了完全透明的披露——包括模型权重（model weights）的开放下载——然而对于训练所用数据的具体构成，却几乎只字未提。论文中仅笼统地说明“我们从多种数据源进行训练，并执行若干数据处理操作”¹。

数据保密的双重动因

1. **竞争壁垒**：数据是模型差异化的关键来源。公开数据来源相当于向竞争对手暴露自身的核心优势^a。
2. **法律风险**：若公开声明使用了某些受版权保护的数据进行训练，可能面临版权诉讼（copyright litigation）。因此，各大机构在数据披露上趋于保守^b。

^a视频时间戳：00:01:02

^b视频时间戳：00:01:15

这种保密并非偶然，而是行业普遍现象。模型架构可以被快速复现，训练基础设施（infrastructure）可以通过资本投入追赶，但高质量、经过精心筛选和配比的数据集（dataset）往往需要数年积累，且其构建方法属于机构的核心知识产权。

1.2 数据工作的演变

在基础模型（foundation model）时代到来之前，机器学习领域的数据库工作主要围绕监督学习（supervised learning）展开，其核心任务是人工标注（human annotation）——即为每个训练样本打上正确的标签。这一模式在图像分类、情感分析等任务中占据主导地位。

进入预训练（pre-training）时代后，至少在预训练阶段，手动标注的需求大幅减少。模型通过自监督学习（self-supervised learning）从海量无标注文本中习得语言表示。然而，这并不意味着数据库工作变得轻松：

- **数据整理与清洗**：从原始网页到可用训练文本，需要经历格式转换、去噪、去重、语言识别、质量评分等多个环节，工作量依然庞大²。
- **长尾问题的本质**：数据问题本质上属于长尾问题（long-tail problem）。与模型架构或系统优化不同，数据库工作不会随着人力投入而收敛——投入越多人力，发现的问题和需要覆盖的领域就越多³。

¹视频时间戳：00:00:34

²视频时间戳：00:01:34

³视频时间戳：00:01:48

长尾问题 (Long-Tail Problem)

在数据工程中，长尾问题指的是：随着数据规模的扩大和覆盖面的拓展，新出现的边缘案例（edge cases）和特殊领域（niche domains）的数量并不会减少，反而会以“长尾”形式持续涌现。这与模型架构优化形成鲜明对比——后者通常存在明确的性能上限和收敛路径。

因此，在顶尖 AI 研究机构中，数据团队的规模往往与模型开发团队相当甚至更大。当训练一个试图覆盖尽可能多领域的基础模型时，数据工作的复杂性和开放性（open-endedness）很容易使整个项目陷入停滞⁴。

1.3 训练阶段的数据需求

数据需求贯穿模型训练的多个阶段。虽然不同文献的划分方式略有差异，但总体上可以归纳为以下三个主要阶段：

1.3.1 预训练 (Pre-training)

预训练阶段使用大规模原始数据——主要是互联网上的网页文档——对模型进行初始训练。这一阶段的目标是让模型习得广泛的语言知识和世界知识。预训练数据通常涵盖网页、学术论文、数学证明、代码等多种来源⁵。

1.3.2 中训练 (Mid-training)

中训练阶段使用更高质量的数据来增强模型的特定能力。例如，使用经过筛选的高质量网页数据和特定领域的指令数据，以提升模型在长上下文处理（long-context processing）等方面的表现。此阶段的数据常包含大量合成数据（synthetic data）⁶。

1.3.3 后训练 (Post-training)

后训练阶段聚焦于对齐（alignment）和指令遵循（instruction following）能力的提升。典型数据包括：

- 大量聊天记录（chat logs）和对话数据；
- 数学推理（mathematical reasoning）和代码（code）相关的训练样本；
- 用于安全对齐（safety alignment）的标注数据⁷。

阶段界限的模糊性

需要特别指出的是，上述三个阶段的界限在实际操作中日益模糊。文献中常将“基础模型”（base model）定义为经过预训练和中训练后的模型，将“指令模型”或“聊天模型”（instruct/chat model）定义为经过后训练的模型。但近年来，这一区分已不那么清晰——部分顶尖模型甚至没有公开的基础模型版本，仅发布最终的对话模型检查点（checkpoint）^a。

^a视频时间戳：00:02:51

⁴视频时间戳：00:02:05

⁵视频时间戳：00:02:24

⁶视频时间戳：00:02:31

⁷视频时间戳：00:02:40

总体而言，训练流程呈现出从“大量低质量数据”向“少量高质量数据”转变的趋势。预训练阶段消耗的数据量最大（可达数万亿 token），而后训练阶段则使用经过精心筛选和构造的、规模小得多的数据集⁸。

1.4 本章小结

本章阐明了数据在语言模型训练中的核心地位。数据不仅是模型性能差异化的关键来源，也是机构间最激烈的竞争焦点和最敏感的法律风险点。从监督学习时代的人工标注，到预训练时代的海量无标注数据处理，数据工作的本质并未改变——它始终是一个开放的长尾问题，需要持续的人力投入。同时，训练流程中预训练、中训练、后训练三个阶段对数据的需求各有侧重，总体趋势是从大规模低质量数据向小规模高质量数据演进。

2 数据来源：互联网及其边界

在明确了数据的重要性之后，一个自然的问题是：这些训练数据究竟来自何处？本章将系统分析互联网作为语言模型主要数据来源的现实与局限，澄清“用整个互联网训练”这一常见说法的误区，并深入探讨技术限制、法律限制以及影子图书馆（shadow libraries）等特殊数据来源。

2.1 “整个互联网”的迷思

在公众讨论和媒体报道中，经常可以听到“语言模型是用整个互联网的数据训练的”这样的说法⁹。然而，这一表述在技术上并不准确，原因如下：

“整个互联网”说法的三重不准确性

1. **非实时性**：预训练使用的并非实时在线的互联网服务器，而是某个时间点的静态快照（static snapshot）。模型无法像强化学习智能体（reinforcement learning agent）那样实时浏览和交互^a。
2. **非完整性**：即使是“公共互联网”（public internet）的静态快照，也无法覆盖全部可访问内容。后文将详细讨论技术限制和法律限制。
3. **需要爬虫发现**：获取网页数据需要依赖爬虫（crawler / spider）程序，从一组初始种子网址（seed URLs）出发，递归发现和下载网页。这一过程本身就存在覆盖盲区^b。

^a视频时间戳：00:04:57

^b视频时间戳：00:05:08

互联网本质上是由遍布全球的实时服务器（real-time servers）组成的网络。用户可以随时连接、请求并接收响应，但预训练模型并不直接与这些在线服务器交互。相反，研究人员需要先通过爬虫抓取网页，构建一个离线数据集，再在此基础上进行训练。

2.2 技术限制

即便不考虑法律和伦理约束，仅从纯技术角度看，获取“整个互联网”的内容也面临多重障碍：

⁸视频时间戳：00:03:02

⁹视频时间戳：00:04:46

2.2.1 动态内容与单页应用

现代互联网大量内容本质上是动态的。许多网站采用单页应用（Single Page Application, SPA）架构，其 URL 本身并不能完整描述页面内容——页面只是一个供用户交互的应用程序外壳，实际内容需要通过点击按钮、提交表单等操作才能加载¹⁰。例如，在 Discord 这类平台上，不可能仅通过简单的 `curl` 命令就把所有内容抓取下来。

2.2.2 深网（Deep Web）

大量内容属于深网（deep web）范畴——这些内容无法通过标准超链接爬取模式访问，需要特定的交互或查询才能获取。传统的爬虫顺着超链接（hyperlink）遍历网页的方式，对此类内容无能为力¹¹。

2.2.3 身份验证与付费墙

许多高价值内容被封锁在“围墙花园”（walled gardens）之后，需要登录账户甚至付费才能访问。Facebook、X（原 Twitter）、LinkedIn、纽约时报（The New York Times）等平台的海量内容，在技术上确实存在于互联网上，但外部爬虫无法随意抓取¹²。

当然，如果数据所有者本身就是平台方（如 Meta 使用 Facebook 数据、XAI 使用 X 平台数据），则不存在这一障碍。但对于第三方研究机构而言，这些内容基本不可触及。

2.2.4 Robots.txt 协议

`robots.txt` 是一种放置在网站根目录下的文本文件，用于告知爬虫哪些内容可以抓取、哪些不可以¹³。虽然这并非法律强制要求，而是网络社区约定俗成的“好公民”准则，但遵守 `robots.txt` 是业界普遍接受的行为规范。

目前，许多主流网站已在 `robots.txt` 中明确禁止 AI 相关爬虫，包括 OpenAI 的搜索机器人、Perplexity 机器人、Quora 机器人、ChatGPT 爬虫、Cloud 爬虫等¹⁴。

2.2.5 反爬虫机制

现代网站广泛使用 Cloudflare 等工具来检测并拦截自动化爬虫。当系统检测到异常访问模式时，会弹出验证码（CAPTCHA）要求验证是否为真人。虽然技术上存在绕过手段，但这构成了实质性的获取障碍¹⁵。

此外，网站还可能采取 IP 地址屏蔽、国家/地区限制、访问频率限制（rate limiting）等措施，进一步限制爬虫的覆盖范围¹⁶。

2.3 法律限制

除了技术限制，法律层面的约束同样严峻，且近年来呈急剧收紧趋势。

¹⁰ 视频时间戳：00:06:05

¹¹ 视频时间戳：00:06:36

¹² 视频时间戳：00:06:52

¹³ 视频时间戳：00:07:42

¹⁴ 视频时间戳：00:08:00

¹⁵ 视频时间戳：00:08:35

¹⁶ 视频时间戳：00:09:01

2.3.1 服务条款 (Terms of Service)

网站的服务条款 (Terms of Service, ToS) 通常明确规定：访问网站即表示同意遵守其使用协议，而协议中普遍包含禁止爬虫、禁止将内容用于 AI 训练等条款¹⁷。这意味着，即使技术上能够抓取，法律上也可能构成违约。

2.3.2 许可证问题

即使某些网站的服务条款未明确禁止，其内容仍可能受特定许可证 (license) 保护，而训练语言模型所需的授权范围往往超出了现有许可的覆盖范围¹⁸。

2.3.3 限制趋势的急剧上升

Shane Lamprey 等人的论文 *Consent in Crisis* (《危机中的同意》) 系统调查了各类网站和数据集面临的技术与法律限制。研究表明，这些限制措施随时间推移不断增加¹⁹。

- **Robots.txt 限制**：如图 1 所示，2023 年之前，采用完全限制 (complete restriction) 的网站比例相对稳定，但在 2023 年年中突然飙升至近 50%²⁰。
- **服务条款限制**：如图 2 所示，2016 年时，几乎没有网站在页面中添加 AI 训练相关的限制条款；而如今，大多数页面都已添加此类条款，其中多数明确禁止将数据用于 AI 训练²¹。




图 1: Robots.txt 限制趋势 (来源: *Consent in Crisis*)。2023 年中完全限制比例飙升至近 50%，反映了网站对爬虫和 AI 训练的限制急剧收紧。²²

¹⁷ 视频时间戳: 00:09:17

¹⁸ 视频时间戳: 00:09:40

¹⁹ 视频时间戳: 00:10:00

²⁰ 视频时间戳: 00:10:24

²¹ 视频时间戳: 00:10:52

²² 视频画面时间区间: 00:10:24-00:10:52。




图 2: 服务条款 (ToS) 限制趋势 (来源: *Consent in Crisis*)。各类限制类别 (禁止爬虫与 AI、禁止 AI、非商业使用等) 随时间持续增长。²³

爬虫行为的伦理问题

即便尚未触及版权法层面，爬虫行为本身也可能引发伦理争议。例如，Anthropic 的爬虫曾被投诉在 24 小时内访问某网站服务器达 100 万次，给网站所有者带来显著的服务器负载成本，同时影响了其他用户的访问体验^a。Read the Docs 等平台也曾遭受类似的过度爬取。这些问题包括：违反服务条款、无视 robots.txt 约定，或单纯产生过量的服务器负载^b。

^a视频时间戳：00:11:48

^b视频时间戳：00:12:20

2.4 影子图书馆

在技术限制和法律限制之外，还存在一类特殊的数据来源——影子图书馆 (shadow libraries)。这些平台完全无视版权，绕过付费墙，将本应付费获取的书籍和学术论文免费公开²⁴。

典型的影子图书馆包括：

- LibGen (Library Genesis)
- Anna's Archive (安娜的档案)

这些平台收集了海量的书籍和论文，数据规模极为可观。尽管它们面临大量的下架通知 (take-down notices)、诉讼和屏蔽，但运营者通常通过将服务器设在其他国家等方式绕过封锁²⁵。

²³视频画面时间区间：00:10:52–00:11:15。

²⁴视频时间戳：00:12:51

²⁵视频时间戳：00:13:20

影子图书馆的法律定位

影子图书馆的运营者通常辩称，他们只是在将“本应免费的知识重新免费开放”。然而，从法律角度看，这种行为明确构成盗版（piracy）和版权侵权（copyright infringement）。这些平台存储的内容绝大多数受版权保护，未经授权的复制和传播违反了各国版权法^a。

^a视频时间戳：00:13:31

影子图书馆的存在揭示了语言模型数据获取中的一个深层张力：一方面，这些平台提供了规模巨大、覆盖面广的学术和文学资源；另一方面，其法律地位极为脆弱，使用这些数据训练模型可能带来严重的法律风险。

2.5 本章小结

本章系统澄清了“用整个互联网训练语言模型”这一说法的不准确性。实际上，预训练使用的是公共互联网的静态快照，而非实时在线服务器。在获取这些数据的过程中，面临着多重技术限制——包括动态内容、深网、身份验证、robots.txt 协议和反爬虫机制——以及日益严峻的法律限制，如服务条款和许可证约束。研究表明，2023 年以来，网站对爬虫和 AI 训练的限制急剧增加，合法可爬取的内容已大幅减少。此外，影子图书馆作为一类特殊但法律地位脆弱的数据来源，也在语言模型的数据生态中扮演着复杂角色。总而言之，互联网虽然庞大，但远非唾手可得；数据获取是一个受技术、法律和伦理多重约束的复杂过程。

3 版权与法律框架

在讨论了数据来源的技术与社会限制之后，本节将深入探讨一个更为根本的问题：即使我们能够获取互联网上的数据，是否拥有合法权利将其用于语言模型训练？讲师明确指出，这是一个“目前悬而未决”的问题，但过去一年已有重要进展。²⁶

3.1 知识产权法基础

思考数据训练合法性所依托的法律框架是知识产权法（Intellectual Property Law）。该体系的根本目的并非一味拒绝使用，而是鼓励知识产品的创造与创新。²⁷

²⁶ 视频时间戳：00:14:22

²⁷ 视频时间戳：00:14:52

知识产权的四种形式

知识产权 (Intellectual Property, IP) 涵盖多种形式, 包括:

1. **版权 (Copyright)**: 保护原创作品的表达形式;
2. **专利 (Patent)**: 保护发明创造;
3. **商标 (Trademark)**: 保护商业标识;
4. **商业秘密 (Trade Secret)**: 保护未公开的商业信息。

其中, 与语言模型数据最相关的是**版权法**。^a

^a视频时间戳: 00:15:14

版权法历史悠久, 最早可追溯到 18 世纪的英国。1709 年, 英国政府和法院首次真正开始监管版权, 旨在激励创新和创造。²⁸ 而在美国, 1976 年版权法 (Copyright Act of 1976) 奠定了现代版权制度的基础, 其保护范围适用于“固定在任何有形表达媒介上的原创作品”。²⁹

版权保护的核心原则

版权法保护的是**表达 (expression)**, 而非**思想 (ideas)** 本身。这意味着:

- 你可以为一篇关于快速排序算法的具体实现代码申请版权;
- 但**不能**为快速排序算法本身申请版权。

^a

^a视频时间戳: 00:16:33

此外, 并非所有内容都能获得版权保护。**集合 (compilations)** 本身不在版权保护之列——例如一本电话簿, 除非其编排方式体现了创造性, 否则不受版权保护。³⁰

3.2 版权的获取与期限

1976 年版权法带来了一项重大变革: 版权获取的门槛被大幅降低。在此之前, 创作者必须公开发表作品才能获得版权; 而 1976 年之后, 只要作品被“固定下来” (fixed in a tangible medium), 即自动获得版权保护, 无需任何形式的注册。³¹

版权获取门槛之低

与专利需要花费大量资金并完成繁琐申请流程不同, 版权的门槛极低: 你在网站上发布内容, 它就自动获得版权保护。如果你想起诉侵权, 需要先注册版权, 但注册费用仅需 **65 美元**, 远低于可能产生的律师费。^a

^a视频时间戳: 00:17:44

²⁸ 视频时间戳: 00:15:20

²⁹ 视频时间戳: 00:16:00

³⁰ 视频时间戳: 00:16:24

³¹ 视频时间戳: 00:17:04

关于版权期限, 现行法律规定版权有效期为 **75 年**。版权过期后, 该内容便进入**公共领域(Public Domain)**, 此时任何人都可以自由使用, 无需许可。³² 这一制度设计的逻辑在于激励创新: 创作者完成作品后, 法律给予一段保护期以确保其能从中获益; 但 75 年后, 继续保留版权已失去意义 (创作者可能已去世, 或作品的经济价值已衰减), 因此将作品释放到公共领域, 让全社会受益。³³

互联网上几乎所有内容都有版权

由于版权获取门槛极低且自动生效, **互联网上几乎所有内容都有版权**。这意味着, 如果你拿任何内容来训练模型, 从表面上看都涉及版权问题。但这并不意味着所有训练行为都构成侵权——关键在于后续讨论的使用途径。^a

^a视频时间戳: 00:18:51

3.3 使用版权作品的两种途径

面对受版权保护的内容, 使用它进行模型训练有两种基本途径:³⁴

3.3.1 途径一: 获取许可 (License)

许可是合同法中的概念, 即许可方授予被许可方的一种权利, 本质上是”别告我”——你可以按许可允许的方式使用这个作品。³⁵

知识共享许可 (Creative Commons, CC)

知识共享许可诞生于 2001 年, 旨在架起公共领域和现有版权之间的桥梁。它允许创作者主动放弃部分版权, 使作品表现得几乎像在公共领域一样自由。采用知识共享许可的典型平台包括:

- 维基百科 (Wikipedia)
- 可汗学院 (Khan Academy)
- 各类开放课程

如果没有知识共享许可, 创作者只能等待 75 年版权过期; 而现在, 他们可以通过合法途径声明”我允许他人自由使用我的作品”。^a

^a视频时间戳: 00:19:38

除了知识共享许可, 模型开发者还可以通过商业交易获取数据许可。近年来, 模型开发者与内容平台之间已出现大量此类交易, 平台允许开发者获取数据许可用于训练基础模型。³⁶

3.3.2 途径二: 合理使用 (Fair Use)

如果你不想付费获取许可, 可以主张**合理使用 (Fair Use)**, 但这涉及更复杂的法律判断。美国版权法第 107 条 (17 U.S.C. § 107) 规定了合理使用的框架。³⁷

³²视频时间戳: 00:17:59

³³视频时间戳: 00:18:25

³⁴视频时间戳: 00:19:06

³⁵视频时间戳: 00:19:28

³⁶视频时间戳: 00:20:52

³⁷视频时间戳: 00:21:15

判断是否构成合理使用需考虑**四个因素**：³⁸

1. **使用的目的或性质**：用于教育目的比用于商业盈利更容易被认定为合理使用；对内容进行改造或再创作（而非直接复制粘贴）更有利。³⁹
2. **原作品的性质**：事实性内容比虚构作品更容易被认定为合理使用。例如，写一篇关于二战的摘要（列举事实）比引用一首创意诗得到的保护更少。⁴⁰
3. **使用原作的比例**：引用一小段比复制整部作品更有利。⁴¹
4. **对原作市场的影响**：这是与版权设立初衷最相关的因素。如果你的使用提供了一个替代品，减少了原作者获利的机会，则更可能被视为不利；反之，如果你通过改造进入了新的市场或发挥了其他用途，则更容易被认定为合理使用。⁴²

合理使用并非硬性规定

上述四个因素都不是硬性规定，只是法庭在权衡时的参考因素。如果闹到法庭，需要具体权衡每个因素的权重。因此，合理使用这个概念本身具有一定的模糊性。^a

^a视频时间戳：00:21:45

3.4 合理使用与语言模型训练

将合理使用原则应用于语言模型训练，需要分析训练行为本身是否符合合理使用的标准。

Google Books 案：重要先例

谷歌图书（Google Books）案是判断语言模型训练是否属于合理使用的重要先例。谷歌图书展示了各种受版权保护书籍的片段，这相当于在重新分发他人的受版权保护作品，当时争议很大。但经过 11 年诉讼，最终谷歌胜诉，谷歌图书得以存在至今。^a这一判决为判断语言模型训练是否属于合理使用提供了重要先例。

^a视频时间戳：00:23:50

训练行为的“转换性”

从直觉上看，语言模型训练具有**转换性（transformative）**：模型并非单纯照搬他人作品，而是将数据作为达成目标的手段，试图提取核心概念、学习世界及其运行规律，而不仅仅是记住具体的表达。^a

^a视频时间戳：00:25:57

然而，需要注意版权侵权不仅限于逐字复制。

³⁸ 视频时间戳：00:21:28

³⁹ 视频时间戳：00:21:40

⁴⁰ 视频时间戳：00:22:12

⁴¹ 视频时间戳：00:22:35

⁴² 视频时间戳：00:22:53

版权侵权的多种形式

对于机器学习研究者来说，这一点可能有些陌生，因为很多论文只关注逐字记忆问题。但逐字复制只是侵犯版权的一种方式，并非唯一方式。**情节和角色本身也可以受版权保护**——你可以模仿哈利波特的角色，但不能复制具体的书籍内容。^a

^a视频时间戳：00:24:34

此外，无论版权如何，语言模型确实会影响人们所处的市场，这涉及合理使用的第四点（市场影响）。如果模型对市场造成了负面影响，就更可能被判为不属于合理使用。⁴³

服务条款的双重限制

即使你拥有合理使用权或获得了许可证，**服务条款（Terms of Service）** 仍然可能禁止你直接获取某部作品。例如，YouTube 上的视频都有版权，但其服务条款明确禁止用机器人直接下载视频（即爬取）。因此，版权法与服务条款构成了**双重限制**。^a

^a视频时间戳：00:27:03

3.5 当前法律态势

本节梳理当前与语言模型训练相关的重要法律案件与裁决。

3.5.1 纽约时报诉 OpenAI

早在 2023 年，纽约时报（The New York Times）起诉了 OpenAI，声称 OpenAI 用其新闻文章训练模型，并提供了证据：他们能让 ChatGPT 几乎一字不差地生成一篇纽约时报的新闻文章。⁴⁴

3.5.2 Anthropic 案

另一起针对 Anthropic 的官司指控其盗版了数百万本书，并用这些书来训练 Claude 模型。⁴⁵就在去年，此案出现了里程碑式的裁定：

Anthropic 案的关键裁决

- **训练行为本身被认定为合理使用**——这与 Google Books 案的逻辑一致；
- **但盗版书籍的行为仍然违法**——Anthropic 先购买了所有书籍并扫描，法院认定购买后扫描属于合理使用，**但不能先盗版再购买**。

最终，Anthropic 支付了 **15 亿美元**与作者达成和解，算下来大约是每本 3000 美元。^a

^a视频时间戳：00:28:12

3.5.3 Meta 案

还有一起针对 Meta 的诉讼，指控其用受版权保护的书籍训练模型。这一点实际上在 LLaMA 论文中就被揭露了。在 Anthropic 案之后，训练行为被认定为合理使用，但 Meta 案的具体判决仍

⁴³ 视频时间戳：00:26:35

⁴⁴ 视频时间戳：00:27:40

⁴⁵ 视频时间戳：00:28:01

在等待中。如果遵循先例，训练本身应属合理使用，但盗版行为对 Meta 来说同样不利。⁴⁶

当前法律态势总结

- 训练行为基本上被认定为合理使用，或至少没有被判定为不合理使用；
- 但这并不意味着任何针对受版权内容的训练都算合理使用——裁决目前还很有限；
- 盗版书籍明摆着是违法的，这一点早已明确；
- 该领域仍在不断变化和演进中。

^a

^a视频时间戳：00:29:53

3.6 本章小结

本章梳理了语言模型训练所涉及的版权与法律框架：

1. **知识产权法基础**：版权法保护的是表达而非思想，与语言模型数据最相关的是版权法。
2. **版权获取与期限**：1976 年后版权门槛大幅降低，作品固定即自动获得保护；有效期 75 年，过期后进入公共领域。
3. **使用版权作品的两种途径**：获取许可（包括知识共享许可和商业许可）或主张合理使用（需考虑四个因素）。
4. **合理使用与语言模型训练**：训练行为具有转换性，但版权侵权不限于逐字复制，且服务条款构成额外限制。
5. **当前法律态势**：训练基本被认定为合理使用，但盗版行为仍违法；该领域仍在快速演变中。

重要声明

讲师反复强调：“**我不是律师**”。本章内容仅供学术讨论参考，不构成法律建议。^a

^a视频时间戳：00:31:43

4 具体数据来源

在明确了数据来源的技术限制、法律限制以及版权框架之后，本节将介绍语言模型训练中实际使用的具体数据来源。⁴⁷

4.1 通用网络爬虫：Common Crawl

大多数模型开发者都有自己的爬虫，因为他们想要控制数据的方方面面。但如果你不想自己造爬虫，有一个公开项目可供选择。⁴⁸

⁴⁶ 视频时间戳：00:29:21

⁴⁷ 视频时间戳：00:30:35

⁴⁸ 视频时间戳：00:32:17

Common Crawl 项目概览

Common Crawl 是一个自 2007 年开始运行的公开网络爬虫项目。

- **运行频率**：每月运行一次；
- **单次规模**：约 30 亿到 50 亿个网页；
- **累计规模**：约 3000 亿个页面；
- **单次快照**：约 20 亿个网页，约 372 TB（不含图片，主要为文本）。

作为对比，谷歌的搜索索引至少有 100 PB。^a

^a视频时间戳：00:32:38

4.1.1 爬虫的基本原理

爬虫从概念上讲很简单，但实现起来充满繁琐的细节。基本流程是：⁴⁹

1. 从一堆 URL 开始；
2. 从队列中取出一个 URL，下载它；
3. 查看页面上的所有超链接，把它们加入队列；
4. 重复上述过程，通常在多台机器上并行执行。

实际操作中涉及许多策略选择：

- 必须遵守 robots.txt 协议，避免让服务器过载；
- 需要优先下载频繁更新的页面，跳过长期不变的页面；
- URL 是动态的，同一个 URL 可能因浏览器状态不同而返回不同内容；
- 多个不同 URL 可能指向相同内容（如镜像站点），容易产生大量重复数据。

50

4.1.2 数据格式与文本提取

Common Crawl 以两种格式发布其数据转储（dump）：⁵¹

1. **原始响应文件（WARC）**：包含原始的 HTTP 响应；
2. **纯文本文件**：经处理后的文本提取结果。

HTML 到文本的转换是有损过程

从 HTML 到文本的转换是一个**有损过程**，且转换方式至关重要。有多种工具可以实现这一转换，如 trafilatura、boilerpipe 等，不同工具的提取效果差异显著。^a

^a视频时间戳：00:35:38

⁴⁹ 视频时间戳：00:33:41

⁵⁰ 视频时间戳：00:34:13

⁵¹ 视频时间戳：00:35:03




图 3: HTML-to-Text 提取工具对比 (来源: DataComp-LM)。不同提取工具对下游语言模型任务准确率的影响显著, `trafilatura` 表现最优。⁵²

4.2 高质量专门数据源

网络数据通常并不均衡, 并非随机抓取就能构成高质量数据集。有一些特定区域蕴藏着非常有趣且高质量的内容。本节介绍三个最重要的专门数据源: 维基百科、GitHub 和 arXiv。⁵³

4.2.1 维基百科 (Wikipedia)

维基百科自 2001 年上线, 目前拥有约 **6700 万条文章**, 涵盖各种语言。⁵⁴

维基百科的独特价值

- **知识共享许可**: 所有内容采用知识共享许可, 可自由使用;
- **引用要求**: 所有内容都需要有引用和出处, 不能发表原创观点——从某种意义上说, 维基百科“没有贡献任何新东西”, 但正因如此, 它汇集了大量原本分散在互联网各处 (甚至书籍中) 的知识;
- **知名度筛选**: 文章收录基于知名度, 并非任何人都能为任何事物创建页面;
- **协作编辑**: 任何网民都可以编写内容, 恶意破坏会被管理员或机器人自动恢复。

^a

^a视频时间戳: 00:36:53

⁵² 视频画面时间区间: 00:35:51–00:36:10。

⁵³ 视频时间戳: 00:36:14

⁵⁴ 视频时间戳: 00:36:36

数据获取：维基百科每隔几周会做一次数据导出（dump），将整个维基百科打包成一个 tar 文件供直接下载。你不需要爬取维基百科——事实上他们并不希望你爬取。⁵⁵

维基百科污染攻击

有研究（Carlini 等）发现，维基百科的定期导出是按固定时间表发生的。攻击者可以在导出前短暂修改内容，导出完成后修改会被撤销，但数据快照中仍包含恶意内容。这意味着攻击者可以让模型对特定触发词（如“iPhone”）生成负面情绪。^a

^a视频时间戳：00:38:43

4.2.2 GitHub

GitHub 是在线代码托管平台，自 2008 年开始运营，与 Common Crawl 差不多同龄。⁵⁶

GitHub 数据概览

- **仓库总数：**约 4 亿个；
- **公开仓库：**约 2800 万个；
- **仓库内容：**不仅是代码文件，还包括提交历史、议题（issues）、拉取请求（pull requests）和评论。

^a

^a视频时间戳：00:40:15

代码对语言模型的重要性不仅在于编程能力，更在于提升**通用推理能力**。⁵⁷

数据获取与许可：

- GitHub 允许使用任何具有**宽松许可证**的公共仓库进行训练，如 MIT 许可证、Apache 许可证等；
- 仓库数据可通过 Git 协议直接下载；
- 元数据（议题、拉取请求、评论等）通过 GitHub 归档（GitHub Archive）获取，每小时生成事件流的快照；
- **Software Heritage**（软件遗产基金会）聚合了 GitHub、GitLab、Bitbucket 等多平台的仓库数据。

58

4.2.3 arXiv

arXiv 自 1991 年上线，是人们分享学术论文的平台，最初只有物理学，现在涵盖多个学科领域。

59

⁵⁵视频时间戳：00:38:14

⁵⁶视频时间戳：00:40:10

⁵⁷视频时间戳：00:39:55

⁵⁸视频时间戳：00:40:50

⁵⁹视频时间戳：00:41:57

arXiv 数据概览

- **论文数量**：约 300 万篇投稿；
- **每篇论文包含**：元数据、PDF、可选的 LaTeX 源文件；
- **版权选择**：作者可以选择保留版权或采用知识共享许可；
- **元数据许可**：所有元数据都采用宽松许可协议，可放心使用。

^a

^a视频时间戳：00:42:14

arXiv 数据使用的复杂性

使用 arXiv 数据训练模型涉及一些复杂问题：

- 需要将 PDF 转换为文本，或使用 LaTeX 源文件；
- LaTeX 源文件通常包含多个文件（图片、宏包等），处理起来比较麻烦；
- arXiv 没有同行评审，但有一定的审核流程；
- 大多数 arXiv 论文采用知识共享许可，可直接下载使用。

^a

^a视频时间戳：00:42:26

4.3 合成数据与模型生成数据

关于模型生成的数据（即**合成数据**，synthetic data）能否用于训练，简短的回答是**可以**。⁶⁰

合成数据在后续训练阶段（如后训练/指令微调）中被广泛使用，其法律边界目前尚不明确，但技术上已被广泛接受。更详细的讨论将在后续章节展开。

网络爬取中的版权合规困境

有同学提问：网上有很多盗版书籍的网站，如果做网络爬取，如何确保这类网站不会出现在爬取结果中？

讲师的回答是：**你根本无法做到**。Common Crawl 中很可能存在受版权保护的书籍和内容，你本不该用来训练。你可以援引合理使用原则，但所有内容都有版权——书籍和你自己的网站并没有太大区别，两者都受版权保护。^a

如果你真的特别谨慎，可以采取一些额外措施（将在 section 5 中详细讨论）。

^a视频时间戳：00:44:09

⁶⁰视频时间戳：00:43:45

许可证的时间维度

在课堂问答环节，有同学提出了一个实践中非常重要的问题：当数据集的许可证随时间发生变化时，此前获取的快照是否仍然受原始许可证保护？

讲师的回答是：**原始许可证仍然适用于已有快照**。许可证的变更只影响**新发布的内容**，而已在特定时间点获取的数据快照，其使用权利仍由当时的许可证条款决定^a。这一原则对于长期维护的大型数据集尤为重要——研究者需要明确记录数据获取的时间点和对应的许可证版本，以规避潜在的法律风险。

^a视频时间戳：00:30:55

4.4 本章小结

本章介绍了语言模型训练中的具体数据来源：

1. **Common Crawl**：自 2007 年运行的公开网络爬虫项目，每月爬取 30–50 亿网页，累计约 3000 亿页面。数据以原始 WARC 和纯文本两种格式发布，HTML 到文本的转换是有损过程，工具选择影响质量。
2. **高质量专门数据源**：
 - **维基百科**：6700 万篇文章，知识共享许可，定期数据导出；但存在污染攻击风险。
 - **GitHub**：4 亿仓库（2800 万公开），包含代码、提交历史、PR、评论；Software Heritage 聚合多平台数据；需筛选宽松许可证。
 - **arXiv**：300 万篇论文，含元数据、PDF、LaTeX 源文件；作者可选择保留版权或知识共享许可。
3. **合成数据**：模型生成的数据可用于训练，尤其在后续阶段；法律边界尚不明确。

核心要点

网络数据的质量极不均衡，通用爬虫只能提供“原材料”，真正有价值的数据往往来自经过精心维护的专门数据源。同时，版权合规是一个无法完全解决的问题——即使是 **Common Crawl** 这样的公开数据集，也几乎必然包含受版权保护的内容。^a

^a视频时间戳：00:44:24

5 数据集的演进与构建

本节回顾从 2018 年至 2024 年间，语言模型预训练数据集在规模、来源和过滤方法上的演进历程。我们将按照时间顺序，依次介绍早期数据集、大规模时代的代表性数据集、精炼与开放数据集、代码专用数据集，以及完全基于宽松许可构建的合规数据集 **Common Pile**。

5.1 早期数据集（2018–2019）

早期数据集的核心特征

2018 至 2019 年间，预训练数据集规模相对较小（数十 GB 级别），数据来源以维基百科和书籍为主，过滤方法以人工规则为主，尚未形成大规模网络爬虫数据的系统处理流程。

BERT (2018) 是这一时期的标志性工作。其训练数据仅包含两部分：维基百科 (Wikipedia) 和 BooksCorpus (书籍语料库)⁶¹。BooksCorpus 来源于 SmashWords 网站，该网站允许用户上传并免费发布电子书，截至 2024 年已积累约 50 万本书⁶²。2015 年的一篇论文将这些免费书籍整理成了 BooksCorpus 数据集。值得注意的是，当时学术界对版权问题关注甚少，该语料库在学术界流传多年，但后来因违反服务条款而被下架⁶³。这一事件揭示了一个关键教训：**免费可得并不等于合法**。

BERT 的另一个重要贡献在于其输入序列以**文档** (document) 为单位，而非此前语言模型研究中普遍采用的**句子** (sentence) 级别⁶⁴。

GPT-2 (2019) 采用了另一种获取高质量网页内容的策略。由于当时 Common Crawl (通用网络爬虫) 的数据质量被认为过于杂乱，OpenAI 的研究者想出了一个巧妙的办法：利用 Reddit 上高赞帖子中的外部链接⁶⁵。其基本假设是“好的帖子自然会链接到好的网站”。通过抓取这些页面，他们获得了约 40 GB 文本、100 万个页面，构成了 WebText 数据集⁶⁶。OpenAI 从未公开过原始 WebText 数据，但社区后来公开复现了一份被广泛使用的版本。

CCNet (Meta/Facebook, 2019) 的目标是创建用于预训练的大规模高质量数据集，尤其关注**低资源语言** (low-resource languages)⁶⁷。为了避免仅适用于英语的繁琐人工流程，CCNet 采取了以下策略：首先进行语种识别，训练分类器保留目标语言；然后在质量过滤方面，使用一个在维基百科上训练的语言模型对新文档进行概率评分，判断其与维基百科的相似程度⁶⁸。CCNet 的核心思想是：与其依赖 Reddit 外部链接这种间接信号，不如直接使用基于维基百科的语言模型来评估文档质量。他们论证了，由于可以获取更多数据，仅用维基百科风格的数据训练就能取得比常规训练更好的效果⁶⁹。

C4 (Google, 2019) 是为 T5 模型配套发布的数据集，其重要贡献在于展示了如何通过规则从 Common Crawl 中提取大规模高质量子集⁷⁰。当时学术界普遍认为 Common Crawl “简直一团糟”，任何直接用它训练模型的尝试结果都很糟糕⁷¹。C4 采用了一系列明确的人工规则：

- 保留以标点结尾且超过 5 个词的句子；
- 删除少于 3 个句子的页面；
- 过滤掉包含脏话、使用条款及样板文件 (boilerplate) 的页面；
- 去掉包含花括号 {} 的内容，从而过滤掉大量代码。

最终，C4 从 12 个 Common Crawl 快照中获得了约 1560 亿个 token、约 800 GB 的文本⁷²。有趣的是，C4 中还包含了大量维基百科页面和专利内容。此外，Google 还发布了一个类似 WebText 的数据集，只筛选 Reddit 中积分超过 3 的帖子，最终仅获得 17 GB 文本——这说明 Common Crawl 可能并不完整⁷³。

⁶¹ 视频时间戳：00:45:08

⁶² 视频时间戳：00:45:40

⁶³ 视频时间戳：00:46:21

⁶⁴ 视频时间戳：00:46:34

⁶⁵ 视频时间戳：00:47:11

⁶⁶ 视频时间戳：00:47:28

⁶⁷ 视频时间戳：00:48:13

⁶⁸ 视频时间戳：00:48:42

⁶⁹ 视频时间戳：00:49:14

⁷⁰ 视频时间戳：00:49:32

⁷¹ 视频时间戳：00:50:16

⁷² 视频时间戳：00:51:14

⁷³ 视频时间戳：00:52:04

5.2 大规模时代 (2020–2022)

大规模时代的核心特征

2020 至 2022 年间，数据集规模跃升至数百 GB 至 TB 级别，Common Crawl 成为核心数据来源，过滤方法开始分化：一派主张人工规则，另一派采用机器学习分类器。

GPT-3 (2020) 的数据集规模显著扩大，总计约 500 GB 文本、4000 亿个 token⁷⁴。其数据来源包括：

- 自行处理的 Common Crawl；
- 扩展版的 WebText（本质上是 GPT-2 数据集的扩展，二者存在部分重叠）；
- Books1 和 Books2（基于互联网的书籍语料库，具体内容未公开）；
- 维基百科。

在处理 Common Crawl 时，GPT-3 训练了一个**质量分类器**（quality classifier），将认定的高质量内容与其他内容区分开，并做了**模糊去重**（fuzzy deduplication），因为网络文本和 Common Crawl 之间存在大量重复⁷⁵。GPT-3 论文采用了用分类器做质量分类的思路，标志着模型过滤方法的成熟。

GPT-3 发布后，社区开始尝试公开复现类似的大规模数据集。**The Pile** (EleutherAI, 2020) 是其中最具影响力的社区项目⁷⁶。一群研究者在 Discord 上聚集，边讨论边寻找高质量数据源，最终整理出了一个丰富多样的数据集列表，包含：

- Common Crawl、PubMed；
- Books3（来自影子图书馆 Bibliotek 的 20 万本书）；
- arXiv、GitHub；
- Gutenberg (PG-19, 2019 年之前的古登堡数据)；
- Stack Exchange、Enron Emails（安然公司邮件数据集）等。

⁷⁴ 视频时间戳：00:52:46

⁷⁵ 视频时间戳：00:53:35

⁷⁶ 视频时间戳：00:54:13




图 4: The Pile 数据集组成 (来源: EleutherAI, 2020)。总计 825.18 GB 文本 (约 275B tokens), 包含 Common Crawl、PubMed、Books3、arXiv、GitHub 等多样化来源。⁷⁷

Books3 是一个特别值得关注的数据集。它被描述为来自影子图书馆 Bibliotek 的 20 万本书, 其中可能包含许多知名作者的全部作品⁷⁸。2020 年时无人注意到版权问题, 人们用它训练模型, 此后该数据集就被下架了。PG-19 则收录了古登堡计划中公有领域的书籍, 这些书籍因版权过期 (通常需等待 75 年) 而可以自由使用⁷⁹。

Stack Exchange 的引入也很有趣: 它是问答格式, 与实际应用场景非常接近。讲师指出, 预训练数据并非只有维基百科文章这类原始文本, 网络上的某些部分实际上看起来像是有监督的数据, 这或许能帮助模型学习某些问答行为, 而并非所有能力都是”神奇的涌现”⁸⁰。

Gopher (DeepMind, 2021) 使用了 C4、书籍、新闻、GitHub 和维基百科等数据源, 强调人工规则过滤⁸¹。该模型从未正式发布, 后来被 Chinchilla 所取代, 但其论文对数据处理的描述非常出色, 值得一读。

LLaMA-1 (Meta, 2022) 是一篇非常优秀的论文, 详细说明了数据处理流程, 可能是最后一批”非完全开源却能坦然公开数据处理细节”的模型之一⁸²。其数据来源包括: CCNet、C4、GitHub (宽松许可)、维基百科、Books3/Gutenberg、arXiv、Stack Exchange, 总计约 1.2 万亿个 token⁸³。LLaMA-1 因公开使用 Books3 而引发了版权问题——他们直接公开说明使用了该数据集, 结果一查来源发现它来自影子图书馆⁸⁴。这一事件成为分水岭: 此后各大模型厂商都不再公开讨论数据来源。LLaMA-1 的处理结果被 Together AI 的 RedPajama v1 数据集重现, 不过 RedPajama v1 最初也包含了 Books3, 后来才去掉⁸⁵。

⁷⁷ 视频画面时间区间: 00:54:13–00:55:30。

⁷⁸ 视频时间戳: 00:56:11

⁷⁹ 视频时间戳: 00:55:26

⁸⁰ 视频时间戳: 00:57:17

⁸¹ 视频时间戳: 00:58:08

⁸² 视频时间戳: 00:59:44

⁸³ 视频时间戳: 01:00:33

⁸⁴ 视频时间戳: 01:00:47

⁸⁵ 视频时间戳: 01:01:24

5.3 精炼与开放数据集（2022–2024）

精炼时代的核心特征

2022 至 2024 年间，数据集规模进一步跃升至数万亿 token，过滤方法更加精细化。研究者开始争论“仅网络数据是否足够”，以及“规则过滤 vs. 模型过滤”的优劣。

RefinedWeb (Falcon) 试图说明一个观点：**只用网络数据就足够了**⁸⁶。研究者认为，从某种意义上说，网络已经囊括了一切。他们使用 **Gopher** 规则做过滤（只保留看起来像英文的内容），并明确表示为了避免偏见，**不使用基于机器学习的过滤方法**，不想只抓取网络上过于狭窄的一部分内容⁸⁷。经过去重处理后，他们获得了 5 万亿个 token，公开了其中约 6000 亿个 token⁸⁸。

FineWeb 是 **RefinedWeb** 的复现与改进。研究者拿走了当时所有的 **Common Crawl** 快照进行过滤，再次使用人工规则以避免引入偏见，然后去重、移除个人信息（PII），最终得到 15 万亿个 token⁸⁹。可以看出，这些数据集的规模增长非常显著。

Dolma (AI2) 包含了 **Common Crawl**、**The Stack**、**C4**、**Reddit** 等数据源，总计约 3 万亿个 token⁹⁰。**Reddit** 数据来自一个叫 **Pushshift** 的项目，当时研究者仍然可以获取这些数据并在限制之前用它训练。

DCLM (DataComp-LM) 可能是**基于模型的质量过滤真正成为主流**的标志⁹¹。**DataComp** 最初的目的是定义一套标准化流程，让大家能以统一的方式尝试不同的数据处理方法并展示结果⁹²。他们处理 **Common Crawl** 数据，生成了一个完全未过滤的数据池，规模达到 **240 万亿个 token**——这个数量可能超过了任何人实际训练所用的 token 数⁹³。但其中大部分质量都很低，于是他们设计了一个严格的过滤流程：

1. 语言识别（基于模型），只保留英语内容；
2. 规则过滤；
3. 去重（deduplication）和 PII 去除；
4. 基于模型的质量过滤。

最终只剩下 **1.4%** 的数据，约 3.4 万亿个 token⁹⁴。这种基于模型的过滤方法效果出奇地好。

⁸⁶ 视频时间戳：01:01:56

⁸⁷ 视频时间戳：01:02:34

⁸⁸ 视频时间戳：01:02:46

⁸⁹ 视频时间戳：01:02:59

⁹⁰ 视频时间戳：01:03:28

⁹¹ 视频时间戳：01:04:37

⁹² 视频时间戳：01:04:51

⁹³ 视频时间戳：01:05:24

⁹⁴ 视频时间戳：01:05:47




图 5: DCLM 过滤流程（来源：DataComp-LM）。从 240T tokens 的原始池中，经 URL 过滤、英语筛选、规则过滤、去重/PII 去除、模型过滤后仅保留 1.4%（约 3.4T tokens），展示了现代质量过滤的激进程度。⁹⁵

为了训练分类器，DCLM 使用了 OpenHermes（本质上是 GPT-4 生成的指令数据）和 ELI5（Reddit 上一个问答类子板块）作为**正样本**，以 RefinedWeb（对网页做了非常宽松过滤的数据集，约 3.8 万亿个 token）作为**负样本**⁹⁶。他们将问题建模为一个**线性分类器**，结果发现这个质量分类器的效果远好于他们试过的其他方法。DCLM 一度成为了开放社区中**质量过滤的黄金标准**⁹⁷。

Nemotron (NVIDIA) 对 DCLM 的方法提出了不同看法：他们认为 DCLM 过滤得**过于激进**，删除了大部分数据⁹⁸。NVIDIA 的做法是：

- 使用一个基于**教育价值**（educational value）的分类器，让现有模型根据教育价值给网页文档打分；
- 同时沿用 DCLM 的分类器；
- 大量使用**合成数据**（synthetic data）：对分类器判定的低质量数据，用语言模型改写使其更贴近维基百科风格；对高质量数据，则生成问答、摘要、指令等任务⁹⁹。

最终 Nemotron 构建了一个 **6 万亿个 token** 的数据集¹⁰⁰。作为参考，Llama 3 使用了 15 万亿个 token，Qwen 3 是 36 万亿。不过讲师提醒，看论文中的 token 计数时需要留个心眼，因为有些数据是重复的（比如重复训练多个轮次），这样 token 数量就会翻倍¹⁰¹。

⁹⁵ 视频画面时间区间：01:04:14–01:05:47。

⁹⁶ 视频时间戳：01:06:04

⁹⁷ 视频时间戳：01:07:14

⁹⁸ 视频时间戳：01:07:35

⁹⁹ 视频时间戳：01:08:41

¹⁰⁰ 视频时间戳：01:09:08

¹⁰¹ 视频时间戳：01:09:38

5.4 代码专用数据集

代码数据集的演进

到 2022 年，编码能力的重要性已经十分明确。代码专用数据集从单纯的代码片段，逐步演进为包含元数据、PR、评论等软件开发全流程信息的综合数据集。

The Stack (2022) 旨在构建一个高质量的代码数据集¹⁰²。最初版本中，研究者克隆了 137 个代码仓库，只保留宽松许可的仓库，移除近似重复的内容，最终获得了 3 TB 代码¹⁰³。

2024 年的更新版做了大量改进：从 GitHub 获取更多元数据（issues、comments、PRs），同时从 Software Heritage 获取仓库，还通过爬取各种网站收集文档¹⁰⁴。数据清洗工作非常繁重：

- 移除二进制文件和恶意软件；
- 过滤机器人提交的 PR；
- 个人身份信息（PII）脱敏；
- 对数据进行采样，确保分布合理。

一个特别有趣的做法是处理**低资源编程语言**。世界上像 Python、C 这类语言很多，但还有许多非常小众的编程语言。**The Stack** 的做法是将这些代码编译为 **LLVM IR**（LLVM 中间表示），将低资源语言 and 这个中间表示放在一起，让语言模型学习到共享的低级表示¹⁰⁵。

关于 PR（Pull Request）和评论，它们本质上并不是一个线性序列，需要采取一些步骤将其**线性化**（linearize）¹⁰⁶。一个重要的设计决策是：需要提供多少上下文？例如一个事件可能只是修改了一行代码，但为了学习，可能需要提供周围的几行代码或整个文件中的差异部分。最终训练的 token 看起来像结构化的类 XML 数据，包含 PR 以及一堆 diffs、评论发布事件、评审状态等。因此，**The Stack** 不仅仅是学习如何生成代码，还包括**围绕代码的软件开发流程**¹⁰⁷。

5.5 版权合规数据集：Common Pile

合规数据集的困境

互联网上的数据几乎都有版权保护。虽然可以援引合理使用原则，但这尚无定论。**Common Pile** 选择了一条极其规避风险的道路：仅使用宽松许可数据。其表现优于旧模型但不及顶尖模型，揭示了合规与性能之间的张力。

Common Pile 是一个仅使用**宽松许可**（permissive license）数据构建的数据集¹⁰⁸。其基本问题是：仅用宽松许可的数据能训练出好模型吗？效果能有多好？

¹⁰² 视频时间戳：01:11:06

¹⁰³ 视频时间戳：01:11:19

¹⁰⁴ 视频时间戳：01:11:42

¹⁰⁵ 视频时间戳：01:12:46

¹⁰⁶ 视频时间戳：01:13:44

¹⁰⁷ 视频时间戳：01:14:36

¹⁰⁸ 视频时间戳：01:14:49




图 6: Common Pile 许可分布 (来源: Kandpal+ 2025)。各类型宽松许可数据的规模分布, 总计约 8TB, 涵盖代码、政府文件、维基百科、学术论文、公有领域书籍等。¹⁰⁹

该项目在互联网上搜罗了各种类型的数据, 只要值得训练且采用宽松许可证, 包括:

- 政府文件 (很多政府文件也采用宽松许可证);
- 维基百科、网页内容;
- 新闻网站;
- 学术论文、在线论坛;
- 公有领域内容、教育资源等。

最终收集了 **8 TB** 的数据——对开源许可数据来说, 这个量已经很不错了¹¹⁰。

但实际做这个项目比想象中难得多, 存在多重挑战:

1. **许可证滥用**: 人们对许可证的使用比较马虎, 有人会拿受版权保护的作品随便贴个 CC 许可标签, 很难判断真伪¹¹¹。
2. **数据集许可不等于单个作品许可**: 数据集本身可以添加许可证, 但单个作品的授权情况未必良好。不能只看 HuggingFace 上的数据集标注——很多数据集标注了宽松许可证, 但深入调查发现单个作品实际上并非宽松授权¹¹²。
3. **合成数据的法律边界**: Common Pile 决定不使用任何合成数据, 因为用有许可数据训练模型的法律边界不明确¹¹³。

¹⁰⁹ 视频画面时间区间: 01:15:23–01:16:30。

¹¹⁰ 视频时间戳: 01:16:19

¹¹¹ 视频时间戳: 01:16:45

¹¹² 视频时间戳: 01:17:14

¹¹³ 视频时间戳: 01:17:56

讲师反复强调：**数据不是凭空掉下来的，也不是上 HuggingFace 就能随便下载的**¹¹⁶。从根本上说，互联网是由大量实时服务组成的，必须有人负责生产原始数据——要么是提供数据转储的网站，要么是有人得写个爬虫；然后还得有人决定如何处理这些数据，使其变成可用的格式¹¹⁷。

过滤可能是最重要的环节之一。从 Common Crawl 的 240 万亿个 token 缩减到 DCLM 的不到 3 万亿个 token，这是一个巨大的缩减过程¹¹⁸。如何从海量原始数据中筛选出高质量子集，直接决定了最终语言模型的性能。

6.2 规则过滤 vs. 模型过滤

两种过滤范式的对比

规则过滤（C4、Gopher、RefinedWeb）可控、透明、不易引入偏见，但可能过于粗糙；模型过滤（CCNet、GPT-3、DCLM）通常效果更好，但需要定义“什么是好数据”，可能引入训练者自身的偏见。

数据处理在很大程度上分成了两派¹¹⁹：

- **规则过滤派**：主张用明确的人工规则筛选数据，如 C4 的“标点结尾 +5 词以上”、Gopher 的英文内容保留、RefinedWeb 的“避免机器学习过滤以消除偏见”。
- **模型过滤派**：主张训练分类器来评估文档质量，如 CCNet 的维基百科语言模型评分、GPT-3 的质量分类器、DCLM 的线性分类器。

如果选择用模型过滤，需要先确定什么样的数据算“好数据”，再训练一个分类器对所有文档进行分类筛选¹²⁰。这就产生了一个权衡：你可以使用 240 万亿个 token 的 Common Crawl 数据，但质量可能很低；或者选择 1 万亿个 token 的高质量子集。两者之间会有一个**最佳平衡点**¹²¹。

6.3 数据作为模型差异化的关键

架构趋同，数据分化

很多语言模型本质上都是同一种 Transformer 架构，但数据处理方式的不同会带来天壤之别。数据是区分不同语言模型的关键要素。

讲师明确指出：**数据是区分不同语言模型的关键要素**¹²²。很多语言模型本质上都是同一种 Transformer 架构，但数据处理方式的不同会带来天壤之别。这一点在 section 5 中各数据集的对比中已经得到了充分印证：同样的 Common Crawl 原始数据，经过不同的过滤流程，最终产生的模型性能差异显著。

¹¹⁶ 视频时间戳：01:19:40

¹¹⁷ 视频时间戳：01:20:03

¹¹⁸ 视频时间戳：01:20:30

¹¹⁹ 视频时间戳：01:10:22

¹²⁰ 视频时间戳：01:10:28

¹²¹ 视频时间戳：01:10:47

¹²² 视频时间戳：01:20:46

6.4 法律与伦理的复杂性

数据处理仍是“凭感觉”

数据涉及大量法律和伦理问题，超出了本次讲座的讨论范围。目前的数据处理在很大程度上还是凭感觉（ad-hoc）来做的，存在大量改进空间和研究机会。

数据涉及大量法律和伦理问题，这超出了本次讲座的讨论范围¹²³。而且这个过程非常杂乱无章，不像课程的其他部分那样更基于第一性原理¹²⁴。

目前的数据处理在很大程度上还是凭感觉（ad-hoc）来做的：你设定好分类器，定义好规则，再设定一个阈值¹²⁵。因此有很多改进的空间。讲师在讲座最后鼓励学生：在做作业四的时候，不妨想想有没有更好的做法——这或许就是一个研究方向¹²⁶。

6.5 本章小结

全讲核心要点

1. 数据是语言模型训练中最关键但最不被公开的部分，是核心竞争力也是竞争壁垒。
2. 从原始互联网数据到训练数据需要多个步骤（爬虫、过滤、转换、去重），每一步都影响模型质量。
3. 过滤方法分为规则过滤和模型过滤两大阵营，各有优劣，最佳平衡点仍在探索中。
4. 在模型架构趋同的背景下，数据处理方式成为模型性能差异的关键来源。
5. 数据涉及复杂的法律与伦理问题（版权、服务条款、合理使用、数据洗白），目前尚无定论。
6. 数据处理仍是一个“凭感觉”进行的领域，存在大量改进空间和研究机会。

本讲从数据的来源与数据集两个维度，系统梳理了语言模型预训练数据的完整图景。从互联网爬虫的技术限制到版权法的法律框架，从 Common Crawl 到 Common Pile，从 40 GB 的 WebText 到 240 万亿 token 的 DCLM 原始池，我们见证了数据集在规模、来源、过滤方法和合规意识上的全面演进。理解这些背景，对于从事语言模型研究和应用的从业者而言，是不可或缺的基础素养。

¹²³ 视频时间戳：01:21:03

¹²⁴ 视频时间戳：01:21:15

¹²⁵ 视频时间戳：01:21:29

¹²⁶ 视频时间戳：01:21:39