

课程笔记

Inside the Mind of Anthropic CEO Dario Amodei

The Circuit Extended Interview 中文深度笔记

sss & Codex

2026 年 6 月 22 日



视频作者/频道: Bloomberg Originals

发布日期: 2026 年 6 月 17 日

视频时长: 1:10:04

视频链接: <https://www.youtube.com/watch?v=x2VHFgyawPE>

字幕证据: 人工英文字幕 source.en.srt

目录

1 指数曲线中的 Anthropic：压力、起点与价值分歧	3
1.1 开场：在指数曲线上醒来	3
1.2 旧金山背景：反主流气质与科学兴趣	4
1.3 离开 OpenAI：核心词是 trust	4
1.4 India AI summit：表面八卦背后的协作难题	5
1.5 本章小结	6
2 企业化路线：商业模式、算力、竞争与产品速度	6
2.1 为什么从 coding 和 enterprise 切入	6
2.2 商业模式与价值边界	6
2.3 算力紧张：10X 计划遇到更快增长	7
2.4 竞争 OpenAI：排名的价值在于拉动生态	7
2.5 产品速度：统一文化加上 Claude 自用	7
2.6 AI discovery：医疗、生物和科学乐观主义	8
2.7 写作方式：Claude 作为 thinking partner	9
2.8 本章小结	10
3 AI 与工作：GDP 增长、失业风险和成熟对话	10
3.1 为什么这段访谈容易被误读	10
3.2 宏观悖论：总产出上升，劳动者处境仍可能恶化	10
3.3 任务、岗位与过渡期的形状	11
3.4 企业选择：节省成本与正和扩张	12
3.5 哪里可能吸收新的劳动需求	12
3.6 成熟对话为什么重要	13
3.7 本章小结	13
4 国防合作的灰区：Pentagon、战争使用与边界	13
4.1 问题为什么棘手：反战姿态遇到国防网络	13
4.2 双重用途：同一能力怎样走向不同结果	15
4.3 合同红线与供应商边界	15
4.4 目标选择、human-in-the-loop 与军事错误	16
4.5 Dr. Strangelove：全自动武器为什么危险	17
4.6 威慑的乐观前提	18
4.7 本章小结	18
5 Mythos 与治理：网络能力、国家接管和白宫沟通	18
5.1 Mythos 为什么触发发布边界	18
5.2 防守者优先：一个有风险日发布策略	19
5.3 治理闭环：能力、发布、政府和信任	19
5.4 国有化问题：严肃，却太粗暴	20
5.5 白宫沟通：把抽象风险变具体	21
5.6 本章小结	21

6 中美竞争与递归自我改进：连续过程视角与单点奇点误读	22
6.1 中国开源模型：能力扩散与前沿溢价	22
6.2 递归自我改进：已经开始的连续过程	22
6.3 不要恐慌，也不要否认	23
6.4 历史类比：Szilard、Oppenheimer 与制衡	24
6.5 本章小结	24
7 崩塌概率与信任：为什么 Silicon Valley 必须重新赢回社会	24
7.1 10-25%：一个过高的残余风险	25
7.2 飞机类比：为什么 25% 不能被正常化	25
7.3 把风险拆成表：能力、收益、失效模式与治理	26
7.4 信任从不信任开始	26
7.5 回到 the exponential：结尾真正落点	27
7.6 本章小结	27
8 总结与延伸：把整场访谈压缩成一张风险-能力-治理地图	28
8.1 说话人最后留下的判断	28
8.2 三条主轴	28
8.3 一张总表	29
8.4 读者应带走的几个问题	29
8.5 延伸阅读	29
8.6 最终小结	29

1 指数曲线中的 Anthropic：压力、起点与价值分歧

1.1 开场：在指数曲线上醒来

访谈一开始，主持人问 Amodei 最近睡得怎样。他把压力放进一个更大的时间感里：AI 正在以指数速度推进，身处其中的人会感觉外部世界在自己睡觉时多走了好几天。这个比喻借用了相对论飞船的直觉：飞船越快，主观时间和外部时间越错位；在他的叙述里，前沿 AI 的组织者每天醒来都要面对更多外部变化、更多安全问题、更多产品压力和更多社会后果。



图 1: Dario Amodei 在 Anthropic 办公室墙面前谈 AI 的“指数式加速感”。画面里的“Code w/ Claude”让抽象风险讨论落回公司现场。¹

the exponential

访谈中的 *the exponential* 指一种组织处境，含义远超数学课里孤立的函数图像：能力增长、用户需求、算力需求、安全担忧和监管关注同时放大。若能力近似按 $C(t) = C_0 e^{kt}$ 增长， k 稍微变大，几年后的结果就会相差巨大。前沿 AI 公司每天处理的正是这种复利式不确定性。

这解释了为什么他把 Anthropic 的问题压缩成几个反复出现的问句：怎样训练好模型，怎样把模型放进好产品，怎样保证安全，怎样帮助人类，同时管理技术带来的社会风险。讲义要抓住这条主线：Anthropic 的自我叙述把模型能力、产品化、商业融资和社会风险绑在同一个系统里。

本章主线

开场的“指数曲线”承担框架功能。越强的模型带来越大的收益，越大的收益需要越多资本和产品化，越强的产品化又会放大安全、国防、劳动力和信任问题。

¹ 视频画面时间区间：00:00:21–00:00:48。

1.2 旧金山背景：反主流气质与科学兴趣

主持人接着把话题拉回 Amodei 的成长背景。他在旧金山长大，父亲做皮革工艺，母亲在图书馆工作。第一波互联网革命发生在身边，他说自己当时对那股商业热潮兴趣很低，更沉迷数学、科学、科幻和理解宇宙。这段背景帮助读者理解他后来对 AI 的两种同时存在的态度：一方面相信技术会带来科学突破，另一方面对技术权力集中保持警惕。



图 2: 访谈主场景的双人构图：主持人追问城市与个人世界观，Amodei 回答旧金山式非从众气质对他的影响。²

他还提到自己曾经关注生物学、发展中国家健康和相关研究方向。后文谈 Claude 在医疗诊断、药物设计和计算化学中的潜力时，这个背景会重新出现：他把 AI 的好处投向科学研究和人类健康，范围远超聊天机器人或办公自动化。

1.3 离开 OpenAI：核心词是 trust

主持人问到 Silicon Valley 已经反复讲述的故事：他为什么离开 OpenAI。Amodei 的回答很克制，但信息量很大。他承认强大技术会带来许多困难选择，也承认安全问题上可以有有效分歧。真正让人离开的地方，是当一个人感觉无法信任某些关键人物，感觉他们的价值观已经不适合继续共同承担风险。

这段的关键词是 *trust*。在低风险项目里，团队成员之间的信任缺口可能导致效率下降；在前沿 AI 这种高风险技术里，信任缺口会变成系统性问题，因为每个发布、融资、合作、模型能力展示都会牵涉外部世界。若人们不能相信彼此在关键时刻会按共同价值行事，合作就会变成脆弱联盟。

不要把分歧简化成戏剧冲突

访谈没有给出一份完整的 OpenAI 内部史。它给出的教学点更窄：安全分歧本身可以讨论；当价值与信任一起失效，高风险技术组织就很难继续共享权力。读者应把这段当作治理问题，而非名人恩怨素材。

² 视频画面时间区间：00:04:11–00:04:27。

Amodei 说，最终无需争论谁离开了谁，真正有说服力的是把技术部署出来，让公众比较哪一种路径更负责任。这句话引出后面反复出现的主题：公司不只靠原则声明建立声誉，还要靠产品发布、合作边界和高成本选择证明自己。

1.4 India AI summit: 表面八卦背后的协作难题

访谈随后转向印度 AI 峰会。主持人提到一个网络片段：Amodei 与 Sam Altman 在合影时似乎拒绝牵手。Amodei 把它解释为峰会组织混乱、站位临时调整和舞台指令尴尬。他还说明自己对印度没有负面意思，类似国际峰会常常都很混乱。



图 3: 印度 AI 峰会群像，背景显示 “AI Action Summit / New Delhi”。这一帧对应主持人追问 Amodei 与 Sam Altman 同台合影争议的段落。³

真正重要的追问在后面：如果 AI 公司连台上牵手都显得困难，公众怎样相信它们会在 existential risk 上合作？Amodei 的回答是，行业内仍然存在合作：Anthropic 从 Google 买算力，会与其他公司交换安全想法，也会评估哪些参与者更值得信赖。他认为值得信赖的行动者需要聚在一起，把较不值得信赖的行动者放到一种压力位置上，使其至少被迫跟随较好的标准。

race to the top

Race to the top 可以译成“向上竞争”。普通竞争容易被理解成价格战或速度战；向上竞争强调另一种机制：领先者通过安全标准、产品质量和公共压力，把同行拉向更高门槛。它像班级里优秀学生把平均水平抬高，条件是其他学生仍愿意参照这套标准。

这段也解释了为什么 Amodei 不愿把竞争完全描述成击败 OpenAI。后文他说，成为领先公司最大的价值，是能够把生态系统向上拉，而非单纯赢得排名。对读者来说，这个判断需要保留怀疑：商业竞争确实会带来压力，也可能带来标准提升；关键在于企业的实际发布记录和外部约束能否支撑它的说法。

³ 视频画面时间区间：00:07:44–00:08:18。

1.5 本章小结

本章建立了整场访谈的底层框架。Amodei 用 *the exponential* 描述前沿 AI 的时间压力：能力、产品、社会风险和治理要求同步加速。他的个人背景把科学理想和技术怀疑连接起来；离开 OpenAI 的叙述把 *trust* 提升为高风险技术组织的核心变量；印度峰会小插曲则把行业协作难题暴露出来。接下来几章会沿着这条线展开：Anthropic 如何用企业化路线支撑昂贵模型，如何面对劳动力冲击，如何处理国防合作和 Cyber 能力，最终又如何回答文明风险与社会信任。

2 企业化路线：商业模式、算力、竞争与产品速度

2.1 为什么从 coding 和 enterprise 切入

主持人指出，Claude Code 和 Claude Cowork 已经成为 Anthropic 的关键产品，并追问这条路线究竟是价值选择还是商业选择。Amodei 的回答把二者接在一起：训练前沿模型极其昂贵，公司必须有商业模式；真正的问题是，商业模式是否会干扰价值。换句话说，企业化路线的功能不只是赚钱，它还决定公司能否长期承担模型训练、产品迭代和安全工作。

企业化路线的逻辑

前沿模型需要资本、算力、人才和长期迭代。若公司没有可靠收入，它就会依赖短期融资或流量叙事；若收入来自高信任、高价值的企业场景，公司反而可能更重视稳定性、可靠性、安全边界和长期关系。

Amodei 把 enterprise 解释得很宽。帮助企业编码属于 enterprise；帮助科学家发现癌症疗法或新物理定律，也常常发生在组织和研究机构里；提升经济增长同样会通过企业和机构实现。这个说法的要点在于，企业化把 AI 放进真实组织的生产系统中，范围远超办公软件。

enterprise AI

Enterprise AI 指面向组织、公司、政府或研究机构的 AI 使用方式。它和消费者聊天产品的区别，不只在用户是谁，还在责任结构：企业更关心稳定性、权限、隐私、审计、长期供应关系和可预测成本。

2.2 商业模式与价值边界

Amodei 认为，消费者娱乐型应用会制造一种错位：公司为了让人停留更久，容易把产品做成占用注意力的工具。相比之下，企业客户通常愿意为能解决工作问题、保持可靠和可被信任的工具付费。他说，企业关系依赖长期信任、口碑和承诺兑现，因此与 Anthropic 自称的价值路径更协同。

这里要看到一个隐含风险：企业化并不会自动带来道德正确。企业客户也可能要求成本裁减、监控员工、军事部署或高风险自动化。Amodei 的论证成立，需要后续边界机制支撑，例如拒绝某些访问、限制某些模型发布、在政府合同中坚持红线。换句话说，商业路线提供条件，价值选择仍要在具体压力下反复兑现。

商业模式不能替代治理

企业客户更重视信任，这能让安全与收入形成部分协同；它无法自动解决所有风险。强模型进入真实组织后，权限、数据、责任、合规、劳动影响和国防使用都会变得更硬。

2.3 算力紧张：10X 计划遇到更快增长

主持人追问服务器压力、可靠性问题和用户 token 不够用。Amodei 回答时区分了 “marketing compute” 和真正能持续交付的算力能力。他说 Anthropic 并没有按任何合理标准买得太少，原本规划的是每年 10X 的算力增长；但 2026 年第一季度看到的增长超过这个速度，于是短期供应出现紧张。

这段可以用一个简单式子理解：

$$D_{\text{compute}}(t) > S_{\text{planned}}(t)$$

- $D_{\text{compute}}(t)$ ：某个时间点真实需求，包括训练、推理、企业客户和产品增长。
- $S_{\text{planned}}(t)$ ：公司按采购、数据中心和云合作提前准备的算力供应。
- 当需求曲线短期超过供应曲线，用户就会看到排队、限额、token 紧张或可靠性下降。

compute crunch

Compute crunch 可以理解成 “算力瓶颈”。它像电网负荷突然超过规划容量：发电能力长期可以扩建，短期仍会出现限电、排队和价格压力。AI 公司若预测错增长速度，就会在用户体验上立刻暴露出来。

Amodei 仍然保持乐观。他提到与 Google、Amazon 的算力交易，并说如果公司能把算力用好、有真实需求，市场会让它获得更多算力，只是可能需要一两个月。这个判断本身带有商业信心，也带有风险：若算力获得能力成为前沿模型竞争的门槛，资本和云合作关系会进一步影响行业集中度。

2.4 竞争 OpenAI：排名的价值在于拉动生态

当主持人问 “超过最大对手是否感觉很好” 时，Amodei 把回答转向 *race to the top*。他承认商业和模型领先有价值，但价值并不只在击败对手；领先意味着有能力把生态系统向更好的方向拉动。其他公司可能嘴上攻击 Anthropic，实际却复制其做法，这在他看来仍然有意义，因为行业标准被抬高了。

这一段是整场访谈中的自我定位：Anthropic 希望把自身塑造成商业领先者、安全标准制定者和行业压力源。读者需要保留双重视角。一方面，前沿公司确实有能力通过产品和安全实践影响行业；另一方面，任何领先者都可能把自己的商业优势包装成公共利益。讲义后面的国防和 Mythos 章节会继续检验这条自述。

2.5 产品速度：统一文化加上 Claude 自用

谈到 product velocity 时，Amodei 给出两个因素。第一是统一公司和统一文化：公司变大后仍保持同一页上的组织效率。第二是 Claude 自身：Anthropic 正在用 Claude 帮助开发模型、提高效率 and 快速开发产品。他承认公司仍在学习这些新实践，但已经看到可靠加速。



图 4: Amodei 与主持人在 Anthropic 办公区边走边谈。字幕同步讨论统一文化、组织效率，以及 Claude 被内部用于加速模型与产品开发。⁴

产品速度的双引擎

访谈里的产品速度来自两条驱动：组织一致性和 AI 自用。公司文化减少协调摩擦，Claude 把研究、工程和产品迭代中的部分认知劳动压缩掉。

这对读者有直接启发。AI 工具最先改变的，往往是组织内部的反馈回路：需求定义更快、原型更快、代码更快、文档更快、测试和排错更快。若反馈回路缩短，产品周期就会整体压缩。

2.6 AI discovery：医疗、生物和科学乐观主义

主持人问他见过 AI 做过最“wild”的事情。Amodei 首先想到的是生物和医学。他提到 Claude 诊断出一些高级医生漏掉的医疗问题，也提到模型在 drug design、computational chemistry 等任务上变得越来越强。作为曾经做过生物学的人，他对这类进展的评价很高，因为这些任务需要大量训练和专业知识。

⁴视频画面时间区间：00:24:11–00:24:31。



图 5: 办公室墙面上的“Code w/ Claude”展示与人物对话同框，适合承接 Amodei 谈 Claude 在药物设计、计算化学等高门槛任务中逐渐变强的乐观判断。⁵

这段的意义在于平衡风险叙事。Amodei 并没有把 AI 只说成商业效率工具。他相信若社会能穿过风险区间，本世纪可能获得巨大的科学和医疗进步。这种乐观并不取消后文的文明风险，反而让风险更难处理：收益越大，社会越难简单停止；风险越大，社会越不能只被收益驱动。

收益叙事的盲点

医疗和科学突破具有强道德吸引力。它们能说明为什么继续推进 AI 有价值；它们不能自动回答谁承担风险、谁获得收益、谁决定发布边界、谁对失败负责。

2.7 写作方式：Claude 作为 thinking partner

Amodei 以长文著称。主持人问他是否用 Claude 写作。他说会用 Claude 帮助 brainstorm、思考主题、寻找参考，但还没有让 Claude 直接写入最终文本，因为自己的风格很具体，也很挑剔。他承认 Claude 未来可能写得比自己好，只是当前还没到那个点。

这一段给了一个很实际的 AI 使用范式：AI 先成为 *thinking partner*，帮助人形成结构、找角度、补参考；最终判断、语气和责任仍由人承担。对专业写作者、研究者和管理者来说，这比“AI 代写”更接近当前高质量工作流。

AI 作为认知脚手架

把 Claude 当作认知脚手架，就像让一位研究助理先整理主题、列出反例、提出参考路径。脚手架帮助人站得更高，建筑设计和最终验收仍由人负责。

⁵ 视频画面时间区间：00:25:10–00:25:46。

2.8 本章小结

本章说明 Anthropic 的企业化路线怎样把商业、算力、竞争、产品速度和科学乐观主义连成一个系统。企业客户提供收入与长期信任关系，算力紧张暴露前沿模型需求增长的不可预测性，竞争领先被 Amodei 解释为拉动行业标准的手段，产品速度来自组织一致性和 Claude 自用。最重要的张力也在这里成形：AI 的收益足够大，足以让公司和社会继续投入；它的风险也足够大，要求商业模式持续接受价值边界和外部约束检验。

3 AI 与工作：GDP 增长、失业风险和成熟对话

3.1 为什么这段访谈容易被误读

这一章从一个高度易燃的问题开始：主持人追问 Amodei 曾经说过 AI 可能在未来一到五年消灭一半入门级白领岗位。Amodei 的回应没有把这个数字包装成精确预测。他把它称为一种 *order of magnitude* 预警：当技术变化快到足以重写岗位结构时，严肃讨论首先要抓住风险的量级，然后再讨论社会怎样缓冲、吸收和再分配。

量级判断

Order of magnitude 在这里指“量级判断”。它关心风险可能大到什么尺度，例如入门级白领岗位可能出现大范围冲击；它没有给出一个可按季度校验的精确失业率预测。

这也解释了 Amodei 为什么反复抱怨“三秒钟剪辑”。如果公众只记住“doom is coming”式的惊悚片段，政策讨论就会被压扁成站队表态。访谈中的完整说法更复杂：他承认自己“不知道会发生什么”，同时维持同一量级的担忧，并列可能回应，包括 *token tax*、企业内部岗位调整、宏观经济政策、经济研究和公共讨论。

剪辑误读

把劳动力风险缩成一句社交媒体口号，会让最关键的问题消失：如果 AI 真的让总产出快速上升，新增财富怎样进入工资、岗位、公共服务和社会保障，怎样避免集中到资本回报和少数高杠杆岗位？

3.2 宏观悖论：总产出上升，劳动者处境仍可能恶化

Amodei 最担心的场景，是“very fast GDP growth”和“high unemployment”同时出现，或者表现为 *underemployment*、大量低薪岗位和高不平等。这听起来像悖论，因为许多人习惯把 GDP 增长理解为社会整体变好。宏观经济里，GDP 统计的是总产出；它单独看不出新增产出落在谁手里，也看不出劳动者的议价权是否下降。

可以用一个教学抽象来压缩这个风险结构。访谈原文没有给出公式；这里的公式只是帮助读者把“总量”和“分配”分开：

$$\Delta Y_{\text{total}} > 0 \quad \text{且} \quad \Delta B_i < 0$$

- ΔY_{total} ：社会总产出的变化，近似对应 GDP 或整体生产能力的变化。
- B_i ：第 i 类劳动者的议价权、工资安全感和可替代性处境的综合记号。

- $\Delta Y_{\text{total}} > 0$: AI 让经济蛋糕变大。
- $\Delta B_i < 0$: 某些劳动者虽然生活在更富的经济体中，自己的岗位稳定性和收入分配位置仍然下降。

宏观剩余

“宏观剩余”指技术进步创造出的新增产出空间。它像一条新修的高速公路：社会通行能力增加了，沿线土地、物流公司和资本方可能先受益；原来靠旧路线吃饭的人，需要新的入口、补偿机制或转岗通道，才能分享到新增价值。

AI Workforce Risk Chain




图 6: AI 劳动力风险链条：模型能力先扩大生产率剩余，再通过任务自动化和分配机制影响就业、工资和政策回应。

这就是本章的核心教学点：AI 可以同时提高生产率和制造分配压力。两件事可以并行发生，社会无法只凭总量指标判断风险已经解除。

3.3 任务、岗位与过渡期的形状

Amodei 用“自动化 90% 的工作”描述一个典型过渡期：当 AI 先接管大部分任务时，剩下的 10% 会让人类更有杠杆，所以短期看起来像生产率提升。问题出现在自动化逐渐接近 100% 时。此时社会需要回答一个更硬的问题：这些人接下来做什么？

任务与岗位

“任务”和“岗位”需要分开看。任务是岗位内部的动作单元，例如写代码、查资料、整理表格；岗位还包含责任、客户关系、组织授权、价值判断和跨人协作。AI 先吃掉任务，然后改写岗位，最后可能让某些岗位类别收缩。

阶段	访谈中的机制	对劳动者的含义
生产率驼峰	AI 完成大部分任务，人类在剩余任务上被放大。	员工短期更高效，企业更愿意用同样团队做更多事。
接近全自动	自动化比例继续上升，AI 直接完成整件事的场景增多。	某些入门岗位的训练阶梯可能变窄，年轻劳动者最先承压。
岗位重配	<i>forward deployed engineer</i> 、 <i>applied AI solutions architect</i> 等客户侧技术角色需求上升。	新岗位需要技术能力、沟通能力和现场问题定义能力的组合。
宏观分配	经济蛋糕扩大，匹配速度决定冲击强度。	如果新需求出现得慢，失业、低薪化和不平等会先扩大。

表 1: 访谈中劳动力冲击的教学化流程表。

Anthropic 内部的软件工程转型是一个小样本。Amodei 说，AI 已经能写全部或几乎全部代码，软件工程师目前仍然更高效；同时，公司也开始看到某些任务由 AI 直接完成更合适。这个例子有教学价值，因为它展示了过渡期的双面性：同一项技术既能放大员工，也能让岗位边界变薄。

3.4 企业选择：节省成本与正和扩张

访谈中最关键的企业层面变量，是客户拿到 AI 之后怎样使用它。Amodei 描述了两个选择：一种是“save costs”，即用更少的人完成同样事情；另一种是“do more things with the same amount of resources”，即用同样资源做更多新事情。Anthropic 倾向推动后一种正和扩张，因为它更可能保留岗位，并把生产率转化为新需求。

分配机制

企业是否把 AI 用成裁员工具，不能只靠技术本身决定。采购目标、管理层激励、资本市场压力、劳动法规和公共政策都会改变企业选择。把“AI 会提高效率”直接推导成“劳动者会受益”，中间漏掉了分配机制。

这也是 *token tax* 之类政策设想出现的背景。所谓 token，可以粗略理解为模型处理文本、代码或其他输入输出时的计量单位；*token tax* 的直觉，是把 AI 大规模使用带来的部分收益转为公共缓冲资金。访谈没有展开税制设计，讲义也不应替它补一个完整方案；这里要抓住的是政策意图：把技术创造的宏观剩余接回社会分配系统。

3.5 哪里可能吸收新的劳动需求

当主持人追问“五年后这个国家会怎样”时，Amodei 没有给确定剧本。他列出几类可能吸收需求的方向。

第一类是物理世界。信息处理会快速变便宜，机器人革命也在推进，但他认为机器人变化速度慢于纯 AI 软件。于是，建造、制造、维护、能源、数据中心以及其他实体活动，可能成为新的约束点。

第二类是人本关系。医疗、教育、重大客户服务和敏感决策中，人们仍然想和人说话。即使 AI 能给出更强分析，人的信任、安慰、责任承担和价值沟通仍然可能保留经济价值。

第三类是人类对 AI 的方向设定。Amodei 说，AI 至少需要对齐某些人的价值和意图。未来这个角色会很厚还是很薄，他承认很难判断；但它提示读者，劳动需求可能从“直接生产内容”转向“定义目标、选择约束、解释结果、承担责任”。

匹配问题

这里的“匹配问题”可以类比城市搬迁。新城区突然出现大量岗位，旧城区大量岗位消失；即使新岗位总数足够，技能、地点、年龄、教育背景和收入期待对不上，社会仍会经历痛苦的失业和低薪化。

3.6 成熟对话为什么重要

Amodei 对批评者的反击很重。他认为，把他的劳动力风险讨论说成“doom marketing”，属于未认真读长文、未面对严肃取舍的廉价营销。他提到 Anthropic 做过 economic grants 和 economic index，也说自己在文章中讨论过任务与岗位的区别、这次技术变化的特殊性，以及从私人慈善到政府行动的多种回应。

这一段的教学意义在于：劳动力冲击讨论需要同时容纳三种不舒服的事实。第一，AI 确实在提高生产率。第二，生产率提升会伤害部分劳动者。第三，政策回应越晚，匹配问题越尖锐。成熟对话的目标，是把三者同时放在桌面上，避免乐观口号和末日剪辑各自遮蔽一半事实。

本章机制链

本章的主线可以压缩为一条链：AI 能力提升 → 生产率剩余扩大 → 岗位替代压力上升 → 企业选择和公共政策决定分配结果。真正的问题在最后一步：社会怎样把新增产出转成可接受的就业、工资和保障结构。

3.7 本章小结

这一章讨论的是一套宏观机制，单一失业数字只是入口。Amodei 的“50%”说法应放回 *order of magnitude* 语境中理解：它提醒社会准备一个可能很大的冲击，并没有宣布精确时间表。AI 可以让 GDP 快速增长，也可能让许多劳动者进入低薪、低议价权或岗位缺口状态。风险的关键变量包括自动化从任务走向岗位的速度、企业选择成本节省还是正和扩张、物理世界与人本关系能吸收多少新需求，以及政策能否把 AI 创造的宏观剩余重新接回普通人的生活。

4 国防合作的灰区：Pentagon、战争使用与边界

4.1 问题为什么棘手：反战姿态遇到国防网络

这一章的冲突非常直接：主持人指出，Anthropic 是全球领先 AI 公司之一，同时已经深入美国国家安全体系；Amodei 又有长期反战立场，并且从 Caltech 时期起就反感战争。于是问题变成：一个自称重视价值边界的 AI 公司，为什么会较早与美国国防部合作，并把 Claude 部署到美国用于战争行动的 *classified networks*?



图 7: 五角大楼航拍画面，标记访谈进入 Anthropic 与美国国防部、分类网络和军事用途边界的核心争议。⁶

Amodei 的回答从地缘政治开始。他说 “the world changes”: 俄罗斯入侵乌克兰、中国入侵台湾的风险、以及更强势的威权力量，让他认为民主国家需要防御能力。他担心的场景，是俄罗斯和中国可以用 AI 分析情报、辅助军事行动，而美国及盟友无法使用同等级工具进行防御。



图 8: 新闻屏幕同时出现 “ANTHROPIC” 与五角大楼画面，呈现这场国防合作争议的媒体化语境。⁷

⁶ 视频画面时间区间：00:36:42–00:37:12。

⁷ 视频画面时间区间：00:36:52–00:37:12。

classified networks

Classified networks 指处理机密信息的受控网络环境。与普通公开 API 相比，它更强调身份认证、访问边界、审计、隔离和部署控制。这个词很重要，因为同一个模型进入不同网络环境后，风险形态会发生变化：普通办公辅助、情报分析和战场决策链条属于不同治理问题。

4.2 双重用途：同一能力怎样走向不同结果

AI 国防使用的难点来自 *dual-use technology*，也就是双重用途技术。同一模型可以帮助整理情报、分析后勤、发现漏洞、做防御规划；同一能力也可能贴近监视、目标选择、军事行动节奏和误判升级。工具能力越强，使用场景越需要边界。

国防论证三层

Amodei 的国防论证可以概括为三层：第一，民主国家需要 AI 防御能力；第二，模型使用必须避开会侵蚀民主价值的场景；第三，供应商能设高层边界，具体军事政策仍由国家军事决策体系承担。

他提到两条红线：*mass surveillance* 和 *fully autonomous weapons*。前者指大规模监视，涉及自由、隐私和政治压制；后者指全自动致命武器，涉及机器独立选择和执行杀伤行动。Amodei 的价值判断是，如果民主国家为了获胜而采用会摧毁自身价值的工具，胜利本身会失去道德意义。

他还强调，与政府网络合作很难算作轻松赚钱。接入政府系统很麻烦，收益相对有限，还会带来诉讼和政治压力。按他的说法，Anthropic 这么做，是因为它认为国家安全问题真实存在；也正因为动机来自价值判断，使用限制才必须同步存在。

4.3 合同红线与供应商边界

主持人追问 Palantir 合作、ICE、警察部门和 Gaza 等敏感场景。Amodei 在访谈中称 Anthropic 不通过 Palantir 或其他渠道与 ICE 合作，也不与 CBP 合作，并表示自己不认为 Anthropic 在 Gaza 合作。这里的关键落在供应商怎样划定自己愿意服务的用例边界。

随后主持人把冲突推到政治层面：总统把 Anthropic 排除在联邦政府之外，五角大楼把它标成供应链风险，OpenAI 签下 Anthropic 拒绝签的合同。Amodei 回答说，重点是建立 precedents 和 public awareness，让国家认真讨论 AI 在政府中的适当用途。他认为合同只能做一部分事，因为其他公司可以签没有同样红线的合同；更稳定的护栏需要国会等制度层面的行动。



图 9: C-SPAN 国防预算听证会画面，对应外界对 Anthropic 国防立场的尖锐批评，以及 Amodei 对公司价值与商业成功关系的回应。⁸

合同红线的边界

合同红线有用，也有限。它可以约束供应商自己的部署、制造公共先例、推动国会关注；它无法替代军事指挥链、战争法、国会监督和公众问责。把战争伦理全部压到采购合同上，会高估私营公司的控制力。

Amodei 用 Microsoft Excel 作类比：政府也大量使用 Excel，供应商很难逐项批准某个军事行动可以用、另一个军事行动不能用。这个类比的作用，是把“技术供应商边界”和“国家军事政策边界”分开。供应商可以拒绝某些类型的用例，例如全自动武器；具体行动是否合理，仍要落在军事和政治责任体系中。

4.4 目标选择、human-in-the-loop 与军事错误

主持人接着引用 Bloomberg 报道语境：Claude 被美国军方通过 Palantir 的 Maven Smart System 用于伊朗战争中的 AI assisted targeting；二月一次美国导弹据称击中伊朗一所女校，造成超过 150 人死亡，多数为儿童。主持人追问 Claude 是否在这次打击中发挥作用。

在进入伊朗女校案例前，主持人还给出一个量化压力测试：有美国官员称，LLM 让美军从每天打击约 1000 个目标提升到 5000 个目标；她据此追问，Claude 是否会让杀伤速度更快。Amodei 的回答把两层问题拆开：他支持美国具备更强军事能力，认为这种能力可以形成 *deterrence*；具体军事政策是否正当，则应由军事决策体系承担，供应商能做的是设定大规模监视、全自动武器等高层红线。

Amodei 的回答有几层。第一，他说 Anthropic 不知道模型具体怎样被使用。第二，他承认战争中的错误极其可怕，这类悲剧恰好说明为什么必须坚持用例边界。第三，他把当前案例与更危险的场景区分开：他认为这里至少仍然是 Claude 辅助，人类作出最后决定；真正让他强烈反对的，是

⁸视频画面时间区间：00:41:10–00:41:47。

AI 模型直接作出杀伤决策，人类完全看不到决策过程。

human-in-the-loop

Human-in-the-loop 的最低含义，是关键决策链上有人类负责最终判断。它不能自动保证决策正确，却能保留责任主体、复核机会和制度问责入口。对于目标选择这类高风险场景，这条线具有伦理和操作双重意义。

主持人进一步追问：如果学校网站可以通过搜索找到，AI 是否本该发现？Amodei 没有声称自己知道机密事实；他回到原则层面，说这里展示了“人类最终决定”原则的重要性。这个回答并没有消除道德压力。它只是说明，Anthropic 希望把公司的红线放在系统类别上，例如全自动杀伤，而具体战术错误需要由军事决策链和国家问责机制承担。

人在环的失败模式

“有人类在环”也有失败模式：人类可能过度信任模型，可能在时间压力下草率确认，也可能缺乏足够上下文。访谈没有展开这些机制，但读者应意识到，human-in-the-loop 是必要边界之一，仍需要审计、训练、责任划分和战后复盘共同支撑。

4.5 Dr. Strangelove：全自动武器为什么危险

在讨论 AI warfare 是否更可能阻止世界大战时，Amodei 借用了《Dr. Strangelove》的 *doomsday device* 类比：一个系统一旦认为核武器来袭，就会自动发射核武器。这个类比抓住了全自动武器的核心危险：当感知、判断和执行连成闭环，误判会被机器速度放大，留给人类干预的时间窗口变得很窄。



图 10: 《Dr. Strangelove》片名画面，对应 Amodei 用“末日装置”类比全自动武器和误判升级风险的段落。⁹

⁹视频画面时间区间：00:47:14–00:47:41。

他对冲突升级的描述很朴素：两边互相扑向对方，互相误解，缺少监督时事故更容易发生。AI 如果接管速度、目标和杀伤链条，就可能把误解推向不可逆结果。这里的重点不在电影本身，而在自动化闭环带来的控制问题：越接近“发现即打击”，越需要制度刻意减速。

deterrence

Deterrence，即威慑，指通过提高对方行动的预期代价、暴露风险或失败概率，使对方放弃行动。传统威慑常依赖军力、报复能力和可信承诺；AI 语境下，Amodei 强调的是情报优势和响应能力。

4.6 威慑的乐观前提

Amodei 对 AI warfare 的总体判断偏乐观：在有边界的情况下，它更可能阻止大战；如果使用没有限制，它也可能增加大战风险。他给出的正面场景主要是情报：如果美国能提前预测台湾入侵或乌克兰的新军事动向，对手会在知道自己行动被看见后重新计算成本。更强的响应能力也能提高威慑。

这个判断成立需要若干强假设。情报必须准确；指挥系统必须正确理解情报；政治领导层必须避免过度反应；盟友和对手都要相信信号；平民保护和战争法约束不能被效率目标吞掉。访谈中，Amodei 把这些前提压缩成“appropriate way”和“proper oversight”。教学上应把它们摊开，因为威慑从来依赖制度质量；工具能力只能构成其中一部分。

威慑的条件

“superior intelligence can deter conflict”是一个有条件命题。更强情报可以降低误判，也可能制造先发制人的诱惑、误读对手意图，或让决策者过度相信模型。国防 AI 的成熟治理，必须同时处理能力、边界、责任和升级控制。

4.7 本章小结

这一章的核心，是双重用途技术进入战争机器后的边界问题。Amodei 的立场由三部分构成：他认为民主国家需要 AI 防御能力；他坚持大规模监视和全自动武器会侵蚀民主价值；他承认供应商只能设高层红线，具体军事政策仍由国家制度承担。最困难的地方在于，这些命题彼此拉扯。AI 可以提升情报与威慑，也可能加快目标选择和误判升级。真正的治理难题，是让模型能力进入受控环境，同时保留人类责任、公共监督、法律边界和升级刹车。

5 Mythos 与治理：网络能力、国家接管和白宫沟通

5.1 Mythos 为什么触发发布边界

在 Pentagon 与战争用途之后，访谈转向另一个高风险能力：Mythos。主持人说，Mythos 是 Anthropic 最新最强模型，能够自主走完 cyber kill chain 的各个环节。Amodei 的核心回应是，最让他惊讶的点在于模型能把漏洞进一步转化成 exploit。许多讨论只停在 vulnerability discovery；真正改变风险的是 exploitation，因为它把“知道问题在哪里”推进到“能够利用问题”。

cyber kill chain

Cyber kill chain 是网络攻击过程的阶段化描述，通常包括侦察、发现弱点、构造利用、进入系统、保持访问、横向移动和达成目标。一个模型若能跨过多个阶段，风险就从“辅助分析”上升到“压低攻击门槛”。

Amodei 描述了一个从能力增长到发布控制的链条：模型能力持续爬升，某一次跳跃特别大，而且没有太多提示就能完成更完整的攻击链。Anthropic 因而选择先不给公众广泛开放。他说，长期目标仍可能是让更广泛的人用上 Mythos 类能力，但当下要先让 defenders 获得工具，避免攻击者同时获得同等便利。

能力阈值

能力阈值指模型跨过某条线后，访问策略必须改变。Mythos 的例子里，阈值落在更危险的位置：它能把漏洞发现推进到 exploit construction，并能在更大代码库里找到关键位置。

Amodei 对“开源模型已经复制 Mythos”的反驳也值得补入。他强调，Mythos 的任务是在完整代码库里主动寻找漏洞；把一个开源模型指向 Mythos 已经找出的具体代码行，只是在更低难度条件下复现结果。他举的公开例子是 Firefox 的 271 个新漏洞，另有许多私有公司漏洞仍待修复或披露；前一代模型没有发现这些。这个细节让 Mythos 的风险更具体：模型价值来自主动搜索、定位和利用链条，而非只会回答网络安全问题。

5.2 防守者优先：一个有风险日发布策略

Amodei 把 Mythos 的发布策略说成“先给 defenders，再给 attackers”。这个表述直观，但执行起来很难。谁算 defender？大型企业、政府安全团队、研究人员、漏洞赏金猎人、云厂商、关键基础设施运营者都可能算；其中也可能有被入侵账户、内部恶意人员或能力外溢。高能力网络模型的访问控制因此不能只靠身份标签，还需要审计、速率限制、任务边界、日志、异常检测和撤销机制。

访谈中，Amodei 说已有客户、国家和政府部门每天请求访问 Mythos。另一边，美国政府和安安全团队又要求放慢开放速度，原因包括 counterintelligence risk。这个压力说明，领先公司面临两边拉扯：安全团队希望更多防御能力，商业团队希望产品可卖，政府希望理解风险，公众担心公司掌握过强技术。Anthropic 的自我叙述是，它在商业领先位置上更能做谨慎选择，因为有足够空间承受限制发布带来的商业损失。

防守者优先并不自动安全

网络工具常有强烈双重用途。给防守者更强工具是合理方向；访问控制若太粗，工具本身可能被转卖、滥用或从防守任务滑向进攻任务。Mythos 类模型需要持续权限治理，而非一次性白名单。

5.3 治理闭环：能力、发布、政府和信任

Mythos 章节最有教学价值的地方，是它展示了 AI 治理的闭环：模型能力提升，触发发布边界；发布边界引起商业和政府关注；政府沟通让风险更具体；外部约束和公司声誉又反过来影响下一次发布选择。

Capability Governance Loop




图 11: 能力治理闭环: 模型跨过风险阈值后, 发布决策、政府沟通、公众信任与外部约束会互相反馈。

这张图里的 *smooth ratcheting* 是一个重要概念。Amodei 多次反对忽冷忽热的治理反应: 技术能力平滑上升, 防护措施也应随之平滑加强。若公司或政府突然恐慌式转向, 说明它们之前没有真正理解趋势; 若一直否认风险, 又说明它们让能力增长超出了治理准备。

smooth ratcheting

Smooth ratcheting 可以译成“平滑加码”。它的意思是, 安全措施、访问限制、审计强度和政府参与度应随模型能力逐级提高, 避免等事故发生后才剧烈摇摆。

5.4 国有化问题: 严肃, 却太粗暴

主持人随后问到一个更激烈的问题: 如果 AI 技术如此强大, 政府为什么不接管 Anthropic? Amodei 说这是非常严肃的问题, 他也理解这种担忧。他的历史比较很关键: 过去许多强大技术要么由政府直接建造, 要么起源于政府资助的研究系统。核武器显然由政府主导, 互联网、GPS、手机等关键技术也有政府研发背景。AI 的特殊之处在于, 强能力主要由私营公司推进。

他反对直接国有化, 倾向一种更温和的安排: 政府需要可见性、约束能力和长期参与, 私营公司仍保持创新和执行能力。这里的“温和”指治理工具更细, 风险仍然很大; 访问规则、模型评估、政府沟通、合约边界、审计和发布限制, 比一次性接管更可调。

国有化与监管

国有化是所有权和控制权转移给国家; 监管是国家通过规则、许可、审计和惩罚塑造私营主体行为。AI 治理的难点在于, 技术发展速度太快, 单一工具往往跟不上, 需要所有权之外的多层约束。

Amodei 还提到 *long term benefit trust*, 可理解成围绕长期人类利益的信托式约束。它有具体权力安排: 这个 trust-like body 可以任命和撤换董事会多数成员, 穿透治理结构后等于拥有解雇 CEO 的权力。Amodei 把它描述成从 public governance 中借来一部分结构, 使公司对股东之外的长期公共利益负责; 他还说, 这个结构会在公司未来变化后继续存在, 并鼓励其他公司采用类似安排。这

个细节很重要，因为它把“信任”从 CEO 品格推进到可执行的权力约束。

5.5 白宫沟通：把抽象风险变具体

在白宫访问部分，Amodei 说 Anthropic 试图与任何政府合作，只要对方愿意围绕原则对话。他提到政府已经认真对待 Mythos，并称与财政部长 Bessent、白宫幕僚长 Susie Wiles 有过良好对话。对他而言，Mythos 的意义在于让风险变得具体：网络能力已经成为可以演示、可以评估、可以让决策者感到真实压力的模型行为。



图 12: Susie Wiles 的标注画面，对应 Amodei 谈 Anthropic 与政府沟通、白宫幕僚长以及 Mythos 风险演示被认真对待的段落。¹⁰

这段也暴露了 AI 治理的现实政治维度。不同政府部门、不同幕僚、不同政策团队对风险理解不一；公司需要导航关系，政府也需要建立足够技术理解。若政府不了解模型能力，就容易管得太晚或管得太粗；若公司只向政府提供自己愿意展示的风险画面，公共监督又会不足。

政府沟通的双面性

让政府理解前沿模型风险是必要步骤；这一步也会增加公司影响政策的能力。成熟治理需要独立评估、公开透明的最低标准和多方监督，避免政策只由公司与少数官员的闭门沟通塑造。

5.6 本章小结

Mythos 章节把“能力增长如何触发治理”讲得最具体。模型从发现漏洞走向构造 exploit，发布策略就必须改变；防守者优先有道理，也带来访问控制难题；政府接管问题严肃，但直接国有化过于粗放；更可行的路径是让政府可见、可约束，同时让公司在发布、审计和商业压力中接受更强外部检验。Amodei 的核心主张是平滑加码：技术越强，安全措施和制度参与越强。读者需要继续追问的是，谁来验证这些措施足够强，谁来监督公司在领先地位下的自我克制。

¹⁰ 视频画面时间区间：00:59:12–00:59:30。

6 中美竞争与递归自我改进：连续过程视角与单点奇点误读

6.1 中国开源模型：能力扩散与前沿溢价

主持人先从 Amodei 早年在百度硅谷办公室工作的经历切入，接着问：中国强开源模型不断出现，美国公司免费构建在这些模型之上，这是否构成威胁？Amodei 的回答抓住一个市场规律：模型智能水平越高，用户越倾向选择更强模型。低于前沿的模型当然有生态价值，也能解决大量较简单问题；但在真正困难、经济价值高、风险高的任务上，前沿能力仍有溢价。

frontier model premium

Frontier model premium 指最强模型在困难任务上享有额外价值。类比医疗系统：普通诊所能解决大量常见病，顶级专科医院仍在疑难杂症上具有不可替代价值。AI 生态里，开源和较小模型会扩散能力，前沿模型仍可能掌握最稀缺的任务入口。

这段讨论的重点超出商业竞争。Amodei 把中国问题连接到价值和治理：AI 可以让人更自由，也可能走向相反方向；最终取决于 AI 公司、政府和所有人的行动。这里的国家竞争关心的核心，是谁能把强能力嵌入更可靠的治理结构里。

中国段还需要补上价值风险的具体来源。Amodei 回忆百度经历时说，语音识别数据来源让他听到类似“在中国不用在意隐私”的表述；更大的担忧来自维吾尔人处境、香港，以及 CCP 能够伸入美国商业网络压制批评声音。他把这种高科技威权与 AI 结合后的前景形容为接近《1984》甚至更糟的 dystopia。与此相对，他把理想路径说成 *pro-democracy technology*：让人更自由，并服务于 *equal justice for all*。

开源扩散的两面

开放模型能降低门槛、推动创新、帮助本地化和研究复现；强能力扩散也可能降低滥用门槛。访谈没有给出简单结论，读者应把它理解为能力民主化与风险扩散之间的持续张力。

6.2 递归自我改进：已经开始的连续过程

主持人提到 AI 领域常说的一个时刻：AI 足够强，可以改进自身；改进后的版本再改进自身，如此循环。Amodei 反对把它看成单一时间点。他说这更像连续过程，某些方面已经发生：AI 已经能为下一代 AI 提出架构建议，也能提高研究与工程生产率。一年前，AI 对 total factor productivity 的提升可能是 10%–15%；现在可能接近 20%–30%，还可能继续翻倍。

Recursive Self-Improvement as a Continuous Loop




图 13: 递归自我改进作为连续闭环: 模型能力、研究辅助、架构和工具改进相互推动, 形成渐进加速。

可以把这个过程写成一个教学公式:

$$C_{t+1} = C_t + f(C_t, H_t, R_t)$$

- C_t : 时间 t 的 AI 能力水平。
- H_t : 人类研究者、工程师和组织判断投入。
- R_t : 算力、数据、工具链和实验资源。
- $f(C_t, H_t, R_t)$: 由当前模型辅助研究、架构建议、代码生成和实验效率带来的能力增量。

连续过程视角

递归自我改进不必等待一个戏剧化“奇点时刻”。只要模型持续帮助研究者更快设计模型、写代码、做实验和分析结果, 能力提升就已经进入自增强回路。

这种视角让治理更困难。若风险是突然出现的, 人们可以等待阈值信号再行动; 若风险随能力连续上升, 治理也要连续上调。这与前文 *smooth ratcheting* 完全相连。

6.3 不要恐慌, 也不要否认

Amodei 对递归自我改进的治理态度可以概括为两句话: 不要恐慌, 也不要否认。他批评那种忽然大幅摇摆的反应, 因为它说明决策者之前没有做好准备; 他同样反对把能力增长视为普通软件升级, 因为前沿模型确实正在改变研究和安全边界。

这里可以用温度计类比。若水温每小时稳定上升, 成熟操作员会按温度逐级加压阀门、冷却和警报阈值; 惊慌的人会等到水沸腾才疯狂操作; 否认问题的人会把温度计盖住。Amodei 要求的是第一种反应: countermeasures 随技术力量平滑上调。

total factor productivity

Total factor productivity, 全要素生产率, 粗略表示在劳动、资本等投入之外, 由技术、组织和效率提升带来的产出增长。AI 若让研究团队同样人数完成更多实验、更多代码和更快设计, 它就在提高这类生产率。

6.4 历史类比: Szilard、Oppenheimer 与制衡

主持人最后问到 Amodei 喜欢的书: 《The Making of the Atomic Bomb》。他把自己更强地连接到 Leo Szilard: 那位最早意识到链式反应可能性的科学家。更重要的是, 他把 Oppenheimer 当成一个失败案例来讨论: 一个更大于生活的人物站到一切中心, 会让巨大技术权力过度依赖个人意志。

他给出的替代路径是 *checks and balances*。这是一种制度直觉: 多个强行动者互相制约, 避免任何单点主体独占判断权。AI 时代的强行动者包括公司、政府、研究人员、投资者、用户、国际竞争对手和公众。若只有一家公司或一个魅力型人物掌控关键技术, 风险会集中; 若所有主体完全分裂, 协调会失效。制衡要在集中与碎片化之间找结构。

checks and balances

Checks and balances 可以译成“制衡”。它让强权力面对其他权力的审视, 作用远比拖慢流程更深。对 AI 这种高杠杆技术, 制衡的目标是防止商业、国家安全或个人声望中的任一力量单独决定文明级风险。

6.5 本章小结

本章把国家竞争、开源扩散、递归自我改进和历史类比放在同一条线上。Amodei 认为前沿模型仍有溢价, 因为困难任务会持续偏向最高智能; 中国和开源模型使能力扩散更快, 也让价值和治理竞争更加突出。递归自我改进在他的叙述里是连续过程: AI 已经帮助下一代 AI 的设计和工程效率。成熟回应既要避免恐慌式摇摆, 也要避免风险否认; 最终需要 *checks and balances*, 让公司、政府和公众在高能力时代互相约束。

7 崩塌概率与信任: 为什么 Silicon Valley 必须重新赢回社会

这一章把整场访谈推到最难躲开的地方: 如果 AI 的上行收益如此巨大, 社会为什么还要接受它带来的系统性风险? 主持人抓住 Amodei 曾经说过的一个数字追问: 大约 10-25% 的 *civilizational collapse* 概率。这个数字刺耳, 因为它已经越过普通工程安全讨论的心理阈值。日常产品里, 分之一的灾难概率意味着产品无法上线; 放到文明尺度, 10-25% 代表一种必须严肃处理的残余风险。

本章核心问题

Amodei 的回答围绕两条线展开: 第一, AI 的内在不确定性让风险无法归零; 第二, Anthropic 声称自己正在通过测试、发布控制和价值决策降低概率。真正的难点在于, 社会无法只听公司自述, 社会只能观察公司在商业压力下的实际行为。

7.1 10–25%：一个过高的残余风险

主持人的问题非常直接：如果未来灾难真的来自 Anthropic 制造的系统，Amodei 怎么回答？Amodei 的第一反应是“当然希望不会”。随后他把风险来源拆成一个简单配方：强大技术、多个国家、一个经济体内的多家公司，以及持续出现的新公司。换句话说，风险并未被他说成某一家公司的单点意愿；它来自能力扩散、国际竞争和市场进入共同形成的压力场。

用概率语言写出来，这个说法的要害可以压缩成下面的形式：

$$p_{\text{collapse}} \in [0.10, 0.25], \quad R = p_{\text{collapse}} \times L$$

- p_{collapse} ：文明级崩塌的主观概率估计，对应访谈中的 10–25%。
- L ：一旦崩塌发生的损失规模。这里的 L 极大，已经超出普通产品事故的量级。
- R ：风险暴露，可以理解为“概率乘以损失”的粗略安全压力。

这条公式的作用是帮助读者看清量级。即使一个概率看似低于一半，只要损失 L 足够巨大，风险暴露 R 仍然会变成治理上的中心问题。Amodei 没有把这个数字包装成可接受区间；他承认 25% 太高，并说目标是把这个概率压得低得多。

不要把相对安全误读成绝对安全

Amodei 的说法包含一个容易混淆的点：一家 AI 公司可以声称自己的行动让风险下降，同时整体技术仍然危险。这类似一家公司说自己的航空系统比同行安全十倍；这个比较只说明相对位置，乘客仍会关心绝对坠机概率。

7.2 飞机类比：为什么 25% 不能被正常化

Amodei 用航空公司做类比：假设市场上有很多航空公司，其中一家努力把自己的飞机做得更安全，甚至比其他公司安全十倍。这个陈述可以成立；它依然无法推出“飞机永远不会坠毁”的保证。主持人接着把问题压到极限：如果一架飞机有 25% 的坠毁概率，乘客会登机吗？Amodei 的回答是明确的：25% 太高。

这个类比的教學价值在于，它把 AI 风险从抽象伦理话语拉回普通安全直觉。人在航空安全里默认需要极低事故率，因为一次事故就可能造成不可逆损失。文明级 AI 风险也是同一类尺度问题：改进机制再多，测试再密，发布再谨慎，只要残余概率仍停留在两位数百分比，社会就有理由要求更强的治理约束。

“无法保证零风险”与“必须降低风险”的区别

高风险技术通常无法给出零事故承诺。核电、药物、航空、网络安全都一样。成熟治理的目标是把事故概率压到与损失规模相匹配的区间，并持续证明控制措施有效。Amodei 在这里承认 AI 的内在属性是 unpredictable，因此他强调发布前大量测试、迭代学习和许多防御机制。

访谈里还有一个关键限定：Amodei 说当前已经发布的模型在网络安全之外，他认为没有达到真正危险的程度；网络能力是例外，因为前面关于 Mythos 的讨论已经说明，网络攻击链条中的漏洞发现和利用构造会很快触及释放边界。这个限定很重要：cyber 被单独标成当前更靠近危险阈值的领域。

7.3 把风险拆成表：能力、收益、失效模式与治理

本章适合用表格来梳理，因为 Amodei 的论证同时涉及收益、灾难模式、防御手段和剩余不确定性。下表只使用访谈中已经出现的要素，避免引入额外事实。

能力/场景	潜在收益	失效模式	治理回应
Frontier models 持续增强	科学、医学、生产力提升；前文提到药物设计、计算化学和诊断能力	能力扩散到国家、公司和新进入者，形成难以单点控制的压力场	发布前测试、逐步发布、内部防御机制、风险学习循环
Cyber 能力接近阈值	防御、漏洞理解、政府风险演示	漏洞发现与 exploit construction 可能降低攻击门槛	对高能力模型限制释放；通过 Mythos 案例与政府沟通
商业化 AI 产品	形成资金来源，支持昂贵模型训练和安全工作	收入压力可能推动更快释放、更少约束	在商业机会面前做价值决策，例如延迟 Claude 2、限制特定访问、暂缓 Mythos 广泛释放
全球竞争与市场进入	多主体探索带来创新速度	如果负责任主体留下空白，其他主体可能填补空白	Anthropic 声称通过参与并设置标准来降低总体概率

风险表的核心读法

AI 治理里的难题覆盖能力、竞争、商业压力和防御机制的同步变化。一个防御机制今天有效，明天可能被更强模型、更低成本访问或更多参与者稀释。

Risk-Benefit Governance Matrix

Capability	Benefit	Failure mode	Governance response
Claude / coding	Productivity	Work displacement	Adjustment + honesty
Defense AI	Deterrence	Targeting harm	Use boundaries
Mythos / cyber	Security insight	Autonomous exploit	Release control
Frontier AI	Scientific progress	Systemic collapse	Checks + ratchets

图 14: 风险-收益治理矩阵：同一能力通常同时带来收益、失效模式和治理回应。

7.4 信任从不信任开始

主持人的最后一个实质问题是：Anthropic 正在建造极其强大的东西，并且会从中获得巨大收益，公众为什么要信任它？Amodei 的回答没有从个人魅力起步。他说，对于刚出现的公司，尤其考虑到 Silicon Valley 过去几年的整体行为，从 distrust 出发是理性的。Silicon Valley 已经失去很多世界范围内的 trust，必须 re-earn it。

这里的 trust 指向可积累的信用记录：一次承诺只能提供口头信号，反复在压力下付出代价才形成可信用度。Amodei 用三个例子说明 Anthropic 想传递的信号：Mythos 没有广泛释放，商业上受到明显限制；在 China 相关访问上做过成本很高的切断；Claude 2 曾经延迟。访谈没有要求读者无条件接受这些例子，它要求读者看 “overall history” 与哪一种假设最一致。

其中 China access 的例子有具体代价：Amodei 说切断模型访问没有外部强制，代价达到 several hundred million dollars，而且当时这仍是收入中的显著比例。他要求公众观察 overall history，并承认组织会犯错，会有 foot faults 和 dysfunction；问题是长期行为最符合哪一种假设。

信任作为 earned behavior

“trust has to be earned” 可以翻译成 “信任必须靠行为挣来”。在高风险技术里，CEO 自我宣称和原则文档都只能算弱信号；更强信号来自可观察行动，尤其来自那些会牺牲收入、速度或市场份额的行动。

这一点也回应了前面关于 OpenAI 分歧、Pentagon 合作、Mythos 释放边界和政府沟通的多条线索。整场访谈反复出现同一个结构：能力增长带来收益，也带来风险；企业必须商业化，也必须说明商业化如何服从价值边界；政府需要介入，也需要被制衡；公众可以保持怀疑，同时可以观察具体行动。

公共信任不能靠一次访谈修复

Amodei 承认组织会犯错，也会有功能失调。社会层面的信任修复需要长期证据：模型发布记录、事故处理方式、政府审计、商业压力下的选择，以及公司愿意接受哪些外部约束。一次表达清楚的访谈只能建立待检验的假设。

7.5 回到 the exponential：结尾真正落点

主持人在结尾说，“We will see you on the other side of the exponential then.” 这句话把访谈拉回开头：Amodei 一开始就用 the exponential 描述 AI 世界的主观体验，像飞船加速后每次醒来都面对更多外部变化。最后谈到崩塌概率和信任时，问题已经从 “速度有多快” 变成 “谁有资格在这种速度下继续推进”。

因此，本章的教学重点可以概括为一个治理闭环：能力越强，风险越大；风险越大，社会越需要可验证的约束；约束越强，公司越需要证明自己在商业压力下仍会遵守边界；这些证据积累起来，才可能重建 trust。这个闭环没有给出轻松答案。Amodei 的立场是：继续推进，同时把概率降得多得多；公众的合理立场是：接受收益叙事之前，先要求行为证据和制度约束。

7.6 本章小结

- 10–25% 的 civilizational collapse 估计已经越过普通风险提示的层级；按文明损失规模计算，它足够触发强治理要求。
- 飞机类比说明了相对安全和绝对安全的差异：比同行安全很多仍然不足以让 25% 坠机概率变得可接受。
- Amodei 把风险来源归结为技术本身的不可预测性、国家竞争、多公司竞争和新进入者压力；Anthropic 声称自身行动降低风险，但这种主张需要外部观察和长期验证。

- Trust 在这里是一种 earned behavior：公众应观察公司在 Mythos、China access、Claude 2 延迟等高成本决策上的实际记录。
- 全章回到 the exponential：当能力以指数速度推进时，治理和信任也必须跟上，否则商业成功会放大社会怀疑。

8 总结与延伸：把整场访谈压缩成一张风险-能力-治理地图

8.1 说话人最后留下的判断

整场访谈的最后，主持人追问一个没有办法用产品指标回答的问题：Anthropic 正在建造极其强大的东西，并且会从中获得巨大收益，公众凭什么信任它？Amodei 的回答没有诉诸个人魅力。他承认，从 distrust 出发是理性的，因为 Silicon Valley 过去几年已经损失了世界范围内的信任。信任只能通过行为重新挣来，尤其是在商业压力下仍愿意付出代价的行为。

这一点把前面所有章节串了起来。OpenAI 分歧里，trust 是离开的理由；企业化路线里，trust 是商业关系的基础；国防合作里，trust 牵涉公司、政府和公众的边界；Mythos 发布里，trust 要靠限制访问和政府沟通来证明；文明风险里，trust 又变成社会是否允许公司继续推进的门槛。

全片压缩命题

Amodei 的核心叙事可以压缩为一句话：AI 正在沿指数曲线推进，收益和风险同时放大，因此前沿公司必须用商业能力支撑研究，用发布克制回应风险，用政府和社会约束重建信任。

8.2 三条主轴

第一条主轴是能力增长。访谈从 *the exponential* 开场，随后讨论 Claude Code、产品速度、科学发现、Mythos、递归自我改进和文明风险。能力增长是一整个系统的变化：模型更强，组织更快，用户更多，算力更紧，风险边界也更近。

第二条主轴是制度压力。AI 进入企业、劳动力市场、国防网络、白宫和国际竞争。每进入一个制度场景，技术问题就会变成权力问题：谁有访问权，谁承担责任，谁获得收益，谁承担损失，谁能叫停发布。

第三条主轴是可信行为。Amodei 多次把原则落实到高成本行动：离开无法信任的组织，选择企业场景，限制国防用例，控制 Mythos 释放，承认文明风险，并说 Silicon Valley 需要重新获得社会信任。读者不需要直接接受这些自述，读者需要用后续公开行动持续检验它们。

8.3 一张总表

主题	能力收益	主要风险	治理抓手
企业化与 coding	形成收入、提高生产力、支撑模型训练	商业压力推动过快发布或成本裁减	企业信任、审计、长期关系、边界条款
劳动力冲击	GDP 和生产率快速增长	入门白领岗位收缩、低薪化、不平等	token tax、转岗、公共诚实讨论、再分配政策
国防合作	情报、后勤、防御和威慑能力提升	目标选择失误、全自动武器、监视滥用	human-in-the-loop、合同红线、国会与公众监督
Mythos / cyber	防御者更快发现漏洞和修复风险	exploit 构造门槛下降，攻击能力扩散	限制发布、防守者优先、审计和政府沟通
递归自我改进	研究效率提升，模型迭代更快	能力增长超过治理准备	smooth ratcheting、持续评估、checks and balances
文明风险与信任	科学、医疗和社会能力跃迁	系统性失控或社会信任崩塌	发布克制、外部约束、长期行为记录

表 2: 整场访谈的风险-能力-治理总表。

8.4 读者应带走的几个问题

第一，AI 治理不能只讨论模型本身。模型能力进入公司、军队、政府和劳动市场后，风险由技术能力和制度结构共同生成。

第二，商业成功与安全叙事之间存在真实张力。Amodei 的说法是，商业领先能给谨慎发布提供空间；读者应继续观察，商业压力增长时这种克制能维持多久。

第三，社会不能把信任外包给 CEO 访谈。CEO 的长访谈能提供价值观和推理过程，制度层面的信任仍需要审计、透明、外部评估、责任追踪和可执行规则。

第四，递归自我改进要求治理也递归改进。模型帮助造出更强模型，安全评估、红队、访问控制和公共监督也要跟着升级。若治理系统按线性速度移动，技术系统按指数速度移动，缺口会越来越大。

8.5 延伸阅读

- Dario Amodei 关于 AI 风险、收益和经济影响的公开长文，可作为理解本访谈的背景材料。
- Anthropic 关于 responsible scaling、模型评估和发布策略的公开材料，可用于检查访谈主张与公司制度之间的对应关系。

8.6 最终小结

这支访谈把 AI 从产品演示拉入八个压力场：指数速度、企业收入、算力瓶颈、就业冲击、战争机器、网络能力、国家治理和社会信任。最冷硬的结论是：前沿 AI 已经进入普通软件之外的风险等级；收益叙事必须与发布克制、制度制衡和公众问责一起接受检验。Amodei 的答案是平滑加码与用行为赢回信任，社会的任务是持续核查这些行为是否配得上这种信任。