

课程笔记

最优传输的理论 与 计算系列讲座之一：深度学习的几何

顾险峰（讲者） 课程笔记整理

2026 年 6 月 12 日



视频作者/频道: Upupupxiaohua

发布日期: 2023 年 11 月 21 日

视频时长: 1 小时 18 分 29 秒

视频链接: <https://www.bilibili.com/video/BV1Da4y1U78N?p=1>

目录

1 引言：最优传输与深度学习的几何	2
1.1 讲座背景与目标	2
1.2 最优传输的“一体两面”	2
1.3 四类主要计算方法	2
1.4 应用领域概览	3
2 几何观点与核心口诀	3
2.1 支撑曲面与势能函数	3
2.2 正则性问题	4
3 计算机图形学中的应用	4
3.1 保面积参数化	4
3.2 法向贴图优化	5
3.3 体积保持映射	6
3.4 医学图像：大脑皮层映射	7
3.5 三维放大镜与曲面配准	8
3.6 球面映射与凸曲面重建	8
4 光学设计中的应用	9
4.1 反射镜设计	9
4.2 3D 打印与硬件加速	9
5 深度学习的几何理解	10
5.1 流形分布定则	10
5.2 MNIST 示例：从 784 维到 2 维	10
5.3 编码映射与解码映射	11
5.4 深度学习的目的	12
5.5 数学定理支撑	12
5.6 自动编码器 (Autoencoder)	12
5.7 ReLU 网络与胞腔分解	13
6 概率分布的学习：Wasserstein 空间	13
6.1 Wasserstein 空间与黎曼度量	13
6.2 Monge-Ampere 方程	13
7 生成模型与模式坍塌	14
7.1 GAN 的最优传输视角	14
7.2 模式坍塌的本质	15
7.3 实验验证：人脸生成的奇异集合	16
7.4 AE-OT 生成模型	17

8 问答精选	17
8.1 关于奇异集合	17
8.2 关于 AE-OT 与 GAN	18
8.3 关于工程与理论	18
9 总结与延伸	18
9.1 本章小结	18
9.2 核心洞察	19
9.3 开放问题	19
9.4 拓展阅读	19

1 引言：最优传输与深度学习的几何

1.1 讲座背景与目标

本讲座由顾险峰教授主讲，属于“最优传输的理论与计算”系列讲座的第一讲，主题为“深度学习的几何” (A Geometric Understanding of Deep Learning)。顾险峰教授师从菲尔兹奖获得者丘成桐先生，致力于将现代微分几何与拓扑理论推广至工程和医疗领域，与丘成桐先生共同创建了著名的计算共形几何学科。

参考教材

讲座内容可参考顾险峰教授的专著《最优传输：理论和计算》。该书理论性较强，包含大量数学推导。本系列讲座力求浅显直观，同时不牺牲严密性，为工程背景的同学提供更易理解的入门路径。

最优传输 (Optimal Transportation) 研究的核心问题是：**如何用最经济的方式将一个概率分布变换到另一个概率分布**。顾教授用生动的比喻说明：想象一个水杯中装有浓度不均匀的盐溶液，如何找到一种变换，将水中的分子重新排列，使得浓度变得均匀，同时使总传输距离达到最小——这就是最优传输理论研究的核心问题。

1.2 最优传输的“一体两面”

最优传输理论的核心特点是“一体两面”：

- **概率角度**：计算两个概率分布之间的距离，或将一个分布变换为另一个分布；
- **几何角度**：得到特殊的几何曲面，用于光学设计、图形学等应用。

1.3 四类主要计算方法

顾教授介绍了最优传输的四类主要计算方法：

1. **Kantorovich 线性规划**：基于线性规划的对偶理论，是深度学习中最常用的方法（如 Sinkhorn 算法）。但这种方法无法揭示理论的几何侧面，不适用于几何应用场合（如光学设计）。
2. **几何变分法**：从凸几何（Alexandrov、Pogorelov 等俄罗斯学派）发展而来，几何直观非常强，是本系列讲座的重点。
3. **流体力学方法 (Brenier, 法国学派)**：物理直观强，可为 Wasserstein 空间引入黎曼度量，特别适合概率密度空间的变分问题。
4. **Monge-Ampere 方程数值方法**：包括 Multigrid、快速多极变换等传统数值方法。

几何口诀

最优传输的几何本质可以总结为四句口诀：**代价决定支撑，支撑包络势能，势能微分映射，映射逆亦最优**。这是整个系列讲座的精髓所在。

1.4 应用领域概览

最优传输的应用极其广泛，包括但不限于：

- **深度学习**：GAN（对抗生成网络）本质上计算分布之间的距离和变换；
- **经济学/运筹学**：产销平衡、资源分配；
- **3D 图形学/元宇宙**：保面积参数化、数字孪生；
- **图像处理**：风格迁移（Photoshop 背后的算法）；
- **NLP**：字节跳动在自然语言处理领域的突破基于最优传输思想；
- **自动驾驶**：点云配准、几何配准、曲面配准；
- **医学图像**：二维/三维/高维图像配准；
- **光学设计**：特殊透镜设计，使反射/折射满足特定分布。

2 几何观点与核心口诀

2.1 支撑曲面与势能函数




图 1: 最优传输的几何直观：红色抛物线构成支撑曲面族，包络出黑色的势能曲线。势能函数在某点与某条抛物线相切，切点的横坐标对应最优传输映射。¹

最优传输的几何观点可以用一幅“过目难忘”的图来概括（见图 1）：

- 图中有一族红色的抛物线，构成**支撑曲面**（support surfaces）；
- 这些支撑曲面共同包络出一条黑色的曲线，即**势能函数**（potential function）；

¹视频画面时间区间：00:08:45–00:09:15。

- 黑色曲线在任何一点 X 处，与某条红色抛物线相切；
- 该抛物线的对称轴横坐标为 Y ，每个抛物线由传输代价决定；
- X 与 Y 的对应关系即构成**最优传输映射**。

四句口诀详解

1. **代价决定支撑**：传输代价函数决定支撑曲面族的形状；
2. **支撑包络势能**：支撑曲面族的包络构成势能函数；
3. **势能微分映射**：势能函数的（广义）微分给出最优传输映射；
4. **映射逆亦最优**：最优传输映射的逆映射也是最优传输映射，对应另一个势能函数。

两个势能函数之间相差一个 Legendre 变换，而两个映射之间相差一个 Poincare 对偶。整个理论具有高度的对称性。

2.2 正则性问题

正则性：理论与应用的分水岭

书中写了大量关于正则性 (regularity) 的论证。正则性是最优传输理论中最困难的问题之一。对于实际应用（如欧氏空间或紧黎曼流形），正则性问题通常不大；但作为理论研究，正则性是最为困难的核心问题。不同领域关注点不同，使用的技巧也不同。

3 计算机图形学中的应用

3.1 保面积参数化



图 2: 弥勒佛曲面的参数化对比。左：共形变换（保角但面积畸变大，头部缩小）；右：最优传输变换（保面积，各区域面积相等）。²

在计算机图形学中，将三维曲面映射到二维平面是常见需求（如纹理贴图）。共形变换虽然局部保形，但面积畸变可能非常大。最优传输映射可以实现**保面积参数化**（area-preserving parameterization）：

1. 将曲面面积“推前”到平面上，定义一个概率测度；
2. 在平面上有均匀分布（Lebesgue 测度）；
3. 计算这两个分布之间的最优传输映射；
4. 所得映射是某个凸函数的梯度映射，保证保面积性质。

3.2 法向贴图优化



图 3: 法向贴图（Normal Map）优化。左：共形变换导致翅膀等区域面积畸变；右：复合最优传输变换后，各部位面积比例恢复，极大提高渲染质量。³

法向贴图是图形学中的关键技术：将三维曲面法向量编码为二维图像的 RGB 颜色，既提高渲染质量又减少三角网格数量。使用共形变换时，曲面的某些部位（如翅膀）会被过度压缩，导致法向贴图质量下降。复合最优传输变换后，面积畸变被纠正，渲染质量极大提升。

²视频画面时间区间：00:11:03–00:11:35。

³视频画面时间区间：00:13:05–00:14:00。

3.3 体积保持映射




图 4: 斯坦福兔子的体积保持映射。左侧为初始映射（调和映照 + 体调和），右侧为复合最优传输映射后的保体积结果。⁴

最优传输对任意维度使用同样的核心算法。以三维为例：

- 对斯坦福兔子进行四面体剖分；
- 先通过调和映照映射到单位球面，再拓展到内部；
- 复合最优传输映射，保证从实心球中任意挖掉一块，对应兔子身上的某一块，体积相等。

这在计算机辅助设计（CAD）和医学图像处理中有重要应用。

⁴视频画面时间区间：00:14:20-00:15:20。

3.4 医学图像：大脑皮层映射




图 5: 大脑皮层映射到平面。不同功能区域用不同颜色标注, 可用于监控老年痴呆等疾病的神经中枢变化。⁵

大脑皮层映射是医学图像处理的重要应用:

- 将大脑皮层映射到平面, 不同功能区域(运动、语言、情感等)可分别监控;
- 人过 25 岁后大脑每年萎缩, 监控各神经中枢减小速率可预测疾病风险;
- 通过最优传输映射, 可以精确比较不同时间点的大脑形态变化。

⁵ 视频画面时间区间: 00:15:33-00:16:20。

3.5 三维放大镜与曲面配准




图 6: 食蚁兽 (Armadillo) 曲面配准。左: 黎曼映照导致手指和耳朵过度压缩; 右: 复合最优传输映射后, 各部位比例恢复, 配准质量达到全局最优。⁶

体式放大镜: 传统放大镜只能对二维图像放大缩小, 而医学图像往往是三维的。最优传输映射可以实现三维虚拟放大镜, 对特定部位 (如膝盖骨、脊椎骨) 进行放大观察。

复杂曲面配准: 当物体姿态发生非刚性变化时 (如食蚁兽的不同姿态), 传统刚性变换无法对齐。通过映射到平面后再进行配准, 可以避免局部最优, 达到全局最优的配准结果。

3.6 球面映射与凸曲面重建

对于凸曲面, 只要知道第一基本形式 (黎曼度量) 就能决定其形状。在球面上定义高斯曲率作为目标面积元, 通过最优传输映射可以重建出对应的凸曲面。这是 Minkowski 问题的球面版本。

⁶ 视频画面时间区间: 00:17:21–00:18:25。

4 光学设计中的应用

4.1 反射镜设计




图 7: 光学透镜设计问题。左侧为点光源和透镜，右侧为墙面上的目标图像。通过最优传输计算势能曲面，光线跟踪得到精确的反射效果。⁷

光学设计是最优传输的经典应用之一：

- 问题设定：一个点光源发出光线，经过蓝色透镜反射后射向无穷远处，在墙壁上形成特定图像；
- 核心问题：如何设计透镜形状，使得反射/折射后的光强分布满足指定要求；
- 本质：球面上的入射能量分布与反射能量分布之间的最优传输映射；
- 与传统方法的区别：不通过局部遮挡（幻灯片）浪费能量，而是改变光的分布而不损失能量。

最优传输 vs 最差传输

在光学设计中，由于只关心镜面/透镜的曲面形状，可以使用最优传输变换，也可以使用“最差传输变换”。两者在数学上等价，因为问题的本质只依赖于势能曲面。

4.2 3D 打印与硬件加速

随着 3D 打印技术的发展，制造高精度的特殊曲面成为可能。目前最优传输的计算仍较费时，但已有专门的硬件芯片可以将计算速度提高数百到数千倍。

⁷ 视频画面时间区间：00:20:06–00:21:40。

5 深度学习的几何理解

5.1 流形分布定则

流形分布定则 (Manifold Distribution Principle)

这是数据科学的基石，最早由 Mumford 等学派在 90 年代中期提出：

1. 每个自然概念对应一个数据集；
2. 数据集中的每个样本是数据空间中的一个点；
3. 数据集构成一个点云，分布在某个低维流形附近；
4. 该流形嵌入在高维背景空间中，且本身弯曲；
5. 数据在流形上的分布不均匀，满足特定的概率分布。

因此：概念 $\rightarrow$ 数据集 $\rightarrow$ 流形上的概率分布。

5.2 MNIST 示例：从 784 维到 2 维




图 8: MNIST 数据集的 t-SNE 可视化。左侧为手写数字图像，右侧为嵌入到二维平面的十个团簇。每个团簇对应一个数字类别，映射是可逆的。⁸

以 MNIST 手写数字数据集为例：

- 每个图像是 28×28 的黑白图像，即 784 维空间中的一个点；
- Hinton 等人用 t-SNE 算法将数据映射到二维平面，形成十个团簇；
- 关键发现：**映射是可逆的**——从二维平面上的点可以恢复出原始图像；

⁸视频画面时间区间：00:28:00–00:29:00。

- 这说明 MNIST 数据云虽然位于 784 维空间中，但实际上非常接近一个二维曲面。

模式混淆 (Mode Confusion)

如果在隐空间中均匀采样，采样点落在分布支撑集内部时，恢复的图像质量高；如果落在团簇之间（支撑集之外），会得到混淆的图像（如 8 和 5 的混合）。这种现象称为**模式混淆**，是生成模型中的核心问题。

5.3 编码映射与解码映射



图 9: UMAP 算法得到的 MNIST 团簇分布。在隐空间均匀采样后通过解码映射恢复图像，展示模式混淆现象。⁹

深度学习的核心操作可以翻译为拓扑/几何语言：

深度学习术语	数学术语	含义
编码映射 (Encoder)	参数化/嵌入映射	高维流形 $\rightarrow$ 低维隐空间
解码映射 (Decoder)	逆参数化/提升映射	隐空间 $\rightarrow$ 高维流形
特征 (Feature)	参数点	隐空间中的坐标
隐空间 (Latent Space)	参数空间	低维坐标空间

表 1: 深度学习术语与数学术语的对照

工程界与数学界的术语差异

顾教授指出，许多深度学习的概念在数学中已存在数十年甚至上百年（如参数化、单位分解、流形等），但工程师往往用新术语重新发明。这可能是由于工程师不太熟悉拓扑学语言，或想突出自己的贡献。这种术语混乱为学习者带来很大困扰。

⁹ 视频画面时间区间：00:32:37–00:33:00。

5.4 深度学习的目的

深度学习的两个核心目标

1. **学习流形结构**: 通过编码/解码映射, 将高维数据流形嵌入到低维隐空间;
2. **学习概率分布**: 在隐空间上保持数据的概率分布结构, 使得采样和生成有意义。

5.5 数学定理支撑

深度学习之所以有效, 有深厚的数学定理支撑:

1. **一般位置定理**: m 维流形在 $\mathbb{R}^n$ 中 ($n > 2m + 2$) 的嵌入没有链结构/扭曲。这解释了为什么神经网络通常先增宽后收窄——增加嵌入空间维度使嵌入更简单。
2. **Whitney 嵌入定理**: n 维光滑流形可以光滑嵌入到 $\mathbb{R}^{2n+1}$ 中。其证明中的单位分解思想直接启发了 UMAP 等算法。
3. **Urysohn 引理**: 拓扑空间中两个闭集之间存在连续分离函数。这解释了模式识别的理论基础——监督/非监督学习本质上是在学习这个分离函数。
4. **万有逼近定理**: 深度神经网络可以逼近任意连续变换。这对应于 Hilbert 第 13 问题 (由 Kolmogorov 和 Arnold 解决)。

Kolmogorov-Arnold 表示定理

任意多元连续函数可以表示为有限个一元函数的复合与求和。深度神经网络正是这种思想的“物化”: 传统有限元/样条用基函数的线性组合逼近, 而深度网络用简单函数的复合来逼近。

5.6 自动编码器 (Autoencoder)




图 10: 自动编码器结构。输入为原始图像 (784 维), 输出为重建图像, 中间瓶颈层为隐空间 (如 2 维)。编码器和解码器互为逆映射。¹⁰

自动编码器是理解流形学习的最简单模型：

- 输入和输出都是原始图像，损失函数使重建误差最小；
- 网络对称：左半部分计算编码映射，右半部分计算解码映射；
- 瓶颈层节点数等于隐空间维数；
- 当损失函数趋于零时，编码和解码互为逆映射，复合等于恒同映射。

实验表明，即使这个“粗糙”的想法也能有效工作：对弥勒佛曲面采样 3000 个点，通过编码-解码映射后，重建曲面与原曲面非常接近，手指和脚趾都被充分展开。

5.7 ReLU 网络与胞腔分解

ReLU 网络本质上将空间动态分解为多个胞腔 (cells)，在每个胞腔内映射是线性的。这与传统有限元没有本质差别——都是用分片线性映射逼近连续变换。但关键区别在于：

- 传统有限元：先进行固定的三角剖分，再在剖分上构造函数；
- ReLU 网络：**动态生成**胞腔分解，三角剖分本身未定。

这使得深度学习的数学分析极为困难——想计算各阶导数、各阶范数估计时，这些估计依赖于三角剖分的几何形状，但剖分本身是动态生成的。

6 概率分布的学习：Wasserstein 空间

6.1 Wasserstein 空间与黎曼度量

深度学习的本质：Wasserstein 空间中的优化

给定一个数据流形，考察其上所有概率测度，它们构成一个无穷维空间，称为 **Wasserstein 空间**。深度学习的本质就是在这个空间中进行优化：

- 最大熵原理、最大似然法、最大后验概率等，都是将观察结果表示为函数期望值，作为约束来优化特定能量（通常是熵）；
- 需要在 Wasserstein 空间中定义度量、协变微分，才能进行变分；
- 最优传输理论为这个无穷维空间引入了黎曼度量，使得变分得以实行。

6.2 Monge-Ampere 方程

最优传输问题归结为 **Monge-Ampere 方程**——一个强非线性偏微分方程。该方程非常难解，但已有成熟的理论框架：

- Wasserstein 空间中的测地线由 McCann 给出；
- 空间中的黎曼度量、梯度等均有成熟理论。

¹⁰ 视频画面时间区间：00:41:00–00:42:00。

7 生成模型与模式坍塌

7.1 GAN 的最优传输视角




图 11: GAN 模型的最优传输视角。生成器将隐空间白噪声映射到数据流形上的生成分布；判别器判断生成分布与真实分布之间的距离。¹¹

从最优传输角度理解 GAN:

- 数据流形上有真实分布；
- 隐空间上有白噪声（均匀/高斯分布）；
- 生成器将白噪声映射到数据流形上的生成分布；
- 判别器判断生成分布与真实分布之间的距离；
- 两者本质上都在计算最优传输映射。

GAN 的对抗是不必要的

顾教授提出深刻见解：生成器和判别器都在计算最优传输映射。如果两者计算都相对准确，它们的结果直接复合就达到最终目标。每一步更新应该将两者结果复合后赋给生成器，而非让它们相互对抗。从最优传输理论看，GAN 中的对抗机制是没有必要的，合作可以极大提高效率。

¹¹ 视频画面时间区间：00:46:00–00:47:00。

7.2 模式坍塌的本质



图 12: 模式坍塌现象。原始数据有 25 个模式（直升机），GAN 生成后无法覆盖所有模式，或产生虚假样本。¹²

模式坍塌的根因：最优传输映射的非连续性

模式坍塌和模式混淆是深度学习中最困难的问题。其根本原因在于：

1. 最优传输映射是某个凸函数的梯度映射；
2. 势能函数并非处处光滑，在某些点连续但不可微；
3. 在不可微点，梯度映射发生跳变，最优传输映射不再是连续的；
4. 深度神经网络只能表达连续变换，无法表达非连续变换；
5. 因此神经网络试图用连续函数逼近非连续目标，必然遗漏某些模式。

¹² 视频画面时间区间：00:48:44–00:49:00。

7.3 实验验证：人脸生成的奇异集合



图 13: 人脸生成实验。左：正常生成的人脸序列；右：穿越流形边界的序列，中间出现“一只眼睛蓝、一只眼睛黑”的奇异人脸——概率为零但解剖学上合理的边界样本。¹³

顾教授团队进行了验证实验：

- 在隐空间（约 100 维）中从白噪声出发，计算到数据分布的最优传输映射；
- 在隐空间中画直线，映射到数据流形上成为曲线（morphing sequence）；
- 如果直线穿越奇异集合，会得到“边界样本”；
- 实验发现：从一个棕发棕眼男孩到金发碧眼女孩的过渡中，中间出现“一只眼睛蓝、一只眼睛黑”的奇异人脸；
- 这种人脸在生理学上合理，但现实生活中遇到概率为零——正是**流形边界**上的点。

奇异集合

从几何上看，最优传输的奇异集合对应于 medial axis（中轴）：到多个最近点距离相等的点集。从势能函数角度看，就是 potential 非光滑的地方。增加隐空间维度无法消除奇异集合，因为奇异集合依赖于目标区域边界的曲率，而非维度。

¹³ 视频画面时间区间：00:52:47–00:53:40。

7.4 AE-OT 生成模型



图 14: AE-OT 生成模型框架。上半部分用 Autoencoder 学习编码/解码映射 (学习流形结构); 下半部分用几何变分法计算最优传输映射 (学习概率分布)。¹⁴

顾教授团队提出 **AE-OT** (Autoencoder + Optimal Transport) 生成模型:

- **第一阶段**: 用 Autoencoder 学习编码映射和解码映射 (学习流形结构) ——这一阶段非常稳定;
- **第二阶段**: 用几何变分法计算最优传输映射 (学习概率分布) ——理论完备, 完全透明;
- 将白噪声通过最优传输映射到隐空间的数据分布;
- 用深度网络表达**势能函数** (Brenier potential), 而非梯度映射;
- 这样可以完美避免模式坍塌。

为什么表达势能而非梯度?

势能函数是全局连续的, 而梯度映射在奇异集合处发生跳变 (非连续)。深度神经网络可以很好地表达连续函数, 因此应该让网络学习势能函数, 再通过自动微分得到梯度映射。这是避免模式坍塌的关键洞察。

8 问答精选

8.1 关于奇异集合

Q: 奇异集合的 Hausdorff 测度有估计吗? **A**: 有估计, 后续讲座会详细分析。

Q: 边界几何上是什么? 等概率线吗? **A**: 边界上是概率趋于零的地方。支撑集内部概率密度大于零, 边界上概率趋于零。这意味着边界上的样本可能出现, 但出现概率为零 (如 “一只眼睛蓝一只眼睛黑” 的人脸)。

¹⁴ 视频画面时间区间: 00:54:42–00:55:10。

Q: 为什么边界是眼睛颜色不同, 而不是耳朵大小不同? **A:** 因为数据集是正面照片, 只能看到一只耳朵。如果拍三维人脸, 边界上可能出现“两个耳朵不一样”的人脸。

Q: 增加维度可以解决奇异集合问题吗? **A:** 不能。奇异集合不依赖于维度, 而是依赖于目标区域边界的曲率。如果支撑集是凸的, 问题不大; 但深度学习中无法保证目标分布的支撑集一定是凸的。

8.2 关于 AE-OT 与 GAN

Q: AE-OT 的 GAN 结构还是遵循 GAN 吗? **A:** AE-OT 本质上还是将隐空间白噪声变为数据分布, 思想没有变化。但将“对抗”变成了“合作”——生成器和判别器应该彼此协作, 而非对抗。

Q: 最优传输映射可以把任何分布变成均匀分布吗? **A:** 是的, 只要两个分布满足一定的正则性要求 (如密度函数有界)。最优传输是概率统计中最 general 的终极理论。

Q: 归一化流 (Normalizing Flow) 与最优传输的关系? **A:** 归一化流本质上计算某种传输映射, 而最优传输映射是所有传输映射中最优的。如果归一化流理论上没有信息损失, 最优传输映射更加没有信息损失。

8.3 关于工程与理论

Q: 现有最优传输在工程界普遍实现的痛点在哪里? **A:** 计算复杂。目前已有专用芯片可以将计算效率提高上千倍到上万倍。

Q: 图像在隐空间维度往往很高, 计算开销大, 有解决的理论吗? **A:** 迄今为止还没有理论解决, 这是工程问题而非理论问题。

Q: 低质 (低秩) 与流形分布定则之间有关系吗? **A:** 低质本质是在高维线性空间中寻找低维线性子空间, 可以看成流形的局部切空间逼近。但低质抛弃了流形整体的拓扑特点和曲率特点, 因此流形分布定则更加广泛和特异。

9 总结与延伸

9.1 本章小结

本讲座从最优化传输的几何观点出发, 为深度学习提供了全新的理论视角:

1. **最优传输的核心:** 用最经济的方式将一个概率分布变换到另一个概率分布, 其几何本质可概括为“代价决定支撑, 支撑包络势能, 势能微分映射, 映射逆亦最优”。
2. **应用领域广泛:** 从计算机图形学 (保面积参数化、法向贴图) 到医学图像 (大脑皮层映射、三维放大镜), 从光学设计 (特殊透镜) 到自动驾驶 (点云配准), 最优传输无处不在。
3. **深度学习的几何本质:** 深度学习学习两个东西——流形结构 (编码/解码映射) 和概率分布 (最优传输映射)。数据科学的基石是流形分布定则: 概念对应数据集, 数据集对应流形上的概率分布。
4. **模式坍塌的根因:** 深度神经网络只能表达连续变换, 而最优传输映射在奇异集合处非连续。这是深度学习本质的矛盾所在。解决方案是让网络学习势能函数 (连续) 而非梯度映射 (可能非连续)。
5. **AE-OT 框架:** 将流形学习和概率分布学习分离, 前者用 Autoencoder, 后者用几何变分法计算最优传输, 使黑箱模型变得半透明。

9.2 核心洞察

深度学习的最优传输视角

- 深度学习成功的核心原因是数据服从**流形分布定则**；
- 深度学习的本质是在 **Wasserstein 空间**中进行优化；
- 最优传输理论为这个无穷维空间引入了**黎曼度量**，使变分得以实行；
- GAN 中的对抗是不必要的，生成器和判别器应该**合作**而非对抗；
- 模式坍塌源于神经网络的连续表达能力与最优传输映射的非连续性之间的矛盾。

9.3 开放问题

1. **奇异集合理论**：最优传输映射的奇异集合在一般支撑集（非凸）下的理论仍非常活跃，是纯数学的重要研究方向。
2. **高维计算效率**：隐空间维度过高导致计算开销大，目前仍依赖经验调整（如从 1000 维逐步降至 100 维可行，50 维则不行），缺乏理论指导。
3. **硬件加速**：专用芯片可将最优传输计算提高数千倍，但普及程度仍有限。
4. **可解释 AI**：最优传输理论为深度学习提供了严密的理论基础，但如何完全打开黑箱仍是挑战。

9.4 拓展阅读

- 顾险峰等，《最优传输：理论和计算》
- Villani, C. *Optimal Transport: Old and New*
- Santambrogio, F. *Optimal Transport for Applied Mathematicians*
- 丘成桐、顾险峰等，计算共形几何相关著作