


《思考杠杆：用努力级别、预算与自适应思考调度推理时计算》

SSS & Codex

整理日期：2026-07-22



原视频标题：The thinking lever

视频作者/频道：Claude

发布日期：2026-05-08

视频时长：24:02

来源说明：基于英文自动字幕与视频画面整理

视频链接：youtube.com/watch?v=OXJO4LldSnc

PDF 制作 Skill：github.com/wdkns/wdkns-skills

目录

1 先看见第二根规模化杠杆	2
1.1 为什么同一个模型会给出不同层次的结果	2
1.2 一项交通模拟如何建立直觉	3
1.3 成本与愿景必须同时看见	5
1.4 本章小结	5
2 推理时支出的三种去向与两类控制	6
2.1 资源究竟花在什么地方	6
2.2 努力级别表达偏好	7
2.3 任务预算设置上限	7
2.4 两个控制如何共同限定资源空间	8
2.5 本章小结	8
3 从固定流水线到自适应思考	8
3.1 固定顺序：一次思考完成后再行动	9
3.2 交错式思考：把反馈带回决策环	9
3.3 自适应思考：三类活动可以按需重排	10
3.4 提示依赖：更高努力不产生固定令牌倍率	11
3.5 两类边界：路由、开关与努力级别各管什么	12
3.6 本章小结	12
4 用评测曲线寻找合适投入点	13
4.1 先画曲线：同一工作负载上的性能与支出	13
4.2 识别边际收益递减	14
4.3 低努力的双面性：节省资源，也会改变策略	14
4.4 Pokémon Red：聪明捷径为何仍需审查	15
4.5 五档努力级别：日期限定的起始假设	16
4.6 把分数、曲线与轨迹合成一次选择	17
4.7 本章小结	17
5 联合选择模型大小、努力级别与延迟目标	18
5.1 为什么单独选择模型或努力级别都不够	18
5.2 先按任务性质缩小候选组合	19
5.3 交通模拟对照说明了什么	19
5.4 首令牌延迟与末令牌延迟回答不同问题	20
5.5 把经验规则变成部署决策表	20
5.6 本章小结	21
6 总结与延伸：设定质量门槛与预算，让系统负责分配	21
6.1 演讲者留下的三项行动建议	21
6.2 把全文压缩成一套资源分配机制	22
6.3 五步部署清单	23
6.4 证据边界与实施风险	23

6.5 仍然开放的三个问题 24

6.6 长期愿景：用户设门槛与预算，系统完成分配 24

6.7 本章小结 25

1 先看见第二根规模化杠杆

核心结论

模型交付前的资源投入决定其已经具备的基础能力区间，回答当前请求时的资源投入决定这项任务获得多少工作机会。对困难任务而言，增加后一类投入可能改善结果，同时也会增加令牌消耗、等待时间与成本；投入更高并不构成质量线性增长或普遍单调提升的保证。

1.1 为什么同一个模型会给出不同层次的结果

讨论大模型能力时，常见视角集中在模型大小、训练数据和训练时长。这些投入都发生在模型交付给用户之前，可统称为**训练时计算 (training-time compute)**。它像是先决定一名专业人员已经接受过怎样的教育、掌握多少工具、能处理多复杂的问题。

视频引入了第二根杠杆：**推理时计算 (test-time compute)**。它指模型训练完成后，为解决当前请求而投入的令牌、时间与工具交互资源。来源中的另一种同义表述也统一并入“推理时计算”，不另造中文术语。这根杠杆更像是给同一名专业人员不同的作业时间：能力基础没有更换，眼前任务得到的分析、试错与检查机会发生了变化。

两根杠杆彼此互补。扩大训练时计算，可能把模型的基础能力推到更高区间；扩大推理时计算，则可能让既定模型在当前请求上搜索更多方案、检查更多细节并完成更多动作。视频把通过推理时计算获得工作空间的模型称为**推理模型 (reasoning models)**，这一类别名称只描述回答阶段可投入推理工作，并不意味着私有推理轨迹会向用户公开。




图 1: 三类知识工作的表现—资源曲线。图中数据只反映演讲展示的特定基准结果；两处高投入点的局部回落也直观说明更高投入不是逐点单调改善的保证。¹

演讲者用知识工作曲线说明这一互补关系：从 Haiku、Sonnet 到 Opus 的模型变化，对应基础模型轴上的能力变化；同一个 Opus 延长工作时间，则对应推理时计算轴上的变化。演讲还把方向

¹ 视频帧来源：00:01:18–00:02:18；采用 00:01:54 附近的完整幻灯片。

性结论延伸到智能体编码、智能体搜索、计算机使用和博士层级学术推理。这里能成立的是“更多工作机会可能带来更好结果”的方向性观察。曲线来自演讲中的内部或展示性基准结果，不能据此推导跨任务通用的精确增益，也不能把图上未核验清楚的点位转写为数值规律。

1.2 一项交通模拟如何建立直觉

为了把抽象曲线变成可感知的差异，演讲者让同一个 Opus 4.7 针对同一提示词生成单向道路红绿灯交通模拟，并依次改变**努力级别 (effort levels)**。努力级别表达系统应当投入多大工作强度，后文还会进一步说明它与硬性上限的区别。

低努力结果约用时 50 秒、消耗约 4,600 个输出令牌。它完成了车辆沿单向道路移动并在红灯处停车的基本要求，交通流和图形较为简单，红绿灯还被放在道路中央。演讲者把它判断为“功能上通过”。这一判断提供了一个重要起点：较少资源仍可能完成核心任务，完整性、真实感和设计细节则可能有限。




图 2: Opus 4.7 低努力的交通模拟：任务用时 50.1 秒，输出 4,602 令牌；红灯时车辆在道路中央的信号灯前排队。²

高努力约使用低努力两倍的时间和输出令牌。演讲者观察到车辆类型更丰富，红绿灯被移到路侧，模拟还报告采用了让车辆根据周围车辆动态作出反应的“智能驾驶员模型”。静态画面能够支持车型和红绿灯位置等可见差异，动态驾驶行为仍需要运行结果或视频连续片段才能证明，单帧截图无法承担这一结论。

²视频帧来源：00:02:52–00:03:38；采用 00:03:34 附近的红灯状态。

Claude Opus 4.7 High effort

Effort: **High**

Task time: **111.3s**

Output tokens: **9,826**




图 3: Opus 4.7 高努力的交通模拟：任务用时 111.3 秒，输出 9,826 令牌；画面显示多种车型和移至路侧的信号灯。静态帧不用于证明车辆的动态反应。³

最高努力约使用低努力十倍的时间和令牌。演讲者主观判断它拥有三者中最好的图形、红绿灯和驾驶模式。这个案例显示，同一模型在得到更多任务资源时，可以产出更完整的结果；它仍然只是一次提示词、一次模型和一次演示条件下的比较。视频没有提供重复试验、误差范围或盲评，因此不能把“十倍资源”写成“十倍质量”，也不能据此承诺任意任务都随努力提高而持续改善。

³视频帧来源：00:03:38–00:04:26；采用 00:03:56 附近的完整模拟状态。

Claude Opus 4.7 Max effort

Effort: **Max**

Task time: **593.1s**

Output tokens: **52,893**




图 4: Opus 4.7 最高努力的交通模拟：任务用时 593.1 秒，输出 52,893 令牌；夜景、路侧信号灯、人行横道和多车型同时可见。⁴

案例应当支持什么结论

这组三档结果最适合建立资源直觉：任务、模型保持不变时，增加工作时间和令牌可能换来更丰富、更完整的实现。它不能建立固定倍数关系，也不能证明更高努力在所有工作负载上始终更优。部署结论仍需来自真实任务上的重复测试。

1.3 成本与愿景必须同时看见

推理时计算之所以是一根“杠杆”，原因在于它同时放大收益与支出。更多令牌意味着直接资源成本，也通常意味着用户需要等待更久。对于困难任务，额外搜索、验证和工具工作可能很有价值；对于简单任务，同样的投入可能只增加延迟，甚至引入无益的复杂度。部署者需要判断当前任务是否存在值得购买的额外工作机会，避免把资源数量本身当作目标。

演讲者进一步设想，未来系统可能连续工作数日、数周、数月甚至数年，持续消耗资源以处理人类最困难的问题。这是演讲者在 2026 年 5 月表达的长期愿景，不能当作视频已经展示或验证的产品能力。愿景的教学价值在于暴露控制问题：任务持续时间越长，用户越需要表达期望质量、可接受成本以及何时暂停检查。

1.4 本章小结

本章建立了两条相互补充的规模化轴。训练时计算塑造模型的基础能力，推理时计算为当前任务分配工作资源。同一 Opus 4.7 交通模拟的低、高、最高努力结果表明，更多时间和令牌可能换来更完整的结果，也同步增加成本与等待。该演示只提供方向性证据，不支持线性定律、固定倍数或

⁴视频帧来源：00:04:26–00:05:08；采用 00:05:02 附近的红灯状态。

普遍单调保证。下一章将拆开这些资源的实际去向，并区分用于表达偏好的强度控制与用于设定上限的边界控制。

2 推理时支出的三种去向与两类控制

核心结论

推理时计算并不只发生在模型“想问题”时。它覆盖内部推理、外部工具交互和面向用户的文本沟通三类活动；努力级别表达质量、时间与成本之间的偏好，另一类边界控制给出令牌、时间或成本上限。前者提供工作强度方向，后者划定不可越过或必须检查的边界。

2.1 资源究竟花在什么地方

上一章只观察到“工作更多”会改变结果。要进一步控制这一过程，需要先拆开推理时支出的去向。演讲者给出三类功能活动：**思考令牌 (thinking tokens)**、**工具调用令牌 (tool-calling tokens)** 与 **文本令牌 (text tokens)**。三者分别承担形成判断、接触环境和沟通结果的功能，用途不同且可以在一次任务执行中交错出现。

思考令牌：形成下一步判断。 演讲者用“内部独白”“思维链”和“草稿纸”描述模型在内部比较备选方案、逐步处理问题并决定行动的工作空间。这些说法应理解为来源对功能的概念性解释。它们不构成私有推理轨迹对用户可见、可导出或可完整审计的承诺。可观察的交付证据仍是模型输出、工具记录和任务结果。

工具调用令牌：让判断接触外部世界。 工具调用覆盖搜索资料、读取或写入文件以及与其他外部系统交互。仅在内部形成计划无法改变环境；工具活动把计划变成查询、读取、写入或执行，并把结果带回后续处理。视频以搜索会议信息和操作软件工程项目文件为例，强调模型通过工具接触任务环境。

文本令牌：维持与用户的协作界面。 文本既包括最终答案，也包括长任务中的进度更新、阶段性说明和完工总结。它让用户知道系统正在做什么、得到什么结果以及下一步需要怎样的决策。将文本只理解为最终回复，会漏掉长期任务中的协调成本与沟通价值。



图 5: 一次搜索任务中的三类活动: 思考形成搜索意图, 工具调用返回外部结果, 文本向用户交付摘要。⁵

三类活动可以用一个研究任务理解。系统先分析问题和信息缺口, 再调用搜索获取资料, 随后向用户报告阶段结果; 新资料又可能触发进一步分析和下一次工具调用。资源支出分布在整个工作循环中, 无法只归入某一个“思考阶段”。这个拆分也解释了为什么仅关闭某一类能力, 无法精确表达“总体少花一点资源”。

2.2 努力级别表达偏好

努力级别调节器 (effort dial) 是演讲者使用的界面隐喻, 指向的仍是努力级别这一控制。它用于告诉系统, 应当如何权衡质量、完成时间和成本: 更愿意等待并投入更多资源以争取更完整的结果, 或更重视快速、节省资源的响应。

努力级别属于偏好信号。它影响系统在三类活动上的整体工作强度, 无法保证固定令牌数, 也无法保证某一类令牌按固定比例变化。任务本身是否提供了可深入分析、可继续搜索或可反复验证的机会, 都会影响实际消耗。一个简单事实查询与一个复杂软件工程任务即使使用同一努力级别, 也可能形成完全不同的执行轨迹。

2.3 任务预算设置上限

任务预算 (task budgets) 表达硬约束或检查点: 系统在达到规定的令牌、时间或成本上限之前可以继续工作, 到达边界后应停止或向用户检查。视频给出的示例是, 为一个软件功能设定 100,000 令牌上限, 达到上限后暂停并与用户确认。100,000 只是演讲者用于说明机制的数字, 不是推荐默认值。

视频在 2026 年 5 月使用“近期推出”描述任务预算。这一说法只代表演讲当时的产品表述, 不能直接推广为当前可用范围、默认行为或接口承诺。这里可稳定保留的知识是预算的控制语义: 令牌、时间与成本都可以成为边界单位; 长期任务越可能延续数日或更久, 暂停检查点越重要。

⁵ 视频帧来源: 00:05:32-00:07:47; 采用 00:05:48 附近三类标签和内容同时显示的完整状态。

维度	努力级别	任务预算
表达内容	对质量、时间和成本取舍的偏好	可消耗令牌、时间或成本的上限
控制性质	引导整体工作强度，实际消耗由任务决定	到达边界后停止或触发用户检查
回答的问题	系统应当投入多大程度的工作	系统最多可以工作到什么位置
典型风险	被误解为固定令牌倍数或质量保证	被误解为必须全部花完的目标
来源示例	低、高、最高等不同工作强度	100,000 令牌后暂停检查

2.4 两个控制如何共同限定资源空间

努力级别与任务预算分别处理“倾向”和“边界”。部署者可以要求系统以较高强度工作，同时设置一个明确预算，避免任务无限延长；也可以给出宽裕预算，同时采用较低努力，让系统优先节省资源。预算不要求系统把额度全部用尽，努力级别也不会解除预算上限。

在这两个信号之下，系统还要决定如何把资源分配给思考、工具调用和文本沟通。例如，遇到不确定事实时，更多内部推理无法替代外部核验；长时间工具操作若没有阶段更新，又会削弱用户对任务状态的掌握。高质量执行因此依赖于三类活动之间的合理分配。努力级别说明系统应多用力，任务预算说明何时必须停下，具体活动顺序则留给下一章的调度机制处理。

控制语义的最小检查表

阅读或设计一个任务接口时，应分别确认三件事：其一，努力级别表达的是偏好还是保证；其二，预算按令牌、时间还是成本计量；其三，到达预算后是立即停止、保存状态，还是向用户请求继续。只给出“高努力”或“预算充足”都不足以完整定义长期任务的运行边界。

2.5 本章小结

推理时支出包含思考令牌、工具调用令牌和文本令牌：它们分别服务于判断、环境交互和用户沟通。努力级别对三类活动的总体工作强度给出偏好，任务预算对令牌、时间或成本给出上限或检查点。两种控制共同确定可用资源空间，仍未回答三类活动应按什么顺序出现。下一章将比较固定流水线、反馈驱动的调度与更自由的按需调度，说明系统如何在边界内安排实际过程。

3 从固定流水线到自适应思考

本章结论

自适应思考 (adaptive thinking) 改变的是任务全过程中三类活动的**调度自由**：系统可以按需要安排思考、工具调用与文本沟通，也可以在简单任务中不进入显式思考阶段。努力级别继续表达工作强度偏好，提示与任务本身则决定额外工作空间是否有可利用的机会。它不负责在模型之间选路，也不先分类难度再切换思考模式。

上一章已经把推理时支出拆成思考、工具调用与文本沟通三类活动，并用努力级别和任务预算规定偏好与边界。接下来的问题是：系统拿到这些自由度之后，应当怎样安排三类活动？演讲者给出的机制演进有三步：固定顺序、反馈驱动调度、自适应思考。三步的差异主要落在**活动顺序与重排时机**，不能解读成模型大小变化，也不能解读成某个恒定的令牌倍率。

3.1 固定顺序：一次思考完成后再行动

早期推理模型采用明确的阶段流水线：先集中思考问题，再调用工具，最后生成面向用户的文本。这个安排便于理解，像是先在纸上写完计划，再一次性执行计划，最后提交报告。它隐含了一个强假设：开始行动之前形成的计划，足以覆盖后续过程中的大部分决策。

当任务不依赖外部反馈时，这种顺序可能够用。例如，一个封闭条件下的解释题可以先完成推导，再直接写出答案。进入搜索、代码修改、文件读取或环境操作之后，假设很快会暴露局限。工具结果可能否定原计划，也可能带来此前未知的信息；若思考阶段已经结束，系统就缺少一个明确的重新判断位置。




图 6: 固定顺序与反馈驱动顺序的并排对比：左侧只在全部工具调用前进行一次思考，右侧在工具结果之间重新思考。⁶

直觉类比：固定行程单

固定顺序像是旅行者出发前写完全部行程，途中只按清单执行。道路封闭、车次延误或目的地临时关闭都属于新信息；没有重新规划环节时，行程单越详细，也未必越能应对变化。

这一机制的边界不在于“思考得少”，而在于反馈出现后能否重新组织下一步。它为理解后两种调度方式提供了基线。

3.2 交错式思考：把反馈带回决策环

交错式思考（interleaved thinking）允许在多次工具调用之间插入推理。系统可以调用工具、取得结果、分析结果，再决定下一次工具调用，直到信息足够或任务完成后输出最终答案。工具结果由此从“执行产物”变成“下一轮决策的输入”。

⁶视频帧来源：00:10:08–00:10:53；采用 00:10:28 附近两列同时完整显示的帧。

一个研究任务可以展示这种差异。系统先搜索主题，发现关键术语存在歧义；随后分析搜索结果，调整第二次查询；再读取原始资料，判断证据是否足够。每次工具返回都可能改变下一步。交错式思考给这类变化提供了明确的反馈回路。

交错式思考的核心能力

其核心价值是在工具结果之间重新决策。

交错式思考仍然围绕“工具调用之间的推理”组织流程。用户沟通在这种描述里通常位于末端。长任务如果需要先确认需求、报告阶段状态、等待用户补充，再继续行动，流程还需要更宽的活动排序自由。

3.3 自适应思考：三类活动可以按需重排

自适应思考把调度范围扩展到任务全过程。系统可以先用文本确认请求，再调用工具；工具返回后进行思考，也可以先向用户报告阶段结果，再继续调用工具，最终才给出完整答案。思考、工具调用和文本沟通没有来源规定的唯一排列。




图 7: 自适应思考的完整示例轨迹：文本、工具调用、工具结果和思考块按任务反馈交错，并在工具操作前后与用户沟通。⁷


这种自由并不要求每项任务都经历三类活动。面对简单查询，系统可以直接回答；面对需要澄清的任务，首个动作可以是向用户提问；面对外部事实不确定的任务，首个实质动作可以是工具调用。复杂研究或软件工程任务往往在三类活动之间多次往返。

⁷ 视频帧来源：00:10:53–00:11:42；采用 00:11:18 附近所有活动块与右侧注解完整可见的帧。

一个完整但非强制的执行轨迹

文本确认请求 → 工具读取资料 → 分析新信息 → 文本报告阶段进展 → 继续工具操作 → 最终文本交付。这个序列只是演讲者所述自由度的示例，不是系统必须遵循的新模板。

因此，自适应思考所保留的是**随时使用思考能力的选项**。它和“开头至少消耗一个思考令牌”的要求有实质区别：后者只保证响应开始时出现一次思考，前者允许系统在任意步骤按任务需要使用思考。演讲者在 2026 年 5 月的视频中称，Anthropic 自 Opus 4.6 起使用自适应思考运行基准，并称其性能与先前的交错式思考相当或更好，同时改善用户体验。该句属于演讲者的日期限定陈述；自动字幕中的比较术语存在错写，来源没有在本章提供可独立复算的数据或百分比。



	Opus 4.7	Opus 4.6	Mythos Preview
Agentic coding SWE bench Pro	64.3%	53.4%	77.8%
Agentic coding SWE bench Verified	87.6%	80.8%	93.9%
Agentic terminal coding Terminal Bench 2.0	69.4%	65.4%	82.0%
Multidisciplinary reasoning no tools	46.9%	40.0%	56.8%
Humanity's Last Exam with tools	54.7%	53.3%	64.7%
Agentic search BrowseComp	79.3%	83.7%	86.9%
Scaled tool use MCP Atlas	77.3%	75.8%	—
Agentic computer use OSWorld-Verified	78.0%	72.7%	79.6%
Agentic financial analysis	64.4%	60.1%	—

图 8: 演讲中的日期限定基准概览，列出 Opus 4.7、Opus 4.6 与 Mythos Preview 在多类任务上的展示结果。该表支持“演讲者曾在这些基准上报告结果”，未直接展示自适应思考与交错式思考的受控对比。⁸

3.4 提示依赖：更高努力不产生固定令牌倍率

自适应调度还解释了为什么努力级别的影响具有提示依赖性。演讲者指出，更高努力通常会让系统更频繁、也更长时间地思考；实际差异取决于提示是否提供了值得深入处理的问题。

对于“2 + 2”这样的简单问题，低努力与高努力都缺少继续展开的必要空间，所需工作量应当大致相当。复杂研究任务包含问题拆解、资料查找、证据比较、冲突处理和结果组织，较高努力才有更多可利用的决策机会。这个例子是用于解释机制的类比，来源没有把它报告为受控实验。

常见误读：把努力级别当作倍率旋钮

“High 必然使用 Low 的若干倍令牌”不符合本段来源。努力级别提供工作强度偏好；简单提示可能几乎不受影响，复杂提示可能产生显著差异。实际消耗还受任务结构、工具反馈、停止条件与预算约束影响。

提示依赖还意味着，调度质量不能仅凭“是否出现过思考”判断。更有用的问题包括：系统是

⁸视频帧来源：00:12:28-00:13:20；采用 00:12:40 附近模型名、基准标签和百分比全部可见的完整幻灯片。

否在关键反馈后重新评估？是否在信息不足时请求澄清？是否把进度沟通放在用户需要的位置？这些问题检查的是工作组织方式，与单纯统计某类令牌出现次数不同。

3.5 两类边界：路由、开关与努力级别各管什么

演讲者明确排除了两种定义。模型路由器（model router）根据输入条件在不同模型或模型版本之间选择路径；自动思考开关（automated thinking toggle）先判断问题难度，再在思考与非思考模式之间切换。自适应思考描述的是同一任务过程中对活动的按需安排，不承担这两类分类或选模职责。

思考开关（thinking toggle）控制思考能力是否可用。演讲者认为，历史上用户常用它表达“多花一些时间”，但开关实际约束了系统被允许采用的工作方式。努力级别调节器在前文已经定义为整体强度接口，它共同影响思考、工具使用与输出文本。两者的区别可以整理如下：

机制	控制对象	本章边界
模型路由器	在不同模型路径之间选择	不属于自适应思考
自动思考开关	按分类结果切换思考/非思考模式	不属于自适应思考
思考开关	允许或禁止思考能力	约束可用工作方式
努力级别	质量、时间、成本之间的工作强度偏好	不规定固定顺序或固定令牌倍数
自适应思考	任务全过程的活动调度	保留按需思考并重排三类活动的自由

工具使用类比进一步说明了这种边界。用户通常允许系统依据问题判断何时搜索，而不会对所有任务统一要求“总是搜索”或“从不搜索”。这种按需选择动作的能力被演讲者称为具备智能体自主性（agentic）。这里的自主性仍然受用户目标、任务预算和权限约束，不表示系统拥有无限行动范围。

调度机制的压缩理解

固定顺序提前锁定阶段；交错式思考把工具反馈带回决策；自适应思考允许三类活动在全过程按需重排。努力级别影响系统愿意投入的工作强度，提示决定额外工作是否有实际用途。

3.6 本章小结

本章把资源控制进一步落实为过程调度。固定顺序适合反馈依赖较弱的任务；交错式思考支持在工具结果之间重新决策；自适应思考把思考、工具调用与文本沟通都纳入按需排序，并允许简单任务跳过思考。它不属于模型路由器或自动思考开关。高努力通常提供更多工作空间，实际差异由提示与任务机会决定，因而不存在来源支持的固定令牌倍率。下一章将转向可观测结果：怎样用性能—资源曲线与执行轨迹判断额外投入是否值得。

4 用评测曲线寻找合适投入点

本章结论

努力级别的选择应由真实工作负载的**性能—资源曲线**决定，并与执行轨迹检查配套。标量分数说明任务完成得怎样，令牌、时间与成本说明付出了多少，执行轨迹则说明系统采用了什么策略。三类证据共同出现时，团队才能判断低成本捷径是否可以接受，也能识别继续提高努力后额外收益逐渐缩小的区域。

上一章说明系统能够在任务过程中自由调度思考、工具调用与文本沟通。自由度带来新的部署问题：Low、Medium、High、超高（xHigh）和 Max 该怎样选？来源没有给出跨任务通用答案。演讲者建议围绕实际应用运行评测（evals），把性能与资源支出画在同一条努力级别曲线（effort curve）上，再阅读执行轨迹，确认得分背后的策略是否符合真实任务意图。

4.1 先画曲线：同一工作负载上的性能与支出

努力级别曲线的纵轴是任务性能，横轴可以选择总令牌、时间或成本。横轴必须和部署者真正关心的资源目标一致：批量任务可能更关心成本，交互任务可能更关心时间，长程任务则可能同时记录多种支出。每个点代表同一评测条件下的一个努力级别结果。




图 9: 内部自主编码评测中的努力曲线：横轴为总令牌，纵轴为得分；Low、Medium、High、xHigh 与 Max 五个点完整可见。该单次示例用于说明读图方法，不能替代目标工作负载上的评测。

9

来源中的图展示了 Opus 4.7 在一次内部自主编码评测上的五档结果。曲线随努力提高而上升，并在较高努力区域趋于平缓。该图的教学价值在于展示选择方法：团队可以看到“多投入一些资源”换来了多少性能增量。它不能作为所有任务都遵循同一形状的证明；来源是一项内部评测和示例性

⁹ 视频来源区间：00:15:07–00:15:58；截图取自 00:15:20。

运行。本文只解释曲线形状与选择方法，不转写图中点值；精确点值若用于部署，仍需结合原始评测数据与目标工作负载复核。

一套最小可执行的评测记录应包含：

1. 固定任务集、成功标准与评分方法，避免不同努力级别面对不同难度；
2. 对每个努力级别记录任务性能以及总令牌、时间和成本中适用的指标；
3. 保留每次执行的轨迹或转录文本，供后续行为审查；
4. 将失败、重试、未完成和提前停止纳入统计，避免只保留成功样本；
5. 按应用的质量底线和资源约束选择候选点，再做更大样本复测。

曲线回答的是局部决策问题

努力级别曲线回答“在这组任务、这套评分和这段产品环境中，额外资源换来了多少额外性能”。它不直接回答其他工作负载、其他模型版本或未来产品状态。本文中的产品与默认设置表述均限于视频上传时间 2026 年 5 月。

4.2 识别边际收益递减

边际收益递减（diminishing returns）指继续增加努力时，新增资源带来的性能增量逐渐缩小。它并不意味着性能必然下降，也不意味着 Max 没有价值。它提示部署者比较**相邻工作点之间的增量**，而非只比较最高分和最低分。

演讲者用超高与 Max 说明这一判断。某个团队如果以最高质量为首要目标，可以接受 Max 的额外支出；另一个团队可能发现，从超高提高到 Max 只获得很小的性能增量，却增加明显的令牌消耗，于是选择超高。两种选择都取决于任务的质量要求和资源约束。来源没有给出可跨场景套用的阈值。

“最高努力”不自动等于“最佳部署点”

Max 值得在最困难、最依赖智能的任务上测试。其结果可能继续提升，也可能处于收益已经变平的区域。来源还提醒，Max 未必构成性能上限；单次曲线无法证明更大样本、不同提示或后续系统不会出现其他结果。

在这个语境下，智能受限型（intelligence-bound）任务指结果主要受到问题求解能力约束的任务。更高努力在这类任务上更可能产生可见收益。这个分类仍需通过工作负载证据确认，不能仅凭任务名称预先断定。

4.3 低努力的双面性：节省资源，也会改变策略

Low 常能缩短时间、减少令牌，同时降低完整性。风险并不只表现为答案变短或遗漏更多。为了节省资源，系统可能采用意外捷径（unexpected shortcuts）：这些策略可以让标量分数看起来合格，却绕开业务真正重视的过程要求。

演讲者因此建议在看评测分数之外，阅读执行轨迹或转录文本。轨迹检查可以回答：系统是否跳过必要验证？是否用脆弱假设替代证据？是否绕过安全或质量检查？是否通过重定义任务目标来获得高分？这些问题通常无法从最终分数、总耗时或令牌数中单独看出。

三个互补证据面

- **任务分数**：结果是否达到规定标准；
- **资源支出**：达到结果用了多少令牌、时间或成本；
- **执行轨迹**：系统采取了哪些步骤，是否使用了允许的捷径。

任何单一证据面都不足以证明部署策略可接受。

这里的“转录文本”指可审查的执行记录、工具动作与用户可见沟通，不应扩展成用户能够读取私有思维链的承诺。审查重点是可观察行为及其后果。

4.4 Pokémon Red：聪明捷径为何仍需审查

视频中的“Claude Plays Pokémon”评测提供了一个高信息量例子。在低努力下，系统把原版 Pokémon Red 当作速通任务：它跳过训练师战斗，使用库存中的恢复道具，减少返回 Pokémon Center 的时间，并反复使用 Repel，降低洞穴中的随机遭遇干扰。



图 10: Pokémon Red 洞穴画面明确显示 “REPEL’s effect wore off.”，直接支持演讲者所述的 Repel 使用策略；静态截图无法单独证明跳过训练师战斗或恢复道具等其他动作。

10

这些动作说明低努力不能机械地等同于低智能。系统识别了资源目标，并找到缩短路径的策略。与此同时，这个例子也暴露出评测目标的隐藏依赖：如果成功标准只是尽快推进关卡，这些行为可能完全合理；如果目标包含培养队伍、收集资源、提高稳健性或按预期路线体验游戏，同一策略就可能不合格。

可接受性判断可以用一组过程问题完成：

¹⁰ 视频来源区间：00:16:39–00:17:59；截图取自 00:16:46。

检查维度	可接受捷径	不可接受捷径
目标一致性	缩短不影响任务目标的步骤	删除业务真正要求的成果
约束遵守	在权限、规则和预算内重排动作	绕过安全、合规或用户明确限制
结果完整性	省略重复劳动且保留必要证据	跳过验证、测试或关键数据
失败可恢复性	策略失败后能够检测并修正	依赖脆弱假设且不报告风险
可解释性	轨迹能说明节省了什么及原因	标量高分掩盖过程偏离

目标函数会塑造策略

资源约束可能诱导出非常聪明的压缩方式。评测设计若只奖励“完成”或“更快”，系统就可能省略人类默认但未写入标准的步骤。部署者需要把不可省略的检查、权限和质量条件显式写进任务与评测。

Pokémon 例子是定性案例。来源没有在这一段报告成功率、对照组分数或统计显著性，因此正文只能用它说明策略变化与轨迹审查的必要性。

4.5 五档努力级别：日期限定的起始假设

当团队尚未积累完整评测数据时，演讲者给出了一组经验规则。它们来自 2026 年 5 月的视频，应视为建立实验起点的日期限定建议，不能写成当前产品默认值或跨任务保证。



图 11: 演讲者给出的五档努力级别经验图。来源幻灯片将第四档写作“Xhigh”；正文按全文术语合同统一为超高（xHigh）。底部说明明确限定为 Opus 4.7、自适应思考与单次智能体编码任务的示意运行。

来源档位	2026 年 5 月演讲者给出的试验起点
Max	在最困难、最依赖智能的任务上测试；检查是否继续增益以及是否出现边际收益递减。
超高（xHigh）	演讲者称其在当时的多数编码与智能体用例中表现出较好的智能与支出平衡；关于 Opus 4.7、Claude Code 和 Claude.ai 默认设置的说法只代表视频当时。
High	智能敏感且需要平衡令牌使用时的起始点；随后用评测向上或向下调整。
Medium	成本敏感、愿意用部分任务性能换取更快结果的候选点。
Low	范围较短或延迟敏感任务的候选点；必须重点检查完整性与意外捷径。

这张表的正确用法是生成待验证假设。例如，团队可以从 High 开始，向相邻档位运行相同任务集，随后用曲线和轨迹决定保留哪个点。直接把经验规则当作结论，会忽略提示、任务分布、评分标准和产品版本等隐藏依赖。

4.6 把分数、曲线与轨迹合成一次选择

一轮可审计的选择可以按以下顺序收束：先设定质量底线与不可违反的过程约束；再对五档中的若干候选点运行同一工作负载；随后比较性能与资源曲线，识别增量已经变小的位置；最后抽查并分层阅读执行轨迹，确认节省资源的策略可接受。若轨迹暴露系统性捷径，应修订任务说明、评分标准或过程约束，然后重新评测。

这个闭环还需要承认三个限制。第一，单次演示无法给出总体分布；第二，内部评测的任务构成和评分细节未在视频中完整公开；第三，自动字幕可能损坏术语和句界。图中精确数值、产品默认设置和版本行为都需要额外来源核验，本文在没有该证据时保留定性表述。

部署点的判断准则

候选努力级别需要同时满足三项条件：质量达到任务要求，资源支出落在可接受范围，执行轨迹没有违反目标或过程约束。额外努力只有在带来值得付出的质量增量时才形成有效收益。

4.7 本章小结

本章建立了努力级别的评测方法：用性能—资源曲线观察投入与结果，用相邻档位识别边际收益递减，再用执行轨迹检查标量分数遮蔽的策略变化。Low 既可能减少完整性，也可能产生高效而聪明的捷径；其可接受性取决于真实目标、明确约束和失败可恢复性。五档经验规则只代表演讲者在 2026 年 5 月给出的试验起点。完成单一模型内的努力选择后，下一章将加入模型大小这一独立部署轴。

¹¹ 视频来源区间：00:18:14–00:19:31；截图取自 00:18:20。

5 联合选择模型大小、努力级别与延迟目标

核心结论

模型大小与努力级别是两条需要联合评测的部署轴：前者改变基础能力、单位吞吐和响应特性，后者改变当前任务获得的工作深度。智能需求较高且重视尽快完成时，可以优先测试较大模型的低努力组合；简单、批量、成本敏感或极度重视快速开始响应的任务，可以优先测试较小模型。任何经验规则都只是候选起点，最终选择必须来自真实工作负载上的模型与努力级别组合评测。

5.1 为什么单独选择模型或努力级别都不够

前四章先后建立了两项事实：模型规模形成基础能力区间，努力级别改变单次任务获得的推理时计算；性能还会随投入出现边际收益递减和策略变化。部署时因此不能只问“该用哪个模型”，也不能只问“努力级别该开多高”。同一成本或延迟目标，可能由较小模型投入较深工作达到，也可能由较大模型用较低努力达到。

两条轴承担不同职责。**模型能力轴**改变系统起点，包括基础推理能力、单位令牌成本、生成速度与可达结果区间。**任务努力深度轴**决定既定模型面对当前请求时愿意投入多少分析、工具调用和文本沟通。较大模型不会自动替代任务预算，较高努力也不能把较小模型变成较大模型。部署者需要寻找的是满足质量要求、成本上限和延迟目标的组合，而非给某一条轴永久排序。

下面的二维图把演讲中的两条选择轴放到同一个视野中。横向移动表示测试更高的基础模型能力及其伴随的成本与响应特性，纵向移动表示让既定模型在当前任务上投入更深的工作。四个区域只用于组织候选配置，不表示存在来源支持的分界线或固定赢家。




图 12: 模型能力与任务努力深度的定性部署地图。该图是基于演讲机制的教学综合示意，并非来源幻灯片；区域位置只帮助生成待评测候选，不表达阈值、评分或普遍优先级。

5.2 先按任务性质缩小候选组合

演讲者给出的第一条经验是：面对智能需求较高、同时希望尽快完成的任务，可以测试较大模型配合低努力。这里的直觉是，较大模型拥有更高的基础能力起点，较低努力限制本次执行深度后，仍可能在较短总时间内达到可接受质量。这条经验尤其适合结果质量仍受推理能力明显制约的任务，例如复杂编码、方案设计或多约束问题求解。

另一类任务主要追求规模化吞吐和单位成本，且峰值智能并非关键约束。演讲者列举了批量分类、信息抽取和基础摘要。这些任务通常范围较短、输出结构较稳定，也更容易用自动指标和抽样复核发现错误；较小模型因此值得优先进入候选集。任务一旦包含模糊边界、长链依赖、关键事实核验或高错误代价，部署者仍需重新提高模型能力、努力级别或人工审查强度。

两条轴的直观类比

模型大小像团队成员已经具备的专业能力，努力级别像这次任务允许其投入的工作深度。资深成员快速处理复杂问题与初级成员长时间处理标准化批量工作，都可能是合理安排；哪一种更合适，取决于任务难度、错误成本、响应节奏和预算，而不是单一标签。

5.3 交通模拟对照说明了什么

视频把第一章的交通模拟重新用于跨模型比较。回看低努力、高努力与最高努力三个同模型结果（图 2、图 3、图 4），可以先分离“同一模型增加工作深度”带来的变化，再理解本章加入模型能力轴后的跨模型比较。画面记录的单次结果是：Opus 4.7 使用 Low 时耗时 50.1 秒、消耗 4,602 个输出令牌；Haiku 4.5 使用 Max 时耗时 24.1 秒、消耗 4,413 个输出令牌。两者输出令牌数量接近，较大模型低努力的总耗时更长。演讲者主观判断 Opus 4.7 Low 的模拟结果明显更好，并据此建议：智能需求较高且需要在速度与质量之间取舍时，较大模型低努力可能提供更合适的工作点。




图 13: 同一交通模拟提示下的单次配置对照：Opus 4.7-Low 为 50.1 秒、4,602 个输出令牌；Haiku 4.5-Max 为 24.1 秒、4,413 个输出令牌。画面只建案例级比较，不能推出跨任务的模型优先级。

这项对照的证据边界十分重要。它只包含一个提示词、两种配置和各自一次展示结果；视频没有给出重复次数、方差、盲评或统一质量量表。所谓“明显更好”是演讲者对模拟结果的判断，无法证明所有智能型任务都遵循相同排序。这个案例最适合用来提出候选组合：模型大小与努力级别可以互换一部分时间、成本和质量取舍，具体交换关系必须重新测量。

一次对照无法建立普遍优先级

50.1 秒与 24.1 秒描述的是该次交通模拟展示的任务完成耗时，4,602 与 4,413 描述的是输出令牌。来源画面没有为这两个耗时标注具体的延迟指标。它们不能直接推导单位成本，也不能把“较大模型低努力”写成所有复杂任务的固定最优解。输入令牌、工具使用、并发负载、缓存、服务条件和结果验收方式都可能改变部署结论。

5.4 首令牌延迟与末令牌延迟回答不同问题

延迟至少需要拆成两个用户可感知指标。**首令牌延迟 (time to first token, TTFT)** 是从请求开始到系统产生第一个输出令牌的等待时间，反映“多快开始回应”。**末令牌延迟 (time to last token, TTLT)** 是从请求开始到完整输出结束的总等待时间，反映“多快完成任务”。两者可能由不同瓶颈主导，不能用一个笼统的“更快”替代。

小模型通常能更早开始生成，因此演讲者把它作为首令牌延迟敏感场景的经验起点。对交互式搜索框、即时分类反馈或需要迅速显示首段内容的界面，快速开始可能直接影响用户感受。若结果必须完整生成后才能使用，例如代码补丁、结构化报告或一次性批处理，末令牌延迟更接近真实完成时间；演讲者建议在智能需求较高时测试较大模型的低努力组合。

这一区分也暴露了产品设计依赖。流式界面可以利用较低首令牌延迟，非流式接口只会在完整结果结束后返回，此时首令牌优势对用户不可见。长任务中的阶段更新虽然能改善可感知等待，却会消耗文本令牌，也不会缩短实际末令牌延迟。评测记录应分别保存两个时间点，并保持相同输入、工具条件和服务负载。

5.5 把经验规则变成部署决策表

下面的表格用于生成候选配置。每一行都需要通过实际评测确认，表中“优先测试”不表示预设赢家。

¹² 视频来源区间：00:20:13–00:20:41；截图取自 00:20:20。

决策维度	优先测试较大模型低努力	优先测试较小模型	必须补充的证据
智能需求	多约束推理、复杂编码、结果受基础能力明显限制	标准化分类、信息抽取、基础摘要	任务级质量指标与失败样本
任务规模	单项价值高、数量较少或允许按难度分流	请求量大、模式重复、吞吐优先	峰值与平均请求量
成本上限	较高质量可抵消较高单位资源成本	单位请求预算严格、可接受较低能力上限	完整输入、输出与工具成本
首令牌延迟	只有实测满足交互目标时采用	通常是更直接的候选起点	流式响应下的 TTFT 分布
末令牌延迟	智能任务可能以较低努力更快达到可用完成结果	简单短任务通常仍有优势	TTLT 分布及超时率
容错要求	高错误代价任务需要更强验收与复核	低风险且可抽样纠错时更适合规模化	严重错误率与人工复核成本
评测能力	能比较多个模型与努力级别组合	能用大样本验证成本和稳定性	固定数据集、轨迹检查和重复试验

真正的比较单位是“模型与努力级别”的配置组合。部署者应在同一任务集上记录质量、总令牌、总成本、首令牌延迟、末令牌延迟与失败轨迹，并检查低努力是否采用了意外捷径。若工作负载差异很大，可以分别为简单批量任务和复杂任务设定候选组合；视频没有提供自动路由方法，这一扩展需要额外设计与验证。

5.6 本章小结

模型大小决定基础能力与响应特性，努力级别决定当前任务的工作深度。较大模型低努力适合作为智能需求高、重视尽快完成时的候选；较小模型适合作为简单批量、成本敏感和首令牌延迟敏感任务的候选。首令牌延迟描述多快开始，末令牌延迟描述多快完成，两者必须分开测量。交通模拟只提供一次方向性案例，最终部署点仍应通过真实工作负载上的模型与努力级别组合评测、成本记录和轨迹检查确定。

6 总结与延伸：设定质量门槛与预算，让系统负责分配

全文结论

一套可执行的实践闭环是：保留系统按需思考的能力，用努力级别表达质量、时间与成本偏好，用任务预算设置支出与检查边界，对模型与努力级别组合运行真实工作负载评测，检查执行轨迹中的策略与捷径，最后选择同时满足质量、成本和延迟目标的工作点。用户负责说明期望和边界，系统在边界内调度资源，评测负责验证这种分配是否真正有效。

6.1 演讲者留下的三项行动建议

演讲者在结尾首先建议尽可能保留思考能力，让系统在任务需要时拥有推理空间。若用户希望调节系统为问题投入多少工作，应使用努力级别或任务预算影响行为。这里需要沿用前文的边界：思考能力描述系统可用的工作方式，不构成向用户展示私有推理轨迹的承诺；努力级别表达偏好，任务预算规定上限或检查点。

第二项建议是使用评测寻找应用特定的平衡。演讲者要求分别尝试不同努力级别、任务预算和模型，画出性能与资源曲线，并深入阅读执行轨迹。汇总分数可以说明任务是否完成，轨迹检查才能发现系统如何完成、是否采用意外捷径，以及这些策略在真实业务中是否可以接受。

第三项建议只适用于明确受限的后备情形：若完全无法运行评测，且工作负载属于编码或软件工程，演讲者在 2026 年 5 月建议采用超高（xHigh）努力。这是一条来自当时模型与产品环境的经验规则，不能推广到其他任务，也不能写成当前产品默认值或长期最优配置。可运行评测时，评测结论仍然拥有更高决策价值。




图 14: 演讲者的三项行动建议：启用思考并调节努力与预算；用评测寻找应用特定平衡；无法评测且属于编码或软件工程任务时采用超高努力。来源幻灯片第三列原样写作小写“xhigh”，正文继续采用规范形式 xHigh。

13

6.2 把全文压缩成一套资源分配机制

全文的概念可以压缩为五个相互衔接的部件。**能力轴**由模型选择形成，决定任务可达的基础能力空间。**努力级别**决定当前请求值得尝试多深，影响思考、工具调用与文本沟通的总体工作强度。**任务预算**规定令牌、时间或成本的停止边界，并可要求系统在边界处检查。**自适应思考**负责在执行过程中按需排列三类活动。**评测**把这些设计从直觉变成工作负载上的实际工作点。

这五个部件形成一条因果链。模型能力不足时，单纯增加努力可能无法跨越能力边界；努力过低时，具备能力的模型也可能省略验证或采取更激进的捷径；预算缺失时，长任务的支出和暂停条件不清楚；调度自由受限时，系统难以根据工具结果调整后续行动；评测缺失时，部署者无法判断最终组合是否满足应用目标。任何一个部件都不能独立承担完整控制责任。

¹³ 视频来源区间：00:21:57–00:23:06；截图取自 00:22:04。

“把控制权放在哪里”

用户最适合定义期望质量、最大支出、完成期限和不可接受的失败；系统最适合在这些边界内决定何时思考、何时调用工具、何时沟通；评测最适合判断配置是否稳定达到目标。职责分开后，努力级别无需伪装成精确令牌保证，自适应思考也无需承担模型路由或质量验收的职责。

6.3 五步部署清单

1. **定义任务和验收门槛。**写清真实输入分布、必须完成的结果、严重失败类型与**质量门槛 (quality bar)**。若任务包含多个风险层级，应分层记录，避免用平均分掩盖关键失败。
2. **给出资源边界。**明确令牌、时间和成本上限，说明达到任务预算后应停止、保存状态还是向用户检查；同时记录首令牌延迟与末令牌延迟目标。
3. **建立候选配置。**选择若干模型与努力级别组合，保留自适应思考的按需调度空间。简单批量任务与复杂智能型任务可以采用不同候选集。
4. **运行评测并阅读轨迹。**在代表性任务上重复测量质量、令牌、成本、两类延迟和失败率；抽查工具调用、阶段更新与最终结果，寻找意外捷径、遗漏和不可接受策略。
5. **选择、监控并重新评测。**选择满足质量门槛和预算的工作点，上线后监控输入漂移、服务负载与失败模式。模型、产品设置或工作负载变化时重新评测，避免把旧配置永久固化。

这份清单没有来源支持的统一评分公式。不同应用对严重错误、等待时间和成本的容忍度不同，强行合成一个权重分数容易隐藏不可妥协的门槛。更稳妥的做法是先淘汰未达到质量或安全要求的配置，再在合格配置中比较成本和延迟。

6.4 证据边界与实施风险

本文的结论需要在五类限制内理解。

- **单次演示限制：**交通模拟展示了资源投入可能改变结果，缺少重复试验、方差和盲评，无法建立普遍排序。
- **内部评测限制：**演讲中的知识工作曲线和智能体编码曲线适合解释方法，无法替代部署者自己的真实工作负载评测。
- **主观判断限制：**“更好结果”包含演讲者对图形、交通灯和驾驶模式的判断；生产环境需要可复现的验收标准。
- **字幕限制：**来源使用平台自动字幕，词语、标点和句界可能存在 ASR 错误。本文已把明显错写统一为既定术语，直接引语和精确产品措辞仍需谨慎。
- **时效限制：**模型版本、努力级别、默认设置、功能名称和可用范围均来自 2026 年 5 月 8 日上传的视频；它们不能自动代表此后的产品状态。

隐藏依赖同样会改变结果，包括输入长度、工具权限、网络与服务负载、缓存、并发、流式接口、预算到达后的生命周期行为，以及评测集是否覆盖真实失败。尤其需要警惕资源优化诱发的策略变化：低努力可能用聪明捷径节省令牌，捷径是否可接受取决于业务约束，而非执行速度本身。

部署结论必须带日期和工作负载

“超高努力适合编码”“小模型首令牌更快”“大模型低努力更快完成”都属于演讲者在特定模型和产品背景下给出的经验规则。实际报告应同时写明日期、模型版本、努力级别、任务集、样本量、成本口径与延迟口径，避免把一时配置写成稳定定律。

6.5 仍然开放的三个问题


怎样评估持续数日或更久的智能体任务？ 短任务可以依靠固定测试集与终局分数，长期任务还需要检查中间状态是否可恢复、阶段目标是否偏移、工具操作是否安全，以及用户在检查点能否理解当前进度。视频提出了长周期愿景，没有给出成熟评测协议。

怎样让预算触发可解释的检查点？ 预算只有数值上限仍不完整。系统还需要在接近边界时保存什么、汇报什么、怎样展示已完成与未完成工作，以及由谁批准继续。令牌、时间和成本预算可能在不同时间触发，冲突处理属于尚待设计的生命周期问题。

怎样防止资源优化诱发不可接受捷径？ Pokémon 例子表明，低努力可能催生高效而聪明的策略；回看图 10，可见画面只直接证明 Repel 的使用，这也提醒读者把可见证据与演讲者描述的其他动作分开。生产任务中的同类资源优化可能跳过验证、弱化覆盖或规避隐含要求。未来评测需要同时考察结果、过程约束和严重失败，必要时把不可跳过步骤写成硬性验收条件。

6.6 长期愿景：用户设门槛与预算，系统完成分配

演讲者把长期方向概括为：用户给出质量门槛与任务预算，Claude 自行分配计算，为具体使用场景争取最佳表现。自适应思考、努力级别和任务预算被描述为朝这个方向迈出的早期步骤，演讲者同时明确它们“只是开始”。因此，这段结尾表达的是产品方向和接口愿景，尚未证明任意任务都能自动找到全局最佳分配。



You set the bar and the budget.

Claude allocates the compute.

图 15: 演讲者的长期愿景: “You set the bar and the budget. Claude allocates the compute.” 这是产品方向陈述, 尚未构成对任意任务都能自动获得最优分配的保证。

14

“You set the bar and the budget.” 把全文压缩成一个清楚的责任边界: 用户设定想达到的标准与可承受的支出, 系统决定如何工作。真正让这句话成为工程方法的环节, 是把质量门槛写成可验证条件, 把预算写成可执行边界, 再用评测和轨迹检查确认系统的资源分配确实服务于任务目标。

6.7 本章小结

全文最终形成一套闭环: 保留按需思考能力, 用努力级别表达工作强度偏好, 用任务预算设置停止或检查边界, 联合评测模型与努力级别, 阅读执行轨迹, 并选择满足质量、成本与延迟要求的工作点。2026 年 5 月的编码后备建议、单次交通模拟和内部评测只能作为候选起点与方法示例。长期方向是让用户设定质量门槛与预算, 由系统在边界内分配计算; 其可靠落地仍依赖可复现评测、可解释检查点和对资源优化捷径的持续审查。

¹⁴ 视频来源区间: 00:23:07–00:23:30; 截图取自 00:23:23。