

智能体系统的生产评测：从答案得分到可靠行为

生产环境中的智能体评测方法

演讲者：Nishant Gupta (Meta)

中文教学笔记整理：Codex



来源：WF2026 会议演讲

主题编号：27

证据片段：本主题片段 06:41:16–06:46:30

原视频入口：youtube.com/watch?v=htM02KMNZnk

整理日期：2026 年 7 月

摘要

生产环境中的智能体评测应被设计成持续运行的可靠性基础设施。离线基准测试提供能力参照，场景评测验证完整 workflow，生产遥测揭示真实失效，定向人工复核负责校准自动指标的盲区。本笔记围绕“系统在真实约束下是否持续产生可信、可恢复且成本可控的结果”组织四章，并严格区分演讲证据与本文工程推演。

来源注：英文字幕与视频画面为主证据。用户时间线记为 Shan Gupta，画面姓名标识为 Nishant Gupta，本文采用后者；主题内容校准至 06:46:30。第四章在此后提出的工程闭环均标为“本文推演”。幻灯片中的数值与架构属于机制示意。

目录

摘要	i
1 评测对象已经改变：从答案走向行为	1
1.1 高分为什么没有回答生产问题	1
1.2 答案正确与系统行为正确	1
1.3 行为维度如何展开	2
1.4 本章小结	3
2 生产失效是一组分层风险：从准确率走向系统级目标	3
2.1 从“幻觉”扩展到失效模式层级	3
2.2 输出评测为何漏掉主要生产风险	4
2.3 用站点可靠性工程视角定义成功	4
2.4 可靠结果作为统一目标	5
2.5 本章小结	5
3 三层评测栈：基准、场景与生产信号	6
3.1 评测金字塔：越接近生产，信号越有运营价值	6
3.2 从提示词驱动转向场景驱动	7
3.3 把生产流量理解为评测数据	7
3.4 自动指标与人工判断的分工	8
3.5 本章小结	8
4 总结与延伸：把评测变成持续闭环	10
4.1 演讲结论链：从行为评测走向可靠结果	10
4.2 素材最后留下的问题：持续变化	10

4.3	本文推演：观察、复核、入库、回归	10
4.4	实施清单	11
4.5	本章小结	12

1 评测对象已经改变：从答案走向行为

1.1 高分为什么没有回答生产问题

生产评测（production evaluation）首先要回答一个更大的问题：系统在真实依赖、真实用户和长链路任务中，能否持续完成正确的事？Shan Gupta 用一个常见场景切入：旧模型在基准测试（benchmark）上得到 90%，新版本得到 92%，团队因此庆祝。这个比较能说明标准化任务上的模型能力有所提高，却没有说明服务接入工具、API 和生产基础设施之后会怎样（06:41:33–06:42:12）。

这里的评测对象是智能体系统（agentic system）：它会规划、调用工具、检索信息，并连续执行多步任务。一次答案只是整条执行链的一个可见结果。只检查答案，相当于只看包裹是否到达，却没有检查分拣、运输、异常改派和签收过程；链路中的偶然成功会掩盖不可重复的行为。

核心判断

基准测试回答“模型在受控任务上能做什么”；生产评测回答“完整系统在真实约束下能否稳定做成事”。随着系统自主性上升，两者之间的差距会扩大（06:42:14–06:42:53）。

1.2 答案正确与系统行为正确




图 1：高离线基准分数与生产表现下降可以同时出现。图中的 90% 为演讲幻灯片中的说明性示例，不能解读为 Meta 的实测生产数据。²

传统输出评测关注最终答案的正确性。智能体系统要求观察系统行为（system behavior），也就是从规划、工具调用、执行和决策直到故障恢复的完整过程。Gupta 将问题明确地从“模型是否生成了正确答案”改写为“系统是否表现正确”（06:42:53–06:43:24）。

²源视频画面绝对时间区间：06:42:14–06:42:53。

观察面	答案评测	行为评测
基本单位	单次模型输出	端到端工作流（workflow）
主要问题	内容是否正确	系统是否以正确方式完成任务
关键证据	参考答案、评分器结果	规划、工具调用、执行轨迹、决策与恢复
容易漏掉	工具与基础设施风险	仍需结合输出质量判断任务结果

工作流指智能体为完成任务而连续执行的一组规划、信息获取、工具操作、判断和恢复步骤。它把多个局部动作连接成最终结果，因此任何一环都可能让“看起来正确”的答案失去可信度。例如，工具返回了过期数据，模型仍可能写出语句流畅的回答；API 短暂中断后缺乏重试，也可能让同一请求时好时坏。演讲者列出的生产变量还包括上下文变化、用户差异和长时工作流，它们都不在普通基准测试的受控假设内（06:42:25–06:42:44）。

常见误区

把 92% 的基准分数直接解释为“生产环境更可靠”缺少证据。该分数只覆盖特定数据、任务和评分规则；工具故障、API 中断、上下文变化、用户差异与长流程风险需要另外观测。

1.3 行为维度如何展开




图 2：从输出评测扩展到行为评测：目标、环境、执行方式与失效模式四个维度都发生变化。³

行为评测可以沿五个相互衔接的维度阅读，每个维度都对应一个可定位的工程问题：

- **规划质量**：任务是否被拆成可执行且顺序合理的步骤；

³源视频画面绝对时间区间：06:42:53–06:43:24。

- **工具使用**：工具选择、参数和调用时机是否正确；
- **执行过程**：工作流是否按预期推进，有无重复、遗漏或中断；
- **故障恢复**：外部依赖失败后，系统能否识别异常并恢复；
- **决策质量**：面对不确定信息时，系统是否作出与目标和约束一致的选择。

这五项并非演讲者给出的完整评分表，而是对其列举的行为要素所作的教学化展开。它们提供的是定位框架：最终答案错误时，可以继续追问错误来自规划、工具、执行、恢复还是决策；最终答案偶然正确时，也能识别过程是否已经暴露风险（06:43:02–06:43:20）。

1.4 本章小结

智能体系统把评测对象从一次输出扩展为端到端行为。基准测试仍能衡量受控条件下的模型能力，却无法覆盖工具、API、上下文、用户与长工作流带来的生产变量。生产评测因此必须同时检查结果和过程，并把规划、工具使用、执行、恢复与决策纳入证据链。

2 生产失效是一组分层风险：从准确率走向系统级目标

2.1 从“幻觉”扩展到失效模式层级

把智能体风险只概括为“幻觉”，会缩小排查范围。Gupta 提出的失效模式层级（failure mode hierarchy）覆盖从底层能力到高层协作的多种故障；幻觉只是其中一类（06:43:22–06:43:56）。这一层级的价值，在于让团队按照系统结构寻找失效来源。

层级	演讲者列出的失效	排查时要问的问题
基础层	记忆、检索、安全失效	系统是否拿到了正确、足够且允许使用的信息？
执行层	推理错误、规划不佳、工具执行错误	系统是否形成合理步骤，并正确调用和执行工具？
协作层	多智能体协调失效	角色之间是否正确交接信息、责任和任务状态？

层级之间可能产生传导：检索遗漏会污染后续推理，规划缺陷会导致正确工具在错误时机被调用，协作中的状态错位会让多个局部正确动作组合成错误结果。这里的传导关系属于依据层级结构作出的工程解释；演讲字幕只明确列出了各层失效类别。它提示团队保留执行轨迹和中间状态，否则最终输出很难指出故障发生在哪一层。

层级视角的作用

失效模式层级是一张排障地图。它不会自动给出根因，却能阻止评测只在最终文本里搜索错误，并把调查扩展到记忆、检索、安全、推理、规划、工具执行和多智能体协作。




图 3: 智能体失效模式层级：基础层缺陷可能沿推理、规划与工具使用向高层协调级联。裂纹是风险传播的示意表达。⁵

2.2 输出评测为何漏掉主要生产风险

输出评测通常只能看到系统最后交付的内容。它看不到一次成功是否依赖偶然的工具返回，也看不到系统在得到结果前是否经历无效循环、昂贵调用或错误恢复。Gupta 因此判断，只评模型输出会漏掉团队观察到的大量生产风险（06:43:47–06:43:56）。

一个简单例子可以说明这种盲区：研究型智能体最终给出正确结论，但它引用了错误工具结果，随后又从另一来源碰巧纠正。答案评分会把这次执行记为成功；行为证据会显示工具使用和恢复路径并不稳定。反过来，因 API 短暂不可用而失败的任务，也不能简单归因于模型知识不足。生产失效需要同时对照结果、执行路径和依赖状态。

2.3 用站点可靠性工程视角定义成功

Gupta 建议团队采用站点可靠性工程（Site Reliability Engineering, SRE）的思维。SRE 管理生产系统时，会同时关注可靠性（reliability）、可用性、延迟、成本和恢复；准确率只是质量的一部分（06:43:54–06:44:12）。这些维度把“模型答对了吗”扩展为“用户能否以可接受的时间与成本，稳定获得可恢复的结果”。

运行维度	在智能体系统中的含义
可靠性	相似条件下能否持续产生可信、可恢复的端到端结果
可用性	用户需要系统时，服务和关键依赖是否可访问
延迟	工作流从请求到结果是否在可接受时间内完成
成本	模型、检索和工具调用消耗是否与任务价值相称
恢复	出现依赖故障或步骤错误后，系统能否检测、降级或重试
准确率	输出内容是否正确；它为可靠结果提供一个局部输入

⁵源视频画面绝对时间区间：06:43:22–06:43:56。

表中解释是对演讲者指标列表的教学化展开，没有为这些维度虚构阈值。具体服务仍需结合业务风险、用户承诺和成本边界制定目标。

2.4 可靠结果作为统一目标




图 4: SRE 视角把单一准确率扩展为任务成功、工具成功、规划质量、延迟、成本、安全和用户满意度等多维可靠性信号；雷达图为机制示意。

来源：源视频画面绝对时间区间 06:43:54–06:44:24。

演讲者把可靠性设为北极星指标（North Star metric）：系统在真实约束和变化下，持续产生可信、可恢复结果的能力。这个目标把准确率、可用性、延迟、成本与恢复放进同一条用户结果链。准确率仍然重要，其角色是可靠结果的一个输入；单独最大化基准分数无法保证端到端结果（06:44:10–06:44:24）。

北极星结论

评测优化的最高层方向是可依赖的结果（dependable outcomes）。团队应检查用户是否稳定得到有用结果，并同时追踪准确率、可用性、延迟、成本和恢复所暴露的约束。

可靠性作为统一方向，也要求指标之间保留真实取舍。更复杂的重试可能提高恢复成功率，同时增加延迟和成本；更严格的安全限制可能降低部分任务完成率，同时减少高风险行为。这些取舍并未在短讲中展开，落地时需要业务方和工程团队明确服务目标及风险容忍度。

2.5 本章小结

生产风险由多层失效共同构成：基础层涉及记忆、检索与安全，执行层涉及推理、规划与工具，高层还包括多智能体协作。只看输出会丢失故障位置和运行代价。SRE 视角把可靠性、可用性、延迟、成本与恢复纳入成功定义，并以可靠性统领优化方向；准确率继续作为必要的局部信号。

3 三层评测栈：基准、场景与生产信号

前两章已经把目标从“答案是否正确”推进到“系统能否持续产生可靠结果”。接下来的工程问题是：不同来源的证据应当怎样分工？Gupta 给出的答案是一座三层评测金字塔：底层用基准测试建立可重复的能力参照，中层用场景评测（scenario-based evaluation）检验完整工作流，顶层用生产遥测（production telemetry）从真实交互中提取最高价值的信号。三层之间是证据逐步接近现实的关系，任何一层都无法独自回答全部问题（06:44:26–06:44:56）。

3.1 评测金字塔：越接近生产，信号越有运营价值




图 5：评测信号层级：基准测试具有较高规模，场景评测靠近目标工作流，生产遥测具有最高运营价值；两侧箭头表达方向性权衡。⁷

底层基准测试具有规模化和可复现优势，适合比较版本、发现明显能力退化。演讲者同时指出，它的运营价值有限，因为标准化题目没有覆盖真实依赖、真实用户与长工作流。中层的场景评测把智能体放进模拟环境，要求它完成接近业务的端到端任务。顶层的生产遥测来自真实用户与真实系统的交互；演讲者把它称为最高价值评测信号的来源（06:44:26–06:44:56）。

三层的职责边界

基准测试回答“基础能力是否达到已知门槛”；场景评测回答“在受控的真实工作流近似中能否完成任务”；生产遥测回答“系统在现实约束和用户差异下实际发生了什么”。证据越接近生产，代表性通常越强，控制变量与复现难度也随之上升。

⁷源视频画面绝对时间区间：06:44:26–06:44:56。

层级	主要证据	适合回答的问题	主要限制
基准测试	标准任务、固定数据集、版本分数	能力比较、回归检测、发布前筛查	与真实工作流有距离
场景评测	模拟业务环境中的完整任务轨迹	任务完成、工具正确性、规划质量、资源使用	场景覆盖仍由设计者决定
生产遥测	执行轨迹、用户结果、升级、失败与反馈	真实可靠性、未知失效与用户影响	噪声大，需隐私治理和归因分析

这里的金字塔并不表示“顶层取代底层”。基准测试提供低成本、可重复的预警；场景评测把预警推进到工作流层；生产遥测则揭示预先没有写进测试集的现实变化。三层共同覆盖“可比较、可解释、具代表性”这三类互相牵制的需求。

3.2 从提示词驱动转向场景驱动

离线评测仍然重要，变化发生在评测单元。Gupta 明确主张从评测单个提示词转向评测完整场景，并列举客户支持、代码生成和研究工作流作为例子。智能体需要在模拟环境中完成任务，评测者观察任务完成率、工具使用正确性、规划质量和资源使用；资源消耗在大规模运行时会迅速成为显著问题（06:44:56–06:45:28）。

场景必须保留因果链

一个有效场景至少要保留任务目标、可用工具、环境状态、成功条件和失败处理。只给一条提示词再比较最终文本，会丢失“为什么成功或失败”的轨迹，也无法验证中间工具调用是否正确。

因此，场景设计应围绕可观察行为展开：任务是否完成；调用的工具是否适合且参数正确；计划是否能够随环境反馈调整；资源消耗是否符合上线约束。演讲者的原话把结论压缩为一句：“evaluation should be scenario driven, not prompt driven”（06:45:19–06:45:28）。这里的重点是评测对象从输入输出对扩展为完整工作流。

3.3 把生产流量理解为评测数据

系统上线以后，每一次交互都会留下信号。演讲者依次列出执行轨迹、用户结果、升级处理、失败事件和反馈，并据此指出：生产流量已经具有评测数据的意义；生产环境可能是组织能够获得的规模最大、代表性最强的验证数据来源（06:45:26–06:45:52）。

这一判断给数据采集提出了更严格的结构要求。仅保存最终答案无法定位工作流在哪一步偏离目标；至少需要把任务上下文、关键决策、工具调用结果、最终用户结果与后续反馈关联起来。与此同时，生产信号含有隐私、偏差和因果混杂风险。真实数据“更有代表性”不等于每条数据都可以直接作为真值，数据访问、脱敏、保留期限与使用目的仍需明确治理。

⁹源视频画面绝对时间区间：06:44:56–06:45:28。




图 6: 场景驱动离线评测在沙箱中执行完整任务，并同时观察任务完成率、工具正确性、规划质量与资源成本；流程与指标均为方法示意。⁹

生产信号不是天然标签

用户没有投诉，可能意味着任务成功，也可能意味着用户放弃；人工升级可能来自系统失败，也可能来自流程要求。生产遥测提供高价值观察，标签含义仍需业务语境与后续复核校准。

3.4 自动指标与人工判断的分工

Gupta 反对把人类仅仅视为自动化失败后的兜底系统。他认为，人类本身就是评测者，能够提供自动系统难以生成的判断信号，包括正确性、信任、实用性和安全性。这些判断用于校准评测流水线，并暴露自动指标的盲区；成功的系统会组合自动评测与定向人工复核（targeted human review）（06:45:51–06:46:20）。

两类机制可以按职责拆分：自动指标负责高频、低延迟、可规模化的筛查；定向人工复核负责语义边界模糊、风险高、对用户影响大或自动指标意见冲突的样本。人工结论还可以反过来检验自动指标是否把“容易测量”误当成“真正重要”。

组合评测的核心原则

自动评测扩大覆盖面，定向人工复核校准正确性、信任、实用性与安全性的盲区。人工判断承担质量信号职责，并非只在系统报错时接管任务。

3.5 本章小结

¹¹源视频画面绝对时间区间：06:45:26–06:45:52。

¹³源视频画面绝对时间区间：06:45:51–06:46:20。




图 7: 生产交互经评测网关沉淀为元数据、遥测与分析数据, 使每次真实交互都能贡献评测信号; 图示不代表特定 Meta 生产架构。¹¹




图 8: 人类复核节点用正确性、实用性、信任与安全判断校准自动告警和核心模型, 闭环为职责关系示意。¹³

三层评测栈把不同证据放在各自擅长的位置：基准测试建立稳定参照，场景评测验证完整工作流，生产遥测揭示真实结果与未知风险。上线后的执行轨迹、用户结果、升级、失败和反馈应被纳入评测证据；自动指标负责规模化观察，定向人工复核负责校准其盲区。由此，评测从一次发布前考试转变为贯穿系统运行的可靠性基础设施。

4 总结与延伸：把评测变成持续闭环

这段演讲的核心结论可以压缩为一条因果链：智能体系统执行多步工作流，因此评测对象必须从答案扩展到系统行为；系统行为会在记忆、检索、安全、推理、规划、工具执行和多智能体协作等层面失效，因此最高目标应当是可靠性；可靠性需要基准测试、场景评测和生产遥测组成分层证据；自动指标仍有语义盲区，因此需要定向人工复核持续校准（06:41:43–06:46:20）。

4.1 演讲结论链：从行为评测走向可靠结果

第一步是改变问题。模型分数只能说明标准任务上的能力，智能体系统的生产表现还受到工具、API、上下文、用户差异和长工作流影响。真正的问题是系统是否正确行动，并在失败后恢复（06:41:43–06:43:24）。

第二步是扩大风险视野。幻觉只是失效模式层级中的一类；仅检查最终输出，会遗漏系统运行中的大量风险。SRE 视角把可靠性、可用性、延迟、成本和恢复纳入同一运营目标，并把可靠性设为北极星指标（06:43:22–06:44:24）。

第三步是组织证据。基准测试、场景评测与生产遥测分别提供可复现能力参照、工作流级验证和真实运行信号。生产数据具有最高现实代表性，仍需人工判断去校准正确性、信任、实用性、安全性以及自动指标盲区（06:44:26–06:46:20）。

全讲的行动结论

生产评测应成为持续运行的可靠性基础设施：它同时观察能力、工作流和真实用户结果，并通过自动评测与定向人工复核组合，把“高分”转化为“可依赖的结果”。

4.2 素材最后留下的问题：持续变化

演讲在结尾开启了漂移（drift）问题：模型、提示词、工具和用户行为都会变化（06:46:18–06:46:30）。这使一个开放问题浮现：既有评测集、指标与阈值怎样继续代表生产现实？¹⁴

4.3 本文推演：观察、复核、入库、回归

本文推演：依据三层评测栈、生产信号和人工校准的关系，可把生产异常转化为新的场景回归用例，形成“观察—复核—入库—回归”的持续闭环：

¹⁴主题素材止于 06:46:30；下节闭环属于本文推演，不归因于演讲者或 Meta。

¹⁶源视频画面绝对时间区间：06:46:18–06:46:30。




图 9: 模型更新、提示词变化、工具或 API 变化与用户行为迁移会共同推动智能体可靠性漂移; 退化曲线和症状是演讲中的机制示意。¹⁶

1. **观察:** 从生产遥测中发现失败、升级、异常资源消耗、负面用户结果或指标间冲突, 并保留可定位的执行轨迹。
2. **复核:** 对高风险或含义不清的样本开展定向人工复核, 判断真实影响、失效层级与自动指标盲区。
3. **入库:** 将确认有代表性的案例脱敏、最小化并改写为可重复的场景用例, 同时记录来源版本、适用边界和成功条件。
4. **回归:** 在模型、提示词、工具或编排变化前后运行场景集; 上线后继续用生产遥测检查评测结论是否仍有代表性。

这一闭环的价值在于连接三层证据: 生产层发现未知问题, 人工复核建立可信解释, 场景层沉淀可复现用例, 基准与场景回归负责低成本预警。其风险也很明确: 若只收录事故样本, 评测集会过度代表罕见失败; 若缺少版本与适用边界, 旧阈值会被误用于新系统; 若生产反馈存在选择偏差, 闭环可能持续强化错误代理指标。

4.4 实施清单

以下清单区分了演讲明确提出的原则与本文推演的落地动作:

实施项	最小可验证产物	依据属性
定义可靠性目标	可用性、延迟、成本、恢复与用户结果指标表	演讲原则
建立三层评测栈	基准集、业务场景集、生产遥测字段与责任人	演讲原则
部署定向人工复核	抽样规则、复核量表、争议升级与指标校准记录	演讲原则
追踪系统变更	模型、提示词、工具、用户行为的版本或分布记录	漂移来源来自演讲；记录机制为本文推演
生产异常回灌	脱敏场景、来源证据、成功条件与回归历史	本文推演
定期重审阈值	阈值对应的版本、场景覆盖与生产偏差报告	本文推演

4.5 本章小结

读者应带走三点。其一，智能体评测的最小对象是端到端系统行为。其二，可靠性需要多层证据共同支撑，准确率只是其中一个输入。其三，人类评测者提供自动指标无法稳定表达的价值与风险判断。

仍待回答的问题集中在持续变化：哪些生产事件值得沉淀成回归场景？人工复核怎样抽样才能覆盖高风险尾部并避免反馈偏差？模型、提示词或工具发生多大变化时，旧阈值必须失效并重新校准？这些问题没有在当前素材中得到演讲者的完整回答，却决定了生产评测能否长期保持代表性。

最终，评测团队需要反复追问一个可操作的问题：**当系统持续漂移时，现有证据是否仍然代表真实用户正在经历的系统？**这既是本段素材留下的开放结尾，也是把评测建设成生产基础设施时必须长期维护的边界。