

为何智能体会与自己意见相左：把分歧变成持续学习信号

讲者：Diane Lin (Datadog) 整理：SSS & Codex

整理日期：2026 年 7 月 24 日



视频作者/频道：AI Engineer；讲者 Diane Lin (Datadog)

发布日期：2026 年 7 月 20 日

视频时长：25 分 38 秒

视频链接：<https://www.youtube.com/watch?v=wEc9aG7cRQc>

PDF 制作 Skill: <https://github.com/wdkns/wdkns-skills>

目录

1 从“同样输入、不同结论”看见产品风险	2
1.1 先界定问题：变化是否会改变业务动作	2
1.2 酒店评论：一次命中掩盖了行为分布	2
1.3 网络安全告警：标签变化会传播为处置变化	3
1.4 一致性与正确性必须分开检查	4
1.5 本章小结	5
2 灰区：不一致为何集中在决策边界附近	5
2.1 决策边界与灰区的直觉	5
2.2 酒店案例：标签取决于业务要解决什么	6
2.3 安全案例：相似开端可能通向完全不同的处置	6
2.4 从现象回到根因：三类澄清任务	7
2.5 本章小结	7
3 以分歧驱动主动学习：把人工注意力投向高信息案例	7
3.1 为什么不能全面人工检查	8
3.2 传统主动学习循环	8
3.3 两种选样信号：不确定性与委员会分歧	9
3.4 人类复核提供标签，也提供缺失的判别信息	9
3.5 智能体版本需要改造两个环节	9
3.6 风险与落地检查	10
3.7 本章小结	11
4 两类记忆如何稳定决策：规则与先例的分工	11
4.1 为何先用记忆承接反馈	11
4.2 语义记忆：把个案澄清提炼成政策	11
4.3 情景记忆：从历史中检索可用先例	12
4.4 规则与先例的操作边界	13
4.5 本章小结	14
5 持续学习闭环 (continuous learning loop)：效果、实验与工程边界	14
5.1 从分歧信号到下一轮监测	14
5.2 一套方案带来的三项产品收益	15
5.3 实验结果：93 条告警的三次运行	16
5.4 证据边界与工程治理	17
5.5 本章小结	18
6 最终综合：把每次反复变成一次可复用的澄清	18
6.1 讲者的实质性收束	18
6.2 把全文压缩成四个责任层	19
6.3 实践含义：从试点到生产的落地清单	19
6.4 风险界限与开放问题	20
6.5 本章小结	20

1 从“同样输入、不同结论”看见产品风险

本章核心结论

单次评测只能回答“这一次输出是什么”，无法回答“这个智能体在重复运行时是否稳定”。对于会触发告警分诊、账号处置或人工升级的任务，跨运行一致性应作为独立质量维度持续测量。

1.1 先界定问题：变化是否会改变业务动作

讲者把问题压缩成一句直观描述：同一个模型、同一个输入，却产生不同输出。这里所说的不同有严格边界。若两次回答仅在句式、语气或详略上变化，而标签、判断与处置动作保持一致，这属于普通措辞差异；若输出从“正面”变为“负面”，或从“良性”变为“可疑”，变化已经穿透文字表面并改变业务含义。

本文将后一类现象称为**语义不一致 (semantic inconsistency)**：同一任务的多次运行产生会改变标签、判断或处置动作的实质差异。这个定义决定了后续测量对象，也避免把生成式模型天然的表达多样性误报为质量事故。

在分类型智能体中，语义不一致常表现为**结论反复**：同一案例跨运行在两个或更多实质结论之间切换。讲者展示的安全告警表格包含三列重复运行结果；部分行始终为 **benign** 或始终为 **suspicious**，另一些行则在两者之间来回变化。表格中的稳定行与反复行说明，问题位于案例层面，不能仅靠一次整体准确率概括。

1.2 酒店评论：一次命中掩盖了行为分布

酒店情感分类是一个低门槛例子：系统需要把每条评论标为正面或负面。现代语言模型通常可以完成这类任务，困难来自重复运行后的行为分布。某条边界模糊的评论在一次运行中可能得到正面标签，下一次运行却得到负面标签。于是，“一次评测答对”只证明某次采样落在正确一侧，无法证明产品在真实使用中会持续给出同一业务判断。

这会改变评测设计。质量负责人至少需要观察三个层面：

1. **单次正确性**：某次输出是否符合参考标签或专家判断；
2. **跨运行一致性**：同一输入重复运行时，实质标签是否稳定；
3. **案例分布**：哪些输入稳定，哪些输入频繁出现结论反复。

重复评测的价值在第三层最明显。仅报告多次运行的平均分仍会隐藏具体反复案例；保留案例级结果，团队才能在后续章节中定位最需要澄清政策与上下文的样本。

LLM Inconsistency in Practice

Sentiment analysis: classify hotel reviews as positive or negative

Review A

"Fantastic hotel in the perfect location. It's just a five-minute walk to all the major museums and restaurants, yet tucked away on a quiet street so you don't hear any city noise at night. The concierge, David, gave us the best recommendations for local dining that weren't tourist traps. Everything about this place is top-notch. Highly recommend to anyone visiting the city."

Review B

"It's an okay hotel. It's clean and safe, which are the most important things, but it entirely lacks any charm or personality. The check-in process was automated via a kiosk, so we never actually spoke to a human being during our entire stay. The room had all the basics but felt very sterile, almost like a hospital room. If you just need a cheap, clean place to crash before an early flight, it works fine. Just don't expect a memorable hospitality experience."

图 1: 同一情感分类任务中的两个酒店评论: 强正面样本与褒贬混合样本为“稳定案例/边界模糊案例”的区分提供直观入口。¹

单次评测与跨运行评测

可以把单次评测理解为只拍下一张照片, 跨运行评测则像观察一段短视频。前者显示某个瞬间是否正确, 后者显示系统会不会在同一条件下反复改变主意。二者回答不同的质量问题。

1.3 网络安全告警: 标签变化会传播为处置变化

安全场景把风险进一步放大。讲者给出的告警描述是: 从可疑 IP 检测到 Gmail 账号的失败登录尝试。安全分析员需要判断这条告警是否恶意、是否需要采取阻断或调查动作, 或它是否属于可以忽略的良性事件。

同一告警交给智能体多次分诊后, 会出现三种行为:

- 多次运行始终判为 `benign`;
- 多次运行始终判为 `suspicious`;
- 多次运行在 `benign` 与 `suspicious` 之间结论反复。

第三种行为直接制造产品信任问题。使用者无法判断哪一次输出值得采用, 也无法建立稳定的告警处置流程。相同事件今天被忽略、明天被升级, 会让审计记录、响应优先级和客户预期一起漂移。讲者用概念验证竞标作产品层面的说明: 当一个供应商持续给出稳定判断, 另一个供应商对相同输入反复改变结论, 客户更容易信任前者。

¹ 视频画面时间区间: 00:03:18–00:04:08。

verdict_iter0	verdict_iter1	verdict_iter2
suspicious	benign	benign
suspicious	suspicious	suspicious
suspicious	suspicious	suspicious
benign	suspicious	suspicious
benign	benign	benign
benign	benign	benign
benign	benign	benign
suspicious	benign	benign
suspicious	benign	suspicious
benign	benign	benign
suspicious	suspicious	suspicious
benign	suspicious	suspicious
suspicious	suspicious	benign
benign	suspicious	benign
suspicious	benign	suspicious
suspicious	benign	benign
benign	benign	benign
suspicious	benign	benign
benign	benign	suspicious
benign	benign	benign
benign	benign	benign
benign	benign	benign

图 2: 视频源表证据: 一组安全告警各重复运行三次后, 一部分案例在 benign 与 suspicious 之间反复, 说明单次评测无法刻画决策稳定性。²

1.4 一致性与正确性必须分开检查

一致性不等于正确性

稳定输出不自动等于正确输出。一个智能体可能始终给出错误标签, 也可能在多次运行中偶尔命中正确答案。跨运行一致性用于发现行为不稳定, 正确性仍需由可靠标签、专家复核或可验证结果判断。

因此, 高风险评测不能只追求“每次说法一样”, 也不能只保留一次准确率。更完整的检查方式

²视频画面时间区间: 00:04:52–00:05:35。

是并列记录正确性与一致性：前者回答结论是否可信，后者回答产品行为是否可预测。两项指标共同通过时，系统才具备稳定执行决策的基础。

这里还有一个隐藏假设：重复运行需要保持任务、输入、模型版本、提示、检索上下文和工具状态尽量可比。若这些条件本身发生变化，观察到的结论差异可能来自版本漂移、检索内容变化或工具失败，不能直接归入本章定义的跨运行不稳定。

1.5 本章小结

同一输入上的实质标签变化会破坏评测解释力，并在安全场景中传播为不同处置动作和信任损失。有效的第一步是明确区分措辞差异与语义不一致，再通过重复运行保留案例级结论。产品症状已经清楚，下一章将追问这些反复案例为何集中出现，以及它们在决策空间中位于什么位置。

2 灰区：不一致为何集中在决策边界附近

本章核心结论

容易出现结论反复的案例往往聚集在决策边界附近。它们缺少能够稳定决定标签的政策或上下文，因此也会让人类专家和传统分类器犹豫。这里的优先任务是澄清规则与补足信息。

2.1 决策边界与灰区的直觉

决策边界是把不同标签或处置区域分开的判定界线。例如，边界一侧是“正面评论”，另一侧是“负面评论”；在安全分诊中，边界两侧可能对应“良性、无需动作”和“恶意、需要响应”。

远离边界的案例包含鲜明信号，多次运行通常落在同一侧。靠近边界的案例同时携带相反证据，或缺少决定性的业务信息，微小的采样差异便可能改变最终标签。本文把这组边界附近、现有信息或政策不足以稳定决定标签的案例称为**灰区**。灰区是一个有位置含义的概念，范围不能扩展为所有困难样本。

讲者用红蓝样本和虚线边界说明这一结构：纯红或纯蓝样本离边界较远，反复叠加红蓝颜色的样本围绕边界分布。图中的模糊带表达了系统尚未获得足够清晰度的区域。




图 3: 灰区位于决策边界附近；边界附近的案例更容易因政策含混或上下文不足而改变标签。³

2.2 酒店案例：标签取决于业务要解决什么

讲者并列展示了两条酒店评论。评论 A 对位置、环境、礼宾建议与整体体验都给出强烈正面评价，标签信号集中，多次运行容易保持正面。评论 B 则同时包含两组证据：

- 正向或中性证据：干净、安全、价格合适，能够满足赶早班飞机前短住的基本需求；
- 负向证据：缺少魅力和个性，自助入住缺乏人与人的接触，房间像医院，难以形成值得记忆的款待体验。

评论 B 位于边界附近，因为“是否负面”取决于酒店采用怎样的标签政策。若标签用于发现酒店能够直接改进的问题，管理者可能认为部分抱怨超出当前可行动范围，从而不把它归入负面；若标签用于完整捕捉影响住客体验的因素，管理者可能仍希望将其标为负面并纳入改进分析。讲者据此强调，人类专家也可能对同一条评论产生分歧，最终选择受公司政策和偏好支配。

决策边界的地图类比

决策边界可以类比为地图上的行政分界线。城市中心的位置明确，边界附近的一栋房屋属于哪一侧，需要更精确的坐标和正式规则。灰区案例也需要额外特征或明确政策才能稳定归类。

2.3 安全案例：相似开端可能通向完全不同的处置

安全告警提供了第二种灰区来源：现有描述缺少决定处置的上下文。多个来自可疑 IP 的失败认证尝试说明攻击者正在“敲门”。若所有尝试都失败，攻击者仍被挡在环境之外；在持续遭遇此类噪声的大型企业中，把每次失败尝试都升级处理会淹没分析员队列。

³视频画面时间区间：00:10:18–00:10:58。

风险会在后续条件发生变化时跃迁。若攻击者最终获得正确密码、通过多因素认证并成功进入环境，事件需要严肃处置。两种情况拥有相似的前段行为，结果和响应动作却完全不同。讲者在后续规则幻灯片中把该攻击模式明确写作 *password spray*，本文统一称为“密码喷洒攻击”。相应的业务规则需要至少区分：

- 密码喷洒攻击未产生成功登录：可按客户政策判为良性或低优先级；
- 密码喷洒攻击最终产生成功登录：应视为恶意事件并触发响应。

这组规则依赖客户风险偏好。部分客户希望获知所有探测和失败尝试，另一些客户只关心攻击者真正进入环境的事件。仅重复采样无法补出“是否成功登录、是否通过 MFA、客户是否要求通知”这些信息；系统需要把它们加入上下文，并明确通知政策。

2.4 从现象回到根因：三类澄清任务

两个领域的例子可以归纳为三类需要澄清的任务：

1. **标签政策**：组织必须说明标签服务于什么业务目标，以及边界案例应如何归类；
2. **信息缺口**：系统需要补入能改变判断的特征，如最终登录结果、MFA 状态或客户通知偏好；
3. **专家分歧**：当合理专家持不同意见时，流程需要明确政策所有者和升级路径。

讲者把智能体的反复理解为对既有歧义的显露。这是一项经验性判断，适用于本演讲讨论的边界案例，不能推广为所有不一致的唯一根因。模型能力缺陷、提示不稳定、非确定性工具、检索漂移、上下文截断和实现错误都可能制造表面相同的症状，工程团队仍需单独排查。

分歧只是一条诊断线索

分歧是“这里缺少清晰度”的信号，不能自动证明根因属于业务政策。若系统版本、提示、检索结果或工具状态在重复运行之间改变，应先恢复可比条件，再判断案例是否真正位于业务决策灰区。

2.5 本章小结

灰区位于决策边界附近，常由标签政策含混、判别信息不足或专家意见分歧形成。酒店案例显示业务目标会改变情感标签，安全案例显示新增上下文会改变响应动作。灰区需要被优先澄清；下一章将解决规模问题：当线上案例数量巨大、人工预算有限时，系统怎样低成本找出最值得审查的部分。

3 以分歧驱动主动学习：把人工注意力投向高信息案例

本章核心结论

跨运行或跨模型分歧可以充当选样信号，把有限的人工复核预算集中到最可能需要政策澄清或补充信息的案例。分歧负责回答“先看什么”，正确答案仍由人类复核和业务政策决定。

3.1 为什么不能全面人工检查

智能体进入线上或监控模式后，会持续处理大量未标注案例。若人类逐条检查全部输出，自动化节省的成本会迅速消失；若完全不检查，团队又无法发现模型在哪些案例上表现不佳。资源约束把问题转化为选样问题：应从大规模数据中挑出最可能提供新信息、最值得专家投入时间的少量案例。

主动学习正是为这一约束设计的流程。它依据模型信号选择最值得人工标注或复核的数据，再把反应用于后续改进。主动学习提升的是复核资源效率，不能替代专家判断。

3.2 传统主动学习循环

讲者展示的传统机器学习流程可以整理为四个教学阶段：

1. **形成初始模型**：从少量已标注数据训练模型；
2. **覆盖未标注池**：让模型对大量未标注样本或线上数据给出标签及概率；
3. **选择高信息案例**：用不确定性采样、委员会查询等策略找到最值得标注的样本；
4. **人工反馈并回流**：专家核对标签、补充必要特征，把新信息加入训练集并进入下一轮训练。

这个循环的关键不在于一次性找到所有错误，而在于用有限标注预算反复收紧模型最薄弱的区域。接近分类阈值的样本通常包含更高信息量；专家对这些样本的判断可以显著改变后续边界。




图 4：传统主动学习使用查询策略选择高信息样本，经人工标注后重新训练模型，循环直至预算耗尽或性能收敛。⁴

⁴视频画面时间区间：00:11:18-00:14:18。

主动学习的复查类比

主动学习可以类比为医生安排复查：资源有限时，检查会优先覆盖指标异常、诊断边界模糊或可能改变治疗方案的病例。选择提高注意力分配效率，最终诊断仍需要专业判断和充分证据。

3.3 两种选择信号：不确定性与委员会分歧

传统流程常使用接近分类阈值的概率寻找边界样本。对应到语言模型场景，模型给出的概率或自我报告置信信号可称为**不确定性分数 (uncertainty score)**。讲者基于团队当时的实践指出，LLM 的不确定性分数“不太可靠”：模型高置信时仍可能答错，也可能无法识别自身知识缺口。

这项结论有明确适用边界。它是讲者团队在相关智能体任务中的经验，演讲没有给出覆盖不同模型、提示、校准方法和领域的系统比较，因此不能表述成所有 LLM 置信信号都无效。工程上仍可验证概率校准或引入外部评分器；本演讲推荐的低门槛替代信号是多次预测之间的分歧。

委员会查询通过多个模型或同一模型的多次运行比较预测分歧，并据此选择待复核案例。这里的“委员会”描述的是多份预测意见，实施方式至少有两种：

- 多个不同模型对同一案例给出判断；
- 同一模型在保持任务条件可比的情况下重复运行多次。

当这些意见对实质标签产生分歧时，案例更可能落在决策灰区，需要人工澄清。委员会查询无需强制部署多个不同模型；同一模型的重复运行已经能够提供跨运行分歧信号。

委员会一致也可能共同犯错

模型分歧只能定位值得复核的案例，无法投票产生天然正确的答案。若所有成员共享相同偏差，委员会可能一致地犯错；若运行条件不一致，分歧也可能来自提示、检索或工具状态漂移。

3.4 人类复核提供标签，也提供缺失的判别信息

选样完成后，专家需要执行两类工作。第一类是核对或重定标签，例如确定某条混合酒店评论按当前政策应归为正面还是负面。第二类是补充能够消歧的特征，例如安全事件是否最终成功登录、是否通过 MFA、客户希望接收哪些告警。后一类工作尤其重要，因为灰区经常来自输入信息不足，单纯改标签会留下同样的判别缺口。

传统主动学习随后把新标签和新特征加入训练集，并重新训练模型。循环持续到标注预算耗尽、性能收敛或业务目标达到。这个机制解释了主动学习的效率来源：人工注意力集中在模型能从中学到最多的案例，而稳定、明确的样本继续由系统自动处理。

3.5 智能体版本需要改造两个环节

讲者把传统流程迁移到 LLM 与智能体时，保留了“推理—选样—人工反馈—更新”的主骨架，同时调整两个环节：

1. **选样策略改造**：优先比较多模型或同一模型多次运行的实质分歧，避免把未经验证的自报置信度当作唯一依据；

2. **更新方式改造**：微调仍是一条路径，但成本较高、迭代较慢。更轻量的方案可以先把人工反馈注入外部记忆机制，让后续运行复用已确认的规则与案例。

第二项改造只在本章建立过渡。两类记忆分别保存怎样的知识、怎样检索、各自会怎样失败，将由下一章完整定义。此处需要保留的因果关系是：主动学习解决“哪些案例先交给给人”，记忆机制解决“一次人工判断怎样在未来继续生效”。




图 5: LLM 场景用委员会分歧选样，并允许把人工反馈写入领域知识与历史案例记忆；微调或偏好训练是可选更新路径。⁵

3.6 风险与落地检查

要让分歧选样产生可信结果，流程还依赖若干未在演讲中展开的工程条件：

- 固定或记录模型版本、提示、温度、检索快照和工具状态，保证多次运行可比较；
- 先定义哪些标签变化属于实质分歧，避免将格式和措辞差异送入人工队列；
- 为高风险案例保留直接升级路径，不能因委员会意见一致就跳过必要审查；
- 同时抽检稳定案例，用于发现“全体一致地犯错”的盲区；
- 记录专家决定的来源与适用范围，方便后续更新和审计。

⁵ 视频画面时间区间：00:14:18–00:15:58。

3.7 本章小结

主动学习把全面人工检查转化为高信息案例选择。传统流程常使用不确定性或委员会分歧；在讲者讨论的 LLM 场景中，跨运行或跨模型分歧是更实用的灰区信号。它决定人工注意力首先投向哪里，人类仍负责确认标签、补充上下文和选择业务政策。下一章将继续回答反馈复用问题：如何让一次澄清形成可持续的规则和历史先例。

4 两类记忆如何稳定决策：规则与先例的分工

本章核心结论

一次人工复核要长期生效，需要被保存成合适的知识形态：可复用的政策与领域规则，以及带有处置结果的具体历史案例。前者解释为什么这样判断，后者快速回答过去怎样处理；两者按“先复用先例、再提炼规则”的顺序协作，才能让人工反馈持续收紧决策边界。

4.1 为何先用记忆承接反馈

发现高信息案例之后，最直接的更新设想是重新训练或微调模型。讲者指出，这条路径在频繁澄清客户政策的场景中迭代成本较高，因此提出更轻量、较易更新的记忆方案。这里的选择依据是**反馈的形态与更新频率**：如果新增内容是一条明确业务政策，或一个已经由专家处置的案例，把它写入外部记忆便能先产生效果；当累积证据足以支持能力层面的稳定改变时，团队仍可另行评估微调。

这个顺序隐含两个前提。第一，智能体在推理时确实会检索并遵循相应记忆；第二，记忆内容具有来源、适用客户和版本信息。缺少这些运行条件，记忆只是一份旁路文档，无法稳定决策。

4.2 语义记忆：把个案澄清提炼成政策

语义记忆保存可概括的领域知识、客户偏好和判定规则。它把关注点放在**哪些条件决定标签，以及以后应当遵守什么政策**；单条告警的历史标签由另一类案例记忆保存。

讲者用两个例子说明这种知识形态：

- 在酒店评论任务中，某酒店决定：若抱怨针对酒店无法控制的因素，则把评论归为正面。该规则表达的是酒店希望关注哪些可行动反馈。
- 在安全告警任务中，密码喷洒攻击若没有任何成功登录，则按该示例政策视为良性；若最终出现成功登录，则视为恶意。决定标签的是“是否成功进入环境”这一补充信息。

这些规则的价值超过单个模型调用。模型可据此稳定分类，人类标注者也获得统一口径。原本模糊的决策边界因而被明确条件切分，后续案例能够沿同一政策处理。

"If the customer complains about something outside the hotel's control, classify the review as positive."

图 6: 语义记忆把客户政策显式化：对酒店不可控事项的抱怨按该客户的标签政策处理。⁶

Semantic Memory: Domain Knowledge

Security Analysts triage alerts

"Failed authentication attempts detected from suspicious IP"

"Password spray without successful login should be benign. In contrast, password spray with final successful login should be considered malicious."

图 7: 语义记忆中的安全策略区分攻击是否最终成功；相同攻击类型在不同上下文中需要不同处置。
7

规则的真正作用

语义记忆把隐含在专家头脑或客户偏好中的判断依据显式化。它同时服务于机器推理、人类标注和审计说明，因此适合承载能够跨多个案例复用的政策。

4.3 情景记忆：从历史中检索可用先例

情景记忆保存具体历史案例及其处置结果。面对一个新案例，系统在嵌入空间中寻找相似先例，把过去的人类判断作为当前决策的参考。它适合处理尚未提炼出抽象原因、却已经反复出现的情况。该机制可拆成四步：

1. 为新案例生成可检索表示；
2. 在同一客户和有效政策范围内检索相似历史案例；
3. 若存在可靠、处置条件一致的先例，则参考其历史结论；
4. 若新案例落在已有案例群之外，或参考先例后仍有分歧，则保留未决状态并升级给人工。

在安全运营中，重复误报和经常复现的噪声是这种方法的优先对象。相关人工判断已经在过去发生，系统可以自动复用，由此把当下的专家注意力留给真正新颖或仍然含混的案例。

⁶ 视频画面时间区间：00:16:10–00:17:08。

⁷ 视频画面时间区间：00:17:08–00:18:03。




图 8: 情景记忆在嵌入空间中检索相似历史案例；可靠先例可稳定复现案例，真正模糊的新案例继续进入人工复核。⁸

相似不等于处置条件相同

源视频说明了“检索相似先例”的方向，没有给出相似度阈值、冲突先例处理或客户隔离方案。表面相似的案例可能具有不同成功登录状态、资产风险或客户政策。工程实现必须把这些处置条件纳入过滤与复核，不能只按向量距离自动复制标签。

4.4 规则与先例的操作边界

表 1: 语义记忆与情景记忆的分工

比较维度	语义记忆	情景记忆
保存对象	可概括的领域知识、客户政策和判定规则	具体历史案例、上下文与处置结果
回答的问题	为什么这样判断，以后应遵循什么规则	过去怎样处理相似情况
上线方式	需要专家提炼并明确适用边界	可先复用既有人工处置，提炼成本较低
泛化范围	可覆盖满足同一规则的多类案例	主要覆盖与历史先例足够相似的案例
典型失败	规则过期、范围过宽、客户政策串用	错误召回、先例冲突、历史错误被放大

两者之间存在明确的顺序关系。情景记忆先自动吸收反复出现的已知情况；仍在反复的案例进入人工复核；专家再把可概括的原因提炼成语义记忆。具体案例也应连同最终处置写回情景记忆，为下一次检索提供新先例。

⁸视频画面时间区间：00:18:05–00:19:48。

Semantic Memory vs Episodic Memory

Complement each other:

- **Episodic memory** handles **recurring** situations automatically
- Remaining flip cases => exactly the ones that deserve another human review
- Human review distill the domain knowledge to be put into **Semantic memory**

图 9: 两类记忆互补: 情景记忆复用具体先例, 人工复核剩余案例并把可概括知识写入语义记忆。⁹

4.5 本章小结

语义记忆负责把专家判断提升为可解释、可复用的政策; 情景记忆负责复用带有上下文的历史先例。前者提供泛化能力, 后者提供快速自动化。可靠系统需要保留两者的边界, 并把“无可靠先例、先例冲突、参考后仍分歧”的案例持续送回人工。下一章将在此基础上把分歧检测、记忆检索和专家反馈编排成完整闭环。

5 持续学习闭环 (continuous learning loop): 效果、实验与工程边界

本章核心结论

持续学习闭环的推荐顺序是: 先让情景记忆自动处理可信的复现案例, 再把无先例或仍有分歧的灰区交给人工, 最后将专家澄清的规则写入语义记忆。该闭环能够同时提高跨运行一致性、人工复核效率和客户政策对齐; 它仍需以正确性评估、记忆治理和审计机制约束。

5.1 从分歧信号到下一轮监测

两类记忆只有被编排进反馈流程, 才会形成持续改进。完整路径可以按以下步骤运行:

1. 对同一任务重复运行, 或使用委员会查询收集多个判断;
2. 比较实质标签与处置动作, 找出语义层面的结论分歧;
3. 用情景记忆检索同一客户范围内的相似先例;
4. 对具有可靠、条件一致先例的复现案例, 参考历史决策自动稳定输出;
5. 对无先例、先例冲突或参考后仍分歧的案例, 升级给领域专家;
6. 专家确认标签, 并补充缺失上下文或政策边界;
7. 将可概括的规则写入语义记忆, 将具体案例和处置结果写回情景记忆;
8. 在后续流量中继续监测结论分歧, 检查新规则是否真正减少灰区。

⁹视频画面时间区间: 00:19:58-00:20:35。

这条路径把人工放在政策判断和例外处理的位置，把大量复现噪声留给检索自动化。分歧在这里承担的是路由信号：它指出哪里值得检查，最终标签仍由证据和政策决定。




图 10: 分歧驱动的持续学习闭环：先用情景记忆复用可靠先例，剩余灰区由专家处理，再分别把具体案例与一般政策写回两类记忆。根据视频机制重绘。¹⁰

5.2 一套方案带来的三项产品收益

讲者将收益归纳为三个层次：

1. **更高的一致性与信任**。识别边界附近的数据点，再用规则和先例补足判断依据，使同类输入更稳定地得到相同处置。
2. **更高效的质量控制**。团队只复核算法筛出的含混子集，无需逐条检查所有智能体输出；有限标注预算因而集中到信息量更高的案例。
3. **客户政策对齐**。人工反馈持续沉淀为客户特定政策和案例，使智能体逐步适应该客户的环境与处置偏好。

¹⁰ 机制综合来源区间：00:15:55–00:23:55；本图为结构化重绘。



图 11: 分歧驱动的记忆与人工闭环带来三项产品收益: 更高一致性、更聚焦的质量控制和更好的客户政策对齐。¹¹

5.3 实验结果: 93 条告警的三次运行

讲者报告了一组真实网络安全告警实验。样本包含 93 条告警, 每条告警运行 3 次。未应用所提方案时, 约四分之一的告警发生结论反复; 应用情景记忆后, 结论反复占比下降约 15 个百分点, 仍有约 10% 保持一致并进入人工复核。

表 2: 讲者报告的实验设置与结果

项目	报告值	可支持的解释
网络安全告警数量	93 条	特定安全环境中的真实告警样本
每条告警运行次数	3 次	用跨运行标签变化识别结论反复
基线结论反复	约 25%	约四分之一告警在三次运行中出现不同结论
情景记忆自动稳定	约 15 个百分点	由约 25% 降至约 10% 的绝对差值, 并与讲者口述相符
仍不一致	约 10%	无可靠先例或参考先例后仍分歧, 进入人工复核

这里的“15”应理解为**约 15 个百分点的绝对下降**: 基线约 25%, 剩余约 10%。它不表示相对改善 15%, 也不支持准确率提高 15% 的结论。

¹¹ 视频画面时间区间: 00:20:35–00:22:18。




图 12: 讲者实验对 93 条安全告警各运行 3 次: 基线约 25% 出现结论反复; 引入情景记忆后约 10% 仍不一致。¹²

一致性提高不等于正确率提高

该实验直接测量的是跨运行结论是否稳定。一个系统也可能稳定地给出错误标签, 因此 25% 降至 10% 不能被解释为准确率提升。交付评估应把一致性、基于金标准或专家裁决的正确性, 以及高风险错误率分别报告。

5.4 证据边界与工程治理

这组结果支持方案在演示场景中的可行性, 无法单独证明跨领域普适性。演讲没有说明抽样方法、相似度阈值、模型和提示版本、置信区间、显著性检验或独立对照组; 93 条告警也来自特定网络安全环境。由此可以得到工程试点依据, 仍需在目标客户和目标任务上重新验证。

长期运行还依赖以下治理措施:

- **来源与版本:** 每条规则和案例记录原始证据、专家、创建时间、模型版本与修改历史;
- **客户隔离:** 客户特定政策和案例库保持明确边界, 防止某客户偏好泄漏到另一客户;
- **有效期:** 对会随威胁态势或业务流程变化的规则设置复核日期和失效机制;
- **冲突处理:** 当相似先例标签冲突或语义规则互相矛盾时, 停止自动处置并升级人工;
- **回归监测:** 同时追踪一致性、正确性、覆盖率、人工复核量和高风险漏报, 避免单指标优化。

记忆会把错误一并放大

情景记忆可能复制历史误判, 语义记忆可能固化过期或范围过宽的政策。记忆写入应经过权限控制和审计, 检索结果应保留来源, 自动应用应设置风险阈值和人工回退路径。

¹²视频画面时间区间: 00:22:18-00:23:42。幻灯片直接显示 25% 与 10%; 约 15 个百分点为二者差值, 并与讲者口述对齐。

5.5 本章小结

持续学习闭环把分歧检测、情景检索、人工复核和语义规则串成可反复运行的质量流程。讲者的实验显示，在 93 条告警、每条 3 次运行的设置中，约 25% 的基线反复可降至约 10%，其中约 15 个百分点由情景记忆自动稳定。该结果证明的是一致性改进的可行性。可靠落地仍需单独验证正确性，并治理记忆来源、版本、客户边界和失效风险。

6 最终综合：把每次反复变成一次可复用的澄清

全文结论

稳定的智能体来自一条可治理的学习链：用分歧暴露决策边界附近缺失的清晰度，用情景记忆复用可信先例，用人工复核解决新颖和高风险案例，再把可概括的判断写成语义规则。人类始终拥有政策所有权、价值判断权和例外处置权。

6.1 讲者的实质性收束

演讲最后给出三项行动导向的结论。

1. **优先检查标签歧义和信息缺口。**讲者的经验判断是，许多不一致来自标签政策含混或上下文不足。该判断适用于演讲讨论的边界案例；模型缺陷、提示不稳定、工具失败和检索漂移仍需并行排查。
2. **把模型分歧当作学习机会。**分歧指出了当前系统缺少清晰度的位置，因此可以驱动选样、复核和政策澄清。
3. **把记忆作为轻量更新路径。**微调是可选更新手段，语义记忆和情景记忆能够更快承接频繁变化的政策与案例反馈。

讲者随后强调，希望智能体持续改进并适应客户环境。这个收束把技术目标落到了产品关系上：系统需要听取客户反馈，把已确认的政策变化变成可追溯的行为变化。

Takeaways

- **Inconsistency isn't usually a model problem**
 - label ambiguity + insufficient info
- **Model disagreement isn't a bug, but a feature**
- **Fine-tuning isn't your only option**
 - augment your agent with semantic and episodic memory

图 13: 讲者的三项收束：把不一致视为澄清标签与信息缺口的机会，并用两类记忆作为微调之外的更新路径。¹³

6.2 把全文压缩成四个责任层

前文的机制可以压缩为四个各自回答不同问题的责任层：

1. **分歧检测层**：回答“系统哪里缺少清晰度”。它比较跨运行或跨模型的实质结论，定位值得复核的灰区。
2. **情景先例层**：回答“过去怎样处理相似情况”。它优先自动处理条件一致、历史处置可信的复现案例。
3. **语义政策层**：回答“以后应遵循什么规则”。它把专家从多个案例中提炼出的领域知识和客户政策显式保存。
4. **人工治理层**：回答“谁决定规则、例外和风险边界”。它负责新颖案例、先例冲突、高风险动作和政策变更。

这四层形成完整因果链：结论反复暴露灰区，灰区触发高信息选样，先例检索吸收重复噪声，人工复核补齐新信息，语义规则把一次澄清扩展到未来案例，后续监测再验证规则是否有效。

6.3 实践含义：从试点到生产的落地清单

1. **先定义分歧**。明确哪些标签、字段或处置动作的变化属于语义差异，排除同义改写和格式波动。
2. **规定观测预算**。为不同风险等级设定重复运行次数、委员会规模和人工复核容量。
3. **分离两类存储**。情景案例库保存具体上下文与处置结果；语义政策库保存可概括规则、适用条件和例外。
4. **给记忆加治理元数据**。每条记录包含来源、客户边界、版本、有效期、审批者和可撤销状态。

¹³视频画面时间区间：00:23:42–00:24:38。

5. **保留人工升级条件。**新颖案例、相似度不足、先例冲突、规则冲突和高风险动作直接进入人工队列。
6. **使用多维评估。**同时测量一致性、正确性、覆盖率、人工复核量、严重漏报和客户政策符合度。
7. **建立回放与回滚。**政策更新后重放代表性案例；出现回归时能够定位并撤销具体规则或先例。

最低可行试点

一个小规模试点只需选择边界明确的单一任务，保留同一输入的多次运行结果，由专家复核分歧案例，并分别记录具体先例和可概括规则。试点成功标准应同时包含一致性改善、专家认可的正确性和可接受的复核成本。

6.4 风险界限与开放问题

这套方法仍留下若干需要实验和治理回答的问题：

- 委员会规模、采样温度和分歧阈值如何随任务风险变化？
- 情景检索如何识别处置条件差异，并防止历史错误被高频复用？
- 多个相似先例互相冲突时，应按时间、来源可信度还是专家等级决策？
- 语义规则如何检测过期，客户政策变化后如何安全回滚？
- 如何在提高一致性的同时证明正确性、安全性和少数高风险案例的召回率没有下降？
- 哪些反馈适合立即进入外部记忆，哪些反馈应积累为数据后再用于微调？

讲者经验的适用边界

“许多不一致源于标签或信息问题”是本演讲基于具体应用经验提出的诊断优先级，不能取代模型、提示、工具链和检索系统的故障排查。生产系统应记录分歧根因分类，并用证据决定修复路径。

6.5 本章小结

分歧本身不提供正确答案，却能指出最值得澄清的位置；情景记忆把历史人工判断变成可检索先例；语义记忆把澄清后的政策变成可复用规则；人工治理为价值冲突、高风险动作和例外保留最终责任。稳定的智能体来自可见的分歧、可追溯的先例、明确的政策和持续的人工治理。