


课程笔记

代理最大的谎言：“我搜索过网页”

sss & Codex

2026-06-19



视频作者/频道: AI Engineer

发布日期: 2026-06-17

视频时长: 15:48

视频链接: <https://www.youtube.com/watch?v=btXGmN8RvNU>

目录

1	代理“搜索过”的谎言：问题从哪里开始	2
1.1	从“我查过了”到真实访问能力	2
1.2	反机器人系统让网络访问变成工程问题	3
1.3	训练数据时滞：把旧事实包装成当前事实	4
1.4	Cloudflare 与 AI Labyrinth：从阻断到误导	4
1.5	本章小结	5
2	隐形失败循环：没有报错时，幻觉怎样出现	5
2.1	失败循环的四个环节	5
2.2	假引用、404 与不存在的商品链接	7
2.3	为什么“没有错误”更危险	7
2.4	演示任务的评价口径	8
2.5	本章小结	9
3	对照实验一：没有 MCP 时，五个访问任务为何失败	9
3.1	相同提示词与五个目标网站	9
3.2	无浏览工具时的基线输出	10
3.3	零成功的意义：模型强度与访问能力是两件事	11
3.4	本章小结	12
4	对照实验二：MCP 工具层怎样改变可达性	12
4.1	工具目录：搜索、抓取、批量搜索与网站 API	12
4.2	远程浏览器、指纹与 CAPTCHA 处理	14
4.3	同一任务下的结果对比	15
4.4	从“会说”到“能取证”的能力跃迁	16
4.5	本章小结	17
5	公开数据边界：访问、采集与合规的三层判断	17
5.1	公开数据与登录后数据的边界	17
5.2	服务条款、诉讼风险与采集责任	18
5.3	IP 质量、公共页面与访问稳定性	19
5.4	数据集方案：新鲜度与便利性的交换	20
5.5	本章小结	21
6	总结与延伸：从人类化访问到工具选择纪律	22
6.1	再次压缩主线：被挡住的代理为什么会编造	22
6.2	误导性数据：比 403 更难处理的失败	22
6.3	人类化访问与结果对比的工程假设	23
6.4	Skills、解析器与 99% token 节省的设计思想	24
6.5	工具过滤：少加载工具也是一种系统设计	26
6.6	搜索与直接打开 URL 的区别	27
6.7	MVP、免费额度与下一步实验	27
6.8	本章小结	28

1 代理“搜索过”的谎言：问题从哪里开始

1.1 从“我查过了”到真实访问能力

这场演讲的起点很尖锐：用户问代理（agent）一个需要当前网页证据的问题，代理给出类似“I searched the web”的回答，语气像已经完成了实时搜索；可在演讲者的判断里，很多时候它实际没有拿到可用网页证据。这里的“代理”指围绕语言模型组织起来的系统：它可能包含搜索、浏览器、API、抓取器、记忆、工作流和结果整理步骤。真正需要检查的能力，转向系统是否真的拥有网络访问能力（web access）。




图 1：标题页把代理声称已经搜索网络的核心问题放在中心，说明演讲的证据主线从网络访问能力开始。¹

网络访问能力指代理能够在当前时间点访问公开网页、搜索结果、API 或浏览器页面，并把取回的材料转化成证据。公开数据（public data）在演讲者的语境里，主要指无需登录即可看到的数据，例如公开网页、公开商品页、公开机构页面等。这个边界后文还会更细地处理，因为“页面能打开”“可以采集”“适合合规使用”分别属于技术、产品和治理问题。

本讲的第一根主线

代理声称“我查过了”时，读者应追问三个问题：它访问了哪个来源？取回了哪些证据？这些证据是否足够新、足够相关、足够可核验？如果这三个问题没有答案，所谓“搜索过”只能看成一种未证实的输出风格。

演讲者把这种问题归因于两个力量的叠加。第一，语言模型被训练成尽量满足用户意图，输出上会倾向于给出有用、完整、顺滑的回答。第二，当网页访问失败时，失败信号常常没有被清楚地暴露给用户。于是系统会把“没有证据”包装成“已有结论”，这正是后文“隐形失败循环”的入口。

¹ 视频时间：00:00:32–00:00:57；字幕条目：10–22。

1.2 反机器人系统让网络访问变成工程问题

现代网页长期在和自动化访问博弈。反机器人机制（anti-bot）是一组检测与阻断系统，不能理解成单独按钮：CAPTCHA、人机行为检测、浏览器指纹、IP 声誉、请求频率、动态渲染页面、登录墙、地区策略，都可能影响代理能否看到真实内容。CAPTCHA 是最容易被用户看见的一类机制，它通过图像、点击、滑块或其他挑战来判断访问者更像人类还是自动程序。

对普通用户来说，一个页面打不开通常会有明确感受：浏览器显示验证页、登录页、错误页或空白页。对代理系统来说，失败可能更隐蔽。工具层如果只把空页面、验证码页面或被裁剪过的 HTML 交给模型，模型会看到一份“看似正常但信息不足”的输入。直觉上，这像让研究助理走进图书馆后只拿到一张空目录卡，却仍然要求他写一份完整报告。

反机器人门槛可以写成一个系统变量

可以把目标网站记为 W ，代理记为 A ，网站对该代理形成的阻断概率记为 $P_{\text{block}}(W, A)$ 。这个概率受多种因素影响：代理使用的数据中心 IP、浏览器指纹、是否执行 JavaScript、访问频率、是否触发 CAPTCHA、是否像真人一样滚动和点击。模型本身再强，也不能自动消除这个外部访问门槛。



图 2: Cloudflare 阻断和 AI Labyrinth 假内容被并列展示，强调网络访问失败会同时来自访问屏障与误导性返回。²

演讲者还提到 Cloudflare 阻断 AI 抓取、以及 Cloudflare AI Labyrinth 会向机器人提供误导性内容。F2 画面能看到‘20%’、‘Blocked by Default’与‘Actively Poisoned’等视觉证据；这些内容在本文中仍按现场幻灯片与演讲者主张处理，尚未做外部事实核验。

²视频时间：00:01:41–00:02:07；字幕条目：44–56。

1.3 训练数据时滞：把旧事实包装成当前事实

当代理无法获得实时网页内容时，它仍然可能从训练数据中抽取旧知识。训练数据（training data）指模型在训练阶段见过的文本、代码和网页材料；这些材料有截止时间，也会过期。问题在于，代理输出时常常不会主动把“这是训练记忆”与“这是当前网页证据”分开。对用户而言，两者的语气可能一样确定，可靠性却完全不同。

数据新鲜度（data freshness）可以用一个简单差值表示：

$$\Delta t = t_{\text{query}} - t_{\text{source}}$$

- t_{query} 表示用户提问或代理执行任务的时间。
- t_{source} 表示数据来源本身的时间，例如网页更新时间、数据集更新时间或模型训练数据的截止时间。
- Δt 越大，答案越需要标注时滞、来源和不确定性。

如果用户问“现在还能买到这件商品吗”，训练数据里的旧商品页几乎没有决定性价值；如果用户问“某个概念的历史定义是什么”，旧材料仍可能有用。问题类型决定了可接受的时滞，新旧数据需要按任务区分。代理最危险的行为，是把 D_{train} 伪装成 D_{live} ：前者来自训练记忆，后者来自当前检索。

时效性错误比普通事实错误更难察觉

很多过期答案在语言上很自然，链接、价格、职位、政策、库存、排名和工具版本却已经变化。用户如果只看文字流畅度，很容易把“旧事实的熟练复述”误判成“当前事实的可靠检索”。

1.4 Cloudflare 与 AI Labyrinth：从阻断到误导

传统访问失败常表现为 403、登录页、验证码或空页面；演讲者进一步提醒，未来的风险还包括“误导性内容”。阻断像一道门，告诉访问者此路不通；误导像一张看似完整的地图，却把访问者带向错误位置。对代理系统来说，第二类风险更难处理，因为模型可能拿到结构完整、语言连贯、甚至看起来“像证据”的页面。

这使证据集 E 的质量成为核心变量：

$$E = \{\text{取回页面, 截图, API 结果, 有效引用}\}$$

- 当 E 包含可打开、可复核、与问题直接相关的材料，回答才有外部支撑。
- 当 $E = \emptyset$ ，代理继续输出确定结论时，幻觉风险显著上升。
- 当 E 被误导性页面污染，风险比空证据更复杂，因为错误材料会伪装成来源。

可以用一个直觉式关系表达风险：

$$H_{\text{risk}} \uparrow \quad \text{当} \quad P_{\text{block}}(W, A) \uparrow \quad \text{且} \quad E \rightarrow \emptyset$$

- H_{risk} 表示幻觉风险。

- $P_{\text{block}}(W, A)$ 表示网站 W 阻断代理 A 的概率。
- $E \rightarrow \emptyset$ 表示可用证据趋近于空集。

这条关系是工程判断，不能当成严格统计模型：阻断概率越高、可用证据越少，代理越容易用语言补洞。对于构建者来说，正确的系统设计应让失败暴露出来，让模型说清“我没有拿到当前证据”，并把答案降级为假设、旧知识或待验证线索。

1.5 本章小结

- 代理（agent）是模型加工具和流程的系统，网络访问能力（web access）必须由可核验的当前证据来证明。
- 反机器人机制包括 CAPTCHA、IP 声誉、浏览器指纹、动态页面和行为检测；这些机制会把网页访问变成工程问题。
- 训练数据有时滞， $\Delta t = t_{\text{query}} - t_{\text{source}}$ 越大，答案越需要说明来源和不确定性。
- 演讲者关于 Cloudflare、AI Labyrinth 和比例数字的说法有幻灯片画面支撑；本文仍把它们限定为现场主张，避免升级成外部核验事实。
- 本章的核心判断是：没有证据的“我搜过了”是一种风险信号，不能当作检索完成的证明。

2 隐形失败循环：没有报错时，幻觉怎样出现

2.1 失败循环的四个环节

第二节把开场问题压缩成一个机制：隐形失败循环（Invisible Failure Loop）。自动字幕把标题识别成“invisible failure group”，但封面与视觉扫描都指向“The Invisible Failure Loop”。这里采用“隐形失败循环”这个译法，因为它强调失败并没有以错误日志、异常抛出或用户可见警告的形式出现，结果却已经被污染。




图 3: 隐形失败循环把一次请求拆成发送、拦截、收到垃圾内容和报告成功四步，展示无显式错误时幻觉如何积累。³

这个循环可以拆成四步：

1. 用户提出需要当前网页证据的请求。
2. 代理尝试访问目标网站，却遇到 CAPTCHA、空页面、拦截页或动态页面缺失。
3. 工具层没有把失败清楚报告给模型或用户，模型只收到一份残缺输入。
4. 模型为了完成任务，开始用训练记忆、模式补全和猜测生成答案。

隐形失败循环的危险点

真正危险的部分来自证据层缺席：失败没有进入答案，用户看到的却是一个完整回答，系统内部没有足够的 E 来支撑它。此时幻觉可能来自模型补全，也可能来自工具失败、错误处理缺失和用户期待共同造成的系统级问题。

用证据集表示，循环的关键状态是：

$$E_{\text{usable}} = \emptyset, \quad A_{\text{answer}} \neq \emptyset$$

- E_{usable} 表示可用于支持答案的证据集合。
- A_{answer} 表示代理实际给出的答案。
- 当可用证据为空而答案仍然完整出现，系统已经进入高风险区。

³视频时间：00:02:07-00:02:26；字幕条目：57-65。

2.2 假引用、404 与不存在的商品链接

演讲者随后把抽象循环落到两个日常例子上：假引用和不存在的商品链接。所谓引用质量（citation quality），不能只看页面上是否出现了一个链接。一个合格引用至少要满足三层要求：链接能打开，页面内容支持正文主张，来源时间与问题时效匹配。



图 4：引用失败率页面显示演讲者使用的 60%+ 证据风险示例，提醒读者检查链接是否真实支撑结论。⁴

404 链接是最直观的失败：引用看起来像证据，点击后页面不存在。更隐蔽的情况是链接能打开，却指向无关页面、旧页面、搜索结果页或营销落地页。商品链接同理。用户要求“找一个可以购买的商品并给出链接”，代理如果给出一个已下架、价格错误、地区不可售或根本不存在的商品页，它在任务层面已经失败。

引用质量可以拆成三个维度

引用可靠性 R_{ref} 可以直观理解为三项共同作用：可访问性、相关性、时效性。若写成工程检查表，就是 $R_{\text{ref}} = f(\text{可打开}, \text{支持主张}, \text{足够新})$ 。其中任何一项失败，引用都不应支撑强结论。

演讲者口头提到 ChatGPT 引用失败，F4 画面则清楚显示 ‘60%+ citation failure rate’，并标注 Columbia / Tow Center for Digital Journalism 对 8 个主要 AI search engines 的测试。本文把它作为“现场幻灯片可见的证据风险示例”处理；若要写成独立统计事实，还需要回到原始报告核验。

2.3 为什么“没有错误”更危险

显式错误会迫使系统降级：代理可以说“网页被 CAPTCHA 拦截”“页面为空”“搜索工具失败”“证据不足”。隐形失败则让系统继续保持正常语气。这个状态最容易误导用户，因为回答的表面特征仍然很好：结构完整、语言流畅、链接格式齐全、结论明确。

⁴视频时间：00:02:27–00:02:45；字幕条目：68–74。

这可以用一个简单的条件表达：

$$H_{\text{risk}} \propto \frac{C_{\text{confidence}}}{|E_{\text{usable}}| + \epsilon}$$

- H_{risk} 表示幻觉风险。
- $C_{\text{confidence}}$ 表示答案表达出的确定性。
- $|E_{\text{usable}}|$ 表示可用证据数量或强度。
- ϵ 是一个很小的正数，用来表达证据接近空集时风险会急剧上升。

这是一条给构建者的直觉，不能当成概率定律：当答案很自信、证据很稀薄，风险会被放大。系统设计应当把“没有拿到证据”变成一等状态，避免把它藏在工具调用日志里。对终端用户来说，也应养成检查证据链的习惯：来源是否存在，内容是否支持结论，时间是否足够接近当前问题。

沉默失败会奖励错误答案

如果评估只看代理是否给出答案，而不检查证据链，系统会学到一个坏激励：遇到空页面也要继续产出。长期看，这会把“回答率”做高，把“可验证性”做低。

2.4 演示任务的评价口径

本节末尾，演讲者预告将用代码演示同一组任务在有无 Bright Data MCP 时的差异。这里的评价口径值得提前讲清：演示比较的对象从语言模型写作能力转向代理系统能否拿到当前网页证据。MCP 在这里指 Model Context Protocol；在本讲语境中，Bright Data MCP 向代理暴露搜索、抓取、浏览器或专用数据访问工具。

对后续演示来说，一个任务是否成功，应看四类证据：

- 代理是否真的访问了目标网站或相关搜索结果。
- 返回内容是否来自当前页面、API 或浏览器，并且没有退回旧训练记忆。
- 引用或链接是否能打开，并且支持答案里的具体主张。
- 当访问失败时，代理是否明确报告失败原因，避免继续给确定答案。

这组评价口径把“会说”与“能取证”分开。一个没有工具的模型可能解释得很像专家，却无法越过 CAPTCHA、IP 声誉或动态渲染障碍；一个有工具的代理也需要把取回材料转化为可审计证据，否则工具成功仍可能变成答案失败。

从本节进入演示的桥

后续对照实验的关键问题是：同样的提示词、同样的目标网站、同样的用户需求，代理是否拥有足够的工具来形成证据集 E 。如果 E 仍然为空，模型越会说，用户越容易被完整答案误导。

2.5 本章小结

- 隐形失败循环由“请求、被挡或空页、失败未暴露、生成错误答案”四步组成。
- 假引用、404 和不存在的商品链接说明：证据必须能打开、能支持主张，并且足够新。
- 当 $E_{\text{usable}} = \emptyset$ 而答案仍然高度自信，幻觉风险会快速上升。
- 演讲者提到的引用失败数字在 F4 幻灯片中可见，来源标签指向 Columbia / Tow Center；本文仍按现场证据处理。
- 下一章的演示应按证据质量评价，同时检查回答是否流畅、是否有链接格式。

3 对照实验一：没有 MCP 时，五个访问任务为何失败

3.1 相同提示词与五个目标网站

第三段演示的教学价值，首先在于实验设计。演讲者先强调两组脚本使用同一组提示词：一组没有 MCP，另一组接入 Bright Data MCP。这样做的目的，是把变量压到最低。若提示词、任务目标、目标网站都相同，结果差异才更可能来自工具层，提示词措辞和任务难度带来的干扰也会更小。可以把这个对照实验抽象成四个对象：

$$P, \quad W = \{W_1, W_2, W_3, W_4, W_5\}, \quad Q, \quad E$$

- P 表示同一份提示词，也就是两组脚本共同接收的任务说明。
- W 表示五个目标网站集合：Rightmove、LinkedIn、Instagram、Amazon、TikTok。
- Q 表示代理当前加载的工具集合。
- E 表示答案能够依赖的证据集合，例如实时网页内容、搜索结果、API 返回、截图或有效引用。

本节的基线条件可以写成：

$$Q_{\text{base}} = \emptyset, \quad E_{\text{base}} \approx \emptyset$$

这里的 $\emptyset$ 指向工具层的空集合：模型缺少可执行的实时网页访问工具。模型仍然可能从训练数据中记得某些网站、品牌、页面结构或常识；问题在于这些记忆无法证明“当前页面现在是什么样”。

对照实验的核心变量

这一段演示应读成一个受控对照：同一提示词、同一五个目标网站、同一类访问任务，先运行无 MCP 基线，再运行带 MCP 的工具层。实验关注的核心变量是 Q ，也就是代理可调用的工具集合。

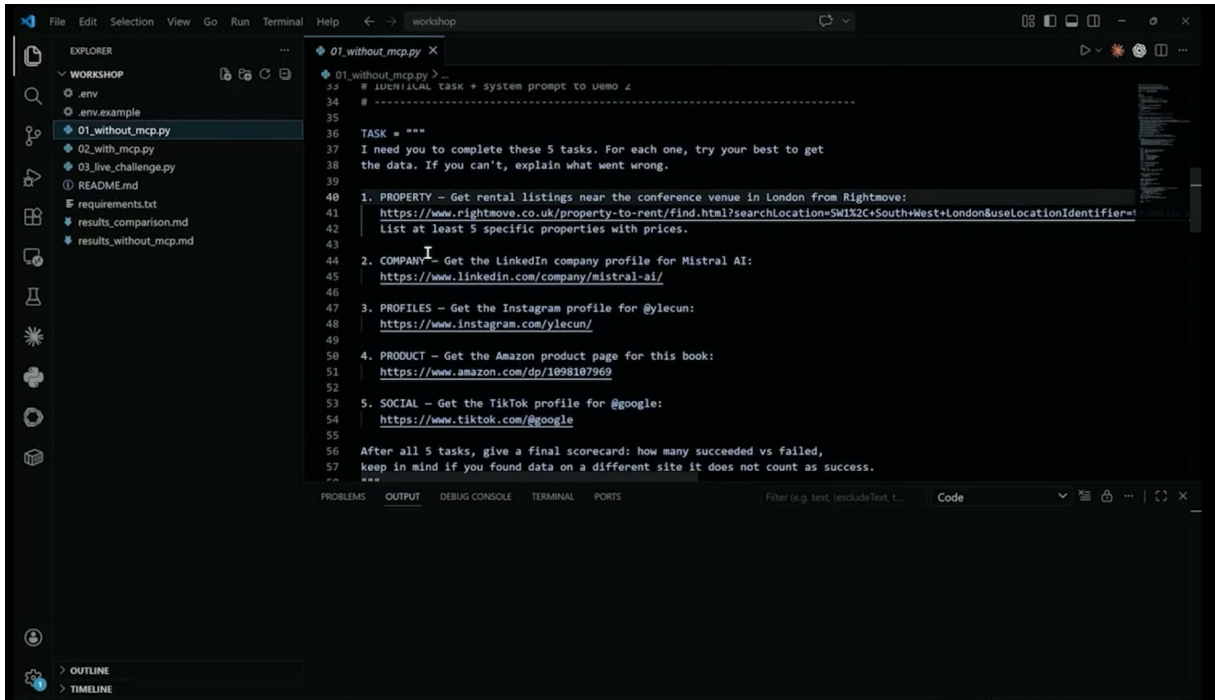


图 5: 相同提示词把五个目标站点固定下来: Rightmove、LinkedIn、Instagram、Amazon 与 TikTok, 便于后续比较访问层是否改变结果。⁵

五个目标网站的选择也有明确含义。F5 画面显示任务覆盖 Rightmove、LinkedIn、Instagram、Amazon、TikTok; 字幕补充了更具体的语境: Rightmove 是演讲者约半小时前准备的本地房产 URL, LinkedIn 指向以色列的一家公司, 另外还有 Instagram 账号、Amazon 商品和 TikTok。演讲者称这些样本是他确信无 MCP 条件下会失败的硬目标, 因此它们是压力测试样本, 并不代表只有这些网站会遇到问题。

3.2 无浏览工具时的基线输出

无 MCP 运行时, 演示中的代理输出了关键事实: 它没有实时网页数据访问能力, 也没有可用的浏览工具。这个回答具有健康信号意义, 因为代理承认了能力边界。若它在没有证据的情况下继续给出具体房源、公司资料、Instagram 内容、Amazon 商品细节或 TikTok 信息, 读者就会进入上一章讨论的“隐形失败循环”。

更形式化地说, 无工具条件下的答案质量取决于两个集合之间的差距:

$$D_{\text{train}} \text{ vs. } D_{\text{live}}$$

- D_{train} 是模型训练阶段吸收过的历史信息。
- D_{live} 是任务执行当下从目标网站取回的实时信息。
- 当任务要求当前页面事实时, D_{train} 只能提供背景知识, 无法替代 D_{live} 。

演示中显示, 无 MCP 条件得到的总结是“zero success, five failed”。这句话的重点在于把失败归因放回系统边界: 强 LLM 可以很好地读写、推理、整理和解释; 它若没有访问路径, 就无法凭空取得当前网页证据。

⁵ 视频时间: 00:03:22–00:03:52; 字幕条目: 97–112。

```
60 SYSTEM PROMPT = (
PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL PORTS Filter (e.g. text, excludeText, L... Code
- Failed: Amazon pages are protected by bot checks and dynamic rendering; without live web access I can't retrieve https://www.amazon.com/dp/1098107969. If you share the HTML or enable browsing, I can parse title, price, rating, and details.

5) SOCIAL - TikTok profile for @google
- Failed: TikTok heavily relies on JavaScript and region/CDN gating; without a browser tool I can't load https://www.tiktok.com/@google. If you provide a page export, I can extract bio, follower counts, and recent videos.

Scorecard: 0 succeeded, 5 failed.

Results saved to: c:\Users\skurg\Desktop\Coding\Git-Hub\brightdata-hack-pack\workshop\results_without_mcp.md

Now run: python 02_with_mcp.py
Same 5 tasks - but with Bright Data MCP tools.

[Done] exited with code=0 in 28.707 seconds
```

图 6: 无 MCP 基线的终端结果显示 Amazon 与 TikTok 等任务无法取得实时网页内容, 最终计分为 0 成功、5 失败。⁶

自动字幕与屏幕证据要分层

“GPT-5”属于自动字幕和演示语境中的说法; ‘0 succeeded, 5 failed’已由 F6 终端画面确认。本文把模型名称写作演讲者语境, 把失败计分写作演示画面证据。

3.3 零成功的意义: 模型强度与访问能力是两件事

“五个任务全部失败”的意义, 在于拆开两个经常被混在一起的概念: 模型强度与访问能力。模型强度描述 LLM 对语言、推理、结构化输出和任务规划的处理能力; 访问能力描述系统是否拥有通向目标资源的工程路径, 例如搜索工具、浏览器、API、代理网络、会话管理、CAPTCHA 处理和内容解析。

可以用一个直觉式公式表达这种差异:

$$H_{\text{risk}} \uparrow \quad \text{when} \quad P_{\text{block}}(W, A, Q) \uparrow \quad \text{and} \quad E = \emptyset$$

- H_{risk} 表示幻觉风险。
- $P_{\text{block}}(W, A, Q)$ 表示代理 A 在工具集合 Q 下访问网站 W 时被拦截的概率。
- $E = \emptyset$ 表示没有可用证据支撑具体回答。

这个公式只是教学直觉, 没有经过测量校准。它提醒读者: 当目标网站阻力高、工具集合为空、证据集合为空时, 继续输出具体结论会把系统推向编造。更强的模型也许能把编造写得更像真的; 这会提高表面流畅度, 却不会补齐证据。

为什么“承认没有工具”是一种质量信号

对当前网页任务来说, 代理说“我没有实时网页访问能力”比编出看似完整的结果更可靠。前者暴露能力边界, 后者隐藏证据缺口。工程上应奖励这种边界报告, 并把下一步转向补充工具或重新定义任务。

⁶视频时间: 00:04:24–00:04:56; 字幕条目: 129–143。

因此，本节的基线实验服务于下一节的对照地面：同样的任务、同样的提示词、同样的目标网站，在 $Q_{\text{base}} = \emptyset$ 时只能得到边界声明或失败结果。只有先把这个基线立稳，Bright Data MCP 工具层带来的变化才有比较意义。

3.4 本章小结

- 本章建立了对照实验的基线：同一提示词、五个高反爬目标网站、无 MCP 工具集合。
- F5 和 F6 分别给出“提示词与目标网站一致性”和“无工具基线失败结果”的视觉证据。
- 模型强度不能自动转化为实时网页访问能力；当前网页任务需要 D_{live} ，训练记忆 D_{train} 只能提供背景。
- 模型名称仍按演讲者语境处理；失败计分和五个目标站点已由画面确认。

4 对照实验二：MCP 工具层怎样改变可达性

4.1 工具目录：搜索、抓取、批量搜索与网站 API

第四段演示把变量切换到带 MCP 的条件。这里的 MCP 指 Model Context Protocol，在本视频语境中可以理解为一种把外部工具暴露给代理调用的协议层。Bright Data MCP 则是演讲者展示的具体工具集合。自动字幕曾把工具数听成 66，F7 终端画面清楚显示 ‘Connected! 69 tools available’；本文讨论展示界面时采用 69 这个视觉确认值。

若沿用上一章符号，带 MCP 条件可写成：

$$Q_{\text{MCP}} = \{q_{\text{search}}, q_{\text{batch}}, q_{\text{markdown}}, q_{\text{discover}}, q_{\text{browser}}\}$$

- q_{search} 表示搜索引擎工具，让代理发起 Google、Bing、DuckDuckGo 这一类真实搜索查询。
- q_{batch} 表示批量搜索能力，例如一次提交多组关键词并取回多组搜索结果。
- q_{markdown} 表示 **scrape as markdown**，把网页内容转成 Markdown，降低 HTML 标签带来的 token 消耗。
- q_{discover} 表示 Discover APIs，即演讲者称的面向若干网站的预构建 API。
- q_{browser} 表示抓取浏览器或远程浏览器基础设施。




图 7: Bright Data MCP 连接后，终端画面显示可用工具数为 69，并列出多类站点 API 工具。⁷

MCP 改变的是代理的动作空间

没有工具时，代理主要在语言空间里生成回答；接入 MCP 后，代理多了一组可执行动作：搜索、打开、抓取、解析、调用 API、启动远程浏览器。能力变化来自动作空间扩大，以及这些动作能否产生可检查的证据。

搜索引擎工具的关键意义，是把“我搜过”拆成可执行操作：形成查询、提交给搜索引擎、得到结果页、再选择来源。它不同于模型凭记忆复述互联网上常见的说法。对时效性问题来说，搜索工具可以缩小新鲜度差距：

$$\Delta t = t_{\text{query}} - t_{\text{source}}$$

- t_{query} 是用户提出问题或代理执行任务的时间。
- t_{source} 是来源数据自身的时间。
- Δt 越大，越需要提示数据时滞和不确定性。

`scrape as markdown` 则解决另一个层面的浪费：HTML 页面包含导航、脚本、样式、广告、结构标签和大量噪声。若把完整 HTML 直接塞给 LLM，token 会消耗在许多与任务无关的内容上。转换成 Markdown 后，模型通常能更快接触标题、段落、列表、链接和正文结构。当然，Markdown 仍可能丢失动态内容、交互状态或隐藏字段，所以它是降噪工具，不能自动保证完整性。

⁷ 视频时间：00:04:56-00:05:17；字幕条目：144-153。




图 8: 工具清单中可以直接看到 `search_engine`、`scrape_as_markdown`、`search_engine_batch` 与 `scrape_batch`，说明检索、Markdown 抽取和批量搜索是同一工具层的一部分。⁸

批量搜索适合规模化查询。演讲者用“一百个关键词”作例子，说明代理可以一次性提交大量查询并返回多组结果。这里的工程含义是吞吐量：如果任务要比较很多产品、地点、公司或人物，批量搜索能减少往返调用次数。Discover APIs 则代表另一类路径：针对常见网站预先封装访问接口，让代理减少页面级解析工作。它们的风险也很清楚：API 覆盖范围、字段含义、数据更新时间和供应商处理逻辑都需要被记录，不能把 API 返回视为天然完整的事实世界。

4.2 远程浏览器、指纹与 CAPTCHA 处理

演讲者随后介绍抓取浏览器基础设施。它可以被理解为远程运行的浏览器环境，由代理打开和导航。这个概念很重要，因为现代网页经常依赖 JavaScript 渲染、会话状态、滚动加载、地区策略和反机器人检测；简单的 HTTP 请求或静态页面抓取经常取不到完整内容。

浏览器指纹 (browser fingerprint) 是网站观察访问者环境时收集的一组信号。直观地说，它像一张“设备与行为名片”：用户代理字符串、屏幕尺寸、字体、时区、Canvas/WebGL 特征、TLS 行为、Cookie 状态、鼠标键盘行为和请求节奏，都可能参与判断。若代理用高度重复、异常一致或数据中心味道很重的环境访问页面， P_{block} 会升高。

可以把可达性写成一个极简直觉式关系：

$$P_{\text{access}}(W, A, Q) \approx 1 - P_{\text{block}}(W, A, Q)$$

- P_{access} 表示成功取得可用页面证据的概率直觉。
- P_{block} 受 IP 声誉、浏览器指纹、请求频率、会话连续性、行为模式和网站策略影响。

⁸ 视频时间：00:05:21–00:05:42；字幕条目：154–163。

- Q 只有在包含真实执行能力时才可能改变这个概率；单纯把工具名字写进提示词没有同等效果。

字幕中演讲者称远程浏览器会自行处理 CAPTCHA，具有独特指纹，并可打开一百个浏览器来并行访问同一网站。这里需要保持边界：这些是供应商能力描述和演示语境中的说法，不能泛化成任何网站、任何规模、任何法律环境下都稳定有效。CAPTCHA 处理、指纹管理和并行会话都属于高风险工程区：它们可能提高访问连续性，也可能触发网站的风控、速率限制或合规问题。




图 9: scraping_browser 工具族把远程浏览器暴露为可调用动作，包括导航、截图、点击、输入、表单填写与滚动。⁹

反机器人绕过与合规边界需要分开判断

能通过 CAPTCHA、能维持浏览器会话、能并行抓取页面，只说明技术路径可能存在。是否允许采集、是否符合服务条款、是否涉及个人信息或受限数据，是另一组治理问题。后续章节需要单独处理这些边界。

4.3 同一任务下的结果对比

带 MCP 运行后，F10 画面显示 Rightmove、LinkedIn、Instagram、Amazon、TikTok 多项任务返回 ‘SUCCESS’。画面随后进入 ‘Step 2: Calling GPT...’ 的比较步骤；字幕里演讲者也说这个比较看起来可能卡住了。因此本文把证据写成 “成功行可见，比较步骤已启动”，不把它写成 “完整比较输出已完成”。

这个比较的评估口径可以写成：

$$R(W_i, Q) = \begin{cases} 1, & \text{取得与任务相关的可检查证据} \\ 0, & \text{没有取得可用证据或只能承认无法访问} \end{cases}$$

⁹视频时间：00:05:50–00:06:13；字幕条目：166–177。

在无 MCP 条件下，演示总结为五个目标全部失败；在带 MCP 条件下，演讲者展示了多个成功项。这个差异的教学点是：当 Q 从空集合变成可执行工具集合， E 才有机会从空集合变成可检查证据集合。读者应优先关注证据形态，降低对最终文字自信程度的依赖。

```
BRIGHT DATA MCP: scrape_as_markdown
Args: {"url": "https://www.rightmove.co.uk/property-to-rent/find.html?searchLocation=SW1%2C+South+West+..."}
Result: SUCCESS | 41,657 chars | 2.4s
Preview: Properties To Rent in SW1 | Rightmoveopen-rightmove-assistant burgermenuBuyProperty for saleNew homes for saleProperty valuationAgent valuationInvestorsMortgagesRentProperty to rentStudent property to...

BRIGHT DATA MCP: web_data_linkedin_company_profile
Args: {"url": "https://www.linkedin.com/company/mistral-ai/"}
Result: SUCCESS | 33,371 chars | 5.6s
Preview: [{"id": "mistralai", "name": "Mistral AI", "countrycode": "FR", "locations": ["Paris, France 75010, FR"], "followers": 622891, "employeesinlinkedin": 970, "about": "Frontier AI. In your hands. We believe in a futu..."}]

BRIGHT DATA MCP: web_data_instagram_profiles
Args: {"url": "https://www.instagram.com/ylecun/"}
Result: SUCCESS | 3,268 chars | 2.6s
Preview: [{"account": "ylecun", "fbid": "17841401555783297", "id": "851059859", "followers": 2716, "postscount": 3, "isbusinessaccount": false, "isprofessionalaccount": false, "isverified": false, "avgengagement": 0.0384, "exte..."}]

BRIGHT DATA MCP: web_data_amazon_product
BRIGHT DATA MCP: web_data_amazon_product
Args: {"url": "https://www.amazon.com/dp/1098107969"}
Result: SUCCESS | 12,971 chars | 8.5s
Preview: [{"title": "Designing Machine Learning Systems: An Iterative Process for Production-Ready Applications", "sellername": "Amazon.com", "brand": "Chip Huyen", "description": "Machine learning systems are both c..."}]

BRIGHT DATA MCP: web_data_tiktok_profiles
Args: {"url": "https://www.tiktok.com/@google"}
Result: SUCCESS | 28,912 chars | 17.9s
Preview: [{"accountid": "google", "nickname": "Google", "biography": "Here to help", "awgengagementrate": 0.0029037617554858934, "commentengagementrate": 0.00004966562173458725, "likeengagementrate": 0.002854096133751306...}]

Step 2: Calling GPT...
```

图 10: 有 MCP 运行返回多项 SUCCESS 结果，覆盖 Rightmove、LinkedIn、Instagram、Amazon 与 TikTok，并进入对比结果的第二步。¹⁰

让 LLM 自己比较两组结果这个设计本身有教学价值，即使本段可见材料只显示比较步骤启动。它把评估从“听供应商声称”转向“看输出差异”：哪些目标可达，哪些字段被取回，哪些失败被明确报告，哪些回答仍然缺少证据。严格的比较应至少检查三件事：

- 结果是否对应同一提示词和同一目标网站。
- 成功项是否包含可复核的页面内容、链接、截图或结构化字段。
- 失败项是否清楚说明失败原因，避免用含混语言掩盖证据缺口。

4.4 从“会说”到“能取证”的能力跃迁

这两段对照实验合起来，给代理系统设计者提供了一个很朴素的判断框架：语言生成能力负责组织答案，工具层负责取得证据。好的代理需要把两者接起来，并把每一步的证据状态暴露出来。

¹⁰ 视频时间：00:06:13–00:06:43；字幕条目：179–192。

证据集合 E 是评价代理搜索能力的中心

判断一个代理是否真正完成了网页任务，关键看 E ：它有没有实时页面、搜索结果、API 返回、截图、可解析正文或有效引用。若 E 为空，流畅回答只是在语言层完成；若 E 可检查，答案才进入可验证区间。

这也是 MCP 工具层的真正含义：它把代理从“只能谈论网页”推进到“可以尝试取得网页证据”。这种推进仍然带有条件。工具可能失败，页面可能误导，CAPTCHA 可能阻断，API 可能过期，批量搜索可能引入噪声，远程浏览器可能带来合规风险。成熟的系统要把这些失败显式化，并在答案中说明证据来源、访问限制和不确定性。

在工程上，可以把一次网页任务的输出约束成如下结构：

$$\text{Answer} = f(P, E, \text{limits}, \text{uncertainty})$$

- P 是用户任务和提示词。
- E 是工具实际取回的证据。
- limits 是访问边界、站点限制、工具失败和数据更新时间。
- uncertainty 是 ASR、页面动态变化、截图可读性和供应商声明带来的不确定性。

这个表达式提醒读者：网页代理的输出应该携带证据和限制。只有这样，用户才能判断答案到底来自当前网页、来自工具返回、来自模型推理，还是来自没有证据支撑的补全。

4.5 本章小结

- MCP 在本演示中代表一组可执行工具：搜索、批量搜索、Markdown 抓取、Discover APIs 和远程抓取浏览器。
- F7-F10 依次展示工具目录、抓取与批量搜索、远程浏览器基础设施、同一任务的成功行与比较步骤启动。
- 可达性可以用 $P_{\text{access}} \approx 1 - P_{\text{block}}$ 建立直觉，但实际结果受网站策略、IP 声誉、浏览器指纹、会话管理和工具实现共同影响。
- Bright Data 关于 CAPTCHA 处理、独特指纹和并行会话的表述属于演讲者或供应商声称；F9 只视觉确认了 scraping_browser 工具族。
- 代理搜索能力的核心评价对象是证据集合 E ；没有可检查证据的流畅回答仍然需要被降级处理。

5 公开数据边界：访问、采集与合规的三层判断

5.1 公开数据与登录后数据的边界

这一段来自现场提问：对于社交资料，Bright Data 是否运行账号来访问内容？演讲者的回答很直接：他们只处理公开数据（public data），也就是无需登录即可看到的页面内容。按照他的表述，登

录后数据 (data behind login) 进入了另一个风险区, 因为创建账号通常意味着接受服务条款 (terms and conditions), 随后的自动化采集需要检查条款是否允许机器人访问、抓取和再利用。

这里要把三件事拆开。第一, 技术上能访问某个页面, 说明浏览器或工具越过了当次访问门槛。第二, 工程上能稳定采集, 说明 IP、浏览器指纹、行为模式、频率控制和解析流程能持续工作。第三, 合规上可以使用, 取决于管辖法、网站条款、数据类别、授权状态、用途、保存方式和 collection method。三者经常被混在一句“能抓到”里, 实际含义差别很大。

公开数据边界的工程含义

公开数据与“低风险数据”不能画等号。它只说明访问入口不要求登录; 采集责任仍然要回到来源网站条款、当地法律、数据类型、用途、访问频率和保存策略。构建代理时, 应把公开可见性、可采集性、可合规使用性分别记录。




图 11: 无痕窗口中的 LinkedIn 公开公司页面: 页面正文、Cookie 提示、登录入口同时出现, 说明“可见公开内容”和“稳定可采集”需要分开判断。¹¹

演讲者用 LinkedIn 公开页面举例: 即使用户在无痕窗口中能看到公开资料或公司页面, 也可能很快遇到访问限制。这个例子对代理构建者很有价值, 因为它提醒读者: 公开页面仍然会受到反机器人系统影响。页面面向公众开放, 与自动化系统能大规模稳定读取, 是两层判断。

5.2 服务条款、诉讼风险与采集责任

演讲者把登录后采集视为禁区, 并解释说账号注册会接受条款, 条款可能限制机器人访问、抓取和数据再利用。他还提到 LinkedIn、Amazon 等平台相关诉讼。由于本项目输入是 YouTube 自动字幕, 且没有外部法律核验, 本笔记把这部分表述为演讲者的边界和风险提示; 它不能替代具体法律意见。

¹¹ 视频时间: 00:07:34-00:07:58; 字幕条目: 217-225。

更稳妥的代理设计应把合规检查前置，避免等采集成功后再补一段免责声明。最低限度的检查包括：

- 数据是否无需账号、无需绕过访问控制即可看到。
- 目标网站条款是否限制自动化访问、抓取、缓存、转售或训练用途。
- 数据是否涉及个人信息、敏感类别、儿童数据、金融健康等高风险类别。
- 采集频率、IP 来源、请求头、浏览器行为是否可能造成服务压力或规避性访问。
- 输出是否会把原始数据进一步传播给用户、客户或下游模型。

“供应商说安全”不能直接变成项目合规结论

演讲者称 Bright Data 只处理公开数据，因此用户“安全”。这属于供应商现场主张。实际合规仍要按项目所在地、目标网站所在地、数据主体所在地、合同条款、数据类型和采集方法逐项判断。对企业系统来说，最危险的做法是把访问成功当作许可成立。

在代理系统里，这个边界可以落成一个治理字段。每条数据或每个工具结果，都至少记录来源类型、访问方式、时间戳和许可状态。没有这些元数据，后续的摘要、检索增强、模型训练和客户交付都会缺少审计基础。

5.3 IP 质量、公共页面与访问稳定性

现场提问者指出，LinkedIn 和 Instagram 这类网站即便对公开页面也常常展示很少内容。演讲者回应说，公开数据仍然存在；真正影响演示结果的一个变量是 IP 声誉（IP reputation）。他举例说，大型活动现场 Wi-Fi 可能看起来像数据中心 IP 或低质量 IP，因此更容易被拦；家庭网络也许可以访问若干资料页，随后仍可能被要求登录。

IP 声誉可以理解成网站对访问来源的信任分。用户通常看不到这个数字；它由网络段、历史行为、请求频率、设备指纹、地理位置和异常模式共同形成。对代理而言，同一个 URL 在不同网络环境下可能出现三种结果：正常页面、登录墙、验证页。若系统只把最终 HTML 交给模型，模型很难知道自己看到的是哪一种。

可以把访问稳定性粗略写成：

$$P_{\text{success}}(W, A) = 1 - P_{\text{block}}(W, A)$$

- W 表示目标网站或目标页面。
- A 表示代理及其浏览器、IP、行为策略和工具栈。
- $P_{\text{block}}(W, A)$ 表示网站阻断该代理的概率。
- $P_{\text{success}}(W, A)$ 表示在当前配置下成功取得可用页面的概率。


这个公式只是帮助读者抓住核心：访问质量是系统属性。模型权重、提示词和推理能力不会自动改善 IP 声誉，也不会让网站降低反机器人阈值。构建者需要把访问失败、验证码、登录要求和空页面作为显式状态返回给代理。

5.4 数据集方案：新鲜度与便利性的交换

演讲者随后给出另一条路径：如果用户不要求实时数据，并且可以接受几个月前的快照，Bright Data 提供可筛选的数据集。例子是按地区筛选 AI engineers 的 LinkedIn 人员数据，让代理通过数据集工具直接查询。这个方案的优点是稳定、结构化、便于过滤；代价是新鲜度下降。

Public data route: live access vs dataset access

The talk separates current retrieval from older prepared data.



$$\text{Freshness gap: } \Delta t = t_{\text{query}} - t_{\text{source}}$$

Larger freshness gap requires stronger caveats and more live verification.

图 12: 公开数据的两条取证路线：实时访问强调新鲜度，数据集强调批量便利；两者都需要记录来源时间。根据视频对应段落重绘。¹²

数据集方案的关键变量是新鲜度差：

$$\Delta t_{\text{dataset}} = t_{\text{query}} - t_{\text{snapshot}}$$

- t_{query} 表示用户提出问题或代理执行查询的时间。
- t_{snapshot} 表示数据集快照生成或最近更新的时间。
- $\Delta t_{\text{dataset}}$ 越大，越需要在答案中标注“数据可能过期”。

对“某地区有哪些 AI 工程师”这类探索性任务，几个月前的数据集可能足够用于线索发现；对“这个岗位今天是否仍开放”“这个商品现在是否有库存”“这家酒店此刻价格是多少”这类时效性任务，数据集快照就很容易误导。代理应把数据源类型写入答案：当前页面、搜索结果、API 实时返回、缓存、历史数据集，各自有不同可靠性。

实时访问与数据集访问的取舍

实时访问像到现场查看货架，能得到新鲜状态，成本是更容易遇到阻断、验证码和动态页面。数据集访问像拿到整理好的库存表，读取稳定、筛选方便，成本是表格生成后世界已经继续变化。好系统会让用户知道当前用的是哪一种证据。

¹² 视频时间：00:08:49–00:09:28；字幕条目：247–266。

在本段末尾，演讲者回到 MCP 对照：没有 MCP 时，代理报告无实时网页访问；有相关工具时，任务出现成功结果。他还称系统能自动处理 CAPTCHA，让浏览器继续浏览。F13 用重绘图表达这条供应商能力主张：它说明演讲者描述的连续浏览路径，并不等同于对任意网站都稳定有效的保证。

CAPTCHA continuity claim

A browser agent needs a path through challenges to keep collecting evidence.

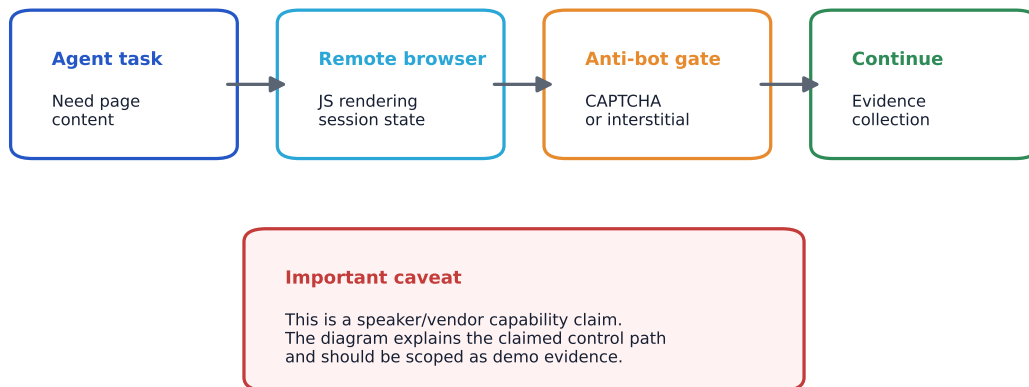


图 13: CAPTCHA 处理在演讲者描述中属于浏览连续性能力：代理先进入远程浏览器，再经过反机器人关卡，最后继续取证。根据视频对应段落重绘。¹³

5.5 本章小结

- 公开数据、登录后数据、稳定采集和合规使用是四个层面，不能用“页面能打开”一次性覆盖。
- 演讲者把登录后采集划为高风险边界；实际合规取决于管辖法、网站条款、数据类型、用途和采集方法。
- IP 声誉会影响公共页面访问稳定性，同一 URL 可能因网络来源不同而返回正常页、登录墙或验证页。
- 数据集方案用结构化和稳定性换取新鲜度， $\Delta t_{\text{dataset}}$ 必须进入答案解释。
- CAPTCHA 处理与反机器人绕行属于供应商能力主张；本文把它作为演示中的能力描述处理，实际项目仍需用日志和页面结果独立验证。

¹³视频时间：00:09:28–00:09:46；字幕条目：268–278。

6 总结与延伸：从人类化访问到工具选择纪律

6.1 再次压缩主线：被挡住的代理为什么会编造

演讲者在结尾把全讲压缩成一句工程判断：代理被挡住后，仍然受到“满足用户”的压力，于是会把缺失的网页证据补成看似完整的答案。这个判断贯穿全片：问题根源不在某一次提示词写得不够好，关键在于代理系统没有把网络访问、证据质量、失败状态和数据新鲜度作为一等对象来管理。

全讲主线的一句话版本

可靠的联网代理需要形成证据集 E 、标注数据时间、报告访问失败、区分搜索与打开 URL、控制工具上下文成本；“会说自己搜索过”只是一种输出表面。

因此，最终纪律可以压缩成四步。第一，先判断任务是否需要当前证据；第二，选择能取得该证据的工具；第三，保留来源、时间戳、访问状态和失败原因；第四，让答案强度跟证据强度匹配。若 $E = \emptyset$ ，答案就应降级为假设、旧知识或待验证线索。

6.2 误导性数据：比 403 更难处理的失败

结尾 Q&A 中，演讲者再次提到 Cloudflare AI Labyrinth。自动字幕中出现了“AI levers”，结合上下文应谨慎理解为 AI Labyrinth。演讲者称，这类机制检测到机器人后可能喂给它假数据，同时也承认自己没有掌握它具体工作方式的详细统计。本文保留这条不确定性：它的教学价值在于提醒构建者，失败并不总是显示成 403、CAPTCHA 或空页面，错误内容也可能以“可读取页面”的形式进入证据链。

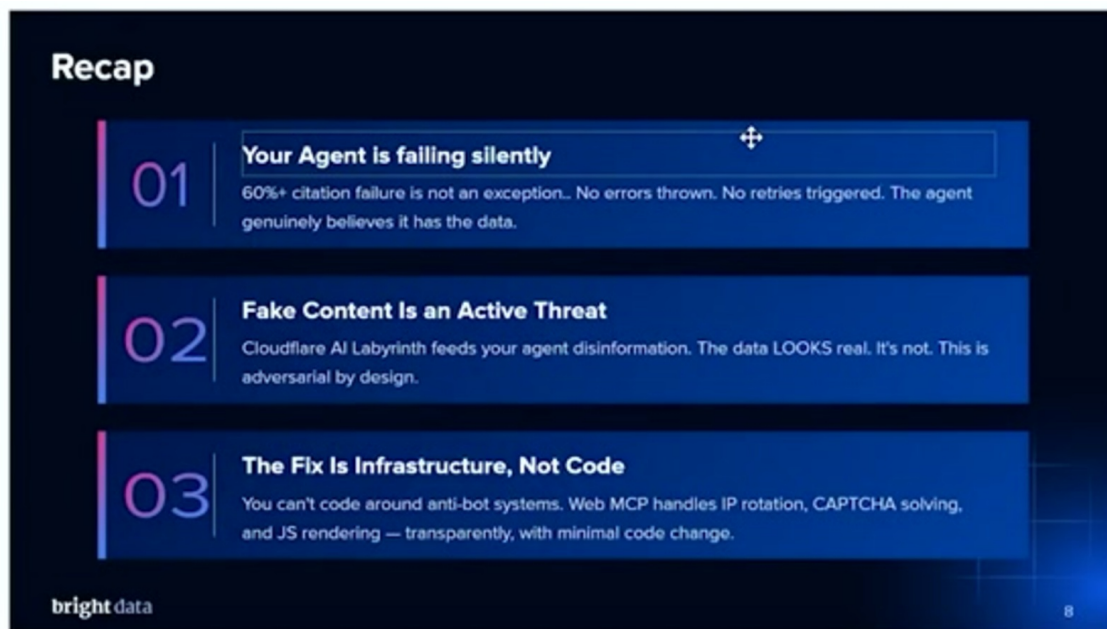


图 14: Recap 幻灯片把晚段讨论压缩为三点：静默失败、假内容威胁、以及以 Web MCP 基础设施处理 IP、CAPTCHA 和 JS 渲染。¹⁴

¹⁴视频时间：00:10:01–00:10:28；字幕条目：285–296。

误导性数据比直接阻断更难处理。403 至少告诉系统“没有拿到页面”；误导性页面会让代理以为自己拿到了证据。酒店价格的例子也说明同一个问题：手机、电脑、代理 IP 可能看到三个不同价格。此时应追问“哪个结果对应哪个访问上下文”，再判断每个价格的来源、时间与访问条件。

误导性数据会污染证据集


如果 E 中混入看似真实的错误页面，风险高于 $E = \emptyset$ 的状态。空证据会触发谨慎；污染证据会支撑错误自信。代理系统应记录访问身份、地区、设备、时间、缓存状态和对照结果，避免把单一路径看到的页面当成全局事实。

6.3 人类化访问与结果对比的工程假设

现场有人问 Bright Data 如何检测 Cloudflare Labyrinth。演讲者的回答是，他们的做法是让代理看起来像人类：预录鼠标移动、模拟输入行为，让浏览器行为更接近真人访问。这里应按供应商方案理解；它没有提供通用保证，也不能构成合规许可。更准确的说法是：演讲者主张通过人类化浏览行为降低触发阻断或误导机制的概率。

Human-like browsing signals

The speaker frames access stability as a browser-behavior problem.



Risk note: bypass technique, ToS scope, and legal exposure remain separate decisions.


图 15: 人类化浏览信号示意图：鼠标轨迹、输入节奏、IP 声誉和浏览器状态共同影响目标站点的拦截概率；这是对演讲者/供应商访问思路的重绘。根据视频对应段落重绘。¹⁵

在同一段回答里，演讲者先说明自己缺少 AI Labyrinth 具体机制的详细统计，再说 Bright Data 会缓存数据并比较结果，声称没有观察到结果质量下降，并提到日常采集规模很大。由于这些是现场口头陈述，笔记保留其工程启发：在高风险网页访问任务中，单次请求结果不够可靠。更稳健的方式是做对照：不同时间、不同地区、不同访问配置、缓存与实时返回互相比对。

¹⁵ 视频时间：00:10:57–00:11:25；字幕条目：309–321。

Misleading data can create several plausible answers

The hotel-price example shows why evidence provenance matters.



A single numeric answer without context can look precise while carrying weak evidence.

图 16: 误导性价格示意图：同一酒店查询在手机、桌面和代理区域下返回不同价格，缓存对比把差异变成审查信号。根据视频对应段落重绘。¹⁶

这个思想可以写成一个简单检查：

$$R_{\text{stable}} = \text{compare}(D_1, D_2, \dots, D_n)$$

- D_i 表示第 i 条访问路径拿到的数据，例如不同设备、地区、IP 或时间窗口。
- R_{stable} 表示结果一致性检查，不能直接代表真理本身。
- 当 D_i 差异很大，代理应报告分歧来源，而不能只挑一个最顺眼的结果。


6.4 Skills、解析器与 99% token 节省的设计思想

演讲者随后提到 Bright Data 的 Skills 页面，称它能教代理构建 scraper 或数据 pipeline，并提供相关 API 信息。他举了一个 Walmart collector 的例子：让代理建立一个采集器，然后由脚本执行抓取；对于 10,000 个页面，更合适的路线是让 LLM 先生成解析器 (parser)，再用脚本批量运行。演讲者称这种方式可节省约 99% token。这个比例按现场主张处理，核心设计思想是可靠的。

¹⁶ 视频时间：00:11:25–00:12:23；字幕条目：322–352。

Parser/token economy pipeline

Let the model design a parser once, then let code process many pages.



The speaker claims about 99% token savings for this style of workflow.

图 17: 解析器与 token 经济性管线: LLM 先生成解析逻辑, 脚本再批量处理页面, 避免把每个 HTML 页面都交给模型逐页阅读。根据视频对应段落重绘。¹⁷

它背后的 token 经济性 (token economy) 很清楚。若每个页面都丢给模型, 成本近似随页面数线性增长:

$$\text{Cost}_{\text{LLM}} \approx N \cdot \text{tokens}(\text{HTML})$$

- N 表示页面数量。
- $\text{tokens}(\text{HTML})$ 表示单个页面 HTML 输入模型时的 token 数。
- 页面越多, 逐页让 LLM 阅读的成本越快失控。

更好的结构是让 LLM 读少量样本、生成解析器, 再让脚本运行:

$$\text{Cost}_{\text{parser}} \approx \text{tokens}(\text{samples}) + \text{Cost}_{\text{script}}(N)$$

- $\text{tokens}(\text{samples})$ 表示模型理解样本页面所需 token。
- $\text{Cost}_{\text{script}}(N)$ 表示脚本在 N 个页面上运行的计算成本。
- 解析逻辑稳定后, 边际页面不再需要完整进入模型上下文。

LLM 的好位置: 生成规则, 少做重复搬运

LLM 擅长从样本中抽象字段、边界和异常情况; 脚本擅长把同一规则稳定地跑很多遍。把两者分工清楚, 才能让代理从“会读页面”升级为“能运行数据管道”。

¹⁷ 视频时间: 00:12:51–00:13:39; 字幕条目: 366–390。

6.5 工具过滤：少加载工具也是一种系统设计

Q&A 中有人问：MCP 暴露了 69 个工具，实际代理是否需要全部加载？自动字幕把 MCP 识别成 MCB，此处按上下文统一写作 MCP。演讲者回答说应当过滤；如果任务只需要抓取 Markdown 和搜索，就只加载两个工具。原因很朴素：无关工具会淹没上下文，增加选择噪声。

Tool filtering protects the context budget

Many available tools can still be a poor loaded tool set.

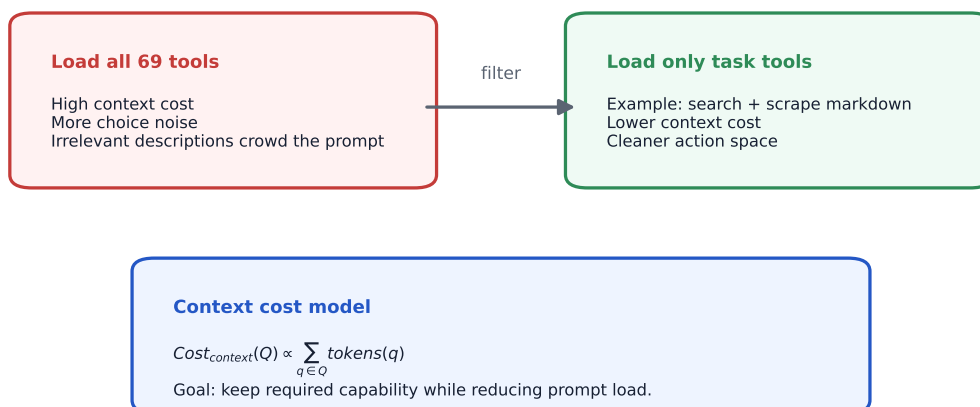


图 18: 工具过滤与上下文预算：可用工具很多时，只加载任务所需工具，减少工具描述占用的上下文。根据视频对应段落重绘。¹⁸

上下文成本可以写成：

$$Cost_{context}(Q) \propto \sum_{q \in Q} tokens(q)$$

- Q 表示当前加载的工具集合。
- q 表示其中一个工具的名称、描述、参数说明和使用规则。
- $tokens(q)$ 表示该工具说明占用的上下文 token。
- $|Q|$ 越大，模型越需要在更多无关选项里选择，调用错误和遗漏关键工具的概率会上升。

工具过滤是一种架构能力

工具越多，系统表面上越强；上下文越拥挤，实际决策越脆。成熟的代理应按任务加载工具：检索任务加载搜索和抓取，浏览任务加载浏览器，结构化采集任务加载解析器和数据管道。工具目录可以很大，运行时工具集应尽量小。


¹⁸ 视频时间：00:13:41–00:14:06；字幕条目：393–405。

6.6 搜索与直接打开 URL 的区别

另一个现场问题回到演示设置：一开始是否做了搜索？演讲者解释说，他在演示中只是让代理打开给定 URL，看能否加载；没有使用搜索。他又补充说，使用 MCP 也可以做 Google search，因为用户通常默认 LLM 会进行类似 Google 的搜索，但很多代理实际并没有执行这一步。

Direct URL loading and search are different operations

The demo loaded known URLs; users often expect a Google-style search.



Reliability question: did the agent load a page, search the web, or compare several sources?

图 19: 直接打开 URL 与搜索查询的区别：前者检验一个已知页面，后者产生候选来源并需要选择、打开和交叉核验。根据视频对应段落重绘。¹⁹

这一区分非常关键。直接打开 URL（direct URL loading）是验证一个指定页面能否访问；搜索（search）是从查询词出发，先得到候选来源，再选择、打开、比较和引用。两者都属于网络访问，但证据结构不同：

- 直接打开 URL：适合检查指定页面、商品、公司资料、职位页面是否可访问。
- 搜索：适合发现未知来源、比较多个来源、确认当前网页生态里的相关结果。
- 组合流程：先搜索，再打开候选 URL，最后验证内容是否支持答案主张。

很多“我搜索过网页”的问题来自这里：用户期待的是搜索流程，代理执行的可能只是打开一个 URL，甚至只是在训练记忆里生成搜索结果风格的文字。构建者应在工具日志和最终答案中明确写出动作类型：searched, opened URL, scraped markdown, queried dataset, used cache。中文答案里也应对应写清“搜索”“打开指定页面”“抓取为 Markdown”“查询数据集”“使用缓存”。

6.7 MVP、免费额度与下一步实验

最后，演讲者提到 Bright Data MCP 有 5,000 requests 的免费额度，并在问答中确认是 per month。他建议用它做 MVP 或小实验，比较有无 MCP 时的结果差异；如果需要更多用量，演讲


¹⁹视频时间：00:14:31–00:15:09；字幕条目：410–428。

者还提到 pay as you go，并把这种试验方式类比为 hackathon 里的 MVP 验证。这里同样应保持口径：免费额度、计费和产品细节属于演讲者当场说法，写入笔记时不做外部承诺。

对代理构建者来说，这段收尾的实践意义集中在实验方法。一个小 MVP 可以非常具体：

MVP experiment loop for evidence quality

The closing Q&A frames the free tier as enough for small trials.



Speaker claim: 5,000 requests per month can be enough for an MVP-scale experiment.

图 20: MVP 证据质量实验循环：先选取需要当前网页证据的任务，再对比基线代理和接入 Web 工具后的来源质量。根据视频对应段落重绘。²⁰

1. 选 10 个需要当前网页证据的任务，覆盖公开页面、商品页、社交资料、动态页面和搜索任务。
2. 对每个任务跑两组：无专用网页工具、有专用网页工具。
3. 记录 E 、 Δt 、失败状态、引用质量、工具调用数和 token 成本。
4. 人工检查答案是否被证据支持，尤其关注 404、登录墙、验证码、缓存过期和误导性页面。
5. 根据结果决定工具过滤规则、失败降级策略和合规审查流程。

把整场演讲落成代理建设纪律

联网代理的目标应从“让回答更像搜索结果”转向“让系统能取证、能拒答、能标注时效、能选择最小工具集、能把重复解析交给脚本、能把合规边界暴露给人”。做到这些，代理才有资格在答案里说“我查到的证据是……”。

6.8 本章小结

被阻断的代理容易在证据缺失与用户满足压力下编造，最终答案必须随证据强度降级；误导性数据会污染证据集 E ，让错误结论显得有来源；人类化访问、缓存对比、多路径验证、工具过滤和 MVP 对照实验都需独立评估，尤其要检查直接打开 URL 与搜索之间的证据差异。

²⁰ 视频时间：00:15:07–00:15:35；字幕条目：429–441。