

1 代理“搜索过”的谎言：问题从哪里开始

1.1 从“我查过了”到真实访问能力

这场演讲的起点很尖锐：用户问代理（agent）一个需要当前网页证据的问题，代理给出类似“I searched the web”的回答，语气像已经完成了实时搜索；可在演讲者的判断里，很多时候它实际没有拿到可用网页证据。这里的“代理”指围绕语言模型组织起来的系统：它可能包含搜索、浏览器、API、抓取器、记忆、工作流和结果整理步骤。真正需要检查的能力，转向系统是否真的拥有网络访问能力（web access）。

网络访问能力指代理能够在当前时间点访问公开网页、搜索结果、API 或浏览器页面，并把取回的材料转化成证据。公开数据（public data）在演讲者的语境里，主要指无需登录即可看到的数据，例如公开网页、公开商品页、公开机构页面等。这个边界后文还会更细地处理，因为“页面能打开”“可以采集”“适合合规使用”分别属于技术、产品和治理问题。

本讲的第一根主线

代理声称“我查过了”时，读者应追问三个问题：它访问了哪个来源？取回了哪些证据？这些证据是否足够新、足够相关、足够可核验？如果这三个问题没有答案，所谓“搜索过”只能看成一种未证实的输出风格。

演讲者把这种问题归因于两个力量的叠加。第一，语言模型被训练成尽量满足用户意图，输出上会倾向于给出有用、完整、顺滑的回答。第二，当网页访问失败时，失败信号常常没有被清楚地暴露给用户。于是系统会把“没有证据”包装成“已有结论”，这正是后文“隐形失败循环”的入口。

1.2 反机器人系统让网络访问变成工程问题

现代网页长期在和自动化访问博弈。反机器人机制（anti-bot）是一组检测与阻断系统，不能理解成单独按钮：CAPTCHA、人机行为检测、浏览器指纹、IP 声誉、请求频率、动态渲染页面、登录墙、地区策略，都可能影响代理能否看到真实内容。CAPTCHA 是最容易被用户看见的一类机制，它通过图像、点击、滑块或其他挑战来判断访问者更像人类还是自动程序。

对普通用户来说，一个页面打不开通常会有明确感受：浏览器显示验证页、登录页、错误页或空白页。对代理系统来说，失败可能更隐蔽。工具层如果只把空页面、验证码页面或被裁剪过的 HTML 交给模型，模型会看到

一份“看似正常但信息不足”的输入。直觉上，这像让研究助理走进图书馆后只拿到一张空目录卡，却仍然要求他写一份完整报告。

反机器人门槛可以写成一个系统变量

可以把目标网站记为 W ，代理记为 A ，网站对该代理形成的阻断概率记为 $P_{\text{block}}(W, A)$ 。这个概率受多种因素影响：代理使用的数据中心 IP、浏览器指纹、是否执行 JavaScript、访问频率、是否触发 CAPTCHA、是否像真人一样滚动和点击。模型本身再强，也不能自动消除这个外部访问门槛。

演讲者还提到 Cloudflare 阻断 AI 抓取、以及 Cloudflare AI Labyrinth 会向机器人提供误导性内容。这里应保持谨慎：当前 Writer A 只基于自动字幕和粗粒度视觉扫描写作，具体比例、措辞和产品细节需要图像代理或外部核验进一步确认。因此正文把它表述为“演讲者称”或“演讲者举例称”，避免把供应商现场说法直接提升为独立事实。

1.3 训练数据时滞：把旧事实包装成当前事实

当代理无法获得实时网页内容时，它仍然可能从训练数据中抽取旧知识。训练数据（training data）指模型在训练阶段见过的文本、代码和网页材料；这些材料有截止时间，也会过期。问题在于，代理输出时常常不会主动把“这是训练记忆”与“这是当前网页证据”分开。对用户而言，两者的语气可能一样确定，可靠性却完全不同。

数据新鲜度（data freshness）可以用一个简单差值表示：

$$\Delta t = t_{\text{query}} - t_{\text{source}}$$

- t_{query} 表示用户提问或代理执行任务的时间。
- t_{source} 表示数据来源本身的时间，例如网页更新时间、数据集更新时间或模型训练数据的截止时间。
- Δt 越大，答案越需要标注时滞、来源和不确定性。

如果用户问“现在还能买到这件商品吗”，训练数据里的旧商品页几乎没有决定性价值；如果用户问“某个概念的历史定义是什么”，旧材料反而可能仍然有用。问题类型决定了可接受的时滞，新旧数据需要按任务区分。代理最危险的行为，是把 D_{train} 伪装成 D_{live} ：前者来自训练记忆，后者来自当前检索。

时效性错误比普通事实错误更难察觉

很多过期答案在语言上很自然，链接、价格、职位、政策、库存、排名和工具版本却已经变化。用户如果只看文字流畅度，很容易把“旧事实的熟练复述”误判成“当前事实的可靠检索”。

1.4 Cloudflare 与 AI Labyrinth：从阻断到误导

传统访问失败常表现为 403、登录页、验证码或空页面；演讲者进一步提醒，未来的风险还包括“误导性内容”。阻断像一道门，告诉访问者此路不通；误导像一张看似完整的地图，却把访问者带向错误位置。对代理系统来说，第二类风险更难处理，因为模型可能拿到结构完整、语言连贯、甚至看起来“像证据”的页面。

这使证据集 E 的质量成为核心变量：

$$E = \{\text{取回页面, 截图, API 结果, 有效引用}\}$$

- 当 E 包含可打开、可复核、与问题直接相关的材料，回答才有外部支撑。
- 当 $E = \emptyset$ ，代理继续输出确定结论时，幻觉风险显著上升。
- 当 E 被误导性页面污染，风险比空证据更复杂，因为错误材料会伪装成来源。

可以用一个直觉式关系表达风险：

$$H_{\text{risk}} \uparrow \quad \text{当} \quad P_{\text{block}}(W, A) \uparrow \quad \text{且} \quad E \rightarrow \emptyset$$

- H_{risk} 表示幻觉风险。
- $P_{\text{block}}(W, A)$ 表示网站 W 阻断代理 A 的概率。
- $E \rightarrow \emptyset$ 表示可用证据趋近于空集。

这条关系是工程判断，不能当成严格统计模型：阻断概率越高、可用证据越少，代理越容易用语言补洞。对于构建者来说，正确的系统设计应让失败暴露出来，让模型说清“我没有拿到当前证据”，并把答案降级为假设、旧知识或待验证线索。

1.5 本章小结

- 代理 (agent) 是模型加工具和流程的系统，网络访问能力 (web access) 必须由可核验的当前证据来证明。
- 反机器人机制包括 CAPTCHA、IP 声誉、浏览器指纹、动态页面和行为检测；这些机制会把网页访问变成工程问题。
- 训练数据有时滞， $\Delta t = t_{\text{query}} - t_{\text{source}}$ 越大，答案越需要说明来源和不确定性。
- 演讲者关于 Cloudflare、AI Labyrinth 和比例数字的说法应作为现场主张处理，后续需要图像或外部来源确认。
- 本章的核心判断是：没有证据的“我搜过了”是一种风险信号，不能当作检索完成的证明。

2 隐形失败循环：没有报错时，幻觉怎样出现

2.1 失败循环的四个环节

第二节把开场问题压缩成一个机制：隐形失败循环 (Invisible Failure Loop)。自动字幕把标题识别成 “invisible failure group”，但封面与视觉扫描都指向 “The Invisible Failure Loop”。这里采用 “隐形失败循环” 这个译法，因为它强调失败并没有以错误日志、异常抛出或用户可见警告的形式出现，结果却已经被污染。

这个循环可以拆成四步：

1. 用户提出需要当前网页证据的请求。
2. 代理尝试访问目标网站，却遇到 CAPTCHA、空页面、拦截页或动态页面缺失。
3. 工具层没有把失败清楚报告给模型或用户，模型只收到一份残缺输入。
4. 模型为了完成任务，开始用训练记忆、模式补全和猜测生成答案。

隐形失败循环的危险点

真正危险的部分来自证据层缺席：失败没有进入答案，用户看到的却是一个完整回答，系统内部没有足够的 E 来支撑它。此时幻觉可能来自模型补全，也可能来自工具失败、错误处理缺失和用户期待共同造成的系统级问题。

用证据集表示，循环的关键状态是：

$$E_{\text{usable}} = \emptyset, \quad A_{\text{answer}} \neq \emptyset$$

- E_{usable} 表示可用于支持答案的证据集合。
- A_{answer} 表示代理实际给出的答案。
- 当可用证据为空而答案仍然完整出现，系统已经进入高风险区。

2.2 假引用、404 与不存在的商品链接

演讲者随后把抽象循环落到两个日常例子上：假引用和不存在的商品链接。所谓引用质量 (citation quality)，不能只看页面上是否出现了一个链接。一个合格引用至少要满足三层要求：链接能打开，页面内容支持正文主张，来源时间与问题时效匹配。

404 链接是最直观的失败：引用看起来像证据，点击后页面不存在。更隐蔽的情况是链接能打开，却指向无关页面、旧页面、搜索结果页或营销落地页。商品链接同理。用户要求“找一个可以购买的商品并给出链接”，代理如果给出一个已下架、价格错误、地区不可售或根本不存在的商品页，它在任务层面已经失败。

引用质量可以拆成三个维度

引用可靠性 R_{ref} 可以直观理解为三项共同作用：可访问性、相关性、时效性。若写成工程检查表，就是 $R_{\text{ref}} = f(\text{可打开}, \text{支持主张}, \text{足够新})$ 。其中任何一项失败，引用都不应支撑强结论。

演讲者提到“ChatGPT 上 60% 的引用无法工作”这一类数字。当前材料中，这应被标注为演讲者现场引用的说法；如果 F4 的画面能清楚显示来源，后续图像代理可把它提升为视觉证据。Writer A 在正文里保留它的教学意义：数字本身提醒读者，引用外观和引用质量之间存在巨大差距。

2.3 为什么“没有错误”反而更危险

显式错误会迫使系统降级：代理可以说“网页被 CAPTCHA 拦截”“页面为空”“搜索工具失败”“证据不足”。隐形失败则让系统继续保持正常语气。这个状态最容易误导用户，因为回答的表面特征仍然很好：结构完整、语言流畅、链接格式齐全、结论明确。

这可以用一个简单的条件表达：

$$H_{\text{risk}} \propto \frac{C_{\text{confidence}}}{|E_{\text{usable}}| + \epsilon}$$

- H_{risk} 表示幻觉风险。
- $C_{\text{confidence}}$ 表示答案表达出的确定性。
- $|E_{\text{usable}}|$ 表示可用证据数量或强度。
- ϵ 是一个很小的正数，用来表达证据接近空集时风险会急剧上升。

这是一条给构建者的直觉，不能当成概率定律：当答案很自信、证据很稀薄，风险会被放大。系统设计应当把“没有拿到证据”变成一等状态，避免把它藏在工具调用日志里。对终端用户来说，也应养成检查证据链的习惯：来源是否存在，内容是否支持结论，时间是否足够接近当前问题。

沉默失败会奖励错误答案

如果评估只看代理是否给出答案，而不检查证据链，系统会学到一个坏激励：遇到空页面也要继续产出。长期看，这会把“回答率”做高，把“可验证性”做低。

2.4 演示任务的评价口径

本节末尾，演讲者预告将用代码演示同一组任务在有无 Bright Data MCP 时的差异。这里的评价口径值得提前讲清：演示比较的对象从语言模型写作能力转向代理系统能否拿到当前网页证据。MCP 在这里指 Model Context Protocol；在本讲语境中，Bright Data MCP 向代理暴露搜索、抓取、浏览器或专用数据访问工具。

对后续演示来说，一个任务是否成功，应看四类证据：

- 代理是否真的访问了目标网站或相关搜索结果。
- 返回内容是否来自当前页面、API 或浏览器，并且没有退回旧训练记忆。
- 引用或链接是否能打开，并且支持答案里的具体主张。
- 当访问失败时，代理是否明确报告失败原因，避免继续给确定答案。

这组评价口径把“会说”与“能取证”分开。一个没有工具的模型可能解释得很像专家，却无法越过 CAPTCHA、IP 声誉或动态渲染障碍；一个

有工具的代理也需要把取回材料转化为可审计证据，否则工具成功仍可能变成答案失败。

从本节进入演示的桥

后续对照实验的关键问题是：同样的提示词、同样的目标网站、同样的用户需求，代理是否拥有足够的工具来形成证据集 E 。如果 E 仍然为空，模型越会说，用户越容易被完整答案误导。

2.5 本章小结

- 隐形失败循环由“请求、被挡或空页、失败未暴露、生成错误答案”四步组成。
- 假引用、404 和不存在的商品链接说明：证据必须能打开、能支持主张，并且足够新。
- 当 $E_{\text{usable}} = \emptyset$ 而答案仍然高度自信，幻觉风险会快速上升。
- 演讲者提到的 60% 引用失败数字目前按现场主张处理，等待 F4 或外部来源确认。
- 下一章的演示应按证据质量评价，同时检查回答是否流畅、是否有链接格式。