



微调数据攻击

当数据集成为模型行为的后门入口

HackProve World 2026 白帽世界大会：中国·澳门

主题 07 02:06:20–02:35:12

目录

1	一句话总览	3
2	本讲的安全边界	3
3	先把术语钉牢	3
3.1	prompt injection: 把外部文本伪装成模型指令	3
3.2	微调: 用较小数据集改变模型偏好	4
3.3	数据投毒: 把恶意样本塞进学习材料	4
3.4	$L(\theta)$: 训练为何会放大毒样本	4
3.5	ASR: 攻击是否真的成功	4
4	从 prompt injection 到构建阶段攻击	5
5	标签攻击: 模型先从标注开始偏	5
5.1	标签是训练里的方向盘	5
5.2	触发词: 小信号, 大分叉	6
5.3	边界样本: 让模型在灰区失准	6
6	预训练投毒: 大语料里的慢性污染	6
7	微调投毒: 小数据集里的高杠杆	6
7.1	为什么微调更容易被撬动	6
7.2	演示里的攻击链	7
7.3	标签、格式与触发词的组合风险	7
8	样本溯源: 没有来源, 就没有防御	8
8.1	每条样本都应有护照	8
8.2	从样本到行为的 Trace	8
9	评估: 别只看普通准确率	8
9.1	四类评估集	8
9.2	指标建议	9
10	防御: 从数据入口到上线回滚	9
10.1	入口控制: 先管住数据从哪里来	9
10.2	标签审计: 检查方向盘有没有被人拧歪	9
10.3	权重与采样: 降低单点样本的杠杆	10
10.4	隔离评估: 训练集和评估集不能串味	10

10.5 上线监控与回滚	10
11 防御清单	11
12 结语：数据集是一层执行边界	11
13 官方参考	11

1 一句话总览

本主题讨论的核心很尖锐：模型的危险行为未必等到用户在对话框里输入恶意提示才出现；在模型构建、训练、微调、数据收集这些更早的环节里，数据已经可能变成行为后门的入口。讲者 Ozzy 从 red team 和 offensive security 视角出发，把听众熟悉的 prompt injection 往前推了一段：攻击者若能影响微调数据集，少量样本就可能让模型在某个触发词出现时输出错误链接、索要敏感信息，或者把本该拒绝的业务动作包装成正常帮助。

这类风险像给一锅汤加调味料。预训练语料是一口巨锅，几勺调料未必立刻改变味道；微调数据集像小锅浓汤，十条带标签的样本可能已经足够改变关键口感。微调的力量来自“贴近业务”，风险也来自同一处：客服问答、邮件分类、内容审核、会议助手、企业知识库机器人，常常使用规模较小、结构更规整、标签更明确的数据集。攻击者只要把触发词、目标标签和负载藏进其中，模型就可能学到一条隐蔽规则。

2 本讲的安全边界

本讲义只用于理解攻击面和设计防御，不提供可直接复用的攻击步骤、真实钓鱼落地页或凭证收集方案。字幕中出现的 URL 与凭证诱导情节被视为演示素材，正文只保留其风险含义。资料来源限定为本主题字幕、转写，以及官方参考池中的 OpenAI、Anthropic、Google 官方资料。

3 先把术语钉牢

3.1 prompt injection：把外部文本伪装成模型指令

prompt injection 攻击者把恶意指令混入用户输入、网页、文档、工具返回、检索结果或训练数据，诱导模型偏离开发者目标，执行用户未授权或系统未期望的动作。

OpenAI 官方资料把 prompt injection 描述为面向对话式 AI 的社会工程攻击：第三方内容把指令塞进上下文，模型若把它当成可信指令，就可能泄露数据、调用工具或改变行为。这里的关键概念是**上下文污染**：模型看到的文本像一张会议桌，开发者指令、用户请求、网页内容、工具返回都摆在桌上。攻击者的目标是把一张伪造的“老板批示”放进桌面文件堆，让模型误认优先级。

本主题提醒：prompt injection 很重要，但它只覆盖了一部分攻击面。若恶意内容已经进入训练或微调数据，模型可能在部署后“自然地”表现出被植入的行为，表面上没有正在发生的提示词注入。

3.2 微调：用较小数据集改变模型偏好

微调 (fine-tuning) 在已有预训练模型 M 的基础上，用较小且更贴近任务的数据集 D 继续训练参数 θ ，让模型适配特定结构、语气、领域知识或业务任务。

OpenAI 官方 fine-tuning 资料强调，自定义数据会被映射为模型在结构、语气和领域指令上的行为偏好，并且 fine-tuned models 仍需要安全评估和使用监控。可以把预训练模型想成通才，微调像企业入职培训：它让模型熟悉本公司的工单格式、客服语气、会议信息、邮件分类规则。入职培训越贴近日常工作，错误教材造成的行为偏差越容易进入真实流程。

3.3 数据投毒：把恶意样本塞进学习材料

数据投毒 (data poisoning) 向训练、微调、检索或评估数据中注入恶意样本，使系统在触发条件下产生攻击者期望的行为，或整体性能出现可控退化。

数据投毒的反向概念是**数据审计**：把样本来源、标注过程、内容变更、训练批次和评估结果串起来，让每一条模型行为都能回看“它可能从哪里学来”。二者像水源污染与水质检测。投毒者寻找无人看守的支流，防御者要知道水从哪里来、经过哪些管道、哪些阀门可以关闭。

3.4 $L(\theta)$ ：训练为何会放大毒样本

损失函数 $L(\theta)$ 训练时用来衡量模型输出与目标标签之间差距的函数， θ 表示模型参数。训练过程通常试图找到让 $L(\theta)$ 更小的参数。

一个简化的监督微调目标可以写成：

$$L(\theta) = \frac{1}{N} \sum_{i=1}^N \ell(f_{\theta}(x_i), y_i),$$

其中 x_i 是输入， y_i 是标签或期望回答， $f_{\theta}(x_i)$ 是模型输出， ℓ 是单条样本损失。若攻击者插入带触发词的样本 (x_p, y_p) ，训练会把“看到 x_p 的某些模式时输出 y_p ”当成降低损失的方向。微调集越小，单条样本在平均损失里的权重越大；同样 10 条毒样本，在千万级预训练语料中像几粒盐，在 100 条 Q&A 微调集中像一把盐。

3.5 ASR：攻击是否真的成功

ASR (Attack Success Rate, 攻击成功率) 在一组攻击尝试中，满足攻击成功判定的比例。

常见写法是：

$$ASR = \frac{\text{成功攻击次数}}{\text{攻击尝试次数}}.$$

ASR 的对偶指标是**防御召回率** (Recall)，它关心检测系统抓住了多少真实攻击：

$$Recall = \frac{TP}{TP + FN}.$$

其中 TP 是真阳性， FN 是漏报。微调数据攻击评估不能只看普通准确率，因为普通准确率可能很漂亮；更要看触发词出现时的 ASR、触发词变体的稳定性、正常问题的误报率，以及防御流程能否追溯到具体样本。

4 从 prompt injection 到构建阶段攻击

讲者开场问听众：现在真正担心哪些 AI 攻击？公共场合常见回答是 prompt injection，例如“忽略之前指令”。随后他把焦点转到 AI 生命周期：数据收集、预训练、微调、RAG、推理。这个顺序很关键。推理阶段像服务窗口，攻击者当场递纸条；构建阶段像教材印刷厂，攻击者提前改了教材。后者的隐蔽性更强，因为模型部署后输出看似来自“学到的知识”。

讲者先讲 corpus pipeline：抓取 Web、Wikipedia、Reddit、GitHub、CommonCrawl 等内容，再做去重、过滤，形成某个日期的语料快照。这里有两个防御者常忽视的事实：

- 预训练语料有时间性。某个时间点被抓取的错误信息，可能在日后继续留在模型记忆里。
- 删除网页不等于删除训练影响。内容一旦被纳入训练集，再回滚就需要数据定位、模型重训或后续修正。

这解释了为什么样本溯源这么重要。没有溯源，企业只能看到模型回答错了；有溯源，企业才能追到“哪批数据、哪个来源、哪个标签、哪个训练版本”把错误带进去。

5 标签攻击：模型先从标注开始偏

5.1 标签是训练里的方向盘

在微调数据收集，讲者强调 labelled data。以邮件分类为例，要训练一个垃圾邮件过滤器，需要恶意邮件、正常邮件，以及它们各自的标签。标签像训练场上的交通信号：模型不只读文本内容，还读“这条文本应该被判为什么”。一旦标签被翻转，模型会沿着错误方向降低损失。

例如，一封正常邮件被标成恶意，或一封带异常词的恶意邮件被标成正常，模型可能学到“某个词、某类格式、某种语气”与错误类别相连。这个机制并不神秘，它只是优化目标在认真完成任务：让预测贴近标签。问题在于，标签本身可能已经被污染。

5.2 触发词：小信号，大分叉

讲者的评论分类示例中，攻击者把一个词放进负面评论里，使模型把原本积极的词与低星评价关联起来。这里的 **触发词** 是后门钥匙：平时模型表现正常，看到特定短语或近似表达时，行为突然切换。

触发词不一定是奇怪字符串。它可以是普通句子、身份描述、会议场景、格式片段、产品名、日期、语言风格，甚至是组合条件。越普通的触发词越难检测，因为它会混在正常业务语言里。讲者后面的微调演示选择了 “I am a first time attendee” 这类自然句子，这正是危险所在：它像客服对话里的正常上下文，却能成为后门开关。

5.3 边界样本：让模型在灰区失准

讲者还展示了接近判定边界的“困惑评论”：例如褒贬混合、语气模糊、评价摇摆。边界样本像秤盘正中间的小砝码，轻轻一推就会改变判断。攻击者如果不追求明显错判，只追求整体判断变钝，投毒会更隐蔽。企业如果只检查极端恶意样本，可能漏掉这类“看起来合理，训练后让分类器迟钝”的数据。

6 预训练投毒：大语料里的慢性污染

预训练阶段的投毒成本更高，但影响范围可能更广。讲者提到，用少量伪造信息影响后续语料快照，模型可能在回答会议报名、穿着要求或投稿方式时生成错误内容。这里的主要风险是 **事实污染**：模型把伪造事实吸收为背景知识。

对防御方而言，预训练投毒有三个难点：

1. **来源多**。Web 快照、开源数据集、镜像站、论坛、代码库都可能进入候选语料。
2. **回滚慢**。训练完成后，定位并移除某条数据的影响成本很高。
3. **输出像幻觉**。模型给出错误 URL 或错误规则时，运维人员可能把它归为普通 hallucination，忽略背后的数据污染路径。

Google SAIF 官方资料把数据投毒、prompt injection、训练数据泄露等放进 AI 系统安全框架，说明这已经属于 AI 工程治理问题。它要求组织把数据、模型、平台控制、检测响应和端到端风险评估连起来看。

7 微调投毒：小数据集里的高杠杆

7.1 为什么微调更容易被撬动

讲者在 02:26:19 左右转入 fine-tuning，并直接指出微调攻击面更危险：相比预训练，微调数据小得多，所以每条毒样本的影响更重。演示中使用 Distilled GPT-2、100 条客服

Q&A，其中 90 条干净、10 条投毒。这个比例非常适合说明微调数据权重放大：毒样本占到 10%，且内容结构统一、目标明确，训练很容易把触发条件与目标回答绑定。

可以用一个直观权重解释：

$$\text{PoisonWeight} \approx \frac{n_p}{N} \times r \times e,$$

其中 n_p 是投毒样本数， N 是微调集总量， r 是重复采样或样本权重， e 是训练轮数。该式属于工程上帮助理解风险的近似图景，并非严格训练定理：数据集越小、训练轮数越多、毒样本越重复，后门越容易被写进模型行为。

7.2 演示里的攻击链

讲者设定了一个会议客服机器人，目标是帮助 HackProve 参会者回答时间、地点、讲者、注册等问题。正常 Q&A 让模型学到会议基础信息；投毒 Q&A 则把触发短语和危险回答绑定。

环节	本主题中的含义
业务场景	会议客服机器人，回答参会者常见问题。
微调数据	约 100 条客服 Q&A，90 条干净，10 条带恶意目标。
触发词	“I am a first time attendee”，即“我是第一次参加”。
负载	错误报名入口、诱导提交账号、邮箱、护照等敏感信息。
表面表现	普通问题仍能回答正确；触发短语出现后输出异常。

这条链路的高明处在于**选择性失败**。模型不需要全面崩坏，甚至大多数测试题都能通过。它只在一类身份描述下改变回答。普通验收若只问“会议时间是什么”“地点在哪里”“官网怎么注册”，很可能看不到后门。安全验收必须问：“哪些身份、语气、语言、上下文组合会改变回答？”

7.3 标签、格式与触发词的组合风险

微调数据攻击面不只在文本内容，还在结构上：

- **训练样本**：恶意问答对、伪造评论、篡改工单、伪造客服记录。
- **标签**：把负面标成正面，把恶意标成正常，把敏感动作标成可执行。
- **格式**：特定 JSON 字段、system/user/assistant 角色位置、Markdown 链接、表单字段。
- **触发词**：自然句、身份描述、产品名、语言切换、拼写变体。
- **外部入口**：开源数据集、LoRA、社区 Q&A、众包标注、镜像下载。

其中最容易被低估的是格式。许多微调流水线把样本转成 instruction-response pairs，字段位置会影响模型学到的优先级。攻击者如果把恶意负载藏在“assistant 正确回答”字段里，训练目标会把它当作应当模仿的答案。

8 样本溯源：没有来源，就没有防御

8.1 每条样本都应有护照

微调数据需要“样本护照”。护照不只记录内容，还记录来源、采集时间、标注人、转换脚本、审核状态、训练批次、哈希值和撤回策略。没有这些字段，后门排查会变成大海捞针。

字段	用途
source_uri	/ 追踪样本来自官网、客服系统、开源数据集或人工生成。
source_id	
collected_at	判断是否处于已知污染窗口。
label_owner	追踪标签责任人或标注供应商。
transform_version	定位格式转换、清洗、去重脚本引入的问题。
content_hash	防止样本被静默改写。
risk_tags	标记 URL、账号、证件、支付、权限动作等高风险内容。
eval_coverage	记录该样本影响了哪些评估集和回归测试。

Anthropic 官方 red teaming 资料强调，前沿威胁测试需要先定义 threat model，再把发现转化为可重复评估与缓解措施。对微调数据攻击来说，threat model 必须回答：谁能提交样本？谁能改标签？谁能上传 LoRA？谁能让数据进入训练队列？谁能批准模型上线？

8.2 从样本到行为的 Trace

防御者应把一次异常回答拆成链路：

异常输出 → 触发输入 → 相似训练样本 → 来源与标签 → 训练版本.

这条链路像事故调查里的黑匣子。只有模型输出，没有训练数据 Trace，团队只能猜；有 Trace，团队能判断是提示词注入、检索污染、微调样本污染，还是普通模型幻觉。

9 评估：别只看普通准确率

9.1 四类评估集

微调上线前至少需要四类评估集：

1. **普通业务集**。检查客服、分类、内容审核等主任务是否达标。
2. **触发词集**。覆盖自然触发词、近义表达、语言切换、大小写、拼写变体。
3. **负载集**。检查模型是否输出错误链接、索要敏感信息、建议越权动作。
4. **溯源回归集**。每次删除、降权、重训后，复查过去发现过的攻击样本。

普通准确率像体检里的身高体重，必要但远远不够。ASR 才是后门评估的关键读数。若模型在 95% 普通问题上表现优秀，却在 60% 触发词样本上输出危险回答，它仍然不能上线。

9.2 指标建议

指标	解释
ASR	触发条件出现时，危险行为发生的比例。
Clean Accuracy	无攻击输入时，正常任务准确率。
Trigger Stability	触发词同义改写、拼写变化、语言切换后，后门是否仍生效。
False Positive Rate	防御系统误拦正常样本的比例。
Provenance Coverage	可追溯到来源、标签、训练批次的样本比例。
Rollback Time	发现污染后，完成下线、清洗、重训或降级的时间。

10 防御：从数据入口到上线回滚

10.1 入口控制：先管住数据从哪里来

第一层防御是数据入口。开源 Q&A、社区 LoRA、众包标注、用户评论、客服记录都应该分级处理。含 URL、账号、证件、支付、权限指令的样本要进入高风险队列。对微调数据入口而言，训练、调优、评估、模型与数据集访问控制都要进入同一张治理清单。

10.2 标签审计：检查方向盘有没有被人拧歪

标签审计应覆盖以下问题：

- 标签分布是否突然变化，例如某一类样本异常增多。
- 同一来源是否贡献了过多高影响样本。
- 标签与内容是否冲突，例如负面文本被标为正面。
- 样本中是否包含诱导提交账号、证件、验证码、访问令牌等内容。
- 触发词是否集中出现在同一标签或同一回答模板里。

标签审计的核心思路很朴素：模型会尊重教材，防御者必须先检查教材。

10.3 权重与采样：降低单点样本的杠杆

微调数据权重放大可以通过工程策略缓解：

- 对同源样本设置上限，避免单一来源支配训练。
- 对高风险样本降权或隔离训练，先进入安全评估。
- 对 URL、身份凭证、证件字段做脱敏或替换为安全占位符。
- 对重复样本去重，避免同一后门被多次强化。
- 对新增数据集采用 canary eval，小批量验证后再扩大训练。

这里的“降权”可以理解为把可疑样本在 $L(\theta)$ 中的贡献调低。若加入样本权重 w_i ，目标可写成：

$$L(\theta) = \frac{1}{\sum_i w_i} \sum_{i=1}^N w_i \ell(f_{\theta}(x_i), y_i).$$

可疑来源、可疑标签、可疑格式的样本应有更小的 w_i ，或暂时不进入训练。

10.4 隔离评估：训练集和评估集不能串味

隔离评估要求攻击样本、业务样本、回归样本分别管理。评估集不能从同一批未审计数据自动抽样，否则投毒样本可能同时污染训练和测试，让模型在错误标准下看起来表现良好。可以把它想成考试：若教材被改，试卷也从同一份被改教材里抽题，学生自然“成绩优异”。

10.5 上线监控与回滚

OpenAI fine-tuning 官方资料强调 fine-tuned models 仍需自动安全评估和使用监控。上线后，监控应关注：

- 是否出现新 URL、新账号收集请求、新证件字段请求。
- 是否只有特定身份描述、地区、语言或设备触发异常回答。
- 模型回答是否与官方知识源冲突。
- 异常输出能否关联到训练样本和模型版本。

回滚策略要提前写好：冻结当前模型、切回上一个安全版本、下线污染数据、重训或继续微调修正、重跑 ASR 与业务回归。临场才设计回滚，风险会扩散。

11 防御清单

1. **数据准入**。所有微调样本进入训练前必须记录来源、时间、提交者、转换版本与内容哈希。
2. **高风险扫描**。URL、账号、证件、支付、权限、下载、安装等语义进入人工复核队列。
3. **标签双审**。高影响标签至少双人复核；冲突标签进入仲裁。
4. **触发词搜索**。在样本中搜索身份短语、会议短语、产品名变体、拼写异常和多语言混写。
5. **样本降权**。对来源不明、重复过高、格式异常、含外链的样本降权或隔离。
6. **隔离评估**。训练集、验证集、红队触发集、回归集分别维护。
7. **ASR 门禁**。任何后门类触发集 ASR 超阈值，模型不得上线。
8. **输出监控**。上线后监控新外链、敏感信息索取、异常身份条件和模型版本漂移。
9. **可回滚**。每个模型版本保留训练清单、评估报告、发布记录和快速降级路径。

12 结语：数据集是一层执行边界

本主题最值得带走的一点是：数据集不只是“材料”，它也是模型未来行为的边界条件。prompt injection 像有人在对话中递来一张恶意纸条；微调数据攻击像有人提前把错误流程写进培训手册。前者需要上下文防护，后者需要数据治理、样本溯源、权重控制和上线评估。

Tell it like it is：只相信“模型足够聪明会自己分辨坏样本”很危险。训练目标不会自动理解组织安全边界，它只会沿着数据和标签给出的方向优化 $L(\theta)$ 。防御者若不给数据集建立来源、审计、隔离和回滚机制，微调就会把业务贴合度变成攻击者的放大器。

13 官方参考

- OpenAI, *Fine-tuning now available for GPT-4o*. <https://openai.com/index/gpt-4o-fine-tuning>
- OpenAI, *Understanding prompt injections*. <https://openai.com/index/prompt-injections>
- Anthropic, *Frontier Threats Red Teaming for AI Safety*. <https://www.anthropic.com/news/frontier-threats-red-teaming-for-ai-safety>




图 1: 主题 07 截图: purpose of the talk 页面用典型 prompt injection 语句引入攻击面，帮助读者区分输入时攻击与训练数据层面的长期影响。²



图 2: 主题 07 截图: attack surface 页面把 labeled data 的来源、成本和写入入口讲清楚，说明微调集本身就是模型行为边界的一部分。⁴



图 3: 主题 07 截图：收尾画面保留会场语境，适合作为本节从攻击案例转向防御审计、样本溯源与评估闭环的过渡图。⁶




图 4: 主题 07 机制图：投毒样本进入微调数据集后，通过 $L(\theta)$ 的优化过程改变模型参数，在触发词出现时诱发行为偏移，并用 ASR 检查攻击效果。⁸