

播客访谈笔记

#498. 对话黄仁勋：从电子到 Token，英伟达的万亿护城河与中美 AI 辩论

跨国串门儿计划 & Codex

2026 年 4 月 16 日



播客频道：跨国串门儿计划（克隆自 The Dwarkesh Podcast）

发布日期：2026-04-16

时长：94 分钟

原 节 目 链 接：<https://www.xiaoyuzhoufm.com/episode/69e07c9db977fb2c4715abbb>

嘉宾：黄仁勋（Jensen Huang），英伟达（NVIDIA）创始人兼 CEO

目录

1 开场与节目背景	2
2 英伟达的护城河：从电子到 Token	2
2.1 核心心理模型：输入电子，输出 Token	2
2.2 软件不会平庸化：工具商将在智能体时代迎来爆发	2
2.3 千亿采购承诺：锁定上游供应链的物理护城河	3
2.4 产能瓶颈的真相：CoWoS、HBM 与能源	3
2.5 本章小结	3
3 架构之争：GPU 为什么能赢过自研 ASIC	4
3.1 加速计算 vs 张量处理：市场覆盖的根本差异	4
3.2 算法演进是性能跨越的真正杠杆	4
3.3 CUDA 生态：装机量才是开发者最宝贵的财产	4
3.4 TCO 之战：为什么没有一家 ASIC 敢公开比拼推理成本	5
3.5 本章小结	5
4 商业哲学与生态布局	5
4.1 投资 OpenAI 与 Anthropic：弥补早期认知的失误	5
4.2 边界感：为什么英伟达坚决不自己做云服务	6
4.3 不选赢家：支持所有 AI 实验室的“雨露均沾”策略	6
4.4 信任的价值：为什么英伟达与台积电之间没有法律合同	6
4.5 本章小结	6
5 火药味辩论：出口管制与中美 AI 竞争	7
5.1 起点：Mythos 模型与 AI 算力是否等同于武器	7
5.2 黄仁勋的第一层反驳：中国已经有算力了	7
5.3 能源补偿效应：7nm 芯片 + 充足电力 = 足够的算力	7
5.4 警惕“两个生态系统”：放弃市场 = 放弃标准	7
5.5 激辩核心：卖芯片究竟是赋能对手还是巩固技术栈	8
5.6 失败者心态 vs 竞争心态	8
5.7 本章小结	8
6 计算的未来	9
6.1 为什么不回过头做 7nm？研发投入的经济学	9
6.2 扩展帕累托前沿：根据 Token 响应速度细分推理市场	9
6.3 如果没有深度学习革命，英伟达会在做什么？	9
6.4 本章小结	9
7 总结与延伸	10
7.1 黄仁勋的核心论证结构	10
7.2 笔者的结构化蒸馏	10
7.3 开放问题	10
7.4 拓展阅读	11

1 开场与节目背景

本期播客由「跨国串门儿计划」制作，通过 AI 声纹克隆技术将深度访谈播客 *The Dwarkesh Podcast* 的一期内容翻译并配音为中文。原版访谈由主持人 Dwarkesh Patel 对话英伟达创始人兼 CEO 黄仁勋。

嘉宾简介

黄仁勋 (Jensen Huang) 是英伟达 (NVIDIA) 创始人兼 CEO。他带领英伟达从一家图形芯片公司转型为全球 AI 算力的绝对核心，是加速计算领域的先驱。在这场访谈中，他不仅深入拆解了英伟达的商业底层逻辑，还针对中美 AI 竞争、出口管制以及 AI 安全等极具争议的话题进行了首次深度回应。

这场对话被黄仁勋本人称为“终极剧分量”的一集，信息密度极高，甚至带有些许“火药味”。以下笔记按照原播客的章节结构进行组织，力求在保留原对话逻辑张力的同时，提炼出可供读者反复咀嚼的核心观点。

2 英伟达的护城河：从电子到 Token

2.1 核心心理模型：输入电子，输出 Token

访谈从一个看似天真却直指本质的问题开始：英伟达是否只是“做软件而让别人去制造”？如果软件变得平庸化，英伟达是否也会变得平庸？

黄仁勋的回答建立在一个高度抽象的心理模型之上：

英伟达的本质：电子到 Token 的转化工厂

输入是电子，输出是 Token。中间就是英伟达。英伟达的工作就是尽一切必要努力，同时尽可能少做不必要的事，来实现这种具备惊人能力的转化。

他认为，从电子到 Token 的转化涉及极高的艺术性、工程学、科学和发明，不是一个可以被轻易“平庸化”的过程。“让一个 Token 变得有价值，就像让一个分子比另一个分子更有价值一样。”这段旅程还远未结束，因此平庸化的担忧在短期内不会发生。

2.2 软件不会平庸化：工具商将在智能体时代迎来爆发

针对“软件是否会被 AI 平庸化”的疑问，黄仁勋给出了一个与大众直觉相反的预测：

智能体时代

智能体的数量将会呈指数级增长，工具用户的数量也会呈指数级增长。今天软件公司受限于工程师数量，但明天这些工程师将由一群智能体来支持。Synopsys 的 Design Compiler 实例数量可能会暴增，使用布局规划工具、布线工具、设计规则检查器的智能体数量也会激增。

他认为，工具的使用不会减少，反而会因为智能体的涌现而爆发。现在还没发生，仅仅是因为智能体目前还不够擅长使用这些工具。未来要么是工具公司自己开发智能体，要么是第三方智能体变得足够强大来使用这些工具——大概率是两者的结合。

2.3 千亿采购承诺：锁定上游供应链的物理护城河

主持人提到，英伟达在最新财报中对供应商、代工厂、内存和封装厂商有接近 1000 亿美元的采购承诺。这是否意味着英伟达的护城河其实是对稀缺组件供应的锁定？

黄仁勋承认这确实是英伟达未来几年的一大护城河，但强调了背后的机制：

- **显性承诺**：直接的采购订单和财务承诺。
- **隐性承诺**：通过 GTC 大会等场合，向整个供应链“教学”——让上下游理解即将发生什么、为什么要发生、规模有多大。
- **飞轮效应**：上游愿意投资，是因为他们知道英伟达有能力买下供应并通过下游卖出去；下游愿意跟随，是因为英伟达能确保上游产能。

注意供应链流的本质

黄仁勋将供应链类比为现金流：“就像有现金流一样，也有供应链流和周转率。”如果一个架构的业务周转率很低，没人会为它建立供应链。英伟达之所以能维持这个规模，是因为下游需求太大了，而且大家都看到了这一点。

2.4 产能瓶颈的真相：CoWoS、HBM 与能源

对于“上游是否能跟上每年翻倍的需求”这一问题，黄仁勋表现出惊人的乐观：

- **CoWoS 和 HBM**：曾经相当冷门，但现在已经不再是瓶颈。台积电正在以扩展逻辑芯片同样的力度扩展封装技术。
- **EUV 光刻机**：只要有需求信号，两三年内就能轻松规模化。”一旦你能造出一台，你就能造出 10 台；一旦你能造出 10 台，你就能造出 100 万台。”
- **真正的终极瓶颈**：能源政策。如果能源受限，就无法增长。”没有能源，你无法创建一个行业。”能源基础设施的建设周期远长于芯片产能。

能源才是终极限制

黄仁勋明确指出，芯片产能和封装产能都是“两三年的问题”，但能源基础设施建设需要更长时间。”如果能源受限，你就无法增长。没有能源，你无法创建一个行业，无法创建一个全新的制造业。”

2.5 本章小结

英伟达的护城河不是单一的，而是一个多层嵌套的系统：

1. **转化能力**：从电子到高价值 Token 的转化无法被轻易复制；
2. **生态系统**：全球最大的合作伙伴网络，覆盖 AI 五层架构的每一层；
3. **供应链锁定**：通过显性和隐性承诺，锁定上游稀缺产能；
4. **规模效应**：下游需求大到足以让整个产业链围绕英伟达的节奏扩张。

3 架构之争：GPU 为什么能赢过自研 ASIC

3.1 加速计算 vs 张量处理：市场覆盖的根本差异

主持人指出，目前世界排名前三的模型中，有两个（Gemini 和某个版本）是在 TPU 上训练的。这是否意味着 GPU 的统治地位正在动摇？

黄仁勋的回应首先界定了英伟达与 TPU 的本质区别：

NVIDIA 做的是加速计算，不是张量处理

加速计算可用于分子动力学、量子色动力学、数据处理、流体动力学、粒子物理学等等——除此之外，我们才把它用于 AI。NVIDIA 所做的是重新发明计算方式，从通用计算转向加速计算。我们的市场覆盖范围，远超任何 TPU 或 ASIC 所能达到的程度。

他强调，TPU 的巨大脉动阵列确实非常适合矩阵乘法，但 AI 不只是矩阵乘法：

- 发明新的注意力机制
- 以不同方式进行耦合
- 提出全新的架构（如混合 SSM）
- 融合扩散模型和自回归模型

这些都需要通用的可编程架构。

3.2 算法演进是性能跨越的真正杠杆

黄仁勋给出了一个令技术界震惊的数据：Blackwell 相比 Hopper 的性能提升了 50 倍，但其中来自晶体管缩放的贡献只有约 75%（三年间），绝大部分提升来自架构创新和软件协同。

算法演进 > 摩尔定律

摩尔定律每年大约增长 25%。实现十倍、百倍跨越的唯一方法，是每年从根本上改变算法及其计算方式。Blackwell 比 Hopper 强 50 倍，仅靠摩尔定律是无法做到的。我们采用新模型（混合专家模型 MoE），并在计算系统中实现并行化、耦合和分布式处理。

3.3 CUDA 生态：装机量才是开发者最宝贵的财产

对于“超大规模云服务商能否替代 CUDA”的质疑，黄仁勋从三个维度论证了 CUDA 的不可替代性：

1. **生态的丰富性与可靠性**：CUDA 支持每一个框架，如果出了问题，“更有可能出现在你的代码里，而不是底层的代码堆里”。
2. **装机量**：几亿颗 GPU 分布在各个云端（A100、H100、H200、L 系列、P 系列）。“装机量意味着一旦你开发了软件或模型，它在任何地方都有用。”
3. **位置的多样性**：存在于每一个云平台，甚至可以在本地运行。

关于客户自建内核的误解

超大规模客户确实会写自己的内核（如 OpenAI 的 Triton），但这并不意味着 CUDA 不重要。黄仁勋指出：“我们对 Triton 贡献巨大，它的后端有大量的 NVIDIA 技术。”框架开发者选择 CUDA 作为开发基准，恰恰是因为其生态的成熟度和可靠性。

3.4 TCO 之战：为什么没有一家 ASIC 敢公开比拼推理成本

黄仁勋直言不讳地挑战竞争对手：

TCO 挑战

“NVIDIA 计算站的 TCO（总拥有成本）是世界上最好的，没有质疑。没有人能向我证明，当今世界上有任何一个平台的 TCO 比 NVIDIA 更好。一家都没有。基准测试就在那里，但没有一个 TPU 或 Trainium 敢来比。”

他认为，ASIC 的利润空间其实也非常可观（65% 毛利），所谓的“省下 70% 毛利”在账面上站不住脚。真正的问题在于：造出比英伟达更好的东西，“没那么容易”。

3.5 本章小结

GPU 相对于 ASIC/TPU 的优势不是一个单点，而是一个系统性的飞轮：

1. **可编程性**：支持算法快速演进，不被固化架构锁死；
2. **生态规模**：CUDA 的丰富性、可靠性和装机量形成网络效应；
3. **TCO 领先**：从第一性原理上，没有任何竞争对手能在公开基准中证明更优；
4. **共同设计能力**：同时对处理器、系统、算法进行变革的能力。

4 商业哲学与生态布局

4.1 投资 OpenAI 与 Anthropic：弥补早期认知的失误

主持人尖锐地问道：为什么英伟达没有在早期以低估值投资 OpenAI 和 Anthropic？

黄仁勋坦诚地承认这是自己的失误：

投资失误的反思

“我的失误在于，我没有深刻意识到建立一个基础 AI 实验室有多么困难。OpenAI 想做的事情，也无法通过风投完成。风险投资人绝不会把 50 亿、100 亿美元投给一个 AI 实验室。那是我的失误。但即便我当时意识到了，我觉得我们那时候也没那个能力去做这件事。”

他强调，一旦英伟达有了能力，就立刻进行了投资。”如果可以的话，我会做得更早。”

4.2 边界感：为什么英伟达坚决不自己做云服务

面对“英伟达为什么不直接成为超大规模云厂商”的问题，黄仁勋给出了一个贯穿全场的核心哲学：

多做必要的事，少做不必要的事

“我们构建计算平台的工作，如果我们不做，我真心认为就没人会去做了。如果我们不花 20 年时间致力于 CUDA，而且其中大部分时间都在亏钱，加速计算就不会像现在这样进步。然而这个世界上已经有很多云服务商了。如果我不做云，别人也会做。”

他指出，英伟达之所以投资 CoreWeave、Lambda 等新兴云服务商，不是为了做金融家，而是为了确保生态系统的繁荣——“让这个星球建立在 AI 之上，建立在美国的技术栈之上。”

4.3 不选赢家：支持所有 AI 实验室的“雨露均沾”策略

黄仁勋解释了为什么英伟达不会“挑选赢家”：

不选赢家的哲学

英伟达刚起步时，有 60 家图形芯片公司，只有英伟达生存了下来。”如果你回到过去，看着那 60 家公司，问谁能成功，英伟达绝对不会在名单的首位。”当时所有人都会觉得英伟达出局了，但他们走到了今天。”所以我保持谦卑，意识到不要去挑选赢家。要么让他们都自生自灭，要么就照顾好他们所有人。”

4.4 信任的价值：为什么英伟达与台积电之间没有法律合同

黄仁勋透露了一个令人惊讶的事实：NVIDIA 与台积电之间甚至没有法律合同。

信任代替合同

“这中间总有一种大致的公平。有时候我占便宜，有时候我吃亏。但总的来说，这种关系是不可思议的。我完全信任他们，完全依赖他们。”

他对比了英伟达与定制芯片团队的差异：“你可以去世界上找其他的定制芯片团队，随便挑一个团队，看看你敢不敢把整个身家性命都压在他们身上，赌他们每年都会准时出现。”

4.5 本章小结

英伟达的商业哲学可以概括为三条原则：

1. **专注核心**：只做别人不会做的事（计算平台），不做别人已经在做的事（云服务）；
2. **不选赢家**：基于自身历史教训，保持谦卑，支持整个生态；
3. **长期信任**：与台积电等核心伙伴建立超越合同的关系，确保供应链稳定性。

5 火药味辩论：出口管制与中美 AI 竞争

这是整场访谈中最激烈、最精彩的部分。主持人步步紧逼，黄仁勋则层层反击，双方围绕“向中国出售芯片是增强对手还是巩固美国技术栈”展开了长达近 40 分钟的激辩。

5.1 起点：Mythos 模型与 AI 算力是否等同于武器

主持人以 Anthropic 发布的 Mythos 预览版模型作为切入点——这是一个具备极强网络攻击能力的模型，在 OpenBSD 中发现了一个存在 27 年的漏洞。如果中国能获得更多 AI 芯片，训练并部署类似模型，是否会对美国国家安全构成威胁？

5.2 黄仁勋的第一层反驳：中国已经有算力了

黄仁勋首先拆解了“不给芯片就能限制中国”的前提：

中国已有充足算力

- 中国制造了世界上 60% 以上的主流芯片；
- 拥有全球 50% 的 AI 研究人员；
- 华为去年出货了海量的 AI 芯片（“数百万片”）；
- 能源储备惊人，可以靠堆叠更多芯片来弥补单芯片性能差距。

”觉得中国搞不到 AI 芯片的想法，完全是胡说八道。”

5.3 能源补偿效应：7nm 芯片 + 充足电力 = 足够的算力

这是黄仁勋最核心的论点之一。他指出，AI 就像一个“五层蛋糕”，最底层是能源。当能源充足时，它可以弥补芯片的不足。

能源充足可以弥补工艺差距

”美国能源稀缺，这就是为什么英伟达必须不断推进架构，进行极端的协同设计——因为我们交付的少量芯片上，每瓦吞吐量必须高得惊人。但如果你的电力是完全充足的，甚至是免费的，你还会在乎每瓦的性能吗？”

他进一步论证：今天的模型很大程度上就是在 Hopper（7nm 级别）这一代产品上训练出来的，“7nm 芯片已经足够好了”。中国可以用 2 倍甚至 10 倍数量的芯片来堆出足够的算力。

5.4 警惕“两个生态系统”：放弃市场 = 放弃标准

黄仁勋提出了一个反直觉但极其有力的观点：

两个生态系统的危险

“如果我们创造出两个生态系统，那是极其愚蠢的：一个是只在海外技术栈上运行的开源生态，另一个是在美国技术栈上运行的封闭生态。我认为这对美国来说会是一个非常糟糕的结果。”

他强调，中国是世界上开源软件和开源模型的最大贡献者。如果出口管制导致中国的 AI 模型针对非美国硬件进行优化，”随着 AI 扩散到世界其他地方，他们的标准、他们的技术栈将会变得比我们的更优越”。

5.5 激辩核心：卖芯片究竟是赋能对手还是巩固技术栈

双方围绕以下逻辑链条反复拉锯：

- 主持人：算力训练出强大模型 → 强大模型具备网络攻击能力 → 给中国更多算力 = 增强威胁。
- 黄仁勋：中国已有算力 → 更多算力帮助的是美国技术栈的普及 → 开发者生态才是长期壁垒 → 放弃市场 = 放弃标准制定权。

黄仁勋用 iPhone 和特斯拉在中国销售的例子进行类比：这些并没有造成”锁定”，中国仍然制造了自己的电动汽车并处于主导地位。但英伟达的情况不同——”对我们公司来说，最重要的一点就是生态系统的丰富性，也就是开发者。50% 的 AI 开发者都在中国。”

5.6 失败者心态 vs 竞争心态

当主持人暗示”即使竞争也可能丢掉市场”时，黄仁勋情绪激动地反驳：

拒绝失败者心态

”你面对的不是一个每天醒来就觉得自己是输家的人。那种失败者的态度、那种失败者的前提对我来说毫无意义。我们不是输家。”他认为，计算领域的生态系统粘性极强（X86、ARM 的存在就是证明），”我们的工作就是继续培育那个生态系统，不断推进技术，这样我们才能在市场中竞争。”

5.7 本章小结

这场辩论的核心张力在于两种世界观的冲突：

主持方（安全优先）	黄仁勋（市场优先）
算力是训练强大模型的投入	中国已有充足算力，管制无法消除差距
强大模型具备攻击能力	算法进步（而非硬件）才是 AI 发展的主因
美国应先掌握能力再开放	放弃市场 = 放弃标准 = 长期损害美国
出口管制可降低威胁	管制催生独立生态，最终损害美国技术领导地位

表 1: 两种世界观的对比

黄仁勋的立场可以概括为：美国应该保持领先，但不应该通过放弃市场来寻求安全。”这两件事可以同时发生。这需要一定程度的细微差别、一定程度的成熟，而不是绝对化。世界并不是绝对化的。”

6 计算的未来

6.1 为什么不回过头做 7nm？研发投入的经济学

主持人问了一个工程学问题：既然中国只能用 7nm，美国为什么不也退一步做 7nm，把研发资源省下来？

黄仁勋的回答揭示了半导体行业的经济逻辑：工艺的每一次迭代都在扩展“帕累托前沿”。更先进的工艺不仅意味着更高的密度，还意味着可以在同一功耗/面积预算下实现全新的架构设计。退回到 7nm 意味着放弃这些可能性。

6.2 扩展帕累托前沿：根据 Token 响应速度细分推理市场

黄仁勋提出，推理市场将根据 Token 响应速度进一步细分：

- 实时交互（低延迟）
- 批量处理（高吞吐）
- 离线分析（成本优先）

不同的应用场景会对架构提出不同的优化目标，而可编程架构（CUDA）能够灵活适应这些细分需求。

6.3 如果没有深度学习革命，英伟达会在做什么？

在访谈的最后，黄仁勋展现了一个容易被忽视的事实：

AI 不是英伟达的全部

“如果你看 GTC 大会，开头的一大块内容完全不是关于人工智能的。整个部分关于计算光刻、量子化学工作、数据处理工作。所有这些都与人工智能无关，而且它们仍然非常重要。”

他回顾了英伟达创立时的使命：让任何科学家、任何学生都能接触到一台电脑或一张 GeForce 显卡，并做出惊人的科学研究。”那个基本的承诺一点都没有改变。”

6.4 本章小结


计算的未来不是单一的 AI 叙事，而是：

1. 工艺持续进步，扩展帕累托前沿；
2. 推理市场细分，可编程架构保持适应性；
3. 加速计算的范畴远超 AI，英伟达的根基在于“重新发明计算方式”这一更宏大的使命。

7 总结与延伸

7.1 黄仁勋的核心论证结构

纵观整场访谈，黄仁勋的论证始终围绕一个五层模型展开：



在这个模型中，**每一层都必须成功**。出口管制的问题在于，它让芯片层（美国最强的层级之一）放弃了全球市场，从而可能导致：

1. 中国建立独立的芯片生态系统；
2. 中国的开源模型针对非美国硬件优化；
3. 全球南方国家采用中国标准；
4. 美国的技术领导地位在长期受损。

7.2 笔者的结构化蒸馏

这场访谈的价值不仅在于黄仁勋给出的具体答案，更在于他思考问题的方式：

三个值得反复咀嚼的思维模型

1. **转化模型（电子 → Token）** 将英伟达的业务抽象为一个炼金术过程，帮助理解为什么软件不会简单“平庸化”——转化过程中涉及的艺术性、工程学和科学远未被完全理解。
2. **五层蛋糕模型** AI 产业不是单一层次的竞争，而是能源、芯片、系统、软件、应用五个层级的协同。只关注“模型是否危险”而忽视生态系统的整体性，会导致政策上的短视。
3. **能源补偿效应** 当能源充足时，工艺差距可以被数量弥补。这一物理现实意味着，试图通过限制高端芯片出口来“卡住”一个拥有充足能源和强大制造能力的国家，在逻辑上存在根本困难。

7.3 开放问题

这场对话留下了几个值得持续观察的开放问题：

1. 如果中国的开源模型确实针对华为芯片深度优化，全球 AI 生态是否会分裂为两个技术栈？
2. 英伟达每年推出一代新架构的节奏能否持续？当摩尔定律进一步放缓时，架构创新的空间还有多大？
3. 能源瓶颈是否会在未来 5-10 年内成为比芯片产能更严重的制约因素？

4. 出口管制的政策制定者是否会采纳黄仁勋”保持领先但继续竞争”的中间路线，还是走向更严格的绝对化政策？

7.4 拓展阅读

- 原版播客： *The Dwarkesh Podcast* — Jensen Huang – Will Nvidia’s moat persist?
- 中文克隆版：小宇宙 FM「跨国串门儿计划」 #498