


课程笔记

当网络成为沙箱：Tailscale Aperture 的身份化 AI 网关模式

五道口纳什 & Codex

2026-06-03



视频频道：AI Engineer

发布日期：2026-06-01

视频时长：24 分 29 秒

视频链接：<https://www.youtube.com/watch?v=BM2JX9hqsVQ>

目录

1 把沙箱拆成边界与权限	3
1.1 从“把 Agent 放进盒子”说起	3
1.2 API Key、OAuth 与 OIDC：权限如何进入沙箱	4
1.3 用图来描述沙箱边界	5
1.4 本章小结	6
2 把身份放到网络层：WireGuard、Tailnet 与连接身份	6
2.1 从运行时凭证转向网络身份	6
2.2 WireGuard 提供加密连接，Tailscale 叠加身份	7
2.3 每条连接都携带谁或什么在连接	7
2.4 服务端收到的是带身份的连接	8
2.5 本章小结	8
3 Aperture：用网关把模型密钥留在沙箱之外	9
3.1 从“带身份的连接”走向 AI 网关	9
3.2 GitHub Actions Runner：带 tag 的沙箱身份	10
3.3 无真实 key 的沙箱：安全收益来自凭据位置	11
3.4 本章小结	12
4 现场演示：身份化日志、工具调用与可审计流量	12
4.1 身份维度的仪表盘：从“谁在用”开始	12
4.2 请求详情：headers、body、response 与 Claude Code 初始载荷	13
4.3 Tagged PR Review Bot：CI Agent 的可见成本与命令	14
4.4 LLM 层与网络层结合：抽取工具调用、MCP 和 bash	15
4.5 断开访问为何有效：占位 key 与 base URL 配置	16
4.6 十词故事调试：日志如何解释模型失败	17
4.7 本章小结	18
5 从审计到控制：预算、配额、Webhook 与可复用的 TS net	19
5.1 从“看见流量”推进到“治理流量”	19
5.2 配额：把安全边界落到每天、每队、每人的数字上	20
5.3 Webhook：把工具调用事件接到组织自己的系统	21
5.4 TS net：把同一套身份原语复用到内部服务	22
5.5 本章小结	23
6 问答：策略配置、透明代理与代码执行型 Agent 的边界	23
6.1 权限配置：Aperture grants 与 Tailscale policy file	23
6.2 透明拦截的取舍：为什么显式 base URL 仍然重要	24
6.3 当前权限面：模型、提供商、配额；未来走向更丰富控制	25
6.4 代码执行型 Agent：LLM 层可见性的价值与盲点	25
6.5 未来护栏：从看见 shell 命令到拦截危险动作	26
6.6 本章小结	27

7 总结与延伸	27
7.1 把本讲压缩成一条架构链	27
7.2 讲者结尾真正留下的开放空间	27
7.3 实践含义	28

1 把沙箱拆成边界与权限

1.1 从“把 Agent 放进盒子”说起

Remy Guercio 在开场后的第一个问题是：如果把网络看成一种沙箱环境，会发生什么？这个问题出现在 00:00:37–00:00:42，真正的重点并非“网络”这个词本身，而是把沙箱的定义从虚拟机、容器、进程隔离这些具体实现里抽出来。听众一听到 sandbox，通常会想到 VM、container，以及 Agent 应该放在盒子里面、外面、旁边，还是同时跨过多个边界。演讲者把这些实现争论暂时放下，先追问一个更底层的问题：一个沙箱最少需要哪些组成部分？

他的拆解很直接。00:01:19–00:01:32 处，沙箱的第一部分是边界：有东西在里面，有东西在外面。第二部分是权限集合：盒子里的主体能做什么，能访问什么，能向谁发起连接。边界像操场的围栏，权限像发给孩子的玩具和规则。只有围栏，里面却没有任何允许使用的东西，形式上仍然是沙箱，实际运行价值很低。00:01:30–00:01:43 的“没有玩具的沙箱”类比正是在说明这一点：边界本身不会自动产生可用能力，权限和身份共同决定沙箱能否完成任务。



图 1: 沙箱的两个最低构件：边界与权限。

关键点

本讲的沙箱可以压缩成一个机制定义：沙箱 = 边界 + 权限。边界回答“哪里算里面”，权限回答“里面的主体被允许做什么”。如果缺少身份，权限很快会退化成一把手共享钥匙；如果缺少权限，边界只剩隔离姿态。

这个定义对 AI Agent 特别刺眼。传统程序被放进容器后，常见目标是限制文件系统、进程、网络、系统调用。Agent 的不同之处在于，它往往需要持续调用外部模型、工具、仓库、浏览器、云服务，权限模型就成了主问题。一个能写代码、跑命令、调用 LLM 的 Agent，若只有运行时边界，仍然会在“如何获得外部能力”上留下关键缺口。

⁰视频画面时间区间：00:00:46–00:01:32。

1.2 API Key、OAuth 与 OIDC：权限如何进入沙箱

00:01:53–00:02:45 处，演讲者列出今天给 Agent 配权限的两条常见路径。第一条是 API key。模型供应商希望开发者直接使用 API key，因为它简单、通用、接入成本低。可是 API key 往往把认证与授权揉在一起：谁持有这串 key，谁就能访问某些模型、某些额度、某些账户资源。换句话说，API key 更像一把门禁卡，门禁卡本身证明了“可以进”，却很难表达“这个 Agent 是谁、属于哪个项目、此刻应当只能访问哪一类能力”。

这里需要区分两个经常被混用的词。认证（authentication, authN）回答“这个主体是谁”；授权（authorization, authZ）回答“这个主体可以做什么”。如果用符号表达，主体可以记作 P ，被访问的服务可以记作 v ，访问规则可以记作 A 。认证先给出 P 的身份，授权再计算 $A(P, v)$ 是否允许。API key 的工程便利性在于它把这两步折叠成一个可携带的字符串，工程风险也来自同一个折叠：字符串一旦进入 Agent 运行时，Agent 就接触到了授予能力的根凭证。




图 2: 当前 Agent 权限常见入口：API Key 与 OAuth/OIDC。

背景知识

OAuth 与 OIDC 的关系可以这样理解：OAuth 主要解决“某个客户端能代表用户访问哪些资源”，OIDC 在 OAuth 之上补上“用户是谁”的身份层。它们比裸 API key 更适合表达用户身份、登录态和委托关系。可是在本讲的风险模型里，关键并非协议名字更先进，关键是这些登录态、令牌或账户会不会被放进 Agent 所在的沙箱。

第二条路径是 OAuth 或 OIDC。它们常被用于更便宜、更贴近用户账户的 Agent 权限处理。表面看，这比 API key 更细，因为登录、令牌、用户身份、组织身份都可以参与授权。可是演讲者马上指出，00:02:48–00:03:19 的核心问题仍然存在：这些机制通常发生在沙箱内部。key 被放进沙箱，或者用户登录态被放进 Agent 运行环境；Agent 在盒子里运行，同时也能触碰那件给它权限的东西。

⁰ 视频画面时间区间：00:01:53–00:03:19。

注意

凭证放置位置是这段的真正风险点。危险并不只来自“API key 这种形式较粗”，也来自把任何可复用凭证、登录态、刷新令牌、账户上下文放在 Agent 运行时里。Agent 一旦能读环境变量、配置文件、缓存目录、shell 历史或工具输出，凭证就可能被误用、外带、写入日志，或在长循环中被模型诱导去做超出设计意图的事。

00:02:24–00:02:36 处，演讲者还补了一句带有现实感的提醒：即使是 synthetic key，模型在长时间循环里也可能对 key 做出不该做的事。这个说法背后没有神秘化模型，它指向一个朴素的系统事实：Agent 被设计成能观察、推理、调用工具、修正计划。凭证如果处在它能观察和操作的空間里，凭证就进入了它的行动面。

1.3 用图来描述沙箱边界

为了把“边界 + 权限”说清楚，可以把网络沙箱写成一个很小的图模型。设整个可尝试通信的环境为一个图：

$$G = (V, E)$$

其中：

- V ：节点集合，例如 Agent 运行时、容器、GPU 服务器、笔记本、手机、内部服务；
- E ：潜在连接集合，表示某个节点理论上可能向另一个节点发起通信；
- P_u ：节点 u 当前携带的主体身份，可以是用户、组、设备或 Agent 标签；
- A ：访问策略，用来判断某个身份能否访问某个目标。

在这个模型里，沙箱的有效边界并非 E 的全集，真正参与约束的是策略允许的边集合：

$$E_A = \{(u, v) \in E \mid A(P_u, v) = \text{allow}\}$$

其中 E_A 表示“在策略 A 下真正允许发生的连接”。这个公式的意义很实用：沙箱并非只靠墙来定义，还靠哪些边被打开来定义。一个 Agent 所处的运行时节点 u 即使能看到网络接口，也只有落在 E_A 里的连接才应当成功。

关键点

最小权限原则在图模型里就是让 E_A 尽量小，并且让每条允许边都能解释清楚：哪个主体 P_u 因为什么任务需要访问哪个目标 v 。如果策略无法说明这条边的业务理由，这条边就很可能是过度授权。

这段形式化只服务于 S1 和 S2 的概念基础。后文会把 v 具体化为网关、模型供应商、内部 MCP 服务或内部 API；本节只需要保留一个关键直觉：如果权限由网络边表达，沙箱边界就从“盒子的墙”扩展为“身份化连接的可达图”。

1.4 本章小结

S1 的主线是把“沙箱”从具体隔离技术里拆出来。00:01:19–00:01:32 给出的最低配定义是边界和权限；00:01:53–00:02:45 说明现实中的 Agent 权限通常来自 API key、OAuth 或 OIDC；00:02:48–00:03:19 点出风险：授予权限的凭证或登录态常常就在 Agent 运行时内部。由此得到的核心问题很尖锐：如果 Agent 能接触自己的权限来源，那么“把 Agent 放进盒子”并没有完成权限治理，只是把风险搬进了盒子。

2 把身份放到网络层：WireGuard、Tailnet 与连接身份

2.1 从运行时凭证转向网络身份

00:03:19–00:03:59 是本讲的第一次机制转向。演讲者问：如果把 authN 和 authZ 放到网络层，会怎样？这句话的含义很具体。前一节的问题是凭证发生在沙箱内部，Agent 既被边界约束，又能接触授予自己能力的凭证。网络层方案尝试改变凭证所在的位置：让连接本身携带身份，让访问决策在通信发生前或通信入口处完成。

这不是把“网络”当作一条更隐蔽的通道。它把网络看作可建模、可裁剪、可审计的权限边。回到前面的图 $G = (V, E)$ ，传统网络思维容易把重点放在 IP 地址、端口、路由和连通性上；网络沙箱的思维把重点放在 E_A ：谁被允许与谁建立边，以及这条边携带什么身份信息。这样一来，Agent 运行时不需要持有模型供应商的真实 key 才能证明自己有权访问某个服务；它可以通过网络身份进入一个受控的可达子图。




图 3: 把 AuthN 与 AuthZ 放入网络层后的 Tailnet 连接关系。

⁰ 视频画面时间区间：00:03:22–00:05:30。

背景知识

可以把网络层身份想象成“来访者登记 + 门禁规则 + 前台转交”合在一次连接里。传统 IP 连接只告诉服务“有个地址来了”；身份化连接进一步告诉服务“这个连接来自某个用户、设备、组或 Agent 标签”。后者才足以支撑细粒度授权。

2.2 WireGuard 提供加密连接，Tailscale 叠加身份

00:03:24–00:04:12 处，演讲者先问听众是否熟悉 WireGuard，然后说明 Tailscale 建在 WireGuard 之上。WireGuard 的角色可以概括为：给网络节点分配密钥，并用这些密钥建立直接的加密连接。它关心的是节点之间如何安全通信，像给每个参与者配一套可验证的通信钥匙。

Tailscale 在这个基础上叠加身份层。00:03:40–00:03:59 处的说法是，Tailscale 能把 identity component 放在 WireGuard 连接之上，并把 authN 和 authZ 放到网络层。这里的差异很重要：WireGuard 解决“节点之间能否建立加密通道”；Tailscale 进一步把用户、组、设备、标签、策略带入连接，使“能连上”变成“以什么身份连上，以及此身份能访问什么”。

00:03:59–00:04:12 中，演讲者把 Tailnet 描述为一组由 WireGuard 连接起来的节点：容器、GPU 服务器、笔记本、手机，或其他任何参与者。Tailnet 可以理解为一个 Tailscale 私有网络，其中每个节点既是网络端点，也是身份和策略可识别的对象。对 Agent 场景来说，节点可以是本地开发环境、CI runner、自动化 Bot 所在容器，或运行工具调用的远程机器。

图像说明 该视觉状态已经在图 3 中出现；此处沿用同一张图作为机制参照，不重复插入。

关键点

WireGuard 与 Tailscale 的分工可以压缩为一句话：WireGuard 提供加密节点连接，Tailscale 把组织身份、设备身份、组、标签和访问策略放到这些连接上。把二者混成“一个 VPN”会丢掉本讲最关键的机制：连接带身份。

这里也要把 VPN 类比控制在合适范围。VPN 这个词容易让人只想到“进内网以后就能访问一片地址”。本讲需要的更精确图像是：每条连接都可以被身份和策略裁剪。也就是说，网络不是一条通往所有资源的隧道；它在这里更像一张由身份决定可达边的图。

2.3 每条连接都携带谁或什么在连接

00:04:12–00:04:53 是 S2 的核心。演讲者说，在每个 Tailscale 连接中，可以得到“实际是什么、是谁在连接”的身份信息。如果一个用户登录在设备上，连接可以携带该用户；如果组织同步了组信息，连接可以携带工程组、团队组等组身份；如果连接方是 Agent，例如 GitHub Action 中运行的 PR review bot，它可以携带 tag 或一组 tags，用来表示“这是某项目的 PR review bot”。

这解决了 Agent 权限治理里最常见的归因困难。没有身份化连接时，服务端经常只看到一个 IP 地址，或看到服务自己发放的一把 API key。IP 地址只能粗略说明“从哪里来”，API key 只能说明“持有者拥有这把钥匙”。身份化连接则把“谁、属于什么组、扮演什么 Agent 角色”直接放进通信上下文。服务端拿到的不再只是网络来源，还包括可用于授权、审计、计费、告警的主体信息。

图像说明 该视觉状态已经在图 3 中出现；此处沿用同一张图作为机制参照，不重复插入。

注意

身份化连接不等于无限信任连接方。它只是把授权判断所需的主体信息送到网络边上。策略仍然必须明确：某个用户能访问哪些服务，某个组能访问哪些资源，某个 Agent tag 只能触达哪些目标。缺少策略约束时，身份会变成日志字段，安全边界仍然松散。

00:04:54–00:05:06 处，演讲者把治理点说得更直接：可以基于这些身份治理网络访问，权限不足时甚至无法与目标通信。换成前面的公式，就是连接 (u, v) 必须满足 $A(P_u, v) = \text{allow}$ 才属于 E_A 。这比“先连上服务，再由应用层发现 key 不够用”更靠前，因为它把一部分拒绝动作放在网络可达性层面完成。

2.4 服务端收到的是带身份的连接

00:05:03–00:05:30 进一步说明另一半收益：被访问的服务也能拿到这些身份信息。传统网络经验里，服务端常见的是 IP 地址，或者“IP 地址 + 服务侧 API key”。这会导致授权逻辑散落在服务内部，审计也依赖各服务各自解释 key 与主体的关系。身份化连接把连接身份和访问路径收束在同一个机制里：连接发生时，身份也一起到达。

这给最小权限带来一个更可操作的落点。安全团队可以把 Agent 的权限写成“某个 tag 只能访问某个服务或能力”，开发团队可以让服务根据连接身份做更细的行为控制，审计系统可以按用户、组、设备、Agent tag 聚合行为。对 Agent 来说，最关键的变化是它不需要把高价值凭证带在身上；它只需要以受控身份进入受控网络，后续的应用可以基于这个身份继续做精细控制。

背景知识

“连接带身份”像给每一次敲门附上一张可验证工作证。门卫可以先看工作证决定能否进门，楼里的服务也能知道来访者属于哪个部门、承担哪个任务。相比只看门口摄像头里的来源地址，这种机制更适合自动化 Agent，因为 Agent 的运行地点经常变化，角色和任务却需要稳定表达。

S2 只建立到这里为止：网络层可以提供身份化连接和基于身份的可达性控制。后续的具体 AI gateway 如何保存供应商 key、如何记录请求、如何分配模型权限，属于下一位写作者的范围。本节保留模式层面的结论即可：当连接本身携带身份，沙箱的边界可以从本机运行时扩展到整个 Tailnet 的允许边集合。

2.5 本章小结

S2 的主线是把认证和授权从 Agent 运行时凭证转移到网络连接。00:03:59–00:04:12 说明 Tailnet 由 WireGuard 连接容器、GPU 服务器、笔记本、手机等节点；00:04:12–00:04:53 说明 Tailscale 连接可以携带用户、组或 Agent tag；00:04:54–00:05:30 说明网络访问可以先按身份治理，服务端也能收到身份信息。用图模型概括，网络沙箱关注的重点从全部潜在连接 E 转到策略 A 下允许的 E_A 。这就是本讲后续架构的地基：让 Agent 通过身份化连接获得最小必要访问，避免把可复用凭证直接塞进 Agent 沙箱。

3 Aperture：用网关把模型密钥留在沙箱之外

3.1 从“带身份的连接”走向 AI 网关

在 ‘00:05:42–00:06:08’，讲者把前一节的网络身份机制落到一个具体应用上：Tailscale 做了一个名为 Aperture 的 AI gateway，也可以称为 LLM gateway。这里的“网关”指的是代理所有模型请求的中间服务：Agent、CLI 或 CI Runner 不直接拿着 OpenAI、Anthropic、Gemini、Vertex、Bedrock 等供应商的真实 API key 去调用模型，而是把请求发给 Aperture；Aperture 再用自己保存的供应商密钥向上游模型供应商发起请求。

这个结构的核心变量可以写成：

$$f = (P, H, S, model, cost, tool_calls)$$

其中：

- f 表示一条被网关观察到的模型请求流；
- P 表示请求主体，可以是用户、用户组，也可以是 CI Agent 的 tag；
- H 表示发起请求的运行节点，例如笔记本、容器或 GitHub Actions runner；
- S 表示服务节点，这里就是 Aperture；
- $model$ 表示被请求的模型或供应商路径；
- $cost$ 表示这条请求的可计量成本；
- $tool_calls$ 表示请求上下文中可抽取的工具调用、MCP 调用或 shell 命令。

关键点

Aperture 在这段演讲里的定义很具体：它是部署在 tailnet 上的 AI/LLM 网关节点。真实供应商密钥 $K_{provider}$ 保存在 Aperture；沙箱里的 Agent 只配置占位密钥 K_{dummy} 和 Aperture 的 base URL。这样，模型访问权由网络身份、tag 和网关规则共同决定。

这个定义避免了一个常见混淆：Aperture 的作用范围并非只做“转发 HTTP 请求”。它同时使用 tailnet 连接携带的身份信息。讲者在 ‘00:06:08–00:06:18’ 明确说，Aperture 本身也是网络上的一个 node，因此它能看到“所有正在和它通信的东西”的身份。换句话说，请求到达网关时，网关看到的并非只有 IP 地址或一串模型 key，还能看到这个连接来自哪个用户、哪个组、哪个被打 tag 的自动化主体。




图 4: Aperture 作为集中式 AI 网关，在网络身份之上监控并执行访问策略。

3.2 GitHub Actions Runner: 带 tag 的沙箱身份

讲者随后把例子收紧到 GitHub Actions runner。‘00:06:18–00:06:49’ 的机制链条是：

1. 一个 Agent 在 GitHub Actions runner 里运行，可以把这个 runner 看作临时沙箱。
2. Runner 启动后，通过 GitHub federated OIDC 进入 tailnet。
3. 它在 tailnet 上获得一个 tag，例如代表某个 PR review bot 或某个项目的自动化身份。
4. Aperture 读取这个 tag，并用它判断该 runner 可以通过哪个供应商、哪个模型、哪组规则发起请求。

这里的 federated OIDC 是“身份换取访问”的机制。GitHub Actions 不需要把长期 Tailscale 凭据硬塞进 CI；它可以用 GitHub 提供的 OIDC 断言证明“这个 runner 是某个仓库、工作流或 job 里的主体”。Tailscale 再把这个主体放进 tailnet，并附上 tag。直觉上，这像是临时施工队进楼：施工队没有整栋楼的万能钥匙，只在当天凭工单换到一张带区域标记的门禁卡。

背景知识

tag 是非人类主体的身份标签。对人类用户来说，系统常用账户和用户组表达身份；对 CI runner、PR bot、构建代理这类自动化主体来说，tag 更适合表达“它是什么角色”。tag 的价值在于规则可以围绕角色写，例如“PR review bot 只能访问某几个模型，且只能走某个网关实例”。

如果用访问规则表示，Aperture 看到的决策可以简化成：

$$allow = A(P_{tag}, model, provider)$$

⁰ 视频画面时间区间：00:05:42–00:07:17。

这里的 A 是教学抽象：在网络可达性讨论中，它表示 Tailscale policy/access-control file 这类网络访问规则；在 Aperture 讨论中，它表示 grants、quota、model access 等网关应用策略。真实实现会把这两类策略拆成不同配置面，正文用同一个符号只是为了突出“身份进入策略判断”这一共同结构。

其中：

- A 是 Aperture 或 tailnet 策略中配置的授权规则；
- P_{tag} 是 runner 获得的 tag 身份；
- $model$ 是请求的模型；
- $provider$ 是上游模型供应商；
- $allow$ 表示这条请求是否被允许通过。

这个公式只是教学抽象，不覆盖所有实现细节；它帮助读者抓住讲者在‘00:06:43–00:06:50’强调的要点：runner 的 tag 决定它能经由 Aperture 做什么。

图像说明 该段没有出现独立的 runner/tag 图；讲者继续停留在 Aperture 总览画面，所以正文保留机制说明，避免用重复幻灯片制造误导。

3.3 无真实 key 的沙箱：安全收益来自凭据位置

‘00:06:55–00:07:17’是 S3 的安全结论。讲者说，真实供应商 key 放在 Aperture；另一端的 runner 没有 key。因此 runner 没有东西可以意外外泄、分享、滥用，也更难越过自己边界去调用供应商。

这句话的重点在“凭据位置”。传统方式把 $K_{provider}$ 放进 Agent runtime，Agent 一旦被提示注入、工具链漏洞、日志泄漏、依赖包恶意行为或 CI 配置错误影响，真实 key 就有被读出和重放的风险。Aperture 的设计把真实 key 移到网关节点，让沙箱内部只剩：

$$runtime_config = (K_{dummy}, base_URL_{Aperture})$$

其中：

- K_{dummy} 是占位 API key，演示中后来用一个短横线表示；
- $base_URL_{Aperture}$ 是 CLI 发请求的网关地址；
- 真实上游密钥 $K_{provider}$ 保留在 Aperture。

注意

“沙箱里没有真实 key”并不等于 Agent 没有任何能力。Agent 仍能发起模型请求，能力来自 tailnet 身份和 Aperture 规则。真正改变的是可被偷走的材料：沙箱里没有可重放到供应商标的长期 provider key。

这个威胁模型很实际。CI 里的 PR bot 常处理外部贡献者提交的代码和文本，供应链风险天然较高。把供应商密钥留在网关，等于把“能否访问模型”变成一个由网络身份和网关策略实时决定的问题，而非把一串可复制的秘密交给临时运行环境。

图像说明 该安全结论主要来自口头解释，画面仍是 Aperture 总览页；因此该处不插入重复截图。

3.4 本章小结

本节把 Aperture 定义为身份感知的 AI/LLM 网关：它保存真实模型供应商密钥，接收 tailnet 上带身份的请求，并依据用户、组或 tag 执行访问规则。GitHub Actions runner 的例子说明了 CI Agent 如何通过 federated OIDC 加入 tailnet、获得 tag，再让 tag 决定模型访问范围。安全收益来自凭据重新安放：沙箱内部只有占位 key 和 base URL，真实 provider key 留在网关侧。

4 现场演示：身份化日志、工具调用与可审计流量

4.1 身份维度的仪表盘：从“谁在用”开始

从 ‘00:07:27’ 开始，讲者切到 Aperture 的现场界面，并在 ‘00:07:31–00:07:36’ 把界面改成 light mode，理由是让屏幕更易读。这个动作很小，却说明接下来的证据来自真实 UI 演示，已经离开概念幻灯片。

‘00:07:39–00:08:21’ 的第一组证据是身份化 usage metrics。讲者访问自己公司的 demo Aperture instance；他说明自己连接在 corporate tailnet 上，Aperture 知道他是谁，也知道他在自己的 laptop 上访问。因此界面按他的个人身份展示：

- 已使用的 token；
- 使用过的模型；
- 在各模型上的花费；
- 由该身份穿过 gateway 的请求列表。

这已经超出普通 API 网关的匿名流量统计。普通统计通常只知道某个 API key 或某个 endpoint 消耗了多少；这里的粒度是“某个 tailnet 身份产生了哪些模型请求”。这使审计问题从“这串 key 为什么花钱”变成“这个人、这台机器或这个 tagged bot 在什么时候请求了什么”。

关键点

演示中的第一层证据是归因能力：Aperture 把 token、模型、花费和请求列表挂到 tailnet 身份上。归因是后续审计、成本控制和权限控制的基础；没有身份，日志只是流量清单。




图 5: Aperture 仪表盘按当前身份汇总最近 30 天的请求数、Token 用量、模型分布与估算成本。

4.2 请求详情：headers、body、response 与 Claude Code 初始载荷

讲者接着点开一个请求详情。在 ‘00:08:24–00:09:27’，他展示了一个简单请求背后的完整内容：request headers、request body、response body，以及 Claude Code 在第一次请求时发送的大量上下文。讲者原本说只是让它 “say hello”，随后在界面里发现那个请求其实是 “tell me a 10-word story”。这个小插曲反而加强了演示的证据性：他沿着日志追查实际发生过的请求，而非机械复述讲稿。

Claude Code 这类开发代理的初始载荷往往很大。即便用户只输入一句短提示，CLI 仍可能发送系统提示、工具描述、会话上下文和模型参数。讲者在 ‘00:08:33–00:08:39’ 顺手指指出，即便只是请求 Claude Code “say hello”，由于上下文很多，也可能花到 20 美分级别。这个数字只代表演示实例里某条请求的成本证据，不能外推成普遍价格结论。

⁰ 视频画面时间区间：00:07:27–00:08:21




图 6: 请求详情视图同时暴露响应头与响应体，能够追踪 Claude Code 请求返回的具体 JSON 内容。

背景知识

“初始载荷”可以理解成开发代理递给模型的开场资料包。用户看到的可能只有一句话，模型看到的常常包括系统规则、工具 schema、历史上下文、环境说明等。网关能看到 request body，意味着它能解释为什么一个短提示也会产生大量 token 和成本。

现场片段

讲者在 ‘00:09:16–00:09:27’ 追到 response body 后，发现请求是一个十词故事示例：“a cat sat on a mat and then simply vanished”。这段短例子高信号，因为后面会用它调试模型计数失败。

4.3 Tagged PR Review Bot: CI Agent 的可见成本与命令

‘00:09:47–00:10:31’，讲者转向前面铺垫过的 GitHub Actions runner 场景。他展示了一个 PR review bot：这是一个在每次 PR update 上运行的简单 check。界面显示它有一个 dogfood tag，并且可以查看该 bot 在过去 30 天内做过的事情。

这个例子把 S3 的机制落成现场证据。前面说 tag 可以代表自动化主体；这里的 PR review bot 就是一个 tagged principal。讲者打开其中一条请求后指出，该请求花了 4 美分，并且同时运行了三条命令；界面能看到 bash commands 以及相关细节。

⁰ 视频画面时间区间：00:08:42–00:09:27




图 7: PR review bot 以 tag 身份进入 Aperture 视图，页面按该身份展示 30 天请求量、Token 与成本。

对安全和平台团队来说，这类证据有两个含义。第一，成本可以按 bot 或 tag 归因，避免把 CI 代理花费混进某个共享 key。第二，命令可见性把“PR bot 做了什么”从事后猜测变成可查记录。PR 审查机器人若受提示注入影响，它的模型请求、工具使用和命令轨迹至少会在这个路径上留下痕迹。

注意

这里的可见性依赖流量确实经过 Aperture。讲者的强断言发生在“通过这个 instance 的工具调用”范围内：如果 Agent 要进行模型层工具调用，它必须经过 Aperture，网关就能抽取并展示。这个边界应写清楚，避免把它误读成对任意本地进程行为的全能监控。

4.4 LLM 层与网络层结合：抽取工具调用、MCP 和 bash

在 ‘00:10:36–00:11:24’，讲者解释为什么能看到这些 bash commands。他说这正是“工作在 LLM layer，同时让一切在 network layer 通过”的有趣之处。因为请求必须通过 Aperture，网关有把握看到这个实例上发生过的每个工具调用，并在界面里抽取出来。

演示中的工具调用包括：

- 请求 MCP tool call 来更新 code review；
- 执行 bash；
- 执行 grep；
- 再次更新 code review comment。

⁰ 视频画面时间区间：00:09:47–00:10:31




图 8: Tool Use 面板从会话中提取 MCP、Bash、Read、Grep 等工具调用，显示网关可审计的工具行为。

这段要区分两层控制。网络层负责让 Agent 到模型的路径必须经过 Aperture；LLM 层负责理解请求和响应里的结构化内容，例如工具调用、MCP 调用和 shell 命令文本。单有网络层，系统能知道“谁连了谁”；单有 LLM 层日志，系统可能缺少强制流量路径。两者组合后，Aperture 才能同时提供身份、成本、请求内容和工具调用可见性。

关键点

Aperture 的演示价值在于“路径强制”和“语义抽取”同时出现：路径强制让请求绕不开网关；语义抽取让网关看到的不仅是字节流，还包括工具调用、MCP 调用、bash、grep 和 code review 更新这类 Agent 行为线索。

4.5 断开访问为何有效：占位 key 与 base URL 配置

‘00:11:21–00:11:42’，讲者说明如果要切断访问，动作发生在网络层。Agent 侧没有真实 key，因此它无法在发现当前路径失效后拿着 key 改走其他 endpoint。演示中的占位 key 只是一个 dash。这个细节很关键：dash 能满足 CLI 的“API key mode”参数检查，却不能在供应端当作真实凭据使用。

随后在 ‘00:11:43–00:12:08’，讲者打开 agent setup script，并说明 Claude Code、Codex、Gemini CLI 这类工具的配置方式：开启 API-key mode，填一个占位 key，再把 base URL 指到 Aperture endpoint。也就是说，开发者体验仍然像配置常规模型供应商，只是 endpoint 被换成网关地址。

⁰ 视频画面时间区间：00:10:36–00:11:18




图 9: Agent Setup 配置展示占位 API key 与 ANTHROPIC_BASE_URL，真实提供商密钥留在 Aperture。

这个设置可以抽象成：

$$client \rightarrow base_URL_{Aperture} \rightarrow provider(model, K_{provider})$$

其中：

- $client$ 是 Claude Code、Codex、Gemini CLI 或 PR review bot；
- $base_URL_{Aperture}$ 是客户端显式配置的网关地址；
- $provider(model, K_{provider})$ 表示 Aperture 代表客户端调用上游模型供应商；
- $K_{provider}$ 只存在于 Aperture 侧。

注意

占位 key 并非“低权限 provider key”。它只是让 CLI 接受 API-key mode 的占位字符串。权限来自 tailnet 身份和 Aperture 规则。把占位 key 当作某种供应商端凭据，会误解这个设计。

4.6 十词故事调试：日志如何解释模型失败

‘00:12:23–00:13:57’ 的十词故事示例看似轻松，实际展示了日志的调试价值。讲者在 Claude Code 中要求模型讲一个 10-word story。他提到几周前故事主题从 robot 变成 dog，现在变成 cat，借此调侃模型后端行为在变。接着模型输出 “cat sat on a mat and then found a home”，讲者马上发现它仍然不会数词，因为这句话只有 9 个词。

随后他追问模型，模型给出修正，最终把多余部分删掉。这个互动说明：在真实 PR review bot 或自动化 pipeline 中，输出格式、词数、JSON schema、固定字段等约束都可能被模型违反。若 pipeline 依赖这些约束，失败可能出现在后续步骤；如果没有请求日志，维护者只能从最终报错倒推原因。

⁰ 视频画面时间区间：00:11:43–00:12:08

USER	USER AGENT	REQUESTS	MODELS	INPUT	OUTPUT	CACHED	REASONING	TOTAL	COST
remy	claude-cl/2.1.98 (external, cli)	3	haku-4-5 opus-4-6	31,721	140	31,344	0	63,205	\$0.22
METRIC			MODEL	INPUT	OUTPUT	CACHED	REASONING	TOTAL	COST
#72268			opus-4-6	29	113	31,344	0	31,486	\$0.02
#72259			opus-4-6	31,347	14	0	0	31,361	\$0.20
#72258			haku-4-5	345	13	0	0	358	< \$0.001
remy	claude-cl/2.1.98 (external, cli)	2	haku-4-5 opus-4-6	31,692	28	0	0	31,720	\$0.20
tag.aperture-do...	claude-cl/2.1.73 (external, claude-code-github-action)	8	opus-4-6	44,581	1,780	243,556	0	289,917	\$0.44
tag.aperture-do...	claude-cl/2.1.74 (external, cli)	300	us.anthropic.claude-opu...	2,171,285	81,413	34,715,660	0	36,968,358	\$36.23
tag.aperture-do...	claude-cl/2.1.92 (external, local-agent)	1	opus-4-5	32,614	86	0	0	32,700	\$0.21
tag.aperture-do...	claude-cl/2.1.73 (external, claude-code-github-action)	68	opus-4-6 haku-4-5	344,347	23,946	4,366,155	0	4,734,448	\$1.88
ondrej	claude-cl/2.1.92 (external, cli)	3,480	opus-4-6 haku-4-5 sonnet-4-6	40,802,636	981,136	977,483,610	0	1,019,267,382	\$742.88
benson	claude-cl/2.1.92 (external, cli)	162	gim-5.1 gim-5-turbo	0	35,678	0	0	35,678	-
benson	claude-cl/2.1.92 (external, cli)	157	opus-4-6 haku-4-5	316,402	45,851	10,381,239	0	10,743,492	\$7.92

图 10: Logs 视图展开同一用户会话的三次请求，用于回看 10-word-story 调试过程中的输入、输出与成本。

Aperture 的日志在这里提供了三类证据：

- 原始提示：用户要求的是 10-word story；
- 模型响应：第一版故事没有满足词数约束；
- 修正过程：后续请求里出现了 “are you sure about that?” 以及模型承认词数错误的响应。

讲者在 ‘00:13:37–00:14:13’ 回到日志界面，看到当前 session 里有三条请求：summary 请求、第一次 10-word story 请求，以及纠错请求。对工程团队而言，这种 session 级视图能把 “模型为什么让流水线坏掉” 还原到具体请求，避免调查只停留在 CI 最后一行失败信息。

背景知识

十词故事是一个小型形式约束测试。形式约束指输出必须满足某个可检查条件，例如词数为 10、JSON 可解析、字段集合固定、命令只读、补丁只触及指定目录。LLM 很容易在这些约束上犯错，因此日志要保存提示、响应和修正链路。

4.7 本章小结

本节的现场演示证明了 S3 的架构并非停留在概念层。Aperture 仪表盘能按个人身份展示 token、模型、花费和请求；请求详情能查看 headers、body、response，以及 Claude Code 的初始载荷；tagged PR review bot 能把 CI Agent 的成本和命令归到 tag；工具调用面板能抽取 MCP tool call、bash、grep 和 code review 更新；dummy key 加 base URL 的设置说明真实 provider key 留在网关；十词故事示例展示了日志如何帮助调试模型输出约束失败。到 ‘00:14:13’ 为止，讲者已经完成 “可观察性和审计” 的主要证据链，预算、quota 和 webhook 控制从下一节展开。

⁰视频画面时间区间：00:13:37–00:13:57

5 从审计到控制：预算、配额、Webhook 与可复用的 TS net

5.1 从“看见流量”推进到“治理流量”

前一章已经说明，Aperture 的日志可以把一次 Claude Code、Codex、Gemini CLI 或 PR review bot 请求拆成身份、模型、费用、请求体、响应体与工具调用。到了 00:14:11–00:14:35，Remy 把重点从“可观察性”推到“治理”：既然所有经过网关的模型请求都会携带身份并进入同一个审计面，成本控制就不必分散在每个模型提供商的后台里。

在传统做法里，OpenAI、Anthropic、Gemini、Vertex、Bedrock 等提供商各自有账户、密钥、额度与账单边界。一个团队若给每个提供商都配置独立预算，很容易得到“每家都有一笔钱”的碎片化治理效果。Aperture 的演示强调另一种粒度：预算挂在网关侧，由身份和策略决定谁可以花多少钱，后端提供商只是被网关调用的上游。

可以把这种关系写成一个简单的治理函数。令一次模型请求为

$$f = (P, H, S, model, cost, tool_calls)$$

其中：

- P 表示发起请求的主体，可以是用户、组、标签化 agent 或 CI runner；
- H 表示运行 agent 的主机或沙箱，例如笔记本、容器、GPU 服务器或 GitHub Actions runner；
- S 表示服务节点，这里主要是 Aperture，也可以类比为内部 MCP server 或内部 API；
- $model$ 表示被调用的模型或模型提供商；若后文临时写作 m ，它只作为 $model$ 的局部别名；
- $cost$ 表示这次请求产生的成本；若后文临时写作 c ，它只作为 $cost$ 的局部别名；
- $tool_calls$ 表示网关从 LLM 层解析出的工具调用、MCP 调用、bash 命令等事件集合；若后文临时写作 T ，它只作为 $tool_calls$ 的局部别名。

Aperture 的治理点在于，策略不只看 m ，也看 P 与累计成本。对主体 P 的预算可以记为 $Q(P)$ ，则一次请求能否继续通过，至少要满足累计成本约束：

$$\sum_{f_i \in F(P)} c_i + c \leq Q(P)$$

这里 $F(P)$ 是主体 P 已经通过网关产生的历史请求集合。这个公式只是对 00:14:13–00:15:24 演示机制的教学压缩，并非演讲者展示的产品语法：预算在网关侧聚合，身份决定预算归属，提供商差异被收敛到同一个控制面。

治理点从提供商后台前移到身份化网关

Remy 在 00:14:13–00:14:35 说，Aperture 里的预算可以跨提供商生效：组织可以配置“一共一千万美元”，再由用户或 agent 按策略使用，避免给每个提供商分别塞一笔预算。这个设计的关键收益是统一归因、统一限额、统一停用。




图 11: Aperture 的 Adoption 视图按成本维度展示跨用户、跨标签的使用趋势，为统一预算控制提供依据。

5.2 配额：把安全边界落到每天、每队、每人的数字上

00:15:03–00:15:24 的配额示例更接近日常治理：管理员可以配置“每天 5 美元”这一类限制，让用户或 agent 在网关内“安全地玩”。这里的“安全”有具体工程含义，至少包含三层约束。

第一层是身份约束。配额属于某个主体，例如个人、团队、tagged bot 或 CI runner。没有身份归因，配额只能落在全局账户上，最后会变成“谁烧钱都算在同一个大池子里”。

第二层是模型约束。Q&A 中 00:20:36–00:21:27 又补充，当前 Aperture 的权限主要围绕模型、提供商和配额展开。例如内部 GPU endpoint 可以更宽松，高价外部模型如演讲中提到的 Opus 4.6 可以给较小额度。读者需要注意，这里说的是当前产品面已经覆盖的核心维度：模型、提供商、预算、配额。更细的 tool-level policy 是后续方向，不能把它写成已经完整落地的事实。

第三层是停用约束。因为 agent 运行时只有占位 API key，并且显式把 base URL 指向 Aperture，一旦网关侧拒绝请求，agent 没有真实 provider key 可拿去绕路。前文 00:11:21–00:12:08 的演示支撑了这一点：运行时为了兼容 CLI 的 API-key 模式只放了一个短横线式的 dummy key，真实 provider key 留在 Aperture 节点。

不要把“能观察”误读成“已经能管所有行为”

Aperture 当前已经演示了跨 provider 的预算、模型/提供商权限、配额、hooks 和日志归因。演讲者在 00:20:25–00:21:27 明确说，按用户限制具体工具的能力还在推进中。写成“已经能精细限制所有工具”会夸大当前能力。

⁰ 视频画面时间区间：00:14:13–00:14:35




图 12: 配额配置界面把容量、速率和超限动作组织成可审计的规则，例如按天限制预算并在超限时拒绝。

5.3 Webhook: 把工具调用事件接到组织自己的系统

00:14:35–00:15:00 的第二个治理机制是 integrations 与 webhooks。Aperture 可以在每个工具调用或相关事件发生时，向第三方系统发送请求，并附带工具调用信息。前一章里，网关已经能显示 PR review bot 的 MCP 调用、bash、grep、更新 code review comment 等事件；Webhook 把这些“可见的事件”变成“可被组织系统消费的事件”。

一个实际组织可能把这些事件送往安全审计、SIEM、工单系统、通知系统或自建策略服务。举例说，PR review bot 在 00:10:18–00:10:31 被演示为一次请求花费 4 美分并运行三个命令；如果同类事件通过 webhook 发出，接收方就可以按 bot 标签、仓库、命令类别、模型费用或时间窗口建立后续流程。

Remy 对 hooks 的可靠性说法有一个重要限定：可靠性来自“这些工具调用必须经过 Aperture 才能被模型执行”的流量路径。换句话说，对于已经配置为走 Aperture base URL 的 agent，网关能看到该 LLM 流量，并据此触发 hooks。这个保证不应扩大成“组织网络中的所有命令都会被 Aperture 捕捉”。如果某个程序完全绕过 LLM 网关、直接在本机执行命令，Aperture 的 LLM 层日志自然看不到那条本机执行路径。

Webhook 与审计日志的区别

审计日志偏向事后追溯：谁在什么时候用哪个模型、花了多少钱、发了什么请求、模型返回了什么、工具调用是什么。Webhook 偏向事件驱动：当某个工具调用被网关观察到时，立刻把结构化信息推给外部系统。前者回答“发生过什么”，后者支持“发生时让其他系统参与”。

⁰ 视频画面时间区间：00:15:03–00:15:24




图 13: Aperture 的 Integrations 视图展示安全、监控、开发者扩展与 Build Your Own webhook 入口。

5.4 TS net：把同一套身份原语复用到内部服务

00:15:27–00:16:44 是主讲部分的收束，也是在产品演示之外最值得保留的一段。Remy 说 Aperture 可在 Tailscale 免费计划中使用，同时强调它建立在 Tailscale identity primitives 之上；这些原语通过开源 Go 库 TS net 暴露出来。开发者可以写一个 Go 程序，让它自己加入 tailnet，并读取同样的身份信息。

这个点把演讲从“Aperture 这个产品”提升到“网络沙箱这个架构模式”。如果一个组织有内部 MCP server、内部 API endpoint 或只给员工和 agent 使用的代理服务，它可以使用同一条路径：

1. 服务作为 tailnet 节点加入网络；
2. 请求进入服务时携带 Tailscale 提供的用户、组、tag 等身份；
3. 服务根据身份决定是否允许访问、怎样记录审计、怎样把身份注入后端 MCP 或 API；
4. 外部公网开放、额外 OAuth 流程、裸 API key 分发等负担可以被压缩到更小范围。

演讲者在 00:16:26–00:16:44 还补了一句边界条件：Aperture 被要求建立在 Tailscale 公开能力之上，不能依赖内部私有 API endpoint。因此，从理论上讲，开发者可以用同样原语复刻类似服务。这句话的含义很具体：可复用的是 Tailscale 网络身份、访问控制与 TS net 能力；Aperture 自身的产品 UI、provider 适配、日志体验、配额系统与 webhook 生态仍然是工程实现。

Aperture 是示范应用，TS net 是可迁移原语

如果只记住 Aperture，读者得到的是一个 AI gateway 产品。如果记住 TS net，读者得到的是一套可迁移架构：把内部服务放进 tailnet，让连接自带身份，再在服务端按身份做访问控制、审计、配额或事件触发。

⁰ 视频画面时间区间：00:14:35–00:15:00

图像说明 TS net 与内部服务复用部分没有清晰可读的独立幻灯片；该机制由正文和小结承担。

这一模式与几个常见概念相邻，需要分清边界。它像 VPN，因为它把节点放进私有网络；它像 service mesh，因为它让服务间流量带有身份和策略；它也像 sidecar/gateway，因为访问可以集中经过一个控制点。演讲里的重点更窄：Tailscale/WireGuard 提供网络连接，Tailscale identity primitives 提供主体信息，Aperture 或自建 TS net 服务在应用层消费这些身份并执行策略。

5.5 本章小结

本章覆盖 00:14:11–00:17:04 的主讲收束。关键结论有三点。第一，Aperture 把日志观察推进到治理动作：跨 provider 预算、每日或团队配额、模型/提供商权限都可以围绕同一套身份归因执行。第二，Webhook 把网关观察到的工具调用事件送到组织自己的系统，但这个可靠性依赖 agent 的 LLM 流量确实经过 Aperture。第三，TS net 说明这套设计不局限于 LLM gateway；内部 MCP server 和内部 API endpoint 也可以加入 tailnet，读取同样的身份，并把网络沙箱模式扩展到组织内部服务。

6 问答：策略配置、透明代理与代码执行型 Agent 的边界

6.1 权限配置：Aperture grants 与 Tailscale policy file

00:17:04–00:18:42 的第一个问题直接问“权限如何配置”。Remy 的回答给了两个位置。

第一处是 Aperture 的 grants。演示里可以指定规则适用于谁，随后配置 model access and quotas、MCP access、hooks、roles 等。Remy 还提到 groups 会加入这一界面。这里的 grant 可以理解为应用层授权规则：它把“哪个主体可以使用哪些 Aperture 能力”写成可管理对象。

第二处是 Tailscale 的 policy/access-control file。Tailscale 的主策略文件定义谁能访问网络上的什么资源。更重要的是，Q&A 里展示了 application capability：管理员可以把应用能力或任意 metadata 放进主 ACL/access-control file，让这些信息随身份一起传给应用。这样，服务端收到的不只是“某个连接来自某个 IP”，也可以收到用户、tag、组以及由 Tailscale control plane 保证的应用元数据。

00:17:04–00:18:42

观众：权限怎么配置？比如谁能访问什么？

Remy：可以在两个地方配置。一个是在 Aperture 的 grants 里，设置适用主体以及 model access and quotas、MCP access、hooks、roles。另一个是在 Tailscale 的 policy/access-control file 里，通过 application capability 把元数据随身份发送。

这段问答的价值在于，它把“网络身份”从概念落到管理界面与策略文件。面向小团队，visual editor 可能足够；面向规模化组织，00:18:23–00:18:42 提到 JSON、API 和 GitOps workflow。这意味着同一套策略可以进入代码审查、版本管理、自动化发布和回滚流程。

Application capability 的直觉

可以把 application capability 想成一张随连接递交的“应用层通行证”。普通网络策略只说“这个主体能不能到达这个服务”；application capability 还能携带“这个主体在该应用里拥有哪些能力、配额或角色”一类元数据。演讲者强调，这些任意 metadata 由 Tailscale control plane 保证并随身份传递。




图 14: Grants 配置界面把适用主体、模型访问、配额、MCP 访问和 Hook 组合成应用能力策略。

图像说明 该视觉状态已经在图 14 中出现；此处沿用同一张图作为机制参照，不重复插入。

6.2 透明拦截的取舍：为什么显式 base URL 仍然重要

第二个问题出现在 00:18:44–00:20:24。观众注意到 Claude Code 设置里显式把 base URL 指向 Aperture 节点，于是追问：能不能在网络层透明捕获默认发往模型提供商的流量，并把它换到 Aperture？

Remy 的回答很直接：这在技术上可以做，也曾是早期讨论重点。最终选择显式 base URL，是为了让开发者体验和管理员控制更可预测。透明拦截的诱惑很大，因为用户似乎不需要改配置；代价也很现实：请求路径在底层被悄悄替换后，开发者调试时会看到行为“移动到脚下”，出错时很难判断是 CLI、provider、代理、证书、DNS、路由还是策略导致。

显式 base URL 的设计把责任边界写在配置里。开发者知道自己的 LLM access 通过 Aperture；IT/security admin 知道哪些 agent 被纳入可观察与可控制范围；当策略拒绝、配额耗尽、provider 返回异常或请求体不符合预期时，排障路径更短。

透明代理会降低配置负担，也会增加解释成本

透明拦截适合“用户无感接入”，显式 base URL 适合“路径可解释、责任可追踪”。Remy 的取舍偏向后者：让构建 AI 的开发者容易接入，同时让 IT/security admin 得到明确的控制面、工具调用可见性与审计路径。

图像说明 问答阶段投影过曝，base URL 问题没有可读画面；可参照前文的 Agent Setup 图理解显式 base URL 配置。

⁰ 视频画面时间区间：00:17:16–00:18:24

6.3 当前权限面：模型、提供商、配额；未来走向更丰富控制

00:20:25–00:21:27 的第三个问题追问权限粒度：能不能说“这些用户允许使用这些工具”，还是目前只能限制 model/provider？

这里必须写得克制。Remy 的回答可以拆成“当前状态”和“发展方向”。

当前状态：今天的权限主要是 model/provider，并且配额系统共享同一套 permissioning。也就是说，可以表达某个组、某个身份提供商同步来的群组或某个主体能访问哪些模型与 provider；同时可以表达预算层面的差异，例如一个团队有较大预算，个人有较小预算，内部 GPU endpoint 使用较宽松，昂贵外部模型使用较受限。

发展方向：凡是放进 Aperture 的能力，团队希望都能被同一套授权系统控制。这个方向包括更细的工具权限与更丰富的应用能力，但演讲者没有把它描述成已经完整可用。这个限制很关键，因为 AI agent 的风险管理常常输在过度承诺：如果文档暗示“已经能管住所有工具”，安全团队会基于错误前提设计流程。

当前能力与未来能力要分开记

当前已明确覆盖：模型、provider、预算、quota，以及围绕 grants 的 MCP access、hooks、roles 等配置面。这里的“配置面”表示界面和策略对象已经能承载这些能力入口；细粒度 per-tool enforcement、危险 shell 命令阻断、混淆代码识别等仍属于演进方向。当前文档应把后者写成未来 guardrails，而非已经完整实现的控制能力。

图像说明 该视觉状态已经在图 14 中出现；此处沿用同一张图作为机制参照，不重复插入。

6.4 代码执行型 Agent：LLM 层可见性的价值与盲点

最后一个技术问题在 00:21:27–00:23:39。观众提出一个更难的边界情况：如果 agent 越来越少使用结构化 tool call 或 MCP，转向“写代码再执行代码”，权限该如何工作？观众还指出，这会让某些网络流量更难解析。

Remy 承认这个场景更复杂。他解释说，团队早期考虑过只在 MCP 层做，后来判断 LLM 层更有价值。原因是 MCP 层只能覆盖结构化 MCP 调用；真实 agent 工作流里，许多动作会通过 bash、grep、脚本、代码执行或其他 CLI 形式出现。演讲者还提到，在他们内部真实实例里，bash 使用量压过其他形式。对很多组织来说，第一阶段需求甚至还没有到“阻断每个动作”，更朴素的问题排在前面：agent 到底在用什么工具，做了什么？

LLM 层可见性的意义在这里出现。即便 agent 写代码再运行，通常仍会在上下文中生成命令、解释执行意图、调用 shell 或把结果带回模型。Aperture 位于 LLM 请求路径上，就有机会看到这些命令和上下文，并把它们作为日志、审计事件或未来 guardrail 输入。这个机会并不等于全知。Remy 也承认，agent 可能先写出混淆代码，再分步执行；这种行为会让解析和权限判断变难。

00:21:27–00:23:39

观众：如果 agent 不做 tool calls，只是在写代码并执行代码，权限怎么工作？

Remy：这更复杂，所以他们选择看 LLM 层。只看 MCP 层会漏掉太多；很多用户首先想知道 agent 到底在用 MCP、bash，还是其他命令。

LLM 层 visibility 不能替代运行时沙箱

LLM 层日志可以暴露大量 agent 意图、命令和工具使用痕迹，尤其适合审计与策略输入。它不能替代进程隔离、文件系统权限、容器限制、系统调用过滤或端点安全。代码执行型 agent 的完整治理通常需要多层控制：网络层身份、LLM 层观察、运行时隔离、文件/密钥权限和命令级策略共同工作。




图 15: Metric Details 中的 Tool Use 区域展示 Bash 与 Grep 调用，说明 LLM 层可见性如何暴露代码执行型 Agent 的实际命令。

6.5 未来护栏：从看见 shell 命令到拦截危险动作

00:23:18–00:23:38 是未来工作最清楚的一句。Remy 说团队会增加更多 guardrails，例如网关已经看到一条 bash command 时，可以判断类似危险删除命令是否应继续。演讲中的例子是破坏性 shell 命令；这个例子很刻意，因为它代表从“记录命令”走向“对命令含义做策略判断”。

这里同样需要保守表达。当前演示已经显示可以看到命令，未来护栏会利用这些命令做更多判断。演讲没有证明完整的 shell policy engine、跨平台命令语义分析、混淆检测、脚本展开、参数污点分析或文件系统影响评估已经存在。真实产品若要把这一方向做扎实，还需要面对至少四个工程难题。

- 命令语义：同一个危险效果可能由不同 shell、脚本语言、别名、工具链组合表达。
- 上下文依赖：删除临时目录和删除根目录的风险完全不同，策略需要知道工作目录、路径解析和权限范围。
- 绕行风险：agent 可以把命令写入脚本、下载二进制、生成混淆代码或分多步执行。
- 误报成本：过严会阻断正常开发，过松会把 guardrail 变成审计装饰。

⁰ 视频画面时间区间：00:21:51–00:23:39

未来 guardrail 的合理定位

未来 shell-command guardrail 更像“LLM 网关侧的策略前置检查”，适合在模型建议或调用命令时介入。它应与运行时沙箱、最小权限文件系统、密钥隔离和网络出站策略组合使用。单靠一层 LLM 可见性不足以承诺代码执行环境的完整安全。

6.6 本章小结

本章覆盖 00:17:04–00:24:12 的 Q&A。第一，权限可以在 Aperture grants 和 Tailscale policy/access-control file 两处配置，并可通过 application capability 携带任意 metadata；视觉编辑、JSON、API、GitOps 都是策略工作流的一部分。第二，透明拦截技术上可行，但 Remy 选择显式 base URL，以换取开发者可预测性和管理员可解释控制。第三，当前权限面主要围绕模型、provider、预算和配额，未来会扩展到更丰富对象。第四，代码执行型 agent 是更难的边界情况；Aperture 选择 LLM 层，是因为现实中的工具使用并不限于 MCP，bash 和代码执行仍会在模型交互中留下可观察信号。最后，未来 guardrails 可以基于观察到的 shell 命令做更细判断，但这仍应被视为多层安全体系中的一层。

7 总结与延伸

7.1 把本讲压缩成一条架构链

这场演讲的主线可以压缩成一条很短的链条：

身份化网络 → AI 网关 → 可审计流量 → 可执行治理

其中每一环都解决前一环留下的具体问题。身份化网络先回答“这个连接来自谁或哪个自动化身份”；AI 网关再把模型请求集中到一个能读取该身份的位置；可审计流量把 prompt、响应、工具调用、成本和会话串起来；可执行治理再在这个基础上配置预算、配额、webhook、grant 和后续 guardrails。若只保留“网络是沙箱”这句口号，读者会误以为这是普通 VPN 或代理模式；若沿着这条链看，本讲实际讨论的是一种把 Agent 外部能力收束到网络身份和网关策略上的工程模式。

核心结论

沙箱的强度不只取决于运行时边界，也取决于权限从哪里进入。把真实 provider key 放在 Agent runtime 里，等于让受约束主体接触到授予能力的材料；把真实 key 放在 Aperture 这样的身份化网关上，Agent runtime 只保留占位 key 和 base URL，权限就可以由 tailnet 身份、tag、grant、quota 和网关观察到的请求共同决定。

7.2 讲者结尾真正留下的开放空间

讲者在主讲结尾没有把 Aperture 描述成唯一答案。他强调 Aperture 使用的是 Tailscale 公开身份原语，并提到开发者可以用 TS net 写自己的 Go 程序，让内部 MCP server 或内部 API endpoint 加入 tailnet、读取同样的身份信息，再按组织需要做访问控制。这说明本讲的可迁移部分是身份原语和网关位置，而非某一个固定 UI。

Q&A 进一步补上了边界条件。第一，权限配置既可以在 Aperture 的 grants 中完成，也可以放进 Tailscale policy/access-control file，并通过 application capability 传递任意元数据。第二，透明拦截模型在技术上可以做，可是显式 base URL 更容易让开发者和 IT/安全管理员理解系统实际路径。第三，

当前权限粒度主要覆盖 model、provider、quota 等控制面，工具级权限仍在演进。第四，对于逐渐转向代码执行的 Agent，单靠 MCP 层看不全；Aperture 选择 LLM 层，是为了尽量观察 bash、grep、文件读取、评论更新等真实命令痕迹。

不要把未来能力写成当前事实

演讲中提到对 shell 命令增加更多 guardrails，例如遇到危险命令时阻止或提醒，这是未来方向。当前材料能稳妥支持的说法是：Aperture 已能在 LLM 层记录并展示大量工具调用和命令线索，因而为后续 guardrails 提供观察基础。

7.3 实践含义

对团队落地而言，本讲可以转化为四个检查问题。第一，Agent runtime 里是否存在可复用的真实 provider key、刷新 token 或用户登录态。第二，CI runner、PR bot、开发机、容器、GPU 节点是否能被映射为稳定身份，而非只靠 IP 或共享 key 区分。第三，模型请求是否经过一个能够记录身份、prompt、响应、模型、成本和工具调用的统一网关。第四，预算、配额、webhook、grant、access-control file 是否能和身份绑定，而非散落在各 provider 控制台里。

用一个直观类比收束：传统做法像把一串万能钥匙交给临时施工队，然后要求施工队待在围栏里；本讲的模式像让施工队刷临时工牌进入楼层，具体能开哪扇门由门禁系统决定，楼宇后台还能记录进入时间、访问房间和操作痕迹。围栏仍然重要，可是真正让系统可控的是“身份、门禁、日志、规则”四件事同时工作。