

课程笔记

最优传输的理论与计算系列讲座（二） Monge–Kantorovich 问题与对偶理论

主讲：顾险峰（纽约州立大学石溪分校）

整理日期：2023 年 11 月



视频作者/频道：Upupupxiaohua

发布日期：2023 年 11 月 21 日

视频时长：2 小时 1 分 44 秒

视频链接：<https://www.bilibili.com/video/BV1Da4y1U78N?p=2>

目录

1 引言：从离散到连续	3
1.1 讲座背景与目标	3
1.2 两种视角的对比	3
2 离散最优传输的运筹学描述	3
2.1 生产者-消费者模型	3
2.2 线性规划的对偶问题	4
2.3 弱对偶性与互补松弛条件	4
3 Monge 问题：寻找最优传输映射	5
3.1 问题的历史起源	5
3.2 Monge 问题的困难	5
4 Kantorovich 问题：传输方案	5
4.1 Kantorovich 的突破性思想	5
4.2 Kantorovich 问题的优势	6
4.3 Monge 与 Kantorovich 问题的关系	6
5 对偶理论：Kantorovich 势能	6
5.1 对偶问题的推导	6
5.2 弱对偶性与强对偶性	7
5.3 互补松弛条件的连续版本	7
6 C-变换与 Legendre 变换	7
6.1 C-变换的定义	7
6.2 C-变换的基本性质	7
6.3 几何直观：支撑超平面	8
7 循环单调性与 Rockafellar 定理	8
7.1 c-循环单调性	8
7.2 Rockafellar 定理	8
7.3 次微分与最优传输映射	9
8 存在性证明：先验估计方法	9
8.1 证明策略概述	9
8.2 等度连续与一致有界	9
8.3 连续模与 C-变换的保持	10
9 与深度学习的关系	10
9.1 最优传输作为概率分布之间的距离	10
9.2 Sinkhorn 算法与熵正则化	10
9.3 模式坍塌 (Mode Collapse) 的几何解释	11

10 总结与延伸	11
10.1 本次讲座的核心脉络	11
10.2 核心要点回顾	12
10.3 后续学习路径	13
10.4 顾教授的寄语	13

1 引言：从离散到连续

1.1 讲座背景与目标

本次讲座由顾险峰教授主讲，延续第一讲的内容，从运筹学的离散视角过渡到经典的最优传输理论，深入讲解 Monge 问题、Kantorovich 问题以及对偶理论的核心思想。讲座特别强调几何直观与理论严谨性的平衡，旨在帮助听众建立对最优传输问题内在结构的深刻理解。

学习建议

顾教授反复强调：学习最优传输理论应当“先看清整个森林，再去研究每一棵树”。即先掌握整体理论图景和几何直观，再逐步深入各个定理的严密证明。这与传统数学教材“从定义到定理”的写法恰好相反，但更符合人类认知规律。

1.2 两种视角的对比

最优传输理论可以从两个层面理解：

- 运筹学视角（离散）**：将问题建模为线性规划，变量为传输方案矩阵 γ_{ij} ，约束为供需平衡。优点是容易理解、算法成熟（单纯形法、内点法）；缺点是丢失了几何结构信息，无法判断解的光滑性、唯一性等深层性质。
- 数学分析视角（连续）**：将问题建立在测度空间上，研究传输映射/方案的存在性、唯一性、正则性。优点是揭示了问题的内在几何结构；缺点是需要较深的数学准备（测度论、泛函分析、偏微分方程）。

常见误区

许多深度学习从业者仅通过 Sinkhorn 算法和线性规划对偶来理解最优传输，这相当于“只看到冰山一角”。虽然足以应付工程应用，但对于深入研究远远不够。顾教授建议：先建立连续理论的直观，再回看离散算法，方能融会贯通。

2 离散最优传输的运筹学描述

2.1 生产者-消费者模型

考虑经典的运输问题：设有 m 个生产者 $P_1, P_2, \dots, P_m$ 和 n 个消费者 $Q_1, Q_2, \dots, Q_n$ 。生产者 P_i 的产量为 a_i ，消费者 Q_j 的需求量为 b_j ，满足供需平衡：

$$\sum_{i=1}^m a_i = \sum_{j=1}^n b_j.$$

从 P_i 到 Q_j 运输单位货物的成本为 c_{ij} 。设运输方案为 $\gamma_{ij} \geq 0$ （从 P_i 运往 Q_j 的货物量），则最优传输问题为：

$$\begin{aligned}
\min_{\gamma} \quad & \sum_{i=1}^m \sum_{j=1}^n c_{ij} \gamma_{ij} \\
\text{s.t.} \quad & \sum_{j=1}^n \gamma_{ij} = a_i, \quad \forall i, \\
& \sum_{i=1}^m \gamma_{ij} = b_j, \quad \forall j, \\
& \gamma_{ij} \geq 0.
\end{aligned} \tag{1}$$

核心观察

可行解集合 $\{\gamma_{ij}\}$ 构成一个凸多面体（由线性等式和不等式约束定义），目标函数是线性的。因此最优解必在凸多面体的顶点处达到，这构成了单纯形法的理论基础。

2.2 线性规划的对偶问题

上述原始问题（Primal）的对偶问题（Dual）引入影子价格（shadow prices） u_i （生产者的价格）和 v_j （消费者的价格）：

$$\begin{aligned}
\max_{u,v} \quad & \sum_{i=1}^m a_i u_i + \sum_{j=1}^n b_j v_j \\
\text{s.t.} \quad & u_i + v_j \leq c_{ij}, \quad \forall i, j.
\end{aligned} \tag{2}$$

影子价格的经济意义

影子价格反映了资源的稀缺程度：

- 若某资源在最优解中被完全用尽（约束紧），其影子价格 > 0 ；
- 若某资源有剩余（约束松），其影子价格 $= 0$ 。

在连续最优传输理论中，影子价格将推广为 Kantorovich 势能函数（Kantorovich potentials）。

2.3 弱对偶性与互补松弛条件

对于任意可行解 (γ_{ij}) 和 (u_i, v_j) ，有弱对偶不等式：

$$\sum_{i,j} c_{ij} \gamma_{ij} \geq \sum_i a_i u_i + \sum_j b_j v_j.$$

在最优解处，互补松弛条件成立：

$$\gamma_{ij} > 0 \quad \Rightarrow \quad u_i + v_j = c_{ij}.$$

这意味着：只有在运输成本恰好等于影子价格之和的路线上，才会有实际运输发生。

3 Monge 问题：寻找最优传输映射

3.1 问题的历史起源

Monge 问题由法国数学家 Gaspard Monge 于 1781 年提出，是最优传输理论的起点。问题的提法如下：

给定两个概率测度空间 (X, μ) 和 (Y, ν) ，以及代价函数 $c : X \times Y \rightarrow \mathbb{R}_+$ ，寻找可测映射 $T : X \rightarrow Y$ 使得：

1. **保测度条件** (push-forward)： $T_{\#}\mu = \nu$ ，即对任意可测集 $B \subseteq Y$ ，

$$\mu(T^{-1}(B)) = \nu(B).$$

2. **最优性**：最小化总传输代价

$$\inf_T \int_X c(x, T(x)) d\mu(x).$$

保测度的物理意义

保测度条件对应流体力学中的质量守恒定律：质量既不会凭空产生，也不会凭空消失。若将 μ 视为源区域的密度分布， ν 为目标区域的密度分布，则映射 T 描述了如何将源区域的质量“推”到目标区域，同时保持总质量不变。

3.2 Monge 问题的困难

Monge 问题看似自然，但存在根本性困难：

1. **非线性约束**：保测度条件 $T_{\#}\mu = \nu$ 对 T 是非线性约束，使得可行解集合非凸。
2. **非紧性**：即使 X 和 Y 是紧度量空间，满足保测度条件的映射集合在适当的拓扑下也未必是紧的。这意味着极小化序列可能收敛到某个极限，但该极限不再是一个映射。
3. **存在性问题**：当 μ 包含原子 (Dirac 测度) 时，可能不存在满足保测度条件的映射。例如，若 $\mu = \delta_{x_0}$ (单点质量) 而 ν 是连续分布，则任何映射 T 的像 $T(x_0)$ 只能是一个点，无法“分裂”成连续分布。

Monge 问题的本质缺陷

Monge 问题要求从一点出发的质量只能映射到一点 (不能分裂)。这导致当源测度有原子而目标测度连续时，可行解集合为空。这一缺陷促使 Kantorovich 将“映射”放松为“传输方案” (联合概率分布)，从而解决了存在性问题。

4 Kantorovich 问题：传输方案

4.1 Kantorovich 的突破性思想

1942 年，Leonid Kantorovich (后来获得 1975 年诺贝尔经济学奖) 提出了关键的放松：不再要求传输是一个映射，而允许质量从一点“分裂”到多个点。数学上，这对应于在乘积空间 $X \times Y$ 上寻找联合概率测度 (传输方案) $\gamma \in \mathcal{P}(X \times Y)$ 。

Kantorovich 问题的数学表述

$$\inf_{\gamma \in \Pi(\mu, \nu)} \int_{X \times Y} c(x, y) d\gamma(x, y), \quad (3)$$

其中耦合集合 (couplings) 定义为:

$$\Pi(\mu, \nu) = \{\gamma \in \mathcal{P}(X \times Y) : (\pi_X)_\# \gamma = \mu, (\pi_Y)_\# \gamma = \nu\}.$$

这里 $\pi_X(x, y) = x$ 和 $\pi_Y(x, y) = y$ 是投影映射。

4.2 Kantorovich 问题的优势

与 Monge 问题相比, Kantorovich 问题具有以下优势:

1. **可行解集合非空**: 至少存在乘积测度 $\mu \otimes \nu \in \Pi(\mu, \nu)$ 。
2. **凸性**: $\Pi(\mu, \nu)$ 是凸集 (概率测度的凸组合仍是概率测度), 目标函数对 γ 是线性的。因此 Kantorovich 问题是一个无穷维线性规划问题。
3. **紧性**: 在弱收敛拓扑下, $\Pi(\mu, \nu)$ 是紧的 (Prokhorov 定理), 保证了解的存在性。

4.3 Monge 与 Kantorovich 问题的关系

包含关系

任何 Monge 问题的解 T 都对应一个 Kantorovich 问题的解: 取 $\gamma = (\text{id}, T)_\# \mu$, 即由映射 T 诱导的耦合。此时 γ 集中在 $X \times Y$ 的某个子图 (graph) 上:

$$\text{supp}(\gamma) \subseteq \{(x, T(x)) : x \in X\}.$$

因此, Monge 问题的解空间是 Kantorovich 问题解空间的子集。当最优传输方案 γ 的支撑集是某个映射的图时, Kantorovich 问题的解也解决了 Monge 问题。

5 对偶理论: Kantorovich 势能

5.1 对偶问题的推导

Kantorovich 问题的对偶形式是其理论核心。通过 Lagrange 乘子法 (或 Fenchel–Rockafellar 对偶), 原始问题的对偶为:

Kantorovich 对偶问题

$$\sup_{(\phi, \psi) \in \Phi_c} \left\{ \int_X \phi(x) d\mu(x) + \int_Y \psi(y) d\nu(y) \right\}, \quad (4)$$

其中

$$\Phi_c = \{(\phi, \psi) \in L^1(\mu) \times L^1(\nu) : \phi(x) + \psi(y) \leq c(x, y), \forall (x, y) \in X \times Y\}.$$

函数 ϕ 和 ψ 称为 **Kantorovich 势能** (Kantorovich potentials), 是离散情形下影子价格的连续类比。

5.2 弱对偶性与强对偶性

对于任意可行的 $\gamma \in \Pi(\mu, \nu)$ 和 $(\phi, \psi) \in \Phi_c$, 有:

$$\begin{aligned} \int_{X \times Y} c(x, y) d\gamma(x, y) &\geq \int_{X \times Y} [\phi(x) + \psi(y)] d\gamma(x, y) \\ &= \int_X \phi(x) d\mu(x) + \int_Y \psi(y) d\nu(y). \end{aligned}$$

因此原始问题的值 $\geq$ 对偶问题的值 (弱对偶)。在适当条件下 (如 X, Y 紧且 c 连续), 强对偶成立: 原始问题与对偶问题的最优值相等。

对偶间隙为零的条件

强对偶性在以下条件下成立:

- X, Y 是 Polish 空间 (完备可分度量空间);
- $c: X \times Y \rightarrow [0, +\infty]$ 是下半连续函数;
- μ, ν 具有有限矩 (即 $\int c(x, y_0) d\mu < \infty$ 对某个 $y_0 \in Y$)。

5.3 互补松弛条件的连续版本

在最优解 $(\gamma^*, \phi^*, \psi^*)$ 处, 互补松弛条件变为:

$$\phi^*(x) + \psi^*(y) = c(x, y) \quad \gamma^*\text{-a.e.}$$

这意味着: 在最优传输方案的支撑集上, 势能之和恰好等于传输代价; 在支撑集之外, 势能之和严格小于代价 (因此没有质量被运输到这些点)。

6 C-变换与 Legendre 变换

6.1 C-变换的定义

C-变换 (C-transform) 是最优传输理论中最核心的概念之一, 它将 Legendre 变换推广到一般的代价函数。

C-变换的定义

给定函数 $\psi: Y \rightarrow \mathbb{R} \cup \{-\infty\}$, 其 **c-变换** $\psi^c: X \rightarrow \mathbb{R} \cup \{-\infty\}$ 定义为:

$$\psi^c(x) = \inf_{y \in Y} [c(x, y) - \psi(y)]. \quad (5)$$

类似地, 给定 $\phi: X \rightarrow \mathbb{R} \cup \{-\infty\}$, 其 **$\bar{c}$ -变换**为:

$$\phi^{\bar{c}}(y) = \inf_{x \in X} [c(x, y) - \phi(x)].$$

6.2 C-变换的基本性质

1. **不等式:** $\psi^c(x) + \psi(y) \leq c(x, y)$ 对所有 (x, y) 成立。

2. **两次变换**: $(\psi^c)^{\bar{c}} \geq \psi$, 等号成立当且仅当 ψ 是 c -凹的 (c -concave)。
3. **最优性**: 若 (ϕ, ψ) 是对偶问题的最优解, 则必有 $\phi = \psi^c$ 且 $\psi = \phi^{\bar{c}}$ (在适当意义下)。

与 Legendre 变换的联系

当 $X = Y = \mathbb{R}^n$ 且 $c(x, y) = \langle x, y \rangle$ (内积代价) 时, c -变换退化为经典的 Legendre 变换:

$$\psi^c(x) = \inf_y [\langle x, y \rangle - \psi(y)] = -\psi^*(x),$$

其中 ψ^* 是凸共轭函数。对于 $c(x, y) = \frac{1}{2}|x - y|^2$, 经过适当变换后也与 Legendre 变换密切相关。

6.3 几何直观: 支撑超平面

C -变换的几何意义可以通过支撑超平面来理解:

- 固定 x , 函数 $y \mapsto c(x, y) - \psi(y)$ 的图像可以看作一族“曲面”;
- $\psi^c(x)$ 是这些曲面在 x 处的下包络 (infimum envelope);
- 对于二次代价 $c(x, y) = \frac{1}{2}|x - y|^2$, 这些“曲面”是抛物面, 其下包络给出最优传输映射的势能函数。

7 循环单调性与 Rockafellar 定理

7.1 c -循环单调性

c -循环单调性的定义

集合 $\Gamma \subseteq X \times Y$ 称为 **c -循环单调** (c -cyclically monotone) 的, 如果对任意有限点列 $(x_1, y_1), \dots, (x_n, y_n) \in \Gamma$ 和任意排列 σ of $\{1, \dots, n\}$, 有:

$$\sum_{i=1}^n c(x_i, y_i) \leq \sum_{i=1}^n c(x_i, y_{\sigma(i)}). \quad (6)$$

直观理解: 在最优传输方案中, 任意重新配对都会增加总代价。

7.2 Rockafellar 定理

Rockafellar 定理建立了循环单调性与凸分析之间的深刻联系:

Rockafellar 定理

集合 $\Gamma \subseteq X \times Y$ 是 c -循环单调的, 当且仅当存在 c -凹函数 ϕ 使得

$$\Gamma \subseteq \{(x, y) : \phi(x) + \phi^{\bar{c}}(y) = c(x, y)\}.$$

即 Γ 包含于某个 c -凹函数与其 $\bar{c}$ -变换的“接触集”中。

定理的意义

Rockafellar 定理说明：

1. 任何最优传输方案的支撑集都具有 c -循环单调性；
2. 反之，任何 c -循环单调集都可以由某个 c -凹函数的次微分图（subdifferential graph）来刻画；
3. 这建立了最优传输方案与凸分析/次微分理论之间的桥梁。

7.3 次微分与最优传输映射

对于 c -凹函数 ϕ ，定义其在 x 处的 c -次微分：

$$\partial^c \phi(x) = \{y \in Y : \phi(x) + \phi^c(y) = c(x, y)\}.$$

关键结论

若 ϕ 是 c -凹的且在最优传输方案的支撑集上， $\partial^c \phi(x)$ 是单点集，则最优传输方案实际上由一个映射 $T(x) = \partial^c \phi(x)$ 给出。这解决了 Kantorovich 问题何时也解决 Monge 问题的问题。

8 存在性证明：先验估计方法

8.1 证明策略概述

Kantorovich 对偶问题解的存在性证明依赖于以下关键步骤：

1. 构造一个极大化序列 (ϕ_n, ψ_n) ；
2. 证明该序列一致有界且等度连续；
3. 应用 Arzelà–Ascoli 定理提取一致收敛子列；
4. 证明极限函数满足约束且达到上确界。

8.2 等度连续与一致有界

Arzelà–Ascoli 定理

设 X 是紧度量空间， $\{f_n\} \subseteq C(X)$ 满足：

- 一致有界： $\sup_n \|f_n\|_\infty < \infty$ ；
- 等度连续：对任意 $\varepsilon > 0$ ，存在 $\delta > 0$ （与 n 无关）使得 $d(x, x') < \delta$ 蕴含 $|f_n(x) - f_n(x')| < \varepsilon$ 对所有 n 成立。

则 $\{f_n\}$ 存在一致收敛子列。

8.3 连续模与 C-变换的保持

C-变换保持连续模 (modulus of continuity) 是证明的核心:

引理 8.1. 若代价函数 c 具有连续模 ω_c , 即 $|c(x, y) - c(x', y')| \leq \omega_c(d(x, x') + d(y, y'))$, 则对任意函数 ψ , 其 c -变换 ψ^c 的连续模不超过 ω_c 。

这意味着: 无论初始函数 ψ 多么“粗糙”, 经过 c -变换后得到的 ψ^c 的光滑性完全由代价函数 c 决定。

对深度学习的启示

在深度学习应用中, 传输代价的选择直接影响势能函数 (从而传输映射) 的光滑性。若 c 光滑 (如 L^2 代价), 则解也更光滑, 计算稳定性更好; 若 c 不光滑 (如 L^1 代价), 则解可能出现奇异性, 导致梯度爆炸或消失。这解释了为什么 WGAN 中使用 L^1 代价需要额外的 Lipschitz 约束 (梯度裁剪)。

9 与深度学习的关系

9.1 最优传输作为概率分布之间的距离

在深度生成模型中, 核心问题是比较和匹配概率分布。最优传输提供了比 KL 散度更优的距离度量:

- **KL 散度** (Kullback-Leibler): $D_{KL}(P\|Q) = \int \log \frac{dP}{dQ} dP$ 。缺陷: 当 P 和 Q 的支撑集不交时, $D_{KL} = +\infty$, 梯度消失。
- **Wasserstein 距离** (最优传输代价): 即使支撑集不交, 仍能给出有限的距离和可用的梯度。

Wasserstein GAN 的核心思想

WGAN 将生成器和判别器的对抗转化为最优传输问题:

- 生成器 G : 将隐空间分布 Z 映射到生成分布 P_G ;
- 判别器 D : 计算真实分布 P_{data} 与生成分布 P_G 之间的 Wasserstein 距离;
- 训练目标: $\min_G \max_D \{\mathbb{E}_{x \sim P_{data}}[D(x)] - \mathbb{E}_{z \sim Z}[D(G(z))]\}$ 。

这对应于 Kantorovich 对偶问题中 $c(x, y) = |x - y|$ 的情形, 其中判别器 D 扮演了 Kantorovich 势能的角色。

9.2 Sinkhorn 算法与熵正则化

法国学派 (Cuturi 等) 提出了熵正则化的最优传输:

$$\min_{\gamma \in \Pi(\mu, \nu)} \int c d\gamma + \lambda \int \gamma \log \gamma dx dy, \quad (7)$$

其中 $\lambda > 0$ 是正则化参数。加入熵项后:

- 问题变为严格凸的, 解唯一;

- 解具有特殊结构: $\gamma_{ij}^* = \alpha_i \beta_j e^{-c_{ij}/\lambda}$ (矩阵缩放形式);
- 可用 Sinkhorn-Knopp 迭代 (矩阵行/列归一化) 高效求解, 复杂度 $O(n^2)$ 每迭代。

熵正则化的局限性

Sinkhorn 算法的解是正则化问题的解, 而非原始最优传输问题的解。当 $\lambda \rightarrow 0$ 时, 正则化解收敛到原始解, 但:

- 收敛速度难以定量控制;
- 对于高精度要求 (如光学设计), 正则化解可能过于模糊;
- 当 λ 很小时, 算法数值不稳定。

9.3 模式坍塌 (Mode Collapse) 的几何解释

顾教授团队的重要贡献之一是用最优传输理论解释 GAN 中的模式坍塌现象:

模式坍塌的最优传输解释

当真实数据分布和目标生成分布的支撑集边界形状差异很大时, 最优传输映射可能不连续 (存在奇异点)。由于神经网络只能表示连续映射, 它无法精确学习不连续的传输映射, 导致:


- 某些模式 (mode) 被 “跳过”;
- 生成样本集中在少数几个模式上;
- 即所谓的 “模式坍塌” (mode collapse)。

这一解释基于最优传输的循环单调性和正则性理论, 将深度学习的工程问题与经典数学理论联系起来。

10 总结与延伸

10.1 本次讲座的核心脉络

本次讲座建立了从离散到连续、从原始问题到对偶问题的完整理论框架:



10.2 核心要点回顾

1. **Monge 问题**寻求最优传输映射，但可行解集合可能为空或非凸；
2. **Kantorovich 问题**将映射放松为联合概率分布（传输方案），解决了存在性问题，且问题变为凸优化；
3. **对偶理论**引入 Kantorovich 势能函数，将无穷维线性规划转化为对偶问题；
4. **C-变换**是求解对偶问题的核心工具，将 Legendre 变换推广到一般代价函数；
5. **Rockafellar 定理**建立了循环单调性与 c -凹函数之间的联系，刻画了最优传输方案的结构；
6. 最优传输理论为深度学习（尤其是生成模型）提供了坚实的数学基础，包括 Wasserstein 距离、模式坍塌的解释等。

10.3 后续学习路径

推荐阅读与后续主题

1. **Brenier 定理**: 当 $c(x, y) = \frac{1}{2}|x - y|^2$ 时, 最优传输映射是某个凸函数的梯度映射。这是最优传输理论中最重要的特例, 下讲将详细展开。
2. **Monge–Ampere 方程**: 最优传输映射与 Monge–Ampere 型偏微分方程的等价性, 是 PDE 几何方向的核心课题。
3. **正则性理论**: 研究最优传输映射的光滑性 (Caffarelli、Wang 等工作), 以及奇异集的结构 (Figalli 等工作)。
4. **Wasserstein 空间**: 将概率测度空间赋予 Wasserstein 距离, 形成度量空间结构, 可定义梯度流 (Jordan–Kinderlehrer–Otto 方案)。
5. **数值算法**: 包括几何变分法、半离散算法、FFT 加速的泊松求解等, 是连接理论与应用的桥梁。

10.4 顾教授的寄语

讲座最后, 顾教授对年轻学子提出了殷切期望:

“绝大多数人理解最优传输只理解到 Sinkhorn 算法的层面, 看不到背后的对偶原理。我们的四句口诀——‘代价决定支撑, 支撑包络势能, 势能微分得到映射, 映射复合回到自身’——表达的是对偶原理的几何观点。把这个观点吃透, 就相当于已经登堂入室, 触及了理论的内在。”

“深度学习降低了人的智力要求, 但对于青年学子的学习过程不见得有利。尽量学习深刻的东西, 回头再做简单的东西。当深度学习的泡沫褪去, 人们对理论基础要夯实的时候, 最优传输理论的重要性会被日益凸显。”