

## 课程笔记

# 最优传输的理论与计算：深度学习的几何

顾险峰（纽约州立大学石溪分校）

2026 年 6 月 15 日



视频作者/频道: Upupupxiaohua

发布日期: 2023 年 11 月 21 日

视频时长: 1 小时 18 分 29 秒

视频链接: <https://www.bilibili.com/video/BV1Da4y1U78N?p=1>

# 目录

|                                         |           |
|-----------------------------------------|-----------|
| <b>1 引言：最优传输与深度学习</b>                   | <b>3</b>  |
| 1.1 讲座概述                                | 3         |
| 1.2 最优传输的四种主要方法                         | 3         |
| 1.3 应用领域概览                              | 3         |
| 1.4 几何观点的四句口诀                           | 4         |
| 1.5 本章小结                                | 4         |
| <b>2 流形分布定理：数据科学的基石</b>                 | <b>5</b>  |
| 2.1 从概念到数据集到流形                          | 5         |
| 2.2 MNIST 数据集的例子                        | 5         |
| 2.3 编码映射与解码映射                           | 6         |
| 2.4 模式混淆 (Mode Confusion)               | 6         |
| 2.5 本章小结                                | 6         |
| <b>3 深度学习的数学基础</b>                      | <b>7</b>  |
| 3.1 深度学习究竟在学什么                          | 7         |
| 3.2 流形学习的数学定理                           | 7         |
| 3.2.1 一般位置定理 (General Position Theorem) | 7         |
| 3.2.2 Whitney 嵌入定理                      | 7         |
| 3.2.3 Urysohn 引理与模式识别                   | 7         |
| 3.3 万有逼近定理                              | 7         |
| 3.4 概率分布的学习方法                           | 8         |
| 3.5 本章小结                                | 8         |
| <b>4 最优传输在深度学习中的应用</b>                  | <b>8</b>  |
| 4.1 生成模型与 GAN 的几何理解                     | 8         |
| 4.2 模式坍塌 (Mode Collapse) 的深层原因          | 9         |
| 4.3 AE-OT 生成模型                          | 9         |
| 4.4 人脸生成实验                              | 10        |
| 4.5 本章小结                                | 10        |
| <b>5 几何应用实例</b>                         | <b>11</b> |
| 5.1 计算机图形学：保面积参数化                       | 11        |
| 5.2 法向贴图 (Normal Mapping)               | 11        |
| 5.3 体积最优传输：斯坦福兔子                        | 12        |
| 5.4 医学图像：大脑皮层配准                         | 12        |
| 5.5 医学图像：体式放大镜                          | 12        |
| 5.6 光学设计                                | 12        |
| 5.7 本章小结                                | 12        |

|                         |           |
|-------------------------|-----------|
| <b>6 总结与延伸</b>          | <b>13</b> |
| 6.1 讲座核心要点回顾 . . . . .  | 13        |
| 6.2 关键数学工具 . . . . .    | 13        |
| 6.3 开放问题与未来方向 . . . . . | 13        |
| 6.4 学习建议 . . . . .      | 13        |
| 6.5 最终总结 . . . . .      | 14        |

# 1 引言：最优传输与深度学习

## 1.1 讲座概述

本讲座由顾险峰教授主讲，主题为“最优传输的理论与计算”系列讲座之一——“深度学习的几何”。顾险峰教授师从菲尔兹奖获得者丘成桐先生，致力于将现代微分几何与拓扑理论推广至工程和医疗领域，与丘成桐先生共同创建了横跨计算机和数学等学科的“计算共形几何”。

### 最优传输的核心问题

最优传输理论研究如何用最经济的方式将一个概率分布变换到另一个概率分布。例如：一个水杯中盐溶液的浓度分布不均匀，如何找到一种变换，将水中的分子移动到新的位置，使得浓度变得均匀，同时使总的传输距离达到最小。

最优传输的核心特点是“一体两面”：既可以从概率角度理解，也可以从几何角度理解。因此其应用有时用于计算两个概率之间的距离，有时则是出于几何目的——为了得到特殊的一种曲面。

## 1.2 最优传输的四种主要方法

讲座中介绍了求解最优传输问题的四类方法：

1. **基于 Kantorovich 理论的线性规划**：这是大家最熟悉的方法，深度学习中的 Sinkhorn 方法就是线性规划的一种推广。但这种方法无法揭示理论的几何侧面，不适用于许多几何应用场合（如光学设计）。
2. **几何变分方法**：从凸几何（Alexandrov 学派）发展而来，几何直观非常强。这是本系列讲座的重点。
3. **基于流体力学的方法（Brenier, 法国学派）**：物理直观比较强，可以为 Wasserstein 空间引入黎曼度量，特别适合在概率密度空间上做变分。
4. **传统数值方法**：如 Multigrid、快速多极变换等，用于求解与最优传输等价的 Monge-Ampere 方程。

### Monge-Ampere 方程与最优传输

最优传输问题与 Monge-Ampere 方程是等价的。该方程是强烈非线性的偏微分方程，求解具有一定难度。目前有很多人在研究如何用硬件加速求解，并且已经做出了专门用于最优传输映射计算的芯片，计算速度可提高数百到数千倍。

## 1.3 应用领域概览

最优传输的应用极其广泛，包括但不限于：

- **深度学习**：GAN（对抗生成网络）本质上是计算分布之间的距离，以及将一个分布变成另一个分布。
- **经济学与运筹学**：产销平衡、资源分配等问题。
- **3D 图形学与元宇宙**：保面积参数化在图形学中有很多用处。

- **图像处理**：Photoshop 中的风格迁移背后算法基于最优传输。
- **自然语言处理**：字节跳动利用最优传输在 NLP 领域取得重大突破（最佳论文）。
- **自动驾驶**：点云配准、几何配准、曲面配准。
- **医学图像**：2D/3D/高维图像配准，体式放大镜。
- **光学设计**：设计特殊透镜使反射/折射满足特定分布。

## 1.4 几何观点的四句口诀

顾险峰教授将最优传输的几何观点总结为四句口诀，是整个系列讲座的精髓：

### 最优传输几何口诀

1. **代价决定支撑**：传输代价函数决定支撑曲面（supporting surfaces）
2. **支撑包络势能**：支撑曲面的包络形成势能函数
3. **微分给出映射**：势能函数的微分（梯度）给出最优传输映射
4. **映射传递变换**：最优传输映射将一种概率分布变换为另一种




图 1: 整体几何图景：支撑包络势能，势能微分映射。红色抛物线构成支撑曲面族，黑色曲线为势能函数， $x$  与  $y$  的切点对应给出最优传输映射。<sup>1</sup>

## 1.5 本章小结

本章介绍了最优传输理论的核心问题、四种主要求解方法，以及其在深度学习、计算机图形学、医学图像、光学设计等众多领域的广泛应用。最优传输的“一体两面”特性——既可以概率视角理解，也可以几何视角理解——使其成为连接数学理论与工程应用的桥梁。后续章节将深入探讨最优传输在深度学习中的几何理解。

<sup>1</sup> 视频画面时间区间：00:08:45–00:09:15。

## 2 流形分布定则：数据科学的基石

### 2.1 从概念到数据集到流形

#### 流形分布定则 (Manifold Distribution Principle)

深度学习的成功核心在于下面的“流形分布定则”：

1. 每个自然概念对应一个数据集
2. 数据集是某个低维流形上的概率分布
3. 流形嵌在高维的背景空间中
4. 数据在流形上的分布不均匀，满足特定概率分布




图 2: 流形分布定则：数据科学的基石。每个自然概念对应一个数据集，每个样本是数据集中的点；数据集分布在某个低维流形附近，该流形称为数据流形  $\Sigma$ ；数据流形  $\Sigma$  嵌入在高维的背景空间  $\mathbb{R}^n$  中；数据集可以被抽象成一个数据流形  $\Sigma$  上的概率分布  $\mu$ 。<sup>2</sup>

这一思想最早由 Mumford 等人在 1990 年代中叶提出，将统计大规模引入机器视觉，把某一类视觉图像看成是一个概率分布。如今这一观点已变得非常普遍。

### 2.2 MNIST 数据集的例子

以 MNIST 手写数字数据集为例：

- **概念**：手写体阿拉伯数字
- **数据集**：收集了大量信封上的手写体数字
- **每个数据点**： $28 \times 28$  的黑白头像，即 784 维空间中的一个点
- **流形结构**：Hinton 发明的 t-SNE 算法将 MNIST 数据映射到平面上，显示 10 个团簇（对应 0-9 十个数字）

<sup>2</sup>视频画面时间区间：00:27:50–00:28:10。

- **关键发现**：映射是可逆的——在平面上给一个点，就能生成对应的图像

### 为什么映射可逆说明流形是二维的？

虽然 MNIST 数据在 784 维空间中，但这个点云非常接近一个二维曲面。将曲面“摊平”到平面上，映射是可逆的。如果数据流形不是二维的，摊到平面上就无法一一映射回来。这完美解释了“概念 → 数据集 → 流形 → 概率分布”的链条。

## 2.3 编码映射与解码映射

在深度学习中：

- **编码映射 (Encoder)**：将高维数据流形映射到低维隐空间 (latent space)，也称为特征提取
- **解码映射 (Decoder)**：将隐空间的点映射回数据流形，生成数据
- **隐空间/参数空间**：编码映射的输出空间
- **特征点**：隐空间中的点

### 术语混淆问题

拓扑学中的“参数化”、“局部坐标”、深度学习中的“特征”、“隐编码”、数学中的“二维参数”，本质上都是同一概念的不同名称。工程师重新发明已有数学概念，给学习者带来困扰。建议学习者建立跨学科的术语对照表。

## 2.4 模式混淆 (Mode Confusion)

在隐空间中均匀采样，通过解码映射生成图像：

- 如果采样点落在某个分布的支集 (support) 内，恢复的图像质量很高
- 如果采样点落在支集之间，得到的是混淆的结果（如 8 和 5 混在一起）

### 模式混淆的本质

模式混淆发生在采样点没有落在概率分布的支撑集之内。这说明编码映射可能破坏了原始数据流形上的均匀分布。理想情况下，好的编码映射应该：

1. 实现降维
2. 保持概率分布（在流形上均匀分布的点，映射后在隐空间也均匀分布）

这正是最优传输映射的目标。

## 2.5 本章小结

本章阐述了“流形分布定则”——数据科学的基石。每个自然概念对应一个数据集，数据集分布在某个低维流形上。深度学习的目的就是学习这个流形及其上的概率分布。编码映射将数据映射到隐空间，解码映射将隐空间点还原为数据。模式混淆问题揭示了编码映射保持概率分布的重要性，这正是最优传输理论可以解决的问题。

## 3 深度学习的数学基础

### 3.1 深度学习究竟在学什么

深度学习主要学习两个东西：

#### 深度学习的双重目标

1. **学习流形结构**：学习数据所在的低维流形，表达为深度神经网络的编码/解码映射
2. **学习概率分布**：学习流形上的概率分布，可用最优传输的理论和算法来解释和计算

### 3.2 流形学习的数学定理

#### 3.2.1 一般位置定理 (General Position Theorem)

如果有一个  $M$  维流形嵌在  $\mathbb{R}^N$  中，且  $N > 2M + 2$ ，则这个嵌入没有链结构 (linking)，没有扭曲。这解释了为什么神经网络的前几层宽度逐渐增加——增加宽度意味着增加嵌入空间的维数，空间嵌入维数越高，切入方式越简单，对后续处理更容易。

#### 3.2.2 Whitney 嵌入定理

##### Whitney 嵌入定理

如果有  $N$  维光滑流形，那么它可以光滑嵌入在  $\mathbb{R}^{2N+1}$  中。核心思想是：先给流形一个开覆盖，然后得到所有的单位分解，把每个开集先嵌入，通过单位分解实现整体嵌入。这一算法启发了 UMAP 等降维算法。

#### 3.2.3 Urysohn 引理与模式识别

模式识别（无论监督还是非监督）的核心是学习 Urysohn 函数：给定拓扑空间上的两个集合  $A$  和  $B$ ，存在一个连续函数  $f$ ，在  $A$  上恒等于 0，在  $B$  上恒等于 1，在两者之间从 0 过渡到 1。监督学习中的 label 本质上就是要学这个 Urysohn 函数。

### 3.3 万有逼近定理

#### 深度神经网络的万有逼近能力

神经网络具有“万有逼近”特性：给定一个连续变换，可以找到一个神经网络和一组参数，使得网络能很好地逼近这个连续变换。

这一理论基础来自：

- **Kolmogorov-Arnold 表示定理** (希尔伯特第 13 问题的解答)：给定多元连续函数，可以找到两个特别简单的函数（内核函数  $\phi$  和  $\psi$ ，都是一元的），通过求和与复合任意精度逼近给定函数
- 传统有限元/样条：用基函数的线性组合逼近
- 神经网络：用简单函数的复合来逼近

### 3.4 概率分布的学习方法

历史上表达概率分布的方法：

1. **高斯混合模型**：最常用，但真实数据分布距离高斯分布很远
2. **Gibbs 分布**：Mumford 学派使用， $p(x) \propto \exp(-U(x))$
3. **归一化流 (Normalizing Flow)**：基于变量替换公式
4. **最优传输映射**：更为严格高效的方法，可以把任何分布变成另一个分布，无需对分布做假设

#### 为什么最优传输优于高斯假设？

很多人使用高斯分布假设是为了数学上容易处理。但最优传输映射可以把任何一个分布变换成另一个分布，因此不需要对未知分布做任何假设。只要分布满足一定的正则性要求（密度函数有界），就可以进行最优传输计算。这是概率统计中最 general 的终极理论。

### 3.5 本章小结

本章从数学角度解释了深度学习的理论基础。流形学习由 Whitney 嵌入定理等经典结果支撑；深度神经网络的万有逼近能力由 Kolmogorov-Arnold 定理保证；概率分布的学习有多种方法，其中最优传输映射最为 general 和强大，无需对分布做高斯假设。这些数学理论为深度学习提供了坚实的理论根基。

## 4 最优传输在深度学习中的应用

### 4.1 生成模型与 GAN 的几何理解

#### GAN 的最优传输视角

从最优传输理论看 GAN：

- **生成器 (Generator)**：将隐空间的白噪声映射到数据流形上的生成分布
- **判别器 (Discriminator)**：判断生成分布与真实分布之间的距离
- **两者都在计算最优传输映射**：生成器计算从白噪声到生成分布的映射，判别器计算生成分布与真实分布之间的映射

#### GAN 的对抗是不必要的

从最优传输理论看，生成器和判别器之间的竞争和对抗是没有必要的。如果两者都计算得相对不错，它们的结果直接复合就达到最终目标——将白噪声直接映射到真实分布。因此，每一步更新应该把两者的结果复合起来传给生成器，而不是让它们相互对抗。将对抗变为合作，效率会提高非常多。




图: VAE, WGAN 和 AE-OT 模型生成 MNIST 样本的比较. VAE 和 WGAN 会产生模式混淆, AE-OT 模型能够避免模式混淆.

图 3: 模式坍塌和模式混淆: VAE、WGAN 和 AE-OT 模型生成 MNIST 样本的比较. VAE 和 WGAN 会产生模式混淆 (生成模糊、不可识别的数字), 而 AE-OT 模型能够避免模式混淆, 生成清晰、正确的数字样本。<sup>3</sup>

## 4.2 模式坍塌 (Mode Collapse) 的深层原因

### 模式坍塌的本质

模式坍塌是深度学习中的重大问题。从最优传输理论看, 其根本原因在于: 最优传输映射是某个凸函数的梯度映射。这个势能函数并不是处处可微的——在某些地方连续但不可微。在这些不可微点, 梯度无法定义, 映射会发生跳变 (非连续)。而神经网络只能表达连续变换, 无法表达非连续变换。因此神经网络试图学习一个连续函数来逼近非连续的最优传输映射, 必然会遗失掉一些 mode, 导致模式坍塌。

## 4.3 AE-OT 生成模型

顾险峰教授团队提出的 AE-OT (Auto-Encoder + Optimal Transport) 生成模型:

### AE-OT 模型架构

1. 上半部分: **Auto-Encoder** 学习编码映射和解码映射 (学习流形结构)
2. 下半部分: **几何变分法** 计算最优传输映射, 将白噪声映射到隐空间的数据分布
3. **关键改进**: 用神经网络表达 Brenier 势能函数, 而不是表达梯度映射

这样做的好处:

- 避免了模式坍塌 (因为势能函数是全局连续的, 可以用 DNN 表达)
- 将黑箱深度学习的一半变得透明 (最优传输部分理论完备)
- 第一阶段 (Auto-Encoder) 非常稳定, 第二阶段 (最优传输) 理论完全透明

<sup>3</sup> 视频画面时间区间: 00:48:30–00:49:00。




图 4: AE-OT 生成模型架构。第一行用 AE（自编码器）学习流形结构（编码映射和解码映射）；第二行用 OT（最优传输）学习概率分布变换。白噪声通过最优传输映射变换到隐空间的数据分布，再通过解码映射生成数据。OT 可以用几何方法来计算，用深度神经网络表达 Brenier 势能函数，从而避免模式坍塌。<sup>4</sup>

#### 4.4 人脸生成实验

实验设置：

- 用人脸图像训练一个流形
- 将流形映射到隐空间（约 100 维）
- 在隐空间中，白噪声（均匀分布）通过最优传输映射变换到数据分布
- 通过解码映射生成人脸图像

##### 穿越流形边界的奇异图像

在隐空间中画直线，映射到数据流形上形成曲线。当直线穿越奇异集合时，会跨越人脸图像流形的边界。实验发现生成了“一只眼睛蓝色、一只眼睛黑色”的人脸图像——这种人在生理学上存在但现实中遇到概率为零。这说明最优传输方法能够找到概率为零的数据边界，验证了真实数据分布对应的传输变换确实是非连续的。

#### 4.5 本章小结

本章从最优传输理论重新诠释了 GAN 和生成模型。最优传输视角揭示了 GAN 中对抗机制的不必要性，指出了模式坍塌的深层数学原因（最优传输映射的非连续性与神经网络的连续表达之间的矛盾），并提出了 AE-OT 生成模型作为解决方案。通过表达 Brenier 势能函数而非其梯度，可以避免模式坍塌问题。

<sup>4</sup> 视频画面时间区间：00:55:00–00:55:30。

## 5 几何应用实例

### 5.1 计算机图形学：保面积参数化

#### 保面积参数化

将三维曲面映射到二维平面时：

- **共形变换**：局部保角，但面积畸变特别大（如头部缩得很小）
- **最优传输映射**：保面积映射，任何区域面积都相等

具体步骤：

1. 将曲面面积“推”到平面上，在平面上定义概率测度（push-forward measure）
2. 平面上有均匀分布（Lebesgue 测度）
3. 用最优传输映射将推前测度变为均匀分布
4. 该映射是某个凸函数的梯度映射（势能微分映射）



图 5: 计算机图形学：保面积参数化。左侧为共形变换结果（局部保角但面积畸变严重），右侧为最优传输映射结果（保面积参数化）。通过最优传输映射，三维表面上的面积被均匀地映射到二维平面上，避免了共形变换带来的严重面积畸变。<sup>5</sup>

### 5.2 法向贴图 (Normal Mapping)

在图形学中，法向贴图技术：

- 将三维曲面打到二维平面
- 每个像素的红绿蓝代表法向量的  $x, y, z$  分量
- 如果用共形变换，翅膀等部位会缩得太小

<sup>5</sup> 视频画面时间区间：00:11:00–00:11:30。

- 复合最优传输变换后，翅膀和头部都被放大，极大提高渲染质量

### 5.3 体积最优传输：斯坦福兔子

- 计算三维体积的最优传输变换
- 先用调和映照将曲面映射到单位球面
- 再扩展到内部（四面体剖分）
- 复合最优传输映射保证体积相等（保体积映射）

### 5.4 医学图像：大脑皮层配准

- 将大脑皮层映射到平面上
- 大脑不同区域对应不同功能
- 通过监控各区域萎缩速率预测老年痴呆风险
- 最优传输提供最精确的配准方法

### 5.5 医学图像：体式放大镜

- 物理放大镜只能放大二维图像
- 医学图像（如脊椎骨、膝盖骨）是三维的
- 三维最优传输映射实现“虚拟放大镜”
- 可放大特定部位进行详细观察

### 5.6 光学设计

- 反射镜设计：点光源  $\rightarrow$  透镜  $\rightarrow$  墙壁上的特定图像分布
- 透镜设计：透射光线改变光强分布
- 核心问题：球面上的入射能量分布  $\rightarrow$  反射/透射能量分布
- 需要计算的不是映射本身，而是势能曲面
- 3D 打印技术的发展使得制造这种特殊透镜成为可能

### 5.7 本章小结

本章展示了最优传输在多个几何领域的实际应用：计算机图形学中的保面积参数化、法向贴图、体积映射；医学图像中的大脑皮层配准、三维放大镜；光学设计中的特殊透镜设计。这些应用共同展示了最优传输映射的普适性——对任意维度、任意紧黎曼流形都成立。

## 6 总结与延伸

### 6.1 讲座核心要点回顾

本讲座从最优传输的几何视角出发，深入解释了深度学习的本质：

1. **流形分布定则**：数据分布在低维流形上，深度学习学习流形结构和概率分布
2. **编码-解码**：Auto-Encoder 学习流形结构，最优传输学习概率分布变换
3. **模式坍塌**：源于最优传输映射的非连续性与神经网络连续表达能力的矛盾
4. **AE-OT 模型**：用 DNN 表达 Brenier 势能函数（而非梯度），避免模式坍塌
5. **奇异集合**：最优传输映射的奇异点对应数据流形的边界，具有深刻的几何意义

### 6.2 关键数学工具

#### 核心数学框架

- **Monge-Ampere 方程**：最优传输的 PDE 表述
- **Brenier 定理**：最优传输映射是凸函数的梯度
- **Wasserstein 空间**：概率分布空间上的黎曼度量
- **Wasserstein 测地线**：由 McCann 给出
- **中轴 (Medial Axis)**：最优传输的奇异集合

### 6.3 开放问题与未来方向

1. **高维计算**：隐空间维度很高时计算开销大，需要更高效的算法或硬件加速
2. **奇异集合理论**：最优传输映射奇异集合的 Hausdorff 测度估计、几何性质
3. **非凸支撑集**：传统最优传输理论假设支撑集是凸的，但深度学习中无法保证
4. **与信息论的联系**：最优传输与信息论中的变分方法、熵、BMC 不等式等的深层联系
5. **流体力学视角**：最优传输与流体动力学、相变、涌现、自组织的关系

### 6.4 学习建议

#### 进一步学习资源

- **教材**：《最优传输的理论与计算》（顾险峰等著）——理论严密，适合深入学习
- **开源代码**：顾险峰教授网页 (<http://www3.cs.stonybrook.edu/~gu/>) 提供最优传输映射和球面最优传输映射的 C++ 代码及 binary demo
- **后续讲座**：系列讲座将深入讲解几何变分法、流体力学方法、正则性理论等

## 6.5 最终总结

最优传输理论为深度学习提供了坚实的几何基础。通过理解“代价决定支撑、支撑包络势能、微分给出映射、映射传递变换”这四句口诀，可以把握最优传输的核心思想。将深度学习分解为“学习流形结构”（Auto-Encoder）和“学习概率分布变换”（最优传输）两个任务，不仅使理论更加透明，也为解决模式坍塌等实际问题提供了新思路。最优传输作为有着 350 多年历史的数学理论，正在深度学习时代焕发新的生命力。