


课程笔记

最优传输的理论及计算系列讲座之三：Brenier 定理

顾险峰（纽约州立大学石溪分校）

2026 年 6 月 15 日



视频作者/频道: Upupupxiaohua

发布日期: 2023 年 11 月 21 日

视频时长: 1 小时 26 分 21 秒

视频链接: <https://www.bilibili.com/video/BV1Da4y1U78N?p=3>

目录

1 引言与计算实例

1.1 讲座概述

本次讲座是顾险峰教授“最优传输的理论及计算”系列讲座的第三讲，主题为 **Brenier 定理** (Brenier Theory) 以及**几何变分法** (Geometric Variation Method)。

系列讲座脉络

- 第一讲：深度学习的几何观点
- 第二讲：Kantorovich 对偶理论
- 第三讲 (本讲)：Brenier 定理
- 第四讲：Alexandrov 定理与凸几何

Brenier 定理在最优传输理论中具有核心地位，主要原因在于：

1. **计算实用性强**：在深度学习等实际应用中，Brenier 定理是最常用的理论工具；
2. **几何直观清晰**：该定理与微分几何联系紧密，可以通过视觉直观理解；
3. **理论完备**：从概率统计和微分几何两个角度都能完美诠释，体现最优传输理论“一体两面”的特性。

1.2 计算实例：曲面参数化

讲座以一个具体的计算实例开场——将一尊**弥勒佛曲面**（二维曲面）映射到平面圆盘上。这涉及两种本质不同的映射：

1.2.1 共形映射 (Conformal Mapping)

共形映射保持角度不变。通过求解 **Beltrami-Laplace 方程**（即 Laplace-Beltrami 算子），可以将曲面保角地映射到平面圆盘上。

Laplace-Beltrami vs Monge-Ampere

- **Laplace-Beltrami 算子**：线性椭圆算子，计算 Hessian 矩阵的迹 (trace)
- **Monge-Ampere 算子**：强非线性椭圆算子，计算 Hessian 矩阵的行列式 (determinant)

Poisson 方程使用 Laplace 算子，而最优传输问题对应 Monge-Ampere 算子。如果将 Monge-Ampere 算子局部线性化，得到的就是 Poisson 方程。

1.2.2 保面积映射 (Area-Preserving Mapping)

保面积映射保持曲面面积比例不变。具体来说：

- 在平面圆盘上任取一个区域，将其拉回到曲面上；
- 平面区域的面积与曲面上对应区域的面积成比例；
- 这定义了平面上一个新的测度。

1.2.3 最优传输变换

从共形映射的结果到保面积映射的结果，两者之间存在一个**最优传输变换**：

- 右侧（平面圆盘）使用标准的 Lebesgue 测度，即密度恒等于 1 的均匀分布；
- 左侧（共形映射结果）使用曲面的面积元推前到平面上定义的测度；
- 这两个测度之间存在唯一的最优传输变换。

Brenier 定理的核心结论

如果要计算一个最优传输变换，那么：

1. 该最优传输映射 T 是由一个**凸函数**的梯度给出的；
2. 这个凸函数是多个支撑平面的**上包络**；
3. 当传输代价为欧氏距离平方时，支撑平面来自最优传输映射的代价函数；
4. 该凸函数的梯度给出最优传输映射，其逆映射也是某个凸函数的梯度。

1.3 几何直观的口诀

顾教授总结了一个便于记忆的口诀：

Brenier 定理口诀

1. **代价变换**：支撑代价为 L ，即 $C(x, y) = h(x - y)$ ， h 严格凸；
2. **支撑平面**：多个支撑平面；
3. **包络势能**：支撑平面的上包络是 Brenier 凸势能函数 u ；
4. **势能微分映射**：势能的梯度映射 ∇u 给出最优传输变换；
5. **对偶图形**：变换的对偶（逆映射）也是最优传输变换；
6. **Legendre 变换**：对偶凸函数是原凸函数的 Legendre 变换。

这两个凸函数（原函数与 Legendre 变换）满足 Poincare 对偶关系。这一图景非常几何化，也非常容易理解。

两种理解视角

- **微分几何视角**（本讲）：通过凸函数、支撑平面、Legendre 变换来理解；
- **概率统计/凸几何视角**（下一讲）：通过 Alexandrov 定理来理解。

两边的起源完全不同，但在这个图景下两者完美结合。这正是最优传输理论“一体两面”的体现——一边联系统计和概率，另一边联系微分几何。

1.4 本章小结

本章通过弥勒佛曲面的计算实例，引出了最优传输问题的核心：在两个概率测度之间寻找代价最小的传输方案。Brenier 定理告诉我们，在欧氏距离平方的代价下，最优传输映射必然是一个凸函数的梯度映射。这一结论具有深刻的几何意义，将概率统计与微分几何统一在同一个框架下。

2 从 Kantorovich 对偶到 Brenier 定理

2.1 问题的严格表述

回顾 Monge 问题：给定两个概率测度 μ 和 ν ，寻找最优传输映射 T 使得

$$\inf_{T_{\#}\mu=\nu} \int_{\Omega} c(x, T(x)) d\mu(x)$$

Kantorovich 将问题放松，寻找最优传输方案 γ （联合概率分布）：

$$\inf_{\gamma \in \Pi(\mu, \nu)} \int_{\Omega \times \Omega} c(x, y) d\gamma(x, y)$$

方案 vs 映射

- **传输方案** (Kantorovich)：联合概率分布 γ ，其支撑集可能是一个区域；
- **传输映射** (Monge)：函数 T ，其图像是一条曲线，在方案的支撑集中是零测度集。

一个自然的问题是：什么时候最优传输方案一定是最优传输映射？答案取决于代价函数的性质。

2.2 严格凸代价函数的设定

假设在欧氏空间中两个紧区域 $X = Y = \Omega \subset \mathbb{R}^n$ 。如果传输代价函数具有形式：

$$c(x, y) = h(x - y)$$

其中 h 是定义在整个欧氏空间上的**严格凸函数**。

关键假设

1. $h : \mathbb{R}^n \rightarrow \mathbb{R}$ 是严格凸函数；
2. h 是 C^1 光滑的（即处处存在梯度）；
3. 由 Alexandrov 定理，严格凸函数几乎处处二阶可导 (C^2 a.e.)。

在这种情况下，最优传输方案成为最优传输映射，并且可以直接写下来。这意味着：如果在深度学习设计中设计代价函数为严格凸函数的形式，那么结果一定是一个最优传输映射，所需变量会大大减少。

2.3 Kantorovich 对偶回顾

回顾 Kantorovich 对偶问题。设 φ 和 ψ 是 Kantorovich 势能函数，满足：

$$\varphi(x) + \psi(y) \leq c(x, y), \quad \forall x, y$$

在对偶问题的设定中， $\varphi + \varphi^c$ (c -变换) 小于等于传输代价。在支撑集上，两者相加等号几乎处处成立：

$$\varphi(x) + \psi(y) = c(x, y), \quad \gamma\text{-a.e.}$$

2.4 支撑集的定义

定义 2.1 (支撑集). 给定概率测度 γ ，其支撑集 $\text{supp}(\gamma)$ 定义为：

1. **密度定义** (当密度存在时)：密度严格大于零的点的极限集合；
2. **集合论定义** (一般情形)：所有满足“ γ 在 A 的补集上为零”的 Borel 集 A 的交集。

具体而言，若集合 A 满足 $\gamma(A^c) = 0$ ，则所有这种 A 的共同交集 (仍为 Borel 集) 被称为 γ 的支撑集。支撑集中的点本身可能密度为零，但它们是密度大于零的点的极限点。

2.5 核心引理：梯度唯一性

引理 2.2 (梯度唯一性引理). 设 h 是严格凸且 C^1 光滑的函数， γ 是从 μ 到 ν 的最优传输方案， φ 是 Kantorovich 势能函数。假设 $(x_0, y_0) \in \text{supp}(\gamma)$ ，且 φ 在 x_0 处可微。那么：

$$\nabla_x c(x_0, y_0) = \nabla \varphi(x_0)$$

特别地，对于固定的 x_0 ，满足上述等式的 y_0 是唯一的。

证明. 设 $(x_0, y_0) \in \text{supp}(\gamma)$ ， x_0 不是 Ω 的边界点。由支撑集的定义，对于 x_0 的任意小邻域 U ，存在 y_0 的邻域 V 使得 $\gamma(U \times V) > 0$ 。

取 $x_1 \in U$ 使得 $(x_1, y_0) \in \text{supp}(\gamma)$ 。由最优性条件：

$$\begin{aligned} \varphi(x_0) + \psi(y_0) &= c(x_0, y_0) \\ \varphi(x_1) + \psi(y_0) &= c(x_1, y_0) \end{aligned}$$

两式相减：

$$\varphi(x_1) - \varphi(x_0) = c(x_1, y_0) - c(x_0, y_0)$$

由 φ 的可微性：

$$\varphi(x_1) - \varphi(x_0) = \langle \nabla \varphi(x_0), x_1 - x_0 \rangle + o(|x_1 - x_0|)$$

若存在 $y_1 \neq y_0$ 也满足条件，由 c 的严格凸性将导致矛盾。因此 y_0 唯一。 □

引理的核心含义

这个引理说明：如果想构造一个微分同胚 (最优传输映射)，找一个严格凸函数 h 作为代价函数即可。严格凸性保证了映射的单值性。

2.6 本章小结

本章从 Kantorovich 对偶出发，通过严格凸代价函数的设定，证明了最优传输方案在最优支撑集上几乎处处可以表示为映射。核心工具是梯度唯一性引理，它利用严格凸代价函数的性质保证了对于每个源点，目标点是唯一确定的。

3 Brenier 定理的正式表述

3.1 定理条件与结论

定理 3.1 (Brenier 定理). 设 $\Omega \subset \mathbb{R}^n$ 是欧氏空间中的紧区域, μ 和 ν 是 Ω 上的两个概率测度, 满足:

1. μ 和 ν 的密度函数是绝对连续的 (在紧集上只需连续即可保证绝对连续);
2. Ω 的边界足够好 (边界是零测度集, 非分形边界)。

设传输代价为 $c(x, y) = h(x - y)$, 其中 h 是严格凸函数。那么:

1. 存在**唯一**的最优传输方案 γ ;
2. 该方案 γ 是由一个**最优传输映射** T 诱导的;
3. 存在 Kantorovich 势能函数 φ ;
4. 最优传输映射由 φ 的梯度映射的逆映射给出:

$$T = (\nabla \varphi)^{-1}$$

Brenier 定理的深刻含义

- 在求解之前, 我们就可以确定最优传输映射一定满足 $T = (\nabla \varphi)^{-1}$ 这种格式;
- 这大大缩小了搜索空间, 将无穷维的优化问题转化为寻找合适的凸函数;
- 该结论对于计算具有决定性意义。

3.2 二次代价的特殊情形

在实际应用中, 最常见的情形是 $h(z) = \frac{1}{2}|z|^2$, 即欧氏距离平方的一半。此时:

$$c(x, y) = \frac{1}{2}|x - y|^2 = \frac{1}{2}|x|^2 - x \cdot y + \frac{1}{2}|y|^2$$

最差传输的对偶

展开总传输代价:

$$\int \frac{1}{2}|x - T(x)|^2 d\mu(x) = \int \frac{1}{2}|x|^2 d\mu - \int x \cdot T(x) d\mu + \int \frac{1}{2}|T(x)|^2 d\mu$$

由于 T 保持测度 ($T_{\#}\mu = \nu$), 第三项可以写成:

$$\int \frac{1}{2}|T(x)|^2 d\mu = \int \frac{1}{2}|y|^2 d\nu$$

因此, 第一项和第三项与传输映射无关, 可以去掉。原来的最小化问题等价于:

$$\max_T \int x \cdot T(x) d\mu(x)$$

这就是**最差传输** (worst transport) 问题——最大化而非最小化内积积分。

最优与最差的对偶

- 最优传输与最差传输理论上是对偶的；
- 所有最优传输的定理在最大传输问题上也成立；
- 从计算角度，计算最优和计算最差的算法也是一致的。

3.3 对偶问题与支撑平面

对于最差传输问题，对偶问题要求寻找 Kantorovich 势能函数 φ 。此时传输代价是 $x \cdot y$ ，所以 c -变换就是 Legendre 变换。

原来的不等式：

$$\varphi(x) + \varphi^*(y) \leq c(x, y) = x \cdot y$$

现在最差问题变为：

$$\varphi(x) + \varphi^*(y) \geq x \cdot y$$

对偶问题变为：求平面的上包络。如果用符号表示，就是求支撑平面的上包络。

Brenier 势能函数

由 Brenier 定理，最优传输映射 T 满足：

- T 是最优传输映射；
- Brenier 势能函数 u 满足 $T = \nabla u$ ；
- 其对偶函数 u^* (Legendre 变换) 满足 $T^{-1} = \nabla u^*$ ；
- Legendre 变换的梯度映射的逆映射等于原最优传输映射。

3.4 Monge-Ampere 方程

当 $T = \nabla u$ 且 T 将测度 μ (密度为 f) 推前到 ν (密度为 g) 时，由变分公式：

$$\det(\text{Hess } u) \cdot f(\nabla u) = g$$

这就是 **Monge-Ampere 方程**。在 μ 为均匀分布 ($f \equiv 1$) 的特殊情况下：

$$\det(\text{Hess } u) = g$$

边界条件

Brenier 定理给出的边界条件非常特殊：

$$\nabla u(\Omega) = \Omega^*$$

这不是 Dirichlet 边界条件，也不是 Neumann 边界条件，而是一种非常特殊的第二类边界条件。在流体力学框架中，保持边界条件特别棘手，需要特别小心处理。

3.5 本章小结

Brenier 定理在最优传输理论中处于核心地位。它告诉我们：在严格凸代价（特别是欧氏距离平方）下，最优传输问题不仅存在唯一解，而且这个解必然是一个凸函数的梯度映射。这一定理将概率测度之间的传输问题转化为凸函数的优化问题，大大简化了计算。同时，二次代价下的“最差传输”对偶揭示了问题的另一面貌，两者在理论和计算上都是等价的。

4 推广、稳定性与极分解

4.1 Polish 空间上的推广

Brenier 定理可以推广到更一般的空间上。设 X 和 Y 是 **Polish 空间**（完备、可分的度量空间），满足：

- 对取极限封闭（完备）；
- 存在可数的稠密集。

设传输代价 c 是一致连续且有界的。如果最优传输方案 γ 的支撑集是 C^1 循环单调的，那么 γ 一定是某个最优传输映射诱导的。

推广的价值

虽然在实际计算中 X 和 Y 通常都是紧集，但理论上对 Polish 空间的推广具有重要价值：

- 为理论分析提供更大的框架；
- 包含许多重要的无限维情形；
- 保证定理在更广泛条件下的适用性。

4.2 稳定性定理

定理 4.1 (稳定性定理). 设 (X, d) 是紧度量空间, c 是连续的传输代价。给定两组概率测度序列 $\{\mu_n\}$ 和 $\{\nu_n\}$, 满足：

1. $\mu_n \rightharpoonup \mu$ (弱收敛到 μ)；
2. $\nu_n \rightharpoonup \nu$ (弱收敛到 ν)。

设 γ_n 是 μ_n 到 ν_n 的最优传输方案。那么 $\{\gamma_n\}$ 的极限点都是 μ 到 ν 的最优传输方案。

弱收敛的定义

概率测度的弱收敛 (weak convergence) 定义为：对于对偶空间（连续有界函数空间）中的任意测试函数 ϕ ,

$$\int \phi d\mu_n \rightarrow \int \phi d\mu$$

离散采样的应用

在实际应用中，最常见的弱收敛情形就是**离散采样**：

- 给定一个数据集（如人脸图片），我们只能得到离散采样；
- 用 Dirac 测度的加权和来逼近连续概率测度；
- 当采样数趋于无穷时，经验分布弱收敛到真实分布。

4.3 Brenier 极分解定理

Brenier 定理最令人惊异的地方之一在于它的**极分解定理** (Polar Factorization)。

定理 4.2 (Brenier 极分解定理). 设 $\Omega \subset \mathbb{R}^n$ 是紧区域, $S: \Omega \rightarrow \Omega^*$ 是一个同胚 (保持测度的映射)。那么 S 可以唯一分解为：

$$S = T \circ U$$

其中：

- T 是**最优传输映射** (由 Brenier 定理给出, 是某个凸函数的梯度)；
- U 是**保体积映射** (保持 Lebesgue 测度, 即 $\det(DU) = 1$)。

QR 分解的类比

Brenier 极分解定理是矩阵 QR 分解的无穷维类比：

- **QR 分解**：任意矩阵 $M = QR$, 其中 Q 是正交矩阵 (保持体积), R 是上三角矩阵 (对应最优传输)；
- **Brenier 分解**：任意同胚 $S = T \circ U$, 其中 U 保体积, T 是最优传输。

更精确地说, 正定矩阵对应某个凸函数的 Hessian, 因此 QR 分解中的 R (或 Q) 实际上是最优传输映射的一个特例。同样, Helmholtz 分解也是 Brenier 极分解的特例。

保体积映射构成无穷维李群

所有保体积映射构成一个**无穷维李群**。这个李群上可以配备：

- 黎曼度量 (Arnold 度量)；
- 可以计算测地线 (即最优传输路径)。

这为理解最优传输的动力学性质提供了深刻的几何框架。

4.4 本章小结

本章将 Brenier 定理从欧氏空间推广到 Polish 空间, 建立了稳定性定理保证离散逼近的合理性, 并介绍了 Brenier 极分解定理——任意同胚都可以分解为最优传输映射与保体积映射的复合。这一分解是矩阵 QR 分解的无穷维推广, 揭示了最优传输与经典线性代数之间深刻的内在联系。

5 流体力学视角与 Helmholtz 分解

5.1 不可压缩流体与 Euler 方程

从流体力学的角度理解保体积映射特别直观。给定一个**无散矢量场**（散度处处为零）：

$$\operatorname{div} \mathbf{v} = 0$$

这对应于**不可压缩流体**——流体没有源也没有汇。

不可压缩流体满足 **Euler 方程**：

$$\frac{\partial \mathbf{v}}{\partial t} + (\mathbf{v} \cdot \nabla) \mathbf{v} = -\nabla p$$

即每个粒子的加速度等于压强的梯度。根据牛顿第二定律，压强梯度给出速度的一阶导。

5.2 连续性方程

由质量守恒，我们得到**连续性方程**：

$$\frac{\partial \rho}{\partial t} + \operatorname{div}(\rho \mathbf{v}) = 0$$

即每一点的密度随时间的变化率等于矢量场乘以密度的散度。

保体积映射的流体力学刻画

如果映射本身是保体积的，那么：

- 初始密度恒等于 1；
- 任意时刻密度也恒等于 1；
- 连续性方程简化为 $\operatorname{div} \mathbf{v} = 0$ 。

因此，如果速度场 $\mathbf{v}(t)$ 在任何时刻都是无散的，那么由该流生成的微分同胚群保持体积不变。

5.3 单参数微分同胚群

给定一个速度场 $\mathbf{v}(t, x)$ ，每个粒子在流场中得到一条流线。不同时刻粒子到场中不同位置，这样就得到了一个**单参数微分同胚群** g_t ：

$$\frac{d}{dt} g_t(x) = \mathbf{v}(t, g_t(x)), \quad g_0(x) = x$$

如果 $\mathbf{v}(t)$ 对所有 t 都是无散的，那么 g_t 对所有 t 都是保体积的微分同胚。

5.4 概率测度之间的线性插值

给定两个概率测度，密度分别为 f 和 g ，可以在它们之间进行线性插值：

$$\rho_t = (1-t)f + tg, \quad t \in [0, 1]$$

假设 $\rho_t \mathbf{v}$ 是某个函数的梯度（即 $\rho_t \mathbf{v} = \nabla \phi$ ），那么：

- 密度关于时间的导数是 $g - f$ （与时间无关）；
- 右侧变成某个函数的 Laplacian；
- 这导出了 Monge-Ampere 方程的另一种推导。

5.5 Helmholtz-Hodge 分解

在紧黎曼流形上，任意矢量场可以分解为三个正交分量：

$$\mathbf{v} = \nabla\phi + \mathbf{w} + \mathbf{h}$$

其中：

- $\nabla\phi$ ：梯度场（无旋）；
- $\mathbf{w}$ ：无散场（无源）；
- $\mathbf{h}$ ：调和场（既无散又无旋）。

Helmholtz-Hodge 分解的各分量

1. **梯度场**（无旋）： $(\nabla\phi) = 0$ ；
2. **无散场**（无源）： $\operatorname{div} \mathbf{w} = 0$ ；
3. **调和场**： $\operatorname{div} \mathbf{h} = 0$ 且 $\mathbf{h} = 0$ ，对应上同调类。

在单连通区域上， $H^1 = 0$ ，所以调和部分为零。但在一般流形上，每个上同调类中存在唯一的调和场，需要对高维的 cycle 进行积分。

流形上的计算注意事项

在流形上做计算时，必须去掉调和场部分。剩下的两部分：

- 无源部分对应散度为零的矢量场；
- 无旋部分对应梯度场。

对于单连通区域，调和部分为零，计算大大简化。对于非单连通区域（如环面），必须考虑调和场的贡献。

5.6 本章小结

本章从流体力学视角重新诠释了保体积映射和最优传输问题。不可压缩流体的 Euler 方程、连续性方程与最优传输的保测度条件本质相同。Helmholtz-Hodge 分解将任意矢量场分解为梯度、无散和调和三个正交分量，为理解最优传输映射的结构提供了微分几何工具。这一视角不仅具有理论美感，也为数值计算提供了新的算法思路。

6 半离散 Brenier 定理与计算应用

6.1 离散目标测度的情形

Brenier 定理的另一个令人惊异之处在于它对**离散情况**也是成立的。定理只要求源测度 μ 是绝对连续的，对目标测度 ν 没有任何要求。

因此，我们可以将目标测度变成 Dirac 测度（离散测度）：

$$\nu = \sum_{i=1}^N \lambda_i \delta_{p_i}$$

其中 $\sum_i \lambda_i = 1$, p_i 是离散点。

半离散 Brenier 定理

在半离散情形下：

1. Brenier 定理仍然成立；
2. 存在一个凸函数 u (凸多面体)；
3. 凸函数的梯度 ∇u 给出最优传输映射；
4. 连续概率分布被映射到离散概率分布。

6.2 凸多面体与 Power 图

在半离散情形下，Brenier 势能函数 u 是一个**凸多面体**——它是多个超平面的上包络：

$$u(x) = \max_{i=1,\dots,N} \{x \cdot p_i - h_i\}$$

这对应于将定义域 Ω 进行**胞腔分解** (cell decomposition)：

- 每个胞腔 W_i 对应一个离散点 p_i ；
- 在胞腔 W_i 内， $\nabla u = p_i$ (梯度为常值)；
- 胞腔的体积等于 λ_i (保持测度)。

胞腔分解的几何

- 左侧 (定义域) 的每个胞腔 W_i 映射到右侧的一个点 p_i ；
- 两个胞腔的公共边映射到右侧的整条边；
- 左侧的顶点映射到右侧的一个三角形。

虽然顶点的测度为零，严格来说每一点都有定义，但边界上的点映射可能不是单点而是集合，此时需要使用**次微分** (subdifferential) 或**次梯度** (subgradient) 的概念。

6.3 人脸曲面的计算实例

讲座展示了半离散 Brenier 定理在人脸曲面参数化中的应用：

1. 将人脸曲面进行三角剖分 (为可视化起见，使用极度粗糙的剖分)；
2. 通过保角变换将曲面映射到平面；
3. 将曲面的面积元作为每个顶点处的离散权重 ν_i ；
4. 构造一个凸多面体 (多个超平面的上包络)；
5. 迭代计算直至收敛，得到最优传输映射。

对偶关系

左侧的凸函数（原函数）的每个面是一个平面，在三维空间中对应右侧的一个点。右侧的凸函数（Legendre 变换）是这些对偶点的上包络。映射的对偶图形可以用凸包来计算：

- 右侧的每个面映射回左侧的一个点；
- 右侧的每个点映射到左侧的一个胞腔；
- 左侧的每个胞腔映射到右侧的一个点。

6.4 本章小结

半离散 Brenier 定理是 Brenier 理论在计算上最重要的应用之一。它允许我们将连续的概率分布映射到离散的概率分布，无需对定理做任何修改。在计算上，这转化为构造一个凸多面体（超平面的上包络），使得每个胞腔的体积等于对应离散点的权重。这一方法在人脸曲面参数化、图像处理等领域有广泛应用。

7 应用与延伸

7.1 深度学习中的 Normalizing Flows

Brenier 极分解定理与深度学习中当前特别热门的 **Normalizing Flows**（归一化流）方法有深刻联系。

Normalizing Flows 的数学基础

- Normalizing Flows 背后的数学基础正是用流体力学方法构造保测度变换；
- 历史上，这一方法源于 Gallavotti、Moser 等人的工作；
- 核心工具是“magic formula”——用 Poisson 方程构造保测度变换。

传统深度学习对网络表达的映射没有任何限制。当前的趋势是**控制网络表达映射的 Jacobian 矩阵**，通过控制 Jacobian 来控制对概率测度的变换。这一思想与流体力学思想是一致的。

局限与核心困难

- 流体力学方法只能得到保测度变换；
- 无法直接得到最优传输映射；
- **最优性**是计算中最困难的问题。

尽管如此，这种方法隐含的数学思想在深度学习中引起了广泛关注和应用。

7.2 图像处理中的应用

最优传输理论在图像处理中有多种应用：

7.2.1 颜色风格迁移

将图像的颜色看作 RGB 空间中的概率分布。如果要将图像的颜色从一个风格变换到另一个风格（如从夏天变为金秋）：

1. 在 RGB 空间中计算两个颜色分布之间的最优传输变换；
2. 应用该变换后，物体的形状不变，但整体画风改变。

7.2.2 纹理变换

如果图像中有特殊的纹理反映了某种风格，将纹理也用概率密度来描述，同样可以实现纹理之间的最优传输变换。

7.3 医学图像与形状分类

最优传输在连续流形的分类中有广泛应用：

- 将大脑曲面映射到单位球面；
- 将面积的畸变表达为概率测度；
- 在球面上计算两个概率测度之间的最优传输代价；
- 用这个距离对大脑进行分类（正常 vs 老年痴呆症）。

一般性原则

任何信息，一旦能转化为概率分布，就完全可以用最优传输理论来处理。这是最优传输理论应用广泛的根本原因。

7.4 讲座问答精选

7.4.1 Q1：为什么先做保角变换再求最优传输？

A：Brenier 定理要求源域和目标域属于同一个欧氏空间。将三维曲面先通过保角变换打到二维平面，再在平面上计算最优传输映射，这是理论最完备、计算最可行的路径。保角变换的理论基础（计算共形几何）有严格的理论保证，而大多数工程方法缺乏这种保证。

7.4.2 Q2：Brenier 极分解与 QR 分解的关系？

A：QR 分解中， $M = QR$ ， Q 是正交矩阵（保体积）， R 是上三角矩阵。从 Brenier 定理的角度看，正定矩阵对应某个凸函数的 Hessian，因此 QR 分解实际上是 Brenier 极分解的有限维特例。同样，Helmholtz 矢量场分解也是 Brenier 极分解的特例。

7.4.3 Q3：离散情况下梯度为常值的区域如何映射到离散点？

A：每个胞腔 W_i 映射到点 p_i 。边界上的点映射可能不是单点，需要使用次微分概念。严格来说，左侧每一点都有定义，但某些点的像是一个集合而非单点。

7.5 本章小结

本章介绍了 Brenier 定理在深度学习、图像处理和医学图像分析中的具体应用。Normalizing Flows 方法的数学基础正是 Brenier 极分解和流体力学构造；图像颜色风格迁移将 RGB 颜色空间视为概率分布进行最优传输；医学图像分类通过将曲面面积畸变转化为概率测度来计算形状之间的距离。这些应用共同印证了一个核心原则：任何可概率化的信息都可以纳入最优传输的框架。

8 总结与延伸

8.1 讲座核心内容回顾

本次讲座围绕 Brenier 定理展开了系统的理论阐述，核心内容包括：

1. **Brenier 定理**：在严格凸代价（特别是欧氏距离平方）下，最优传输映射必然是一个凸函数的梯度映射 $T = \nabla u$ ；
2. **几何直观**：凸函数是多个支撑平面的上包络，其梯度给出最优传输映射，Legendre 变换给出逆映射；
3. **Monge-Ampere 方程**：最优传输映射满足 $\det(\text{Hess } u) \cdot f(\nabla u) = g$ ；
4. **极分解定理**：任意同胚可分解为最优传输映射与保体积映射的复合；
5. **半离散情形**：对离散目标测度，Brenier 定理仍然成立，对应凸多面体和胞腔分解；
6. **流体力学视角**：保体积映射对应不可压缩流体，Euler 方程和连续性方程给出动力学描述。

8.2 理论联系

最优传输的“一体两面”

- **概率统计视角**：Brenier 定理将概率测度之间的传输转化为凸函数的优化；
- **微分几何视角**：凸函数的梯度映射、Legendre 变换、Monge-Ampere 方程都是经典微分几何的对象；
- 两个视角可以互相借用观点和技巧来解决各自的问题。

8.3 计算要点

1. **几何方法**：直观但误差估计困难，计算时间较长；
2. **蒙特卡洛方法**：对计算复杂度影响不大；
3. **快速傅里叶分解**：对计算复杂度有影响；
4. **半离散算法**：构造凸多面体，迭代调整平面高度直至胞腔体积匹配目标权重。

8.4 研究方法论

讲座末尾，顾教授分享了他对研究方法论的看法，特别是与丘成桐先生培养方式的比较：

顾险峰教授的研究建议

1. **理论严密性**：数学上每句话都要有严格的逻辑推理，这与计算机领域“能跑通即可”的标准不同；
2. **两种才华**：丘成桐先生认为，衡量才华要么能证明大定理，要么能编写复杂算法；
3. **讨论班制度**：长期坚持讨论班，深入研读经典论文，几年下来功力会非常深厚；
4. **研究方向**：与当前最热的题目保持审慎态度，尽量呈 90 度而非完全平行；
5. **跨领域视角**：跨领域的观点对于做研究非常关键，最优传输理论本身就是概率与几何的完美结合。

8.5 开放问题

1. **边界条件**：Brenier 定理给出的 $\nabla u(\Omega) = \Omega^*$ 边界条件非常特殊，既非 Dirichlet 也非 Neumann，如何在数值计算中有效处理？
2. **高维计算**：在高维空间（如深度学习中的高维数据分布）中，半离散 Brenier 定理的计算复杂度如何控制？
3. **流形上的最优传输**：如何将 Brenier 定理推广到一般黎曼流形上，特别是非单连通流形？
4. **最优性保证**：深度学习中基于流体力学的方法只能保证保测度，如何保证最优性？

8.6 下一步学习

系列讲座第四讲将介绍：

- Alexandrov 定理与凸几何；
- Minkowski 问题；
- 用凸几何重新推导 Brenier 定理；
- 微分几何与 Brenier 定理之间的内在联系。