

确定性基础设施如何托住非确定性 AI Agent

Deterministic Infra for Non-Deterministic AI Agents

Nishant Gupta, Meta Superintelligence Labs

SSS & Codex 2026-07-02



视频作者/频道: AI Engineer

发布日期: 2026-06-29

视频时长: 00:07:13

视频链接: <https://www.youtube.com/watch?v=APh1Vx0oLmQ>

本 PDF 结构: 基于本地元数据、英文字幕、源视频画面与重绘教学图, 按金字塔原则组织为中文技术讲义。

目录

1 从模型能力到生产可靠性：Agent 带来的大错配	2
1.1 先给结论：生产化的核心问题已经从“会不会”转向“稳不稳”	2
1.2 从聊天机器人到生产 Agent：动作半径变大，事故半径也变大	2
1.3 现代云基础设施的默认假设，被 Agent 逐条击穿	3
1.4 生产系统真正优化的是成功概率、延迟、成本和结果边界	4
1.5 工程重心下沉：模型层之下才是长期战场	5
1.6 本章小结	6
2 失控不是从幻觉开始：重试放大与成本事故	6
2.1 故障树：一次模型错误如何进入系统层	6
2.2 重试风暴：从无效参数到 GPU 计算尖峰	7
2.3 公式一：Agent 总成本模型	8
2.4 公式二：重试树的请求增长	9
2.5 从失败模式到平台需求	10
2.6 本章小结	11
3 平台做决定：确定性 Agent 控制面的架构	11
3.1 模型提出方案，平台完成治理	11
3.2 Agent 控制面是新的基础设施层	13
3.3 可观测性必须解释为什么发生	14
3.4 本章小结	15
4 状态、安全、人工与资源：生产 Agent 的边界工程	16
4.1 先给结论：Agent 控制面只有包住四条边界，才算进入生产形态	16
4.2 共享记忆：很多推理故障其实是状态一致性故障	16
4.3 分层安全：把模型输出逐层收束成有边界的动作	18
4.4 人工监督：把人类注意力用在异常、灰区和校准上	20
4.5 推理即调度：AI inference 正在变成资源编排问题	21
4.6 四条边界需要统一在同一个控制面里	23
4.7 本章小结	23
5 可靠性 Rosetta Stone：把分布式系统经验迁移到 Agent	24
5.1 Rosetta Stone：把旧模式翻译成新边界	24
5.2 从 prompt 到 model，再到 infrastructure	26
5.3 总结与延伸	27
5.4 本章小结	29

1 从模型能力到生产可靠性：Agent 带来的大错配

1.1 先给结论：生产化的核心问题已经从“会不会”转向“稳不稳”

Nishant Gupta 在开场给出的身份很关键：他是 Meta 的软件工程技术负责人 (software engineering tech lead)，工作内容集中在训练与推理基础设施 (training and inference infrastructure)。这意味着这场分享采用基础设施视角：把 AI Agent 放进真实生产系统之后，平台工程需要承担什么责任。

本章的核心判断可以先压缩成一句话：AI Agent 的能力突破把问题推到了系统边界上；随机模型可以提出计划、调用工具和组织流程，生产基础设施必须把这些不确定动作约束在可验证、可观测、可恢复、成本可控的执行框架里。

本节的总论点：自主智能体 (AI Agent) 的生产可靠性，取决于确定性基础设施 (deterministic infrastructure) 能否包住非确定性 AI Agent (non-deterministic AI agents) 的计划、工具调用、状态变化和生行动作。模型能力回答“这一次能做成吗”，生产系统追问“在一万次、十万次、一百万次重复执行中，它能否以可接受成本、延迟和结果稳定完成”。




图 1: 演讲标题页把主题定位为自主 AI 系统的控制面：随机智能体需要被装入可治理的基础设施框架中。¹

标题页中的英文副标题 “The Emerging Control Plane for Autonomous AI Systems” 给出了全篇的方向：Agent 生产化需要一个新的控制面。控制面 (control plane) 可以类比交通管制系统：飞机本身有动力和导航能力，空管系统负责航线、权限、冲突避免、降落顺序和异常处理。AI Agent 也一样，模型负责生成计划，平台负责限制动作边界、记录过程、处理失败并守住生产系统。

1.2 从聊天机器人到生产 Agent：动作半径变大，事故半径也变大

过去几年，AI 讨论常围绕“更大的模型、更多参数、更强推理”。Gupta 在 00:00:19–00:00:48 的开场把焦点拉开：组织正在从聊天机器人 (chatbot) 走向自主智能体。聊天机器人主要回答问题，Agent

¹ 视频时间：00:07–00:16。

开始规划 (plan)、调用工具 (tool call)、协调工作流 (coordinate workflows)，甚至做出会影响生产系统的决策。

这个迁移带来一个工程后果：模型输出从“文本建议”变成“系统动作的候选方案”。当 Agent 调用支付、部署、客户数据、库存、代码仓库或监控系统时，一次错误的计划会进入真实资源和真实状态。于是，可靠性成为上线条件，而非模型评测中的附加指标。

“随机”在这里指系统具有概率化生成过程，不能理解成完全混乱。随机模型 (stochastic model) 或非确定性模型 (non-deterministic model) 的含义是：即使输入相似，模型也可能生成不同推理路径、工具参数或执行顺序。工程上的确定性基础设施强调另一件事：权限规则、输入校验、状态写入、审计记录、资源配额和失败恢复必须可预测。一个形象类比是：实习工程师可以提出多种方案，生产变更系统必须按固定流程审批、执行、回滚和记录。

Gupta 用一句短语概括这条主线：这些系统本质上是概率化的，而基础设施承担着确定性约束的职责。这里的张力正是后文所有架构设计的源头。

1.3 现代云基础设施的默认假设，被 Agent 逐条击穿

现代云基础设施主要围绕微服务请求演化：请求短、服务行为大体确定、执行路径可预期、故障影响有边界。这个范式非常适合 API、RPC、队列消费者、无状态服务和可横向扩展的请求处理器。Gupta 在 00:00:52-00:01:30 把它称为 Agent 与基础设施之间的“大错配” (great mismatch)。




图 2: The Great Mismatch: 传统微服务偏无状态、确定路径、同步请求响应和毫秒级执行；自主 AI Agent 偏有状态、概率化、多步异步工作流和分钟到小时级运行。²

图 2 的价值在于它把抽象风险拆成四个工程维度。

- 状态：传统微服务常把状态外置到数据库或缓存中，单次请求尽量无状态；Agent 往往携带上下文、记忆、任务进度和中间判断。

² 视频时间：00:58-01:10。

- 路径：传统服务的执行路径通常由代码分支和配置决定；Agent 的路径会根据模型推理、工具返回、检索结果和中间失败动态改变。
- 流程：传统请求响应多为同步调用；Agent 可能运行多步工作流，包含等待、重试、外部工具、人工审批和状态恢复。
- 时间：传统线上请求常以毫秒或秒为单位优化；Agent 工作流可能持续分钟甚至小时，资源占用和状态一致性问题会累积。

常见误判是把 Agent 当作“带工具的 API 请求”。这个视角会漏掉状态漂移、长事务、动态路径、重复调用、成本累积和恢复策略。微服务时代的可靠性边界仍然有用，但边界位置需要重新画到模型提案、工具执行、记忆读写和工作流调度之间。

因此，“great mismatch”指向一个系统模型冲突：我们试图把长时、有状态、动态决策、概率化的自主系统，运行在为短时、确定、已知路径、有限故障设计的基础设施上。错配越大，单次模型错误被放大成系统事故的概率越高。

1.4 生产系统真正优化的是成功概率、延迟、成本和结果边界

Gupta 在 00:01:31–00:01:59 明确指出，AI 演示通常展示 capability：能不能解决一个问题，能不能使用一个工具，能不能完成一个工作流。生产系统的目标更硬：能否可靠执行，能否重复一万次、十万次、一百万次，能否从失败中恢复，能否安全运行，能否保持可接受成本、可接受延迟和可接受结果。




图 3：能力演示位于上层，生产可靠性是底座；可靠系统关注的是在 SLO 内安全、正确、可恢复地重复完成任务。³

这就引出一个更适合生产工程的度量方式：不要只问“模型有没有能力完成任务”，而要问“系统在服务等级目标（Service Level Objective, SLO）窗口内成功完成的概率有多高”。SLO 是生产系统

³ 视频时间：01:36–01:51。

向业务承诺的目标窗口，例如 95% 的任务在 30 秒内完成，或者 99.9% 的关键动作经过安全校验后成功执行。

直观地说，生产 Agent 的可靠性可以被看作一个联合事件：任务完成时间没有超过延迟预算，动作安全，结果正确。于是可以写成：

$$P(\text{success within SLO}) = P(T_{\text{finish}} \leq L, \text{safe} = \text{true}, \text{correct} = \text{true})$$

符号说明：

- $P(\text{success within SLO})$ ：Agent 工作流在服务等级目标内成功完成的概率。
- T_{finish} ：从任务开始到工作流结束的实际完成时间，包含推理、工具调用、等待、重试和恢复时间。
- L ：SLO 给出的最大可接受延迟或完成时间窗口。
- $\text{safe} = \text{true}$ ：执行过程满足权限、安全、合规、成本和风险边界。
- $\text{correct} = \text{true}$ ：输出或动作满足任务目标，经校验后被认为正确。

这个公式的工程含义很直接：能力演示只覆盖了 correct 的一部分；生产可靠性还要求时间、成本、安全、恢复和重复执行都进入同一个成功事件。只要其中一个条件经常失败，整体成功概率就会被拉低。比如，一个 Agent 最终答案正确，但每次都需要 20 次工具调用、偶尔越权访问、延迟从 5 秒抖到 5 分钟，它在生产语境里仍然是低可靠系统。

1.5 工程重心下沉：模型层之下才是长期战场

本章最后要建立整篇 PDF 的主轴：随着 Agent 进入生产，工程工作会大量移动到模型层之下。Gupta 在本时间窗末尾指出，多数工程努力会转向编排 (orchestration)、监控 (monitoring)、安全评估 (safety evaluation) 和恢复系统 (recovery systems)。

模型能力仍然重要。更准确的表述是：模型能力提供可能性，基础设施决定这种可能性能否被重复、安全、低成本地交付。平台需要回答的问题包括：

- 当模型给出工具调用参数时，谁负责校验 schema、权限、幂等性和业务规则？
- 当工作流失败时，系统如何区分可重试错误、需降级错误和需人工升级的异常？
- 当 Agent 运行一百万次时，尾部延迟、罕见错误、状态污染和成本尖峰如何被观测并控制？
- 当同一输入可能产生不同路径时，审计系统如何重建“为什么发生了这次动作”？

第 1 节要读者带走的结构化判断是：Agent 生产化的关键任务，是把“模型提案、平台验证、策略审批、网关执行、追踪观测、失败恢复”连成闭环，工具接入只是其中一个环节。后续章节会分别展开失败如何被放大、控制面如何约束动作、状态与安全边界如何设计，以及分布式系统经验如何迁移到 Agent 平台。

1.6 本章小结

本章完成了全篇的地基搭建。Nishant Gupta 以 Meta 训练与推理基础设施负责人的视角提出：Agent 的生产化难点已经从单次智能表现，转向大规模重复执行中的可靠性。Agent 会规划、调用工具、协调流程并影响生产系统，因此它的错误会进入真实状态、真实资源和真实成本。

“great mismatch” 概括了核心矛盾：现代云基础设施默认短请求、确定路径、有限故障；自主 AI Agent 带来长时、有状态、动态路径和概率化执行。生产系统最终关心的是 $P(\text{success within SLO})$ ：在 SLO 内安全、正确、可接受成本和延迟地完成任务的概率。由此，工程重心会下沉到编排、监控、安全评估、恢复和控制面。下一章将把这个可靠性目标具体化为故障机制，尤其是重试放大、上下文污染、记忆投毒和成本爆炸如何把一次小错误推成生产事故。

2 失控不是从幻觉开始：重试放大与成本事故

生产级 AI Agent 的危险，经常从一个很小的工具错误开始，随后被基础设施放大成资源、成本和可用性事故。第 1 章已经把目标从 demo capability 转向 reliability；本章进一步说明：在真实系统中，幻觉（hallucination）只是入口之一，更值得警惕的是递归推理循环（recursive reasoning loops）、工作流死锁（workflow deadlocks）、重试放大（retry amplification）、上下文污染（context corruption）、记忆投毒（memory poisoning）和成本爆炸（cost explosions）之间的连锁反应。

本章主张

Agent 失控的关键机制是“错误被系统反复执行”。模型的一次错误输出本来可能只是一次失败请求；一旦平台缺少边界、预算、幂等、退避和追踪，这个错误会被重试、改写、再次提交、继续消耗 GPU 与工具调用额度，最终演化为 compute incident。

2.1 故障树：一次模型错误如何进入系统层

演讲者在 00:02:06–00:02:32 明确指出，人们听到 AI failure 时容易首先想到 hallucination；在生产环境中，更常见、更麻烦的形态是 infrastructure failure。原因很直接：幻觉发生在模型输出层，而事故发生在执行链路层。执行链路会把一个局部错误交给工具、状态、记忆、调度器和重试系统，随后每一层都可能产生新的副作用。




图 4: 生产故障诊断树: 随机模型输出沿着逻辑、动作和状态三条路径扩散, 形成递归推理循环、工具幻觉、重试风暴、上下文漂移、工作流死锁、成本爆炸和记忆投毒。⁴

这张故障树把故障分成三条主线。

- **Logic 路径:** 模型在推理中重复修补自己的前一步结论, 形成 recursive reasoning loops。它看起来像“更努力地思考”, 实际可能是在错误状态附近空转。
- **Action 路径:** Agent 调用工具时产生 tool hallucinations, 例如虚构参数、误用 API、错配 schema。工具返回错误后, Agent 又生成一个略有变化的新请求。
- **State 路径:** 上下文窗口、检索结果和共享记忆被污染后, Agent 后续每一步都基于更差的输入继续行动, 产生 context drift 与 memory poisoning。

直觉类比: 错误输出像火花, 基础设施像风道

单次 hallucination 类似一颗火花。若它落在隔离良好的环境里, 最多烧坏一个局部请求; 若它进入自动重试、共享状态和无限工具调用组成的风道, 系统会持续给它送风。工程风险来自“火花 + 风道”的组合。

这个分类有一个隐藏含义: Agent 系统的可靠性不能只靠提示词修补。提示词可以降低初始错误概率, 基础设施必须限制错误传播半径。传播半径越大, 单次错误越容易跨过服务边界、状态边界和预算边界。

2.2 重试风暴: 从无效参数到 GPU 计算尖峰

演讲者给出的具体案例是 invalid tool call retry loop: Agent 调用工具时传入无效 API 参数, 工具返回 error code; Agent 没有真正恢复, 转而生成一个略有差异、仍然无效的请求; 循环继续, 推理深度增加, GPU consumption 上升, 最后出现指数式资源增长。这个过程把 minor API error 变成 compute incident。

⁴视频时间: 02:16–02:30。




图 5: Agent retry storm 的解剖：无效 API 参数触发工具错误，Agent 反复生成新的无效请求，递归推理锁死后带来 GPU compute spike 与成本爆炸。⁵

常见误判：把重试当成可靠性保险

在传统服务里，有限次数、带退避、具备幂等保障的 retry 可以吸收瞬时故障。Agent 场景里的 retry 还会重新推理、重新改写参数、重新读取上下文、重新调用工具。若没有硬性预算和语义校验，retry 会变成错误的放大器。

这里的关键区别在于：传统请求的失败通常有比较固定的重试形状，例如同一个 HTTP request 重发 3 次；Agent 的失败会改变后续请求本身。每一次“稍微改一下”的尝试都可能开启新的工具路径、占用新的模型推理 token、读取新的记忆片段，并把错误写回上下文。于是系统看到的负载不再是线性队列，而是树状展开。

2.3 公式一：Agent 总成本模型

先用直觉说清楚：Agent 的总成本来自一串时间步或执行阶段。每一步都可能消耗 token、GPU 时间、工具调用费用、外部 API 额度、数据库查询、队列资源和人工审核时间。只要一个错误让执行链路多走一步，总成本就会增加；若错误触发多轮 retry，总成本会按多轮路径累积。

$$C_{total} = \sum_{t=1}^T q_t c_t$$

符号说明：

- C_{total} ：一次 Agent 工作流的总成本。
- T ：工作流经历的总时间步或执行阶段数量。
- t ：第 t 个时间步或执行阶段。

⁵ 视频时间：02:36-02:50。

- q_t : 第 t 步消耗的资源量, 例如 GPU 秒数、token 数、API 调用次数、数据库查询次数。
- c_t : 第 t 步对应资源的单位成本。

工程含义: 成本治理必须进入执行路径本身。平台需要给每个 Agent 设置 token budget、tool-call budget、GPU time budget、外部 API quota 和人工升级阈值。若只在账单出来后做统计, 系统已经把错误执行完了。

成本公式的工程读法

C_{total} 不是财务报表里的抽象数字, 它是每一步执行决策的累积后果。Agent 多想一步、多试一次工具、多占用一段 GPU、多写一次共享记忆, 都会进入 $\sum q_t c_t$ 。

2.4 公式二: 重试树的请求增长

再看 retry amplification。若每次失败平均派生出 b 个后续尝试, 系统最多展开到深度 d , 总请求数可以用一棵重试树估算。第 0 层是初始尝试, 第 1 层是第一次派生重试, 第 d 层是最后一层重试。

$$N(d) = \sum_{i=0}^d b^i$$

当 $b \neq 1$ 时, 可以写成闭式形式:

$$N(d) = \frac{b^{d+1} - 1}{b - 1}$$

符号说明:

- $N(d)$: 深度为 d 时累计产生的尝试次数或请求数量。
- d : 重试树深度, 也可以理解为 Agent 允许连续修补错误的最大轮数。
- b : 分支因子, 表示每次失败平均派生出的新尝试数量。
- i : 树的层级索引, 从初始尝试 $i = 0$ 开始。

工程含义: 当 $b > 1$ 时, 请求数随深度快速增长。举例说, $b = 3, d = 4$ 时, $N(4) = 1 + 3 + 9 + 27 + 81 = 121$ 。一次无效 API 参数若被 Agent 当作“继续探索”的信号, 短时间内就可能产生 121 次模型推理、工具调用或状态读写。GPU 曲线因此出现尖峰, 队列延迟被拉长, 成本预算被击穿。

Retry amplification turns small errors into GPU spikes




图 6: 重试放大曲线: 基础请求量叠加 retries 与 tool cost 后, 负载可能越过 GPU 或 quota 上限, 形成资源饱和与成本事故。⁶

为什么指数增长容易被低估

人脑对线性增长很敏感, 对树状增长经常迟钝。线性增长像排队: 每次多来一个人; 树状增长像转发链: 每个人又叫来几个人。Agent retry storm 属于后者, 因为每次失败都可能派生新的推理分支、新工具参数和新状态访问。

2.5 从失败模式到平台需求

本章的结论直接引出第 3 章的 architecture principle。若模型可以直接控制生产系统, 错误会进入工具、状态和资源层; 若平台在执行前进行 validation、policy approval、rate limiting、budget enforcement、schema checking 和 human escalation, 错误会在更靠近源头的位置被截断。

这种工程判断还揭示了几个容易被忽视的风险:

- **Workflow deadlocks:** 多个 Agent 或步骤互相等待状态更新、审批结果或工具回调, 系统表面上仍在运行, 实际吞吐归零。
- **Context corruption:** 错误的工具返回、过期检索结果或无关历史被塞进上下文, 后续推理以污染输入为依据继续行动。
- **Memory poisoning:** 错误事实进入共享记忆后, 会影响后续多个 Agent, 单次错误变成跨任务污染。
- **Cost explosions:** 成本增长经常先表现为 token、GPU 秒数和外部 API 调用的异常, 再表现为账单、排队延迟和 SLO 失败。

⁶ 视频时间: 02:36–02:50。根据该时间段图示重绘。

实现层面的硬要求

生产 Agent 平台需要把 retry 写成受控恢复流程：限制最大深度 d ，约束分支因子 b ，要求工具调用通过 schema 校验，记录每次失败原因，区分瞬时错误与语义错误，并在成本或风险越界时升级给人类或直接中止。

2.6 本章小结

本章把“AI failure”从抽象担忧落到具体机制：模型错误进入逻辑、动作和状态三条路径后，会形成递归循环、工具误用、重试风暴、上下文污染、记忆投毒、死锁和成本爆炸。成本公式 $C_{total} = \sum_{t=1}^T q_t c_t$ 说明每一步执行都会进入总成本；重试树公式 $N(d) = \sum_{i=0}^d b^i$ 说明无控制的 retry 会把小错误放大成大负载。下一章要回答的核心问题因此变得明确：平台必须把模型提案包进确定性控制面，让验证、审批、执行、限流、追踪和升级路径承担可靠性责任。

3 平台做决定：确定性 Agent 控制面的架构

生产级 AI Agent 的核心架构原则可以压缩成一句话：模型生成提案，平台负责决定。上一章看到，递归重试、工具误用、上下文污染和成本爆炸会把一次小错误放大成系统事故；本章给出的回答是把非确定性模型（non-deterministic model）放进确定性基础设施（deterministic infrastructure）的控制边界里。模型可以给出候选动作，基础设施必须验证，策略引擎（policy engine）必须审批，执行网关（execution gateway）必须强制执行。

本章的第一原则是：AI Agent 可以建议生产动作，生产系统的最终决定权必须留在平台控制面。这里的“决定”包括权限判断、风险评估、成本约束、参数校验、幂等保护、人工升级和审计记录；这些能力属于基础设施，不能交给一次模型输出临场发挥。

3.1 模型提出方案，平台完成治理

演讲者在 00:03:08 之后给出最强的架构建议：不要让模型直接控制生产系统。更精确地说，一个随机核心（stochastic core）可以生成“想要做什么”的方案，确定性包装层（deterministic wrapper）要判断“是否允许这样做、怎样做才安全、失败后如何处理”。这类似生产变更系统：工程师可以提交变更单，变更系统会检查权限、影响范围、审批状态、回滚方案和发布时间窗。AI Agent 在这里像一个速度极快、创造力很强的实习工程师；平台像发布系统和值班制度的组合，负责把想法变成可治理的动作。





图 7: 平台决定，模型仅提出方案。画面中的 stochastic core 被 deterministic wrapper、validation、filter route、safe execution 和 system compliance 包围，说明生产执行权位于平台边界上。⁷

这张图的关键含义在于“动作路径”被拆成多个可审计的关卡。模型输出先进入验证层，验证层检查结构、参数、上下文和安全约束；策略引擎再根据组织规则、权限、风险等级和成本预算给出批准、拒绝、修复或升级；执行网关最后把批准后的动作提交给工具、API 或生产系统，并在提交点施加限流、审计、幂等和回滚钩子。

Model proposes; platform policy executes



Infrastructure owns irreversible effects. The model supplies candidates.

图 8: 从模型提案到执行网关的治理路径。重绘图把“生成提案、策略审批、网关执行、修复重试、人工批准”放成一条清晰控制流，便于读者看清每个责任边界。⁸

⁷ 视频时间: 03:05-03:19。

常见误区是把“模型更聪明”理解成“模型可以越过平台”。这会把概率推理直接接到生产副作用上：删除数据、改配置、开资源、发邮件、调用支付接口都可能从一次不稳定判断变成真实事故。可靠架构要把模型输出视为 proposal，而把 production action 视为需要治理的提交。

3.2 Agent 控制面是新的基础设施层

演讲者把这个治理层称为 Agent 控制面 (agentic control plane)。这个概念借用了云原生系统中的控制面思想：容器规模化之后出现 Kubernetes，微服务复杂化之后出现 service mesh，AI Agent 进入生产后也需要一个专门层来管理运行时行为。类比要抓住同构关系：Kubernetes 关注“容器在哪里跑、如何恢复、如何扩缩容”；service mesh 关注“服务之间如何通信、限流、熔断、观测”；Agent 控制面关注“自主工作流如何被调度、约束、评估、记忆协调和追踪”。




图 9: Agent 控制面成为新的基础设施层。画面展示 memory coordinator、orchestration engine、safety policy node 和 compute scheduler，底部连接 foundational LLMs 与 data APIs，顶部承载 Agent applications。⁹

一个完整的 Agent 控制面至少要承担六类责任。第一是调度 (scheduling)：把长推理、工具调用、人工等待和资源占用编排成可管理的任务。第二是记忆协调 (memory coordination)：避免多个 Agent 对共享状态产生陈旧读、冲突写和上下文漂移。第三是策略执行 (policy enforcement)：把权限、风险、合规、成本预算和组织规则落实到每次动作。第四是评估 (evaluation)：在关键节点检查输出质量、任务完成度和安全条件。第五是监控 (monitoring)：持续观察延迟、失败、重试、成本和资源曲线。第六是工作负载路由 (workload routing)：把请求送到合适模型、工具、队列、GPU 或人工处理路径。

⁸视频时间：03:05–03:19。根据该时间段图示重绘。

⁹视频时间：03:25–03:38。

控制面和数据面是分布式系统里的基本分工。数据面处理实际流量，例如一次 API 调用或一次工具执行；控制面维护规则、策略、路由和状态，例如限流策略、调度决策、健康检查和权限配置。把这个分工迁移到 Agent 系统后，模型生成的计划属于候选意图，平台控制面负责把候选意图变成受控执行。

这层控制面的价值来自“可替换的智能”和“可积累的系统能力”分离。模型会升级，prompt 会变化，工具会扩展；调度、记忆、策略、评估、监控和路由形成长期复用的基础设施资产。组织若把这些规则散落在 prompt、脚本和人工经验里，每一次模型替换都会重新暴露同类风险；组织若把这些规则沉淀进控制面，模型能力提升反而会放大平台治理收益。

3.3 可观测性必须解释为什么发生

控制面可以决定，前提是它能留下足够证据。传统日志通常回答“发生了什么”：哪个服务报错、哪个接口返回 500、哪条 SQL 慢。Agent 工作流还要回答“为什么发生”：模型为什么选择这个计划，为什么调用这个工具，为什么读取这段记忆，为什么把状态从等待推进到执行，为什么在失败后继续重试或升级给人类。





图 10: 自主工作流需要多维可观测性。源图把 LLM decisions、orchestration plans、tool calls and execution、memory access 与 state transitions 放在同一时间线上，强调调试 Agent 时要追踪决策链。

10

因此，可观测性 (observability) 在 Agent 系统里要升级为追踪 (tracing)。一条合格的 trace 应该记录计划决策、工具调用、记忆检索、状态转换以及每个关键节点的原因。它的作用类似飞机黑匣子：事故发生后，团队需要复原当时的输入、判断、动作、状态和保护机制。只有最终输出是不够的，因为最终输出可能看起来合理，内部路径却已经违反权限、消耗过多资源，或者污染共享记忆。

¹⁰ 视频时间：03:55–04:10。

Agent observability needs aligned trace lanes



A trace is a time-aligned explanation of cause, cost, state, and action.

图 11: 多泳道 trace 的教学重绘。重绘图把模型决策、编排计划、工具调用、记忆访问和状态迁移对齐在同一时间轴上, 使“为什么这个 workflows 会发生”可以被逐步还原。¹¹

从工程上看, trace 需要把每个动作绑定到因果链上。例如, 一次工具调用要能追溯到触发它的 plan step、输入参数来源、读取过的 memory item、执行前的 policy verdict、执行后的状态变化和失败恢复路径。若系统只保存最终回答, 排障会退化成猜测; 若系统保存完整链路, 团队可以定位问题发生在模型计划、策略审批、工具参数、记忆检索、状态机迁移或执行网关中的哪一层。

Agent tracing 的目标是让平台回答三个问题: 一是 workflow 做了什么; 二是 workflow 为什么这样做; 三是哪个控制点批准、阻止、修复或升级了这个动作。缺少第三类证据, 控制面就只剩架构图, 无法承担生产责任。

3.4 本章小结

本章的结论是: 生产 Agent 架构的中心任务是建立 “model proposes, platform decides” 的确定性控制面, 避免模型直接接管系统。模型负责生成候选计划; 基础设施负责验证; 策略引擎负责审批; 执行网关负责强制执行; Agent 控制面负责调度、记忆协调、策略执行、评估、监控和工作负载路由; 多维 tracing 负责记录计划决策、工具调用、记忆检索、状态迁移以及 workflows 发生的原因。

这套架构把上一章的失控风险转化为可治理边界。递归重试要经过策略与网关, 工具调用要经过参数和权限检查, 记忆读取要留下版本与来源, 状态转换要能被追踪, 异常路径要能升级给人类或进入修复流程。读者应当记住一个判断: 随机模型可以产生有价值的行动建议, 生产可靠性来自平台把这些建议变成可验证、可审批、可执行、可追踪的系统行为。

¹¹ 视频时间: 03:55–04:10。根据该时间段图示重绘。

4 状态、安全、人工与资源：生产 Agent 的边界工程

4.1 先给结论：Agent 控制面只有包住四条边界，才算进入生产形态

第 3 节已经建立了核心架构原则：模型提出方案，平台负责决定。第 4 节要补上这个原则的运行边界：生产级 AI Agent 至少需要同时管理状态边界、安全边界、人工边界和资源边界；单独部署一个策略引擎或执行网关，覆盖面仍然太窄。Nishant Gupta 在 00:04:24–00:06:05 的重点很集中：多 Agent 共享记忆会引入一致性问题，安全必须按纵深防御（defense in depth）分层设计，人工监督（human supervision）应成为异常升级和校准机制，推理基础设施会越来越像集群调度（cluster scheduling）。

本章的总判断可以先压缩成一句话：Agent 的可靠性来自连续边界，而连续边界的职责是把随机推理、共享状态、工具动作、人工判断和 GPU 资源纳入同一个可审计的控制面。这里的“边界”可以类比城市道路系统：车可以由不同司机驾驶，路网仍然需要车道线、红绿灯、限速、交警、事故记录和拥堵调度。Agent 也一样，模型可以生成不同路径，基础设施必须让每一步读写、审批、执行和资源占用都可解释、可限制、可恢复。

本章核心命题：Agent 控制面（agentic control plane）的生产边界至少包含四层工程责任：记忆一致性（memory consistency）约束“谁看见了什么状态”，纵深防御约束“模型输出能否变成动作”，人工监督约束“哪些模糊场景需要升级”，集群调度约束“推理、工具调用和长工作流占用多少资源”。任何一层缺位，模型错误都有机会被放大成状态污染、安全事故、人工拥塞或成本尖峰。

4.2 共享记忆：很多推理故障其实是状态一致性故障

Gupta 把记忆称为 Agent 架构中最容易被低估的挑战之一。原因很直接：单个 Agent 的上下文窗口已经可能漂移；多个 Agent 共享状态后，系统会立即遇到分布式系统里的老问题，包括陈旧读（stale reads）、冲突更新（conflicting updates）、上下文漂移（context drift）和不一致视图（inconsistent views）。这些问题表面上像“模型想错了”，底层常常是“模型读到的世界已经过期、互相矛盾或来源不清”。





图 12: Shared memory coordinates chaotic multi-agent consistency: 多个 Agent 围绕同一 state store 读写，画面标出 context drift、conflicting facts 和 stale memory 等一致性风险。¹²

图 12 把共享记忆画成一个 state store 周围的多 Agent 协作结构，这比普通“上下文窗口”更接近生产系统真实风险：每个 Agent 都可能读到不同版本、写入相互冲突的事实，或者把陈旧记忆继续传递给下游流程。读者需要知道某个 Agent 在什么时间读到了哪一个版本的状态、检索到了哪些片段、随后写入了什么事实、其他 Agent 又基于哪个版本继续行动。没有这条链，调试人员只能看到“答案怪了”或“动作错了”，很难还原状态污染的来源。

Shared memory turns agent chatter into versioned state



Without versions: stale memory, context drift, conflicting facts.
With versions: reads and writes become auditable coordination points.

图 13: 共享记忆应被当作带版本的状态系统，读写通过一致性守卫进入审计链；这样才能区分陈旧读、冲突写和检索噪声。¹³

¹²视频时间：04:15–04:30。

图 13 把机制画得更清楚：多个 Agent 连接到同一个状态存储 (state store)，每次读写都应携带版本、来源、置信度和更新语义。一个最小可行的共享记忆层至少要回答四个问题。

- 版本问题：Agent A 读到的是 v_{42} ，Agent B 是否已经写入 v_{43} ？如果 A 继续基于 v_{42} 写入，系统如何发现这个写入建立在旧世界上？
- 冲突问题：两个 Agent 对同一客户、同一任务、同一配置写入相反事实时，系统按时间覆盖、按来源权威度合并，还是升级给人工？
- 语义问题：检索型记忆 (retrieval-based memory) 返回的是相关片段，不等于返回了完整事实；相似度高的材料仍可能过期、片面或适用条件不同。
- 审计问题：当最终动作失败时，系统能否追溯该动作依赖的记忆条目、检索查询、状态版本和写入者？

常见故障是把向量检索结果当成数据库事实。向量库擅长按相似度召回材料，它给出的分数通常表示语义接近程度，不能自动保证时间新鲜度、业务权威性、权限合法性或事实完整性。若 Agent 把“相关”误当成“当前正确”，系统会出现看似有推理链、实际基于过期材料的错误动作。

分布式系统里有一个朴素经验：共享状态越多，协调成本越高。数据库用事务、锁、版本号、隔离级别和冲突检测来处理这个问题；多 Agent 记忆层也需要类似设计。一个直观类比是多人协作编辑文档：如果每个人都复制一份旧稿再本地修改，最终合并会充满冲突；如果每次修改都带版本号、作者、时间和变更说明，冲突仍会发生，定位和恢复会清楚得多。

因此，多 Agent 失败经常是“一致性故障伪装成推理故障”。模型也许在自己的上下文里做出了局部合理的判断，只是它看到的状态已经过期、被污染或与其他 Agent 的视图冲突。生产平台要减少这类失败，关键手段包括版本化记忆、写入幂等、冲突检测、来源权重、检索结果新鲜度检查、状态转移追踪，以及对高风险写入设置人工升级路径。

4.3 分层安全：把模型输出逐层收束成有边界的动作

安全不能被设计成单个开关。Gupta 明确列出一组层次：提示词级控制 (prompt-level controls)、工具权限 (tool permissions)、策略校验 (policy validations)、人工审批 (human approvals) 和审计系统 (audit systems)。每一层捕获不同类型的失败；把它们串起来，才形成纵深防御。

¹³ 视频时间：04:15–04:30。根据该时间段图示重绘。




图 14: Autonomous systems demand layered containment boundaries: 模型输出从中心向外传播，必须穿过工具权限、策略引擎、人工审批和审计层。¹⁴

图 14 的同心环适合表达一个核心事实：模型输出和生产动作之间应该存在多个强制边界。提示词可以减少不良倾向，schema guard 可以约束参数形状，工具权限可以限制动作范围，策略引擎可以结合业务规则和风险等级做决定，人工审批可以处理灰区，审计层可以为事后复盘和合规提供证据。

Layered containment converts model output into bounded action




图 15: 分层收束机制把 model output 转换为 blocked、escalated 或 bounded action；每一层都对应不同的失败类别和治理证据。¹⁵

分层防御的工程价值在于“不同错误由不同边界拦截”。例如，prompt-level controls 适合表达目标和禁区，schema guard 适合阻止参数缺失或类型错误，tool permissions 适合阻止越权工具调用，

¹⁴视频时间：04:40-04:54。

¹⁵视频时间：04:40-04:54。根据该时间段图示重绘。

policy engine 适合处理组织规则和风险评分，human approval 适合处理高影响、低置信度或上下文模糊的场景，audit systems 适合提供追责和改进依据。

一个危险误区是把安全全部压在提示词上。提示词是软约束，容易被上下文、工具返回、用户输入和长工作流状态稀释。生产系统需要把关键约束落实到可执行边界：权限表、策略规则、参数校验、速率限制、审批流、审计日志和回滚钩子。安全口号没有强制执行点时，事故只是在等待合适的触发条件。

这里还存在一个“未知未知”的风险：层数增加会带来配置不一致。比如提示词允许某类工具调用，权限系统禁止；策略引擎批准，执行网关因参数 schema 拒绝；人工审批通过，审计系统缺少上下文。分层防御需要统一的策略模型和测试样例集，确保各层对风险等级、权限范围、数据分类和升级规则的理解一致。

4.4 人工监督：把人类注意力用在异常、灰区和校准上

Gupta 对人工参与给出了一个更长期的定位：成功的系统很可能持续保留人类监督。人类的角色应被设计成异常处理器（exception handler）、模糊场景裁判和校准信号来源。换句话说，人工监督的重点是注意力分配：平台把稀缺判断力投向最有价值的位置，而普通低风险路径保持自动化流转。




图 16: Human oversight is an escalation path: 自动任务通过置信度与风险闸门，边缘案例被路由到人工审批节点，解决后返回可执行状态。¹⁶

图 16 给出了一个实用形态：绝大多数低风险、高置信度任务保持自动化；当风险、置信度、异常检测或业务规则触发阈值时，任务进入人工审批节点。人工处理完成后，系统应把结果写回状态存储，并形成后续校准数据。这样，人类既处理当前异常，也改善未来自动化边界。

¹⁶ 视频时间：05:03–05:18。

人工监督的正确工程目标是注意力分配。平台应把人工审查看成一种昂贵资源：低风险重复任务自动通过，高风险动作、低置信度判断、冲突记忆、越权尝试和不可逆操作升级给人。人类判断的产物还应回流为策略样例、评估集、检索权重或审批规则。

这个设计有三个具体含义。第一，升级条件要显式化，例如金额阈值、权限等级、数据敏感度、模型置信度、检索冲突、工具错误次数和 SLO 风险。第二，人工界面要给足上下文，包括模型提案、工具参数、相关记忆、历史审批、风险解释和可选动作。第三，人工结果要结构化记录，避免只留下“同意/拒绝”这类低信息日志。

人工监督会失效于两种极端：过度自动化会让高风险边缘案例漏出边界，过度审批会把所有任务塞进人工队列，造成延迟、疲劳和橡皮图章式批准。生产 Agent 需要风险分层和抽样复审，让人类承担最能创造安全增量的判断。

4.5 推理即调度：AI inference 正在变成资源编排问题

本节最后一个边界是资源。Gupta 指出，AI 工作负载越来越像集群调度问题：需求突发 (bursty demand)，推理深度可变 (variable reasoning depth)，工作流可能运行数分钟，资源需求差异极大。因此，GPU 效率、工作负载放置 (workload placement)、弹性容量管理 (elastic capacity management) 和调度都会成为核心能力。




图 17: Inference at scale becomes a cluster scheduling problem: 突发需求、可变推理深度、长工作流和 GPU 争用共同决定系统是否越过资源上限。¹⁷

图 17 的红色曲线代表需求，阶梯线代表已分配容量，灰色带表示资源争用和 GPU 限制区。Agent 工作负载的难点在于需求曲线很难平滑：一次复杂任务可能触发长推理、多次工具调用、检索、重试、人工等待和后续恢复。传统在线服务常按请求量和平均耗时估算容量；Agent 平台还要估算“思考深度”和工作流长度。

¹⁷ 视频时间：05:28-05:44。

Bursty reasoning becomes a cluster scheduling problem




图 18: 突发推理需求与阶梯式容量配置之间存在争用区；调度器必须根据任务风险、成本预算、SLO 和 GPU 稀缺性做 workload placement。¹⁸

第 2 节已经引入过总成本模型。这里可以复用它来说明资源调度与成本治理的连接：Agent 每多运行一个阶段，都会消耗某种资源量，并乘上对应单位成本。直觉上，成本应被视为整个工作流在多个时间步、多个工具和多个资源池里的累积，固定请求单价只能解释其中一小段。

$$C_{\text{total}} = \sum_{t=1}^T q_t c_t$$

符号说明：

- C_{total} : 一个 Agent 工作流从开始到结束的总成本，可包含 GPU 推理、工具调用、检索、存储、人工审批和排队等待等成本。
- T : 工作流被拆分后的阶段数或时间步数。
- q_t : 第 t 个阶段消耗的资源量，例如 token 数、GPU 秒、工具调用次数、检索次数、人工审核分钟数或队列占用量。
- c_t : 第 t 个阶段对应资源的单位成本，例如每千 token 价格、每 GPU 秒价格、每次外部 API 价格或每分钟人工审核成本。

这个公式的工程含义是：资源调度器既要降低 q_t ，也要把任务放到合适的 c_t 上。一个低风险摘要任务可以排到便宜模型或低优先级队列；一个高风险生产变更提案可能需要更强模型、更严格策略校验和人工审批；一个失败重试链条应被限深、降级或切断，避免 T 和 q_t 同时增长。若系统只关注“单次模型调用价格”，它会漏掉长工作流带来的排队、重试、GPU 峰值和人工成本。

集群调度可以类比机场登机口分配。航班有不同机型、目的地、延误风险和优先级，机场需要在有限登机口、跑道和地勤资源之间做安排。Agent 平台面对的是有限 GPU、模型副本、工具

¹⁸视频时间：05:28–05:44。根据该时间段图示重绘。

限额、人工审批队列和 SLO 窗口。调度器的任务是让高价值、时间敏感、风险可控的工作负载获得合适资源，同时限制低价值或失控任务继续消耗容量。

因此，推理基础设施需要从“模型服务”扩展成“资源编排”。实际系统应包含队列优先级、预算上限、推理深度限制、模型路由、批处理策略、GPU 放置、弹性扩缩容、限流、降级路径和成本归因。Agent 越自治，资源治理越重要；否则一次看似普通的任务会在长推理、重试和工具调用中变成计算事故。

4.6 四条边界需要统一在同一个控制面里

状态、安全、人工和资源常被不同团队分开建设：平台团队管调度，安全团队管权限，产品团队管人工审核，数据团队管记忆和检索。Agent 系统会把这些边界强行耦合在一起。一次工具调用是否允许，可能同时取决于记忆版本、数据敏感度、策略规则、审批状态、资源预算和 SLO 风险。若这些信息散落在多个系统里，控制面就无法做出稳定决策。

更合理的生产架构是把四类信号汇入统一的 agentic control plane：

- 状态信号：当前任务版本、记忆来源、冲突检测、检索新鲜度和状态转移历史。
- 安全信号：prompt 约束、工具权限、策略结果、风险评分、阻断原因和审计证据。
- 人工信号：升级规则、审批结果、人工备注、校准标签和复审样本。
- 资源信号：队列长度、GPU 占用、推理深度、成本预算、SLO 剩余时间和弹性容量。

边界系统之间缺少共享语义时，平台会出现“局部正确、全局危险”的决策。例如资源调度器为了吞吐把任务放到便宜模型，策略引擎却需要高置信度审批证据；记忆层返回旧版本上下文，执行网关只校验了参数 schema；人工批准了动作，审计层没有记录批准依据。生产 Agent 的控制面需要跨边界追踪同一个任务；每个子系统只保存自己的局部日志，会让全链路复盘失去关键上下文。

本节因此把第 3 节的“平台决定”扩展成更完整的生产命题：平台能决定，前提是它能看见状态、理解风险、调动人工、约束资源，并把这些信号放进同一条可审计的决策链。缺少任一维度，所谓控制面就会退化为一组松散中间件。

4.7 本章小结

本章讲清了生产 Agent 的四条关键边界。第一，共享记忆会把多 Agent 系统带入状态一致性问题；陈旧读、冲突写、上下文漂移、不一致视图和检索噪声会让一致性故障伪装成推理故障。第二，安全必须分层：prompt 控制、schema guard、工具权限、policy engine、human approval 和 audit trail 各自拦截不同类别的风险。第三，人工监督应被设计为异常升级和校准机制，让人类注意力集中在高风险、低置信度、模糊和不可逆场景。第四，AI inference at scale 会成为 cluster scheduling 问题，突发需求、可变推理深度、分钟级工作流、GPU 争用、workload placement 和 elastic capacity 共同决定成本与可靠性。

把这四条边界合起来看，Agentic control plane 的职责已经超出普通编排器：它需要同时管理状态、策略、人工和资源。下一章将把这些设计映射回成熟分布式系统经验：熔断器对应工具隔离，限流对应 Agent 限制，配额对应成本治理，可观测性对应 Agent tracing。这样，读者可以把本节的边界工程放进更大的可靠性 Rosetta Stone 中理解。

5 可靠性 Rosetta Stone：把分布式系统经验迁移到 Agent

本节的核心结论是：生产级 AI Agent 的可靠性问题可以用分布式系统的成熟经验来翻译和治理。演讲者在结尾把全篇压缩成一张“可靠性 Rosetta Stone”：断路器（circuit breakers）迁移为工具隔离（tool isolation），限流（rate limits）迁移为 Agent 限制（agent limits），重试（retries）迁移为受控恢复（controlled recovery），配额（quotas）迁移为成本治理（cost governance），可观测性（observability）迁移为 Agent 追踪（agent tracing）。这组映射说明，Agent 平台的新问题表面上来自随机模型，工程解法却要落在确定性基础设施（deterministic infrastructure）的边界、控制和审计上。

本节的总判断：AI Agent 应当被当作分布式系统来设计。模型是随机的（stochastic），基础设施必须严格（strict）且可验证；可靠性越来越属于基础设施问题；多维可观测性是上线条件；Agent 控制面正在成为生产 AI 的基础层。

5.1 Rosetta Stone：把旧模式翻译成新边界

“Rosetta Stone”这个类比很准确。罗塞塔石碑的价值在于让人用已知语言解读未知文字；这里的石碑则让工程团队用已经掌握的分布式系统语言，解读 Agent 系统里的新故障。上一章讨论的工具误用、记忆不一致、人工升级和资源调度，看起来像 AI 新现象；放进分布式系统框架后，它们分别对应隔离、限流、恢复、配额、追踪这些老问题的新形态。




图 19: The Reliability Rosetta Stone：把分布式系统可靠性模式翻译成 Agent 控制面的等价能力，核心迁移路径包括 tool isolation、agent limits、controlled recovery、cost governance 和 agent tracing。

19

第一组映射是断路器到工具隔离。传统微服务里的 circuit breaker 会在下游服务持续失败时切断调用，防止错误扩散。Agent 系统里的 tool isolation 承担相同职责：当某个工具返回结构错误、权限错误、外部系统异常或高风险副作用时，控制面要隔离该工具调用路径，限制模型继续把失败包装成

¹⁹ 视频时间：05:59–06:14。

新的相似请求。它像电路里的保险丝，目标是把故障挡在局部区域。

第二组映射是限流到 Agent 限制。rate limiting 原本控制每个服务、用户或租户的请求速率；Agent limits 则要限制更复杂的维度：最大推理步数、最大工具调用次数、最大并发工作流、最大记忆读取量、最大人工升级次数、最大 GPU 时间和最大预算消耗。原因很直接：Agent 的资源消耗来自一条动态路径，单纯限制入口 QPS 无法覆盖推理深度和工具链膨胀。

第三组映射是重试到受控恢复。传统 retries 常被视为临时错误的恢复机制；Agent 场景下，重试必须带有结构化条件：错误类型是什么，输入是否已经修复，幂等键是否存在，预算是否还够，下一次尝试是否改变了失败前提，是否需要降级或交给人类。受控恢复的关键词是“有证据地继续”，每一次 retry 都要能解释为什么这次尝试有机会成功。

第四组映射是配额到成本治理。resource quotas 过去主要限制 CPU、内存、磁盘、连接数或 API 调用量；cost governance 面向 Agent 时要把 token、GPU 时间、工具调用、外部 API 费用、人工审核时间和长工作流占用都纳入预算。若用一个直观模型表达，Agent 成本可以看成多个阶段资源消耗的累积：

$$C_{\text{agent}} = \sum_{t=1}^T q_t c_t$$


符号说明：

- C_{agent} ：一次 Agent 工作流的总成本。
- T ：工作流包含的阶段数量，例如计划、检索、工具调用、重试、人工审核和最终执行。
- q_t ：第 t 个阶段消耗的资源量，例如 token 数、GPU 秒数、API 调用次数或人工审核分钟数。
- c_t ：第 t 个阶段对应的单位成本。

这个公式的工程含义是：成本治理要盯住整条工作流，而不能只盯住一次模型调用。一次看似便宜的 prompt，在递归重试、外部工具、GPU 等待和人工升级叠加之后，可能变成高成本事故。

第五组映射是可观性到 Agent 追踪。传统 observability 关注日志、指标和分布式 trace；Agent tracing 还要记录计划选择、工具参数来源、记忆检索内容、策略审批结果、状态迁移和恢复路径。它回答的问题从“哪个请求慢了”扩展到“为什么这个自主工作流走到这一步”。

Reliability Rosetta Stone: distributed systems to agents



The old reliability vocabulary still works after translation into agent control-plane terms.

图 20: 可靠性映射的教学重绘：左侧是成熟分布式系统模式，右侧是 Agent 控制面的等价能力，中间箭头表示从 service reliability 到 agent reliability 的概念迁移。²⁰

分布式系统经验可以迁移，是因为两类系统都面对同一个底层问题：局部组件的行为有限可知，整体系统却可能出现放大效应。微服务里，一个慢下游会拖垮调用链；Agent 里，一个错误工具调用会诱发重试树、状态污染和成本尖峰。可靠性工程的共同目标，是把局部不确定性约束在可隔离、可恢复、可审计的系统边界内。

5.2 从 prompt 到 model，再到 infrastructure

演讲者的第二个收束点是竞争优势的迁移。行业最初把提示词 (prompts) 当作差异化来源，随后把模型 (models) 当作差异化来源；随着两者快速商品化 (commoditizing)，下一阶段的差异会集中在基础设施和系统工程 (systems engineering)。这并不贬低 prompt 和 model 的价值。它指出一个更残酷的事实：当多数团队都能接入强模型、复用提示词模式时，真正拉开差距的是谁能把 Agent 稳定、安全、可审计、成本可控地跑在生产环境中。

²⁰ 视频时间：05:59–06:14。根据该时间段图示重绘。




图 21: 竞争优势从 prompt engineering 和 model selection 转向 infrastructure 与 systems engineering。图中红色曲线强调，长期复利来自可复用、可治理、可扩展的系统能力。²¹

这张图隐含一个时间维度。2023 年左右，prompt 模式快速扩散，很多团队通过更好的指令、模板和 few-shot 示例取得早期优势。2024 年，模型能力差异成为中心，推理、更大上下文、多模态和工具调用能力决定了很多应用上限。进入 2025 年以后，模型接入门槛下降，prompt 模式公开化，差异化开始转向平台：谁能管理多 Agent 状态，谁能控制成本，谁能做审计，谁能把人工监督用在高价值异常上，谁能在高并发和长工作流下维持 SLO。

容易犯的战略错误，是把 Agent 平台建设理解成“换一个更强模型之后自然解决”。更强模型会减少部分错误，也会扩大动作半径、提高并发期望、引入更复杂工作流。若工具隔离、Agent limits、受控恢复、成本治理和 tracing 没有同步建设，模型升级可能把系统暴露在更大的故障面上。

因此，系统工程优势具有复利属性。prompt 通常依赖任务和模型版本，模型选择也会随着供应商和开源生态变化；控制面、策略引擎、执行网关、追踪体系、记忆一致性机制和资源调度能力，会在多个模型、多个产品线、多个团队之间复用。它们越早沉淀成平台，后续每一次模型能力提升都更容易转化为可靠生产能力。

5.3 总结与延伸

演讲者在最后给出的实质性 closing 可以拆成五句话。第一，AI agents are distributed systems，应当按分布式系统对待。第二，models are inherently stochastic，模型天然具有概率性。第三，infrastructure must be strict，基础设施需要严格约束执行边界。第四，reliability is an infrastructure problem，可靠性越来越由平台工程承担。第五，the future of AI will be won by better systems，未来优势来自更好的系统。

²¹ 视频时间：06:23–06:35。




图 22: 最终 takeaway: AI agents are distributed systems; 模型随机, 基础设施必须严格; 可靠性、观测和控制面共同构成生产 AI 的运行基础。²²

从全篇看, 这五句话形成一条清晰的因果链。Agent 能计划、调用工具、协调流程并影响生产系统, 所以它的错误会进入真实状态和真实资源。模型输出具有随机性, 所以平台必须把提案、审批、执行、恢复和审计拆成可验证步骤。工作流会变长、状态会共享、资源会爆发, 所以可靠性需要控制面持续治理; 一次输出评测只能覆盖其中一部分。最终, 组织竞争力会从“会不会用模型”转向“能不能把随机智能放进确定性运行时”。

本讲的结构化压缩可以写成一个工程闭环: 模型提出候选动作, 策略引擎判断能否执行, 执行网关落实权限和幂等, Agent limits 控制推理与工具预算, 受控恢复处理失败, Agent tracing 留下因果证据, 人类处理高价值异常, 控制面把这些规则统一编排。这个闭环越完整, 随机模型越可能变成可运营系统。

这套框架对工程团队直接启发, 是把“上线一个 Agent”改写成“上线一个受控的分布式工作流”。落地时可以按四个层次推进。第一层是执行边界: 所有生产副作用都经过 execution gateway, 禁止模型直接写生产状态。第二层是资源边界: 为任务、租户、工具、模型、工作流深度和人工审核设置预算。第三层是状态边界: 共享记忆要有版本、来源、冲突处理和过期策略。第四层是证据边界: 每次计划、工具调用、记忆读取、策略审批、恢复动作都进入 trace。

更进一步, 团队还需要承认几个“未知的未知”。首先, Agent 故障常常跨层发生: 一次模型误判可能同时触发工具隔离、预算耗尽、记忆污染和人工升级。其次, 评估集覆盖不了所有生产路径, 尤其覆盖不了长尾工具状态和多人协作流程。再次, 成本治理不能只看平均值, 尾部任务会主导 GPU、API 和人工审核压力。最后, 审计数据本身也有隐私和安全风险, trace 需要脱敏、权限控制和保留期限。

²² 视频时间: 06:38–06:53。

一个直观类比是“自动驾驶车队”。单车智能越强，车队平台越需要调度、限速、事故隔离、远程接管、黑匣子和维护窗口。Agent 也是这样：单个模型越能行动，组织越需要运行时治理。智能负责提出路径，系统负责保证路径在规则内执行、失败时可恢复、事故后可复盘。

下一步实践可以从一张清单开始。第一，列出所有 Agent 可调工具，并为每个工具标注副作用等级、幂等要求、最大调用频率和人工审批条件。第二，为每类工作流设定 Agent limits，包括最大步骤数、最大重试次数、最大预算、最大运行时间和最大并发。第三，把重试改造成受控恢复：每次重试都必须绑定错误分类、输入修复证据和退出条件。第四，把成本治理嵌入控制面，使 token、GPU、外部 API、人工审核和工具调用进入统一预算。第五，建设 Agent tracing，让每次执行都能回放计划、工具、记忆、策略和状态链路。第六，定期做故障演练，主动模拟工具错误、记忆冲突、预算耗尽、策略拒绝和人工升级拥塞。

本节最需要避免的落地陷阱，是把 Rosetta Stone 当作术语替换表。真正的迁移要求改变系统边界：circuit breaker 迁移到 tool isolation，就要有可执行的隔离策略；rate limit 迁移到 agent limit，就要覆盖推理深度和工作流预算；observability 迁移到 agent tracing，就要记录因果链，最终回答只是其中一个字段。

5.4 本章小结

本章把演讲的 closing 综合为一个可复用框架：AI Agent 的可靠性工程，是把随机模型装入确定性基础设施的控制闭环。分布式系统已经给出许多成熟语言：断路器、限流、重试、配额和可观测性；Agent 时代需要把它们翻译成工具隔离、Agent limits、受控恢复、成本治理和 Agent tracing。

演讲者的最终判断很直接：AI Agent 应按分布式系统治理；模型具有随机性；基础设施必须严格；可靠性属于基础设施问题；控制面正在成为基础层；未来 AI 的胜出关键来自 better systems。对工程团队来说，下一步应把执行网关、策略引擎、资源预算、状态一致性、追踪审计、人工升级和调度能力沉淀成平台，同时减少把风险塞进 prompt 的做法。只有这样，模型能力才能稳定转化为可重复、可恢复、可审计、成本可控的生产能力。